单位代码：10293　密　级：公开

南京邮电大学

硕 士 学 位 论 文

论文题目：基于上下文特征聚合学习的实时语义分割研究

学　　号　1020051526

姓　　名　张梦纯

导　　师　高广谓

学 科 专 业　控制科学与工程

研 究 方 向　图像语义分割

申请学位类别　工学硕士

论文提交日期　2023.05

Research on Real-time Semantic Segmentation Based on Contextual Feature Aggregation Learning

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of Master of Science in Engineering

By

Mengchun Zhang

Supervisor: Prof. Guangwei Gao

May 2023

南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号：1020051526 研究生签名：张梦纯 日期：2023.5.31

南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名：张梦纯 导师签名：高广谓 日期：2023.5.31

摘要

图像语义分割是模式识别领域里面的基础研究课题之一，但是具有一定的难度和挑战性，它的目标是为输入图像中的每个像素进行标签归类。目前，大多数的语义分割网络的搭建基础都是卷积神经网络，通过大量卷积层的叠加搭建出繁杂的网络。虽然这种方法简单易行，且得到的网络分割性能卓越，但是通常伴随着网络计算量损耗巨大，推理延迟的弊端，故在计算资源和存储资源受限的硬件设备上并不适用，使其在现实应用场景中难以得到推广。针对上述问题，本文基于深度卷积神经网络，就兼顾效率和精度及小内存占比的轻量级实时语义分割网络进行研究，具体研究内容如下：

（1）为了有效进行多尺度上下文信息的融合，设计了一种基于上下文聚合的实时语义分割网络（CFSNet），网络基于对称的编码器-解码器结构，包含了空间注意力模块、不对称卷积模块、多分支不对称卷积模块及通道注意力模块。同时，设计了三条注入分支，将不同尺度的原始图像经处理后，注入主干网络中。在单张 RTX2080Ti GPU 上，CFSNet 能够在 Cityscapes 数据集上以 76.9FPS 的速度进行推理，分割精度高达 71.5%mIoU；在 Camvid 数据集上可以以 88.9FPS 的速度进行推理，分割精度高达 68.8%mIoU，且其参数量仅为 0.69M。

（2）针对高级语义信息提取过程中，空间信息大量耗损这一问题，提出了一种高效多尺度上下文聚合网络（EMCANet）。网络基于分解扩张卷积模块和三分支分解扩张卷积模块，并且在第一个分解扩张卷积模块和三分支分解扩张卷积模块中融入了密集连接的连接方式，以在保持网络计算量和参数量不变的前提下，扩大卷积核的接收域，并且可以收集到多尺度的上下文信息。网络中加入了三条细节信息分支，可以弥补语义信息提取过程中损失的空间信息。EMCANet 整体模型大小只有 0.78M，在硬件平台为 RTX2080Ti GPU 的情况下，它在 Cityscapes 数据集上的推理速度可达 78.7FPS，分割精度为 71.9%mIoU；在 Camvid 数据集上的推理速度可达 85.4FPS，分割精度为 69.4%mIoU。

（3）针对纯卷积神经网络只能对局部特征的依赖关系进行建模这一问题，提出了一种融合卷积神经网络和 Transformer 的高效实时语义分割网络（EBSSNet），其中的 Transformer 部分可以建模全局特征的依赖关系。网络中的基本特征提取单元为双边特征提取单元，并基于此单元搭建了三个双边特征提取模块，并将其与深度可分离卷积、逐深度卷积、Transformer 注意力模块及一条细节信息分支相融合来进行网络搭建。EMCANet 的参数量仅为 0.76M，在单张 RTX3090Ti GPU 上，能够以 81.6FPS 的速度对 Cityscapes 数据集中的图像进行推理，分割精度为 71.6%mIoU；在 Camvid 数据集上的推理速度为 90.5FPS，分割精度为 69.0%mIoU。

综上，本文提出了三种轻量级实时语义分割网络，融合了卷积神经网络及 Transformer 注

意力方法，并用到了空间注意力方法、通道注意力方法、扩张卷积、逐深度卷积和深度可分离卷积等常见轻量级处理图像的策略，使得网络能够高效率、低内存、高性能地运行。大量实验表明，这些网络的实际性能良好，可以在现实硬件系统中加以运用。

关键词：实时语义分割，上下文信息融合，多尺度特征，卷积神经网络，变换器，注意力机制

Abstract

Image semantic segmentation is one of the basic research topics in the field of pattern recognition, but it is difficult and challenging. Its goal is to label and classify each pixel in the input image. At present, most semantic segmentation networks are based on convolutional neural networks, which build complex networks through the superposition of a large number of convolutional layers. Although this method is simple and easy to implement, and the obtained network segmentation performance is excellent, it is usually accompanied by huge network computational loss and inference delay, so it is not suitable for hardware devices with limited computing resources and storage resources, making it difficult to generalize in real-world application scenarios. In response to the above problems, this paper studies a lightweight real-time semantic segmentation network that takes into account efficiency, accuracy and small memory ratio based on Deep Convolutional Neural Network. The specific research contents are as follows:

(1)In order to effectively fuse multi-scale contextual information, a real-time semantic segmentation network (CFSNet) based on context aggregation is designed. The network is based on a symmetric encoder-decoder structure, including spatial attention modules, asymmetric Convolution module, multi-branch asymmetric convolution module and channel attention module. At the same time, three injection branches are designed, and the original images of different scales are processed and injected into the backbone network. On a single RTX2080Ti GPU, CFSNet can infer at a speed of 76.9FPS on the Cityscapes dataset, with a segmentation accuracy of up to 71.5% mIoU; on the Camvid dataset, it can infer at a speed of 88.9FPS, with a segmentation accuracy of up to 68.8% mIoU, and its parameter amount is only 0.69M.

(2)Aiming at the problem that a lot of spatial information is consumed in the process of high-level semantic information extraction, an efficient multi-scale context aggregation network (EMCANet) is proposed. The network is based on the Decomposition Extended Convolutional Module and the Three-Branch Decomposition Extended Convolutional Module, and the first Decomposition Extended Convolutional Module and the Three-Branch Decomposition Extended Convolutional Module incorporate a dense connection connection method to expand the receiving domain of the convolutional kernel on the premise of keeping the number of network computations and parameters unchanged, and can collect multi-scale contextual information. Three detail information branches are added to the network, which can make up for the spatial information lost in

the process of semantic information extraction. The overall model size of EMCANet is only 0.78M. When the hardware platform is RTX2080Ti GPU, its inference speed on the Cityscapes dataset can reach 78.7FPS, and the segmentation accuracy is 71.9% mIoU; the inference speed on the Camvid dataset can reach 85.4FPS, and the segmentation accuracy is 69.4% mIoU.

(3)Aiming at the problem that pure convolutional neural networks can only model the dependencies of local features, an efficient real-time semantic segmentation network (EBSSNet) integrating convolutional neural networks and Transformer is proposed, in which the Transformer part can model the dependencies of global features. The basic feature extraction unit in the network is a bilateral feature extraction unit, and three bilateral feature extraction modules are built based on this unit, which are combined with deep separable convolution, depth-by-depth convolution, Transformer attention module and a detail information branch. The parameter quantity of EMCANet is only 0.76M, and on a single RTX3090Ti GPU, it can infer the images in the Cityscapes dataset at a speed of 81.6FPS, and the segmentation accuracy is 71.6% mIoU; on the Camvid dataset The inference speed is 90.5FPS, and the segmentation accuracy is 69.0% mIoU.

To sum up, this paper proposes three lightweight real-time semantic segmentation networks, which integrate convolutional neural networks and Transformer attention methods, and use spatial attention methods, channel attention methods, extended convolution, depth-by-depth convolution, and depth-separable convolution. Common lightweight image processing strategies such as convolution enable the network to operate with high efficiency, low memory, and high performance. A large number of experiments have shown that these networks have good actual performance and can be used in real hardware systems.

Key words: Real-time Semantic Segmentation, Contextual Information Fusion, Multi-scale Features, Convolutional Neural Network, Transformer, Attention Mechanism

目录

第一章 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 2
1.2.1 传统图像分割方法研究现状 2
1.2.2 基于卷积神经网络的图像语义分割方法研究现状 3
1.3 主要研究内容 5
1.4 论文章节安排 6
第二章 相关背景知识介绍 7
2.1 卷积神经网络的理论基础 7
2.1.1 卷积层 7
2.1.2 非线性激活函数 10
2.1.3 池化层 11
2.1.4 全连接层 12
2.1.5 Dropout 层 12
2.1.6 批标准化层 13
2.2 语义分割任务评价指标 13
2.2.1 精确度 14
2.2.2 运算速度 14
2.2.3 内存使用 14
2.3 语义分割数据集 15
2.3.1 Camvid 数据集 15
2.3.2 Cityscapes 数据集 15
2.4 本章小结 16
第三章 基于上下文聚合的实时语义分割网络 17
3.1 引言 17
3.2 基于上下文聚合的实时语义分割网络 18
3.2.1 通道注意力机制 18
3.2.2 空间注意力机制 19
3.2.3 不对称卷积单元 19
3.2.4 多分支不对称卷积单元 20
3.2.5 整体网络架构设计 22
3.3 实验设计与结果分析 24
3.3.1 数据集和实施细节 24
3.3.2 消融实验 25
3.3.3 与其他先进算法的比较 28
3.4 本章小结 31
第四章 基于多尺度特征的上下文信息融合网络 32
4.1 引言 32
4.2 基于多尺度特征的上下文信息融合网络 34
4.2.1 分解扩张卷积单元 34
4.2.2 三分支分解扩张卷积单元 35
4.2.3 密集连接 38
4.2.4 语义信息分支 38
4.2.5 细节信息分支 39

4.2.6 整体网络架构设计 39
4.3 实验设计与结果分析 41
4.3.1 数据集 41
4.3.2 参数设置 41
4.3.3 消融实验 42
4.3.4 与其他先进算法的比较 44
4.4 本章小结 47
第五章 基于 CNN 和 Transformer 的高效实时语义分割网络 48
5.1 引言 48
5.2 基于 CNN 和 Transformer 的高效实时语义分割网络 49
5.2.1 双边特征提取单元 49
5.2.2 Transformer 注意力机制 50
5.2.3 整体网络架构设计 51
5.3 实验设计与结果分析 53
5.3.1 数据集 53
5.3.2 参数设置 53
5.3.3 消融实验 54
5.3.4 实验结果对比与分析 54
5.4 本章小结 56
第六章 总结与展望 58
6.1 总结 58
6.2 展望 59
参考文献 61
附录 1 攻读硕士学位期间撰写的论文 66
附录 2 攻读硕士学位期间申请的专利 67
附录 3 攻读硕士学位期间参加的科研项目 68
致谢 69

第一章 绪论

1.1 研究背景及意义

近年来，众多研究者对人工智能的研究掀起了一股热潮，并广泛地关注研究深度学习在实际生活中的应用，已经证实深度学习（Deep Learning）[1]可以在应用于自动驾驶、地理信息系统和医学影像分析等众多领域。计算机视觉的实现依赖于深度学习的发展，其任务主要包括图像分类（Image Classification）、目标检测（Object Detection）、图像分割（Image Segmentation）等三大部分。图像分类为指定图像识别出来单个类别（Category）标签，目标检测需要检测出来目标物体位置信息和类别信息（Localization＋Classification）。图像分割[2][3]任务包括语义分割（Semantic Segmentation）任务和实例分割（Instance Segmentation）任务。语义分割的任务是为输入图像中每个像素分配类别标签，以便将该图像划分成不同类别的区域，需要预测出给定图像中各个对象的位置、类别和轮廓信息，才能进行场景理解和视觉分析。输入图像经过语义分割算法，会得到同尺寸的带有语义标签的图像，故图像语义分割也被称为图像语义标注。实例分割基于语义分割，但是须进一步划分出属于同一个类别的各个个体。从现实实际需求来看，分割任务中语义分割技术的应用场景更多，因此更具研究价值。

受生物神经学的启发，创建了可用于计算机视觉的卷积神经网络（Convolution Neural Networks, CNN），并成为研究视觉任务的核心方法，也使得深度学习基础问题都得到了不同程度的改进和提升。卷积神经网络采用局部连接和权重值共享，降低了网络的参数量，并且大规模数据及优秀的训练算法都对卷积神经网络提供了有力的支持，使其对二维图像具有很强的拟合能力。网络的输入即为二维图像，不像传统识别算法那样，需要进行复杂的特征提取和重建数据。传统手工提取特征的方法，依赖于随机森林（Random Forest）[4]、支持向量机（Support VectorMachine, SVM）[5]等决策算法，需要依赖于专家经验和丰富的先验知识，而卷积神经网络可以自适应地学习抽象的高层特征。目前出现的骨干卷积神经网络包含VGGNet[6]、ResNet[7]、AlexNet[8]及GoogleNet[9]等多种多样的类型，大大提高了图像分类的准确率。

卷积神经网络是模式识别领域内的一项重大突破，不但提高了输入图片的分类[10][11][12]，也推动了局部任务结构化的输出，例如物体识别领域中的局部一致性[13]，边界框生成[14][15][16]以及部分区域和关键点检测[17][18]。自然而然地，逐像素的预测成为了下一个推动发展目标，以便实现对于目标物体的像素级别的分割。当图像的语义分割采用了高效的CNN时，其对于

场景的理解和分类能力也将有很大的提升。

从直观角度出发，优秀的语义分割工作应该实现以下目标：①相邻的语义区域需要依据具有明显差异的性质来进行分割；②不同语义其边界需要清晰规整明确[19]；③分割结果图中，不同的语义区域其内部要求平整，而某种性质需要相似，如灰度、纹理等。现在的图像语义分割方法的研究中，一般仅仅能满足上述目标中的一个或两个。若过多地关注相邻语义区域间的差异，会导致语义信息的分类错误；若过多地关注语义分割区域的相同性，会导致分割区域产生不规则边缘。因而，在实际研究中，语义分割方法必须平衡好各种约束条件。

尽管图像语义分割方法的发展前景很好，但因其具有复杂性，仍有许多问题待以解决。众多研究者们仍在努力将新兴算法与图像语义分割方法相融合，以获取更加准确的分割结果。考虑到卷积神经网络的高效性，可以坚信，采用卷积神经网络进行图像语义分割将显著提高图像语义分割效果。

综上所述，图像的语义分割效果还可以在其通用性上进行进一步的提升。在图像语义分割算法中引用卷积神经网络来提高其算法的准确性和通用性，将成为一个研究价值极高的方向，这对于学术界和工业界都具有重要意义。

1.2 国内外研究现状

对于图像分割发展历程，本节从传统的分割方法和采用卷积神经网络的分割方法两个方面考虑，来分析图像分割方法研究现状。

1.2.1 传统图像分割方法研究现状

传统图像分割方法依据统计特性来把图像划定为不同区域，如颜色、纹理、空间结构等。在不同的分割区域之间，这些统计特性相互区别，而在相同区域间，这些统计特性具有很大的相似性。传统的图像分割方法依据分割策略可分为以下 4 类：

（1）基于阈值的分割方法

基于阈值分割方法[20]把灰度值当作图像的特征，通过计算选取一个或者多个阈值，并将该阈值与图像中的像素点进行逐一比较，将每个像素点划分到所属集合，完成整张图像的分割。基于阈值的分割方法常用的有最大熵法[21]、最大类间方差法[22]。该方法的特点为适用领域仅为简单二值图像，对于灰度值分布均匀、分割特征的差异较小的图像，其实用性不高[20]。

（2）基于边缘检测的分割方法

基于边缘检测分割方法[23][24]注意到了图像的各个区域其边缘像素值会产突变，故它先对

图像的边缘像素进行检测，再连接这些检测到的边缘像素，以形成各个区域的边界。判断像素点是否在图像边缘的方法有一阶导数及二阶导数。Sobel 算子[25]、Prewitt 算子[26]、Roberts 算子[27]都是常见的一阶微分算子，Laplace[28]是常用的二阶微分算子。实际情况中，噪声也会产生和边缘一样的间断高频变化，故该方法无法权衡好边缘和噪声的关系。图像的边缘灰度值有剧烈变化并且噪声微弱时，分割效果较好，图像边缘模糊或者噪声多亦或是随意的间断分布，都将导致出现不理想的分割结果，故该方法无法适用于大规模复杂场景。

（3）基于区域的分割方法

基于区域的分割方法[29]注意到了图像中同一区域具有均匀性。区域生长法[30][31]是最为常用的方法，需要设定种子像素，并将该像素作为生长起点，将相邻像素点中，与生长起点具有相似性度量的像素点合并起来，形成区域。但该方法只适合分割图像中的小结构，例如伤疤、肿瘤等，它对噪声也十分敏感，在归并的区域中会形成空洞。

（4）基于机器学习的分割方法

基于机器学习的分割方法依据图像中的低级语义信息，如目标的纹理、颜色等，进行人工特征提取，再输入到属于机器学习领域的专门进行分类的算法中进行图像分割。Zhang 等人[32]采用边缘检测算法获取图像边缘，而后采用随机决策森林（Random Decision Forests）算法来进行物体分类。Chen 等人[33]融合了纹理和光谱两种特征，再采用混淆矩阵方法来进行物体分类。

传统分割方法一般仅运用到了图像低阶的视觉信息（Low-level visual cues），例如统计特性中的梯度、颜色、直方图等。它无需进行多次迭代和训练，不需要过高的计算能力和较大的存储空间即可使用，但极度依赖具体分割任务。在复杂场景中，或在与工业应用相关的图像分割任务中，其适用性并不高，必须加入人为的辅助过程，才能提高其适用性。

1.2.2 基于卷积神经网络的图像语义分割方法研究现状

深度学习卷积神经网络的出现，是的众多模式识别问题都开始运用 CNNs，同时，语义分割问题也将 CNNs 考虑到其应用中。深度卷积神经网络模型包含了三大类别。

第一大类是最早提出的全卷积神经网络 FCNs（Fully Convolutional Networks）[34]。全卷积神经网络的模型训练方法是端到端、像素点到像素点的，以更好地结合图像语义信息。语义信息经过一系列由浅至深、由细至粗的卷积层，产生详细精确的分割结果图。当空间约束不够，或者卷积的感受野过大时，卷积层中的神经元将对应一块面积很大的输入图像，比如 FCN-32，其卷积层输出图像就是原始输入图像的 32 倍，如此巨大的放大倍数将导致粗糙的

分割结果。FCNs 提出了更加优越的模型结构，如 FCN-16 及 FCN-8 以解决 FCNs 模型在这方面的不足。FCNs 在输出层中加入的转置卷积（Transposed Convolution）[35],可以进行上采样，使得输出图像与输入图像的分辨率一致，最终获取到逐像素分类结果图。但当卷积层的感受野固定时，分割效果会在很大程度上依赖于识别物体的大小。FCNs 的分类器采用的是双线性差值算法，也会导致最终得分图的不精确，尤其是在分割图上标定目标物边界形状和结构时。

第二大类是编码-解码结构，针对于像素之间的预测和学习。如 SegNet[36]、DeconvNet[37]及 Decoupled Network[38]、UNet[39]等，其中 Decoupled Network 是半监督的网络结构。DeconvNet 学习训练了一个带有反卷积层、上采样层和 ReLU 层的深层反卷积网络，取代了 FCNs 中的简单分类器。它使用带标签的数据，采用手工方式来进行原图中实例的分割，再用手工分割得到的实例来学习网络的分割，最后对卷积神经网络进行细微调整，以免物体大小变化时，会影响到分割结果。文章中的分割结果仍有待提高，其最主要的想法是合并检测和分割结果，在检测方面，给出一个大概位置，在分割方面，必须标记好每一个点。DeconvNet 网络前期需要巨大的训练工作量，先要对每幅图像使用 SDS[40]生成 2000 个候选框，然后生成各个候选框的 CNN 特征，导致训练时间非常长。SDS 采用掩码后的图像，导致在 CNN 的训练过程中，许多边缘信息并没有得到表达。Decoupled Network 是半监督型网络，它将分类网络和分割网络进行了融合，训练方面并不困难。并且，它使用连接层来对分类网络和分割网络进行一个连接，逐类提取激活图，再分割前景和背景，激活图负责提取优秀先验信息，简化了卷积神经网络的参数学习过程。分类网络提供特殊类的激活图，减少了分割网络优化时候的搜素空间，只有前景和背景这两个类别，可以减少较多卷积神经网络的参数。UNet 是 Ronneberger 等人于 2015 年提出的应用于医学领域的图像分割的一种 U 型网络结构。UNet 网络在编码阶段的下采样方法采用的是卷积和池化方法，以此进行上下文特征的信息提取，解码阶段中，将与编码阶段处于相同位置特征图剪裁成同样尺寸，融合叠加两者的通道维度，逐步进行上采样，以恢复编码阶段损失的上下文的信息。深层信息逐步与浅层信息的融合，使得浅层信息可以对深层信息进行一定的补充，这也使得 UNet 成为医学图像细胞分割处理领域中的佼佼者。

第三大类是基于多尺度结构语义分割网络[41][42]，将输入图像调整至多个尺寸，从卷积网络的不同层提取都多尺度特征，然后进行结合。多尺度特征包括局部特征和全局特征，边界信息主要存在于浅层特征中，语义信息主要存在于深层特征中。浅层和深层的参数数目相差巨大，输入图像尺寸不同时，卷积网络的参数也不同，故多尺度网络结构难以训练。此外，必须经过大量推理，才能获取到多重卷积的特征，近期的一些深度学习分割方法并非采用前馈型方法，一般会采用条件随机场 CRF（Conditional Random Field）[43]中的最大后验的概率

估计亦或是区域建议（Rigional Proposals）[37]完成辅助的推理过程。

1.3 主要研究内容

本文通过对基于深度学习的轻量级实时语义分割网络的研究，总结影响语义分割网络效果的因素，探索计算复杂度低和参数量少且能实现精确分割的网络模型。本文提出的所有的模型全部基于 Pytorch 框架，用到了 NVIDIA RTX 2080Ti GPU 和 NVIDIA RTX3090Ti GPU 进行了训练。本文所做的主要工作如下：

（1）基于上下文聚合的实时语义分割网络。目前，大部分语义分割模型的重点放在了降低网络结构的复杂性和缩短网络推理时间上，设计出高分割精度的模型仍是图像分割领域亟待解决的重要问题。为了解决该问题，本文提出了一种基于上下文聚合网络的实时语义分割网络，该网络将输入图像裁剪至三个不同分辨率，逐一注入网络中，以完善分割的边界和细节信息，并采用了通道注意力和空间注意力机制来巩固网络的上下文信息，最终实现了在较低参数量的情况下和较快的推理速度下，实现良好的分割性能。

（2）基于多尺度特征的上下文信息融合网络。语义分割网络在进行特征提取时，网络层次越深，提取到的高级抽象语义信息将越丰富，然而空间细节信息的损失也越严重，然而精确的分割结果离不开细节信息的存在。为了解决该问题，本文提出了一种能够融合多尺度上下文信息的实时语义分割网络，该网络包含三条尺度不同的细节信息分支，在解码器部分依次与主干网络相同分辨率的特征图进行融合，有效地弥补了编码器在进行语义信息提取过程中所造成的空间信息损耗，该网络在编码时还采用了密集连接的方式，以便提取到多尺度的上下文信息，最终实现了高效率，低计算耗损的精确分割。

（3）基于 CNN 和 Transformer 的高效实时语义分割网络。Transformer 架构基于自我关注，近年来，在自然语言处理（NLP）领域大放异彩，因为其卓越的性能特点，后被慢慢应用至计算机视觉领域里。本文提出了一个将 CNN 和 Transformer 相结合的高效率的实时语义分割网络，基于轻量化编码-解码网络模型，使网络能够很好地平衡分割精度和推理速度。

其中，第三章、第四章和第五章是本文提出的轻量级实时语义分割网络。第三章提出的 CFSNet 的关注点在于如何实现上下文信息之间的聚合，即不同尺度的特征能够在网络中实现有效融合，最终通过特征提取单元中的残差结构及三条注入分支来实现。第四章提出的 EMCANet 在 CFSNet 的基础上，更加关注空间信息的损耗和多尺度信息的采集，融合了密集连接方式，能够在不增加网络参数量和计算量的同时，收集到多尺度和大接收域内的信息，且加入了三条细节信息分支，能够弥补空间信息损失。第五章提出的 EBSSNet 注意到了纯卷

积神经网络进行语义分割的弊端，即不能很好地建模全局依赖，于是将 CNN 与 Transformer 相融合，实现了局部和全局信息的双重建模，其性能介于 CFSNet 和 EMCANet 之间。

1.4 论文章节安排

本文基于卷积神经网络及 Transformer，针对工业应用领域、实际感知模式和自动驾驶等场景下的实时的轻量级语义分割网络模型进行了较为系统的研究，综合考虑模型大小、运行速度和分割精度等重要指标，使其达到最优平衡，达到满足在计算能力和存储能力有限的实际设备中仍能实现实时精确分割的目标。本文包含了六个章节，其组织结构如下所示：

第一章，绪论。本章节首先介绍了图像分割中语义分割的研究背景及意义，接着分析了传统图像分割方法研究现状和基于卷积神经网络的图像语义分割方法研究现状，然后阐述了本文主要研究内容，最后介绍文章的章节安排。

第二章，相关背景知识介绍。本章节介绍了与图像语义分割相关的技术研究。首先讲述深度学习卷积神经网络的理论基础，接着讲述 Transformer 的理论基础，然后介绍图像语义分割的典型网络结构，最后介绍语义分割中常用的性能指标以及训练数据集和测试集。

第三章，基于上下文聚合的实时语义分割网络。本章先介绍了网络中用到了两种注意力机制-通道注意力机制和空间注意力机制，然后介绍了构建的不对称卷积单元和多分支不对称卷积单元，并对网络的整体架构设计进行详细阐述，最后在两个常用的道路场景数据集-Cityscapes 和 Camvid 数据集上，进行了消融实验和与其他算法性能的比较，彰显出该网络的独特长处。

第四章，基于多尺度特征的上下文信息融合网络。本章首先介绍了网络中的基本特征提取单元，即分解扩张卷积单元和三分支分解扩张卷积单元，然后介绍了网络解码过程中对特征提取单元用到的特有的密集连接方法，讲述细节信息分支在网络中起到的作用后，阐述整体网络结构设计，最后在 Cityscapes 和 Camvid 这两个数据集上进行实验，论证网络有效性。

第五章，基于 CNN 和 Transformer 的高效实时语义分割网络。本章首先介绍了搭建的双边特征提取单元及 Transformer 注意力机制，然后详细阐述了整体网络结构，最后在 Citysacpes 和 Camvid 这两个基准数据集上进行实验，并与前本文两章提出网络进行对比，验证优越性。

第六章，总结和展望。对本文所做研究内容进行概括总结，并对未来轻量级实时语义分割技术的研究方向进行展望。

第二章 相关背景知识介绍

2.1 卷积神经网络的理论基础

深度学习中的最重要的一个神经网络结构就是卷积神经网络，它是一种受到生物学里接收域（Receptive Field）机制启发的一种前馈神经网络，专用于处理具有与网格结构相似的数据，如时间序列数据和图像数据，故主要应用于处理图片、视频、音频和自然语言。卷积神经网络涵盖了卷积、非线性激活及池化等操作，这些操作环环相扣，一层层地抽离出输入图像中的高级语义信息。

2.1.1 卷积层

卷积层中，卷积对特征图进行计算处理，输出内容传递至下一层卷积。卷积计算采用能够学习的卷积核，因而卷积神经网络大多采用卷积层来进行特征的表示。能够学习的卷积核，简单说来，就是众多输入特征图对每个输出特征图均产生影响，可以表示为：

$$x_j^l = f(\sum_{iM} x_i^{l-1} * k_{ij}^l + b_j^l) \tag{2.1}$$

其中，x_j^l 表示该卷积层输出结果，x_i^{l-1} 表示上一层卷积层的输出特征地图，k_{ij}^l 表示该卷积层卷积核，b_j 表示该卷积层偏置，M_j 表示第 j 个输入的特征地图。

二维卷积运算过程如图 2.1 所示。输入图片上，卷积核始终完成滑窗操作，对输入进行加权及相加操作，获取输出结果。

随着卷积神经网络的不断发展，科研人员们提出了各种各样的高效卷积以实现卷积更加广阔的应用领域。扩张卷积（Dilated Convolution）,分组卷积（Group Convolution）及深度可分离卷积（Depth-wise Convolution）都是常见的效率较高的卷积。

扩张卷积最初使用在小波变换[44]领域，目的是提升小波变换的速度。在这之后，扩张卷积逐渐被应用至语义分割领域，出现了经典的 Deeplab 卷积神经网络。扩张卷积运算过程如下图 2.2 所示。

根据图 2.2 可知，扩张卷积在进行采样的时候，会间隔一定的步长，所间隔的步长被叫做采样率，步长等于 1 的时候，扩张卷积就变成了标准卷积。与标准卷积相比，扩张卷积在保持参数不变的情况下，可以获得更大接收域，获取更加丰富的上下文信息。扩张卷积接收域

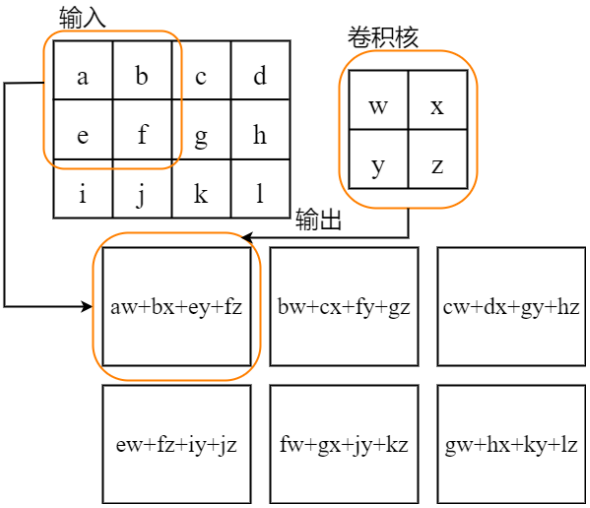

图 2.1 二维卷积运算过程示意图

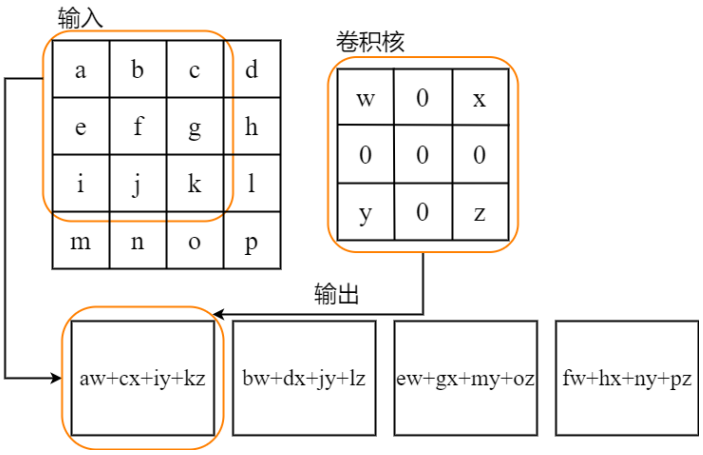

图 2.2 扩张卷积运算过程示意图

的计算公式可以表示为：

$$r_n = r_{n-1} + (k-1) \times \prod_{l=1}^{n-1} s_i \tag{2.2}$$

其中，r_n 是当前卷积层的接收域，r_{n-1} 是上一层卷积层的接收域，s_i 是第 i 层池化或卷积的步长，k 是卷积核尺寸。

分组卷积是由 Krizhevsky 等人[45]提出的，在 AlexNet 网络中得以运用，其主要目的是为了减少硬件资源的使用。分组卷积主要思想是将特征图分配给多个 GPU 分别进行处理，最终再融合多个 GPU 的处理结果。设定经过卷积运算，特征图的大小保持不变时，当输入矩阵的大小为 $H \times W \times C_1$，对于大小为 $h \times w \times C_1$，数量为 C_2 的标准卷积核，输入矩阵经其处理后，会得到 $H \times W \times C_2$ 尺寸的输出矩阵。上述运算过程如图 2.3 所示。

分组卷积对标准卷积的运算过程进行了优化，分组数目通过指定的分组组数 g 来决定，输入数据被划分为 g 组。输入图像的高度和宽度需要保持不变，仅仅是在深度方向上实行分

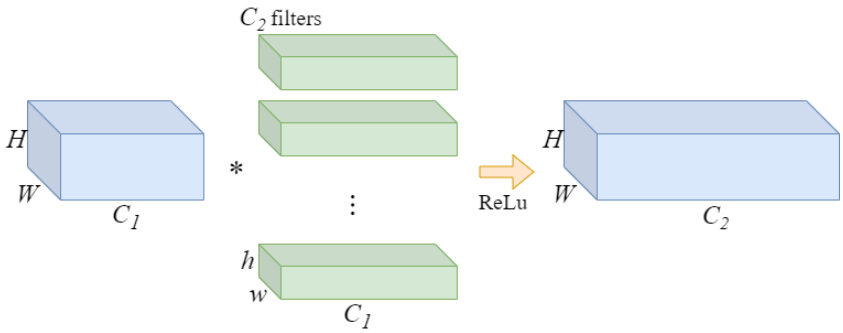

图 2.3 标准卷积示意图

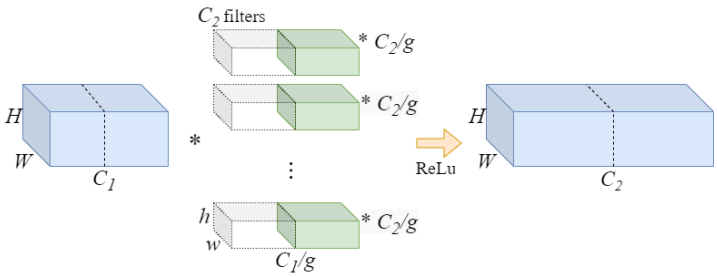

图 2.4 分组卷积示意图

组，每组的输入图像通道数为C_1/g，相应地，进行卷积运算的每个卷积核也输入C_1/g个通道的图像，但卷积核的尺寸保持不变。显而易见，每组卷积核数量需要变为C_2/g。经过分组卷积的运算后，输出矩阵的大小为$H\times W\times C_2/g$，数量为g组。分组卷积运算过程如图 2.4 所示。

分组卷积是标准卷积的子运算，它将标准卷积拆解为了g组，可以降低对硬件资源的限制，并减少参数量。用标准卷积进行运算时，所需参数量为：$h\times w\times C_1\times C_2$，当用分组卷积进行运算时，所需参数量为：$h\times w\times(C_1/g)\times(C_2/g)\times g=h\times w\times C_1\times C_2\times(1/g)$，故参数量减少$1/g$倍。

深度可分离卷积的基础思想是把标准卷积运算过程拆分为两步进行运算，这两步分别称为深度卷积（Depthwise Convolution）和逐点卷积（Pointwise Convolution），其目的是为了减少参数量，降低运算成本。深度可分离卷积运算过程如图 2.5 所示。

设定经过卷积运算，特征图的大小保持不变时，当输入矩阵的大小为$H\times W\times C_1$，对于大小为$h\times w\times C_1$，数量为C_2的标准卷积核，输入矩阵经其处理后，会得到$H\times W\times C_2$ 尺寸的输出矩阵，则标准卷积运算需要 的参数量。当采用深度可分离卷积时，深度卷积需要 的参数量，逐点卷积需要的参数量，故深度可分离卷积共需要 的参数量，其所需参数量仅为标准卷积所需参数量的，故深度可分离卷积是一种高效、计算复杂度较低的卷积方法。

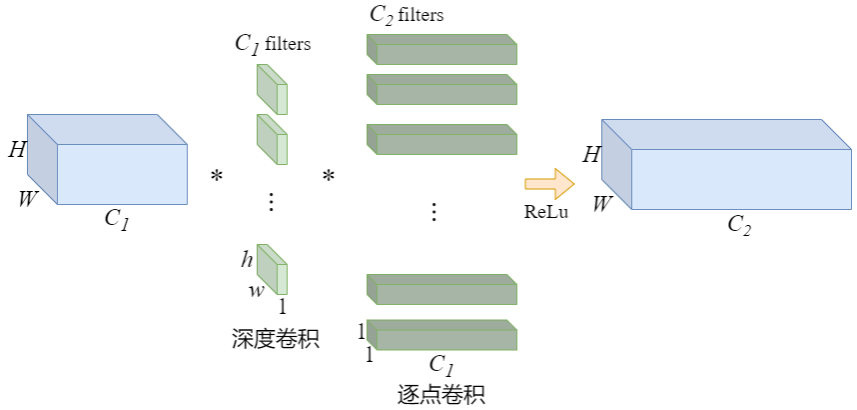

图 2.5 深度可分离卷积示意图

2.1.2 非线性激活函数

为了让卷积神经网络更优地进行图像处理，需要在网络中加进非线性激活函数，避免输出结果与输入图像呈现完全线性，使得卷积神经网络也可以应用于许多非线性的模型中。Sigmoid、ReLu、Softmax、Tanh 都是一些比较常用的非线性激活函数。

（1）Sigmoid

Sigmoid 激活函数也被称作 Logistic 激活函数，其核心思想是把实数数值进行压缩，映射到 0 至 1 区间里，能够应用在概率预测输出卷积层。此函数把大的负数值转变为趋于 0 的数，把大的正数值转变为趋于 1 的数，其表达式如下式（2.3）所示，函数图像如图 2.6（a）所示。

$$f(x)=\frac{1}{1+e^{-x}} \tag{2.3}$$

Sigmoid 函数可导，其值域为[0,1]，也标准化了神经元的输出。但函数值在 0 和 1 附近时，梯度值近似 0，导致了梯度消失的现象。且它里面包含的 epx()函数计算成本比其他非线性激活函数高很多，在输入数值近似 0 时，易造成梯度爆炸现象。此外，该函数输出值始终为正，造成权值更新始终保持同一方向，对收敛速度造成影响。

（2）ReLu

ReLu 激活函数又被称为线性整流函数，或修正线性单元。其表达式如下式（2.4）所示，函数图像如图 2.6（b）所示。

$$f(x)=\max(0,x) \tag{2.4}$$

ReLu 激活函数收敛速度较快，在 $x>0$ 时，不会出现梯度消失的现象，且具有稀疏性，运算成本低，时间空间复杂度也很低。但该函数只有正向梯度，$x<0$ 时，梯度会消失，若神经元是非激活状态，反向传播时，会导致更新网络权重失败。

（3）Softmax

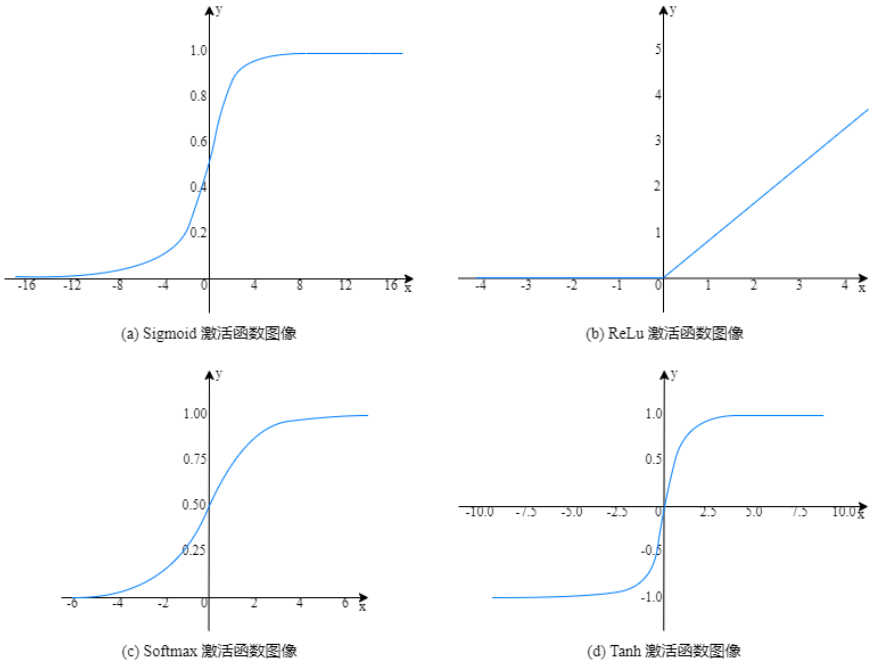

图 2.6 Sigmoid、ReLu、Softmax 及 Tanh 激活函数图像

Softmax 激活函数输出结果是[0,1]区间的概率值，是对输入数据归于特定类别的概率的判断，常用在分类模型中，且只在输出层中应用，隐藏层中并不会使用该函数。一般与交叉熵损失函数同时使用。表达式如下式（2.5）所示，函数图像如图 2.6（c）所示。

$$y_k = \frac{e^{a_k}}{\sum_{i=1}^{n} e^{a_i}} \tag{2.5}$$

其中，n 表示神输出层经元的个数，k 表示当前神经元序号，a_k 表示第 k 个神经元的输入信号。

（4）Tanh

Tanh 激活函数又被称为双曲正切激活函数，其值域为[-1,1]。其输出值中心为 0，故不会出现只向着单一梯度方向更新的现象。但该函数具有梯度消失、爆炸及因包含指数运算使计算量较大等缺点。表达式如下式（2.6）所示，函数图像如图 2.6（d）所示。

$$f(x) = \frac{e^{2x} - 1}{e^{2x} + 1} \tag{2.6}$$

2.1.3 池化层

池化层的作用是选择特征和过滤信息，池化过程中会丢失部分信息，但会大量缩减参数量和计算成本，是模型效果和计算性能之间实现良好平衡的结果，其本质是下采样操作。最常见池化运算有两种，即平均池化（Average Pooling）和最大池化（Max Pooling）。

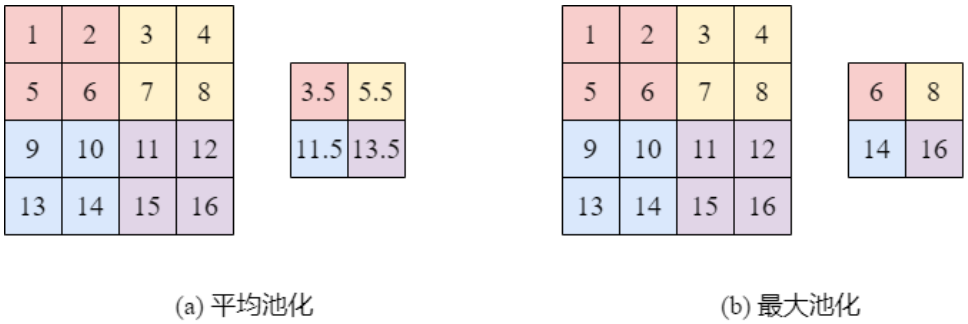

图 2.7 平均池化和最大池化操作过程示意图

平均池化是对特征图上的特征点求平均值，它能够最大程度上保留背景，但平均池化后的图片易变得模糊。在神经网络正向传播过程中，平均池化就是对范围内的像素点取均值，在反向传播过程中，根据范围大小，特征值被平均后传递给各个索引位置。最大池化是对特征图上的特征点取最大的值，它能够最大程度上保留关键纹理特征，是目前最为主流的池化方法。在正向传播时，最大池化需要取范围内最大数值，并记住其索引位置，以便反向传播时的计算，在反向传播过程中，需要将特征值逐一填充至正向传播时记住的最大值索引处，其他的位置均补 0。图 2.7 的（a）和（b）分别表示出了平均池化和最大池化的操作过程。

2.1.4 全连接层

全连接层需要把前一卷积层输出二维特征图转换为一维向量，上层节点逐一与其节点相连，其核心功能在于压缩输入图像经过一系列卷积操作和池化操作后得到的特征图，并按照压缩特征进行模型的分类过程，是卷积神经网络中的分类器，负责映射网络学习到的特征至实例标记空间，其本质是进行两个特征空间的线性变换。全连接层一般采用卷积来进行操作，前面一层若全连接，则全连接层可以采用卷积核大小为1×1的卷积，前面一层若为卷积层，则全连接层可以采用卷积核大小为$h\times w$的全局卷积，其中，h及w分别表示前一卷积层输出特征图的高和宽。

2.1.5 Dropout 层

Dropout 是由 Hinton[46]等人于 2012 年提出的，其目的是为了减少只有少量训练数据的大训练模型的过拟合情况。在网络进行训练时，依照固定概率暂时地删减神经网络中的节点，故当训练网络采用随机梯度下降法进行训练时，各个 mini-batch 训练的网络均不一致。当神经网络节点数目为n，各个神经节点有被保存和被舍去两种可能性，故会出现2^n个训练网络，能够很好地进行模型融合。Dropout 层实现过程如图 2.8 所示。

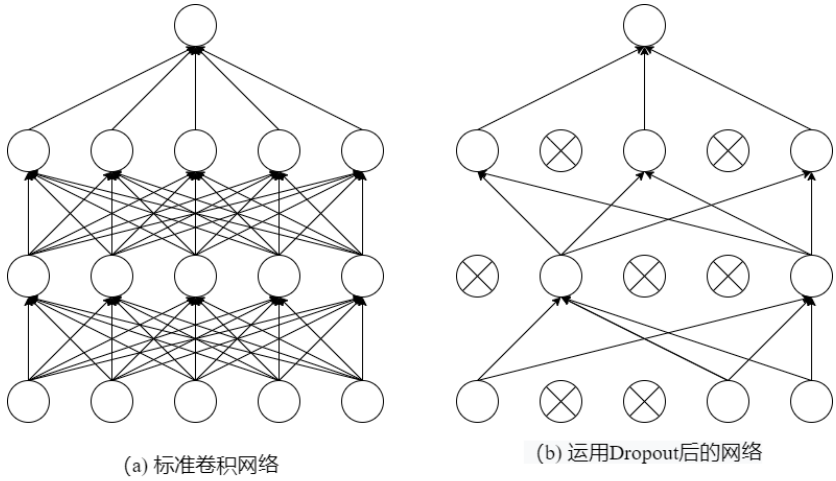

图 2.8 Dropout 实现过程演示图

算法 1 批标准化算法
Input: m 维度的批数据块 $\mathrm{B}=\{x_1,x_2,\cdots x_m\}$；准备学习的参数 γ 和 β Output: $y_i = BN_{\gamma,\beta}(x_i)$
Step1: 对批数据块求取均值: $\mu_{\mathrm{B}} \leftarrow \frac{1}{m}\sum_{i=1}^{m} x_i$ Step2: 对批数据块求取方差: $\sigma_{\mathrm{B}}^2 \leftarrow \frac{1}{m}\sum_{i=1}^{m}(x_i-\mu_B)^2$ Step3: 标准化批数据块的数据: $y_i \leftarrow \gamma\hat{x}_i+\beta = BN_{\gamma,\beta}(x_i)$ Step4: 训练待学习参数 γ 和 β Step5: 对输入数据进行参数为 γ 和 β 的尺度和平移变换得到输出结果 $y_i \leftarrow \gamma\hat{x}_i+\beta = BN_{\gamma,\beta}(x_i)$

2.1.6 批标准化层

卷积神经网络中，前面所有层的参数都会影响下一层的输入数据，网络越深，网络参数的轻微变化会越大。故在训练时，每层都要持续地适应前层运算获得的新分别，减慢了网络收敛进程。批标准化的出现解决了这个难题，并缩小了训练时内部隐藏层的协方差偏差。批标准化层一般应用于卷积层和密集连接层之后。批标准化的实现步骤如算法 1 所示。

2.2 语义分割任务评价指标

语义分割是一种像素级别的图像分割任务，它的一些常用评价指标有精确度、运算速度

和内存使用。

2.2.1 精确度

常用的精确度的评价指标均基于混淆矩阵（Confusion Matrix），如像素准确率（Pixel Accuracy, PA）、类别像素准确率（Class Pixel Accuracy, CPA）、类别平均像素准确率（Mean Pixel Accuracy, MPA）、交并比（Intersection over Union, IoU）和平均交并比（Mean Intersection over Union, MIoU）等。本文就目前最为常用的像素准确率，类别平均像素准确率和平均交并比进行说明，假设语义分割结果的类别数目为n_{class}，第i类被预测成第j类像素数目为n_{ij}，那么第i类被正确预测像素数目为n_{ii}，第i类总像素数目为$t_i=\sum_j n_{ij}$，则像素准确率可以表示为：

$$PA=\frac{\sum_i n_{ii}}{\sum_i t_i} \tag{2.7}$$

类别平均像素准确率可以表示为：

$$MPA=\frac{1}{n_{class}}\times\sum_i \frac{n_{ii}}{t_i} \tag{2.8}$$

平均交并比可以表示为：

$$MIoU=\frac{1}{n_{class}}\times\sum_i \frac{n_{ii}}{t_i+\sum_j n_{ji}-n_{ii}} \tag{2.9}$$

2.2.2 运算速度

神经网络模型的运算速度是极重要的指标，尤其在网络进行推理时。网络训练或学习并非实时需求，故训练时间的重要性不大，除非网络训练时运行速度过慢。运算速度很大程度上依赖于硬件资源的好坏，一般情况下，需要在相同硬件资源下，去比较网络运算速度才是有意义的。

2.2.3 内存使用

虽然多数实际应用场景中，内存可以进行扩充，但在一些嵌入式设备上，内存资源很有限，对于高端 GPU 卡而言，内存资源也并非可无限占用，故内存使用情况是考量语义分割模型的重要指标。

2.3 语义分割数据集

相比于图像分类任务所使用的数据集 ImageNet 而言，图像语义分割所使用的数据集较小，常用数据集有 PASCAL VOC[47] 、Gatech[48]、MSCOCO[49]、Camvid[50][51]及 Cityscapes[52]等。本文提出的轻量级语义分割网络均在 Camvid 和 Cityscapes 两个数据集上实施训练和测试，故下面仅对这两个数据集进行介绍。

2.3.1 Camvid 数据集

Camvid 数据集[50][51]全称为 The Cambridge-driving Labeled Video Database，由剑桥大学发布公开，内容为城市道路场景，涵盖 5 个长度不一的视频片段，图像数据取自视频帧，共 701 张图像数据。该数据集分为训练集、验证集及测试集三个子集，其中训练集中有 367 张图片，验证集中有 100 张图片，测试集中有 233 张图片。Camvid 原始分辨率大小为960×720，采用 11 种类别评估精度，包含：道路（Road）、树木（Tree）、交通标志（Symbol）、自行车（Bicyclist）、汽车（Car）、建筑物（Building）、天空（Sky）、行人（Pedestrian）、行人道（Sidewalk）、围墙（Fence）、电线杆（Pole）等，此外，它还包含一个未标注的类别，训练的时候需要将其省略。

2.3.2 Cityscapes 数据集

Cityscapes 数据集[52]全称为城市景观数据集，涵盖了 50 个城市街景的 3D 视频序列，具备两种评价标准，分别是 fine 和 coarse。Fine 中包含了 5000 张精细标注图片，coarse 中包含了 5000 张精细标注图片和 20000 张粗糙标注图片。精细标注的图片中，有 2975 张图片被划分到了训练集，500 张图片被划分到了验证集，1525 张图片被划分到了测试集。该数据集原始分辨率大小为2048×1024，因原始分辨率太大，造成显存紧张，故常见语义分割网络中一般会将其裁剪至1024×512的分辨率。它采用 19 种细分类别（Class）和 7 种粗分类别（Category）来评估精度，细分类别包含道路（road）、建筑物（building）、栅栏（fence）、墙壁（wall）、行人道（sidewalk）、电线杆（pole）、交通灯（traffic light）、天空（sky）、交通标志（traffic sign）、摩托车（motorcycle）、植物（vegetation）、火车（train）、地形（terrain）、行人（person）、骑手（rider）、汽车（car）、卡车（truck）、公共汽车（bus）、自行车（bicycle）等，粗分类别包括洼地（flat）、自然景观（nature）、物体（object）、人（human）和车（vehicle）等。可以从像素级、实例级及全景语义标签三个方面来评估视觉处理算法在语义分割城市场景理解任务中的性能。官网下载的数据集没有测试集标签，须进行在线评估。评估结果包含四个指标：

IoU class、iIoU class、IoU category 和 iIoU category。

2.4 本章小结

本章先详细介绍了卷积神经网络的理论基础，就卷积神经网络基本结构中的卷积层、非线性激活函数、池化层、全连接层、Dropout 层和批标准化层进行了较为系统的阐述，接着对于语义分割算法，详细说明了精确度、运算速度和内存使用三种最为常见的评价指标，最后介绍了本文提出的轻量级语义分割网络中所用到的 Camvid 和 Cityscapes 两种数据集。

第三章 基于上下文聚合的实时语义分割网络

3.1 引言

语义分割是一种逐像素进行分割的图像分割方法，需要分类一张图像上的每一像素，归属于一个类别的像素会被划为一类，并将对应标签标注其上，该方法已成为计算机视觉领域的重点研究方向。在自动驾驶系统中，识别和分析道路背景和在无人机使用时，决策着陆点以及许多嵌入式设备里，语义分割都有着举足轻重的效果。目前，语义分割的常用方法均围绕着深度卷积神经网络展开，采用编码-解码的网络结构。编码器的作用是下采样，在此过程中提取输入信息的语义信息，解码器的作用是上采样，以使得分割结果图与输入图像保持同样尺寸。目前，语义分割方法常分为两类，一类方法采用深度网络的架构，另一类方法采用轻量级的网络架构。VGGNet 和 ResNet 是深度网络的核心结构，深度网络的分割精确度高，但是网络的参数量巨大，推理时间很长，给计算资源有限的设备带来了很大压力，故不适用于硬件资源不充足的嵌入式设备中，在必须进行实时分割的现实场景中，也并不能够适用。故为了能够使语义分割在实际场景中更加适用，科研人员把研究重心逐渐转移到了轻量化的网络架构上。轻量化的网络架构参数量小，推理速度快，训练及测试时间短，但是分割准确度却有所降低。因而，如何能够设计出兼具分割准确度、小参数量和快速推理速度的网络，仍然是图像语义分割方向的研究重点。

为实现语义分割精确度和推理速度的良好平衡，本文设计了一种高效的轻量化语义分割网络，名为上下文聚合对称网络（Context Fusion Symmetric Network, CFSNet）。提出的上下文聚合对称网络创新点如下：

（1）CFSNet 中引入了不对称卷积单元（ACU），并且将通道注意力机制加入到了 ACU 中，通道注意力机制使得 ACU 能够在深度方向上，获取到更多关键信息，进行最大程度上的图像特征提取。

（2）CFSNet 中引入了多分支不对称卷积单元（MACU），MACU 中不但加入了通道注意力机制，并且运用了级联融合方式来融合不同卷积核所提取到的特征，以此来消除 MACU 中扩张卷积所产生的网格伪影。

（3）CFSNet 整体采用了一种对称架构，能够缩短网络运行时间，提升效率。在 Cityscapes 和 Camvid 两个常见道路场景数据集上的实验，证明了 CFSNet 是有效的。CFSNet 的参数量仅为 0.69M，但在 Cityscapes 上取得了 71.5%的 mIoU，在 Camvid 上取得了 68.8%的 mIoU。

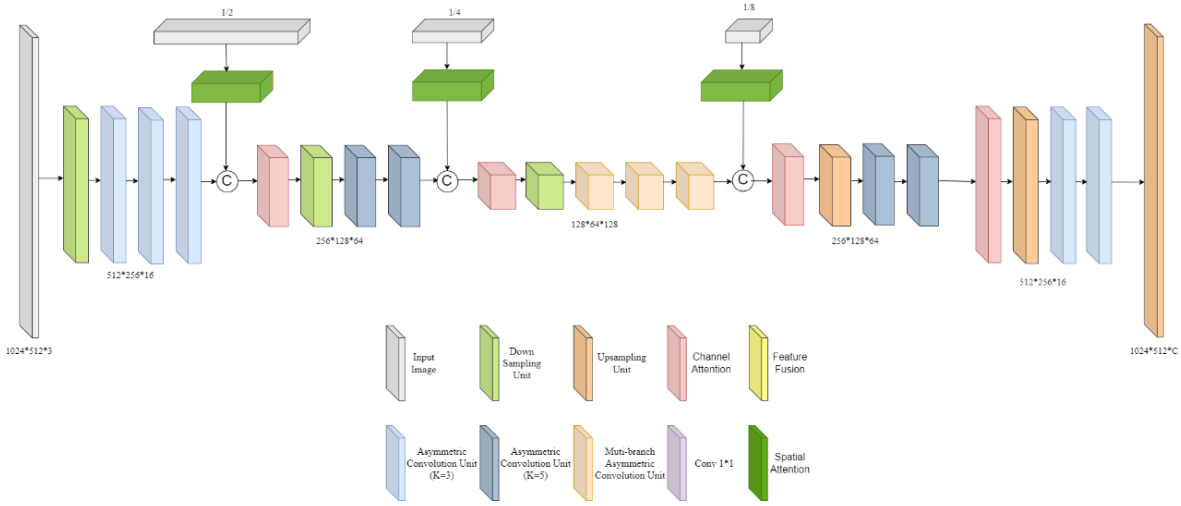

图 3.1 CFSNet 网络结构图

3.2 基于上下文聚合的实时语义分割网络

3.2.1 通道注意力机制

受 ECANet 启发[53]，在 CFSNet 的两种特征提取单元中均加入了通道注意力机制（见图 3.2 和图 3.3），主干网络第二次和第三次下采样操作及每次上采样操作之前，也用到了通道注意力机制（见图 3.1），来增大分割性能。通道注意力的目的在于对各个通道之间的相关性进行建模，给各个通道赋值相应的系数用以表示其权重，以突出关键特征，压制次要特征产生的影响，即立足于全局信息，有选择地对高意义特征通道进行放大，对低价值特征通道进行缩减。而标准卷积仅仅对通道进行通道融合操作。CFSNet 采用的通道注意力机制中，应用了不降低维度的非全局跨越通道信息交换方法，在不改变通道数的方法下，对通道进行全局平均池化。它采用了一维稀疏卷积，以此进行图像特征图间连接方法的优化，它只和它 k 邻域的各个通道交互信息，即只有 k 个像素参与了某一通道注意力预测，能够以相对更少的参数量实现较高的性能。同时，本文所采用的通道注意力机制，为排除进行交叉验证人为调整 k 的现象的出现，提出了自适应的这种方法来固定 k 的值，其中，跨通道交互涵盖区域和通道数量存在比例关系。CFSNet 两种特征提取单元及主干网络中用到的通道注意力模块的处理步骤如下式所示：

$$CAB(X) = X \times \sigma(f_{k\times k}(T(APool(X))) \tag{3.1}$$

其中，CAB 指的是 ACU、MACU 和主干网络中用到的的通道注意力模块，$f_{k\times k}$ 指的是卷积核尺寸为 $k\times k$ 的卷积，T 指的是对于标量数据的缩小、放大和转置行为。

3.2.2 空间注意力机制

受 CBAM[54]启发，在 CFSNet 中运用了空间注意力机制，对三种输入分辨率图像进行处理后，再与主干网络进行融合。空间注意力机制研究特征图中的位置关系，来形成注意力图像，说明特征图里必须重点关注的位置和必须进行抑制的位置。它的意图是对重点区域的特征进行重点表达，给各个像素点赋予权重，并产生掩膜（mask），加权后进行输出。那么，指定目标区域的特征会被加强，不相关背景区域的特征会被削弱。空间注意力机制中，会先在通道维度上，进行全局最大池化和全局平均池化，然后生成两张特征图以表示不同的信息。然后把这两张特征图用较大卷积核尺寸的7×7卷积进行特征融合。最后一步，使用 Sigmoid 激活函数来形成权重地图，乘上注意力机制的输入特征，最后指定区域的特征就会被突出。CFSNet 中用到的空间注意力模块的处理步骤如下式所示：

$$SAB(X) = X \times \sigma(f_{7\times7}(Concat\{APool(X), MPool(X)\})) \tag{3.2}$$

其中，SAB 指的是 CFSNet 中用到的空间注意力模块，$X \in R^{C\times H\times W}$ 指的是输入特征，σ 指的是 Sigmoid 激活函数，$f_{7\times7}$ 指的是卷积核尺寸为7×7的卷积，$Concat$ 指的是级联运算，$APool$ 指的是全局平均池化运算，$MPool$ 指的是全局最大池化运算。

3.2.3 不对称卷积单元

不对称卷积单元（Asymmetric Convolution Unit, ACU）中，采用了扩张卷积、不对称卷积和通道注意力机制，其结构图如图 3.2 所示。不对称卷积就是把一个卷积核尺寸为$k\times k$的标准卷积进行分解，拆分成卷积核尺寸分别为$k\times1$和$1\times k$的两个卷积。标准卷积运算是二维的，但是使用不对称卷积时，转变为两个一维卷积运算相加，这极大地降低了卷积运算的复杂度，所需的参数量及计算量也大大减少。当k的数值越大的时候，计算量和参数量减少得越多。不对称卷积与标准卷积在k的取值相同时，输出特征图也相同。

ACU 中使用了两个用3×3卷积分解而来的不对称卷积。第一个用3×3卷积分解而来的不对称卷积用来提取局部特征信息，第二个3×3卷积为扩张卷积，被分解为了3×1扩张卷积和1×3扩张卷积。扩张卷积的使用可以增大特征提取单元的感受野，故第二个3×1卷积和1×3卷积起到了提取上下文全局信息的效果。当连续使用多个不对称卷积单元，并且这些不对称卷积单元均采用不同的扩张率时，就可以达到提取多尺度上下文信息的目的。

除此之外，两个3×3卷积分解而成的3×1卷积和1×3卷积中使用了通道注意力机制，放置了一个通道注意力模块，以便进行重要通道信息的加强，突出其信道特征。ACU 中使用经典

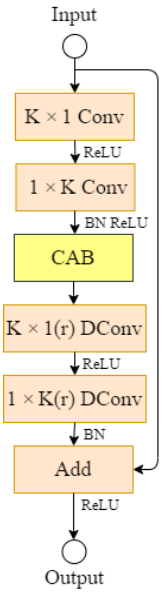

图 3.2 不对称卷积单元（ACU）结构图

的残差架构，以便更好地进行上下文信息的融合。ACU 中的运算过程可以进行如下表示：

$$y_{ACUout} = \rho(C_{1\times k,r}(C_{k\times 1,r}(CAB(C_{1\times k}(C_{k\times 1}(x_{ACUin}))))) + x_{ACUin}) \tag{3.3}$$

其中，x_{ACUin} 表示 ACU 的输入，x_{ACUout} 表示 ACU 的输出，$C_{m\times n}$ 表示卷积核尺寸为 $m\times n$ 的卷积，$C_{m\times n,r}$ 表示卷积核尺寸为 $m\times n$ 且扩张率为 r 的卷积，ρ 表示的是 ReLU 非线性激活函数，CAB 表示的是通道注意力模块。

3.2.4 多分支不对称卷积单元

CFSNet 网络中另一个特征提取单元是多分支不对称卷积单元（Multi-branch Asymmetric Convolution Unit, MACU），其结构图如图 3.3 所示。四条多分支不对称卷积分支构成一个多分支不对称卷积单元，且这四条多分支不对称卷积分支中均使用了不对称扩张卷积，其卷积核尺寸依次为 3，5，7，9，扩张率的值始终为 2。四条分支分别进行卷积运算后，再使用等级特征融合方法进行融合。四条分支采用卷积核尺寸不同的卷积，目的是为了获得多个尺度的全局上下文信息，使得语义信息更加全面和丰富。扩张卷积能够增大输入图像的接收域，但是使用它，也会出现网格伪影的现象，利用等级特征融合的方式进行卷积分支的融合，能够有效地避免网格伪影现象出现，同时，还可以维持高计算效率。等级特征融合方法是用层次化方法对学习而来的特征映射进行逐层融合，在层次结构上，逐级别地对感受野最小的支路与感受野大一个级别的支路进行融合。最后，对所有支路的输出再进行一次级联，后续再对级联后的输出特征图使用通道注意力模块以及卷积核尺寸为1×1的分组卷积。MACU 的处

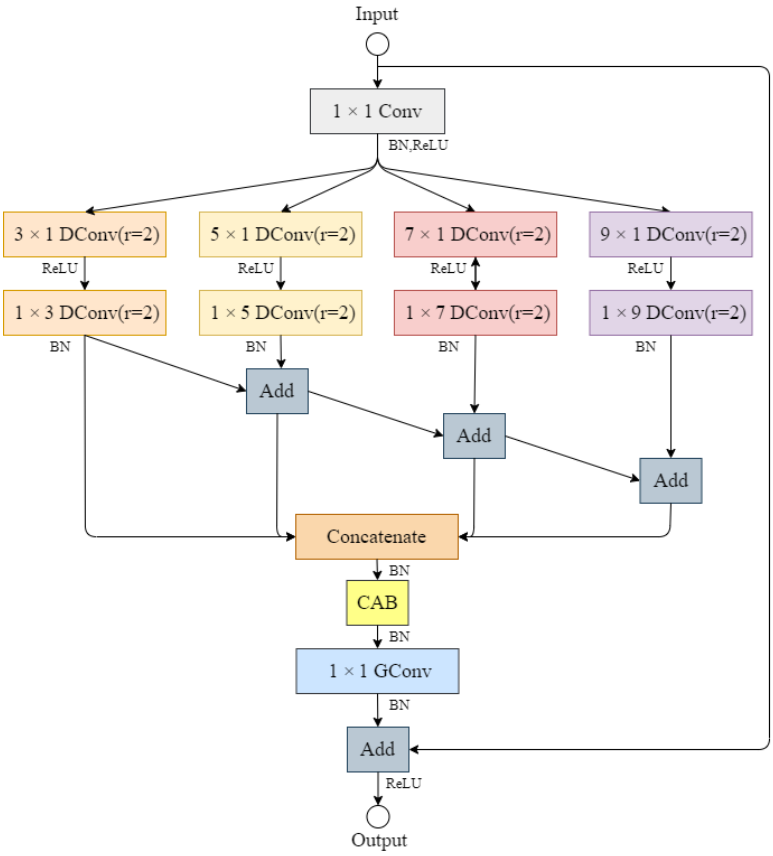

图 3.3 多分支不对称卷积单元（MACU）结构图

理过程可以依次进行如下表述：$I_1 = C_{1\times1}(I_{in})$，$I_{31} = DC_{3\times1}(I_1)$，$I_{32} = DC_{1\times3}(I_{31})$，$I_{51} = DC_{5\times1}(I_1)$，$I_{52} = DC_{1\times5}(I_{51})$，$I_{71} = DC_{7\times1}(I_1)$，$I_{72} = DC_{1\times7}(I_{71})$，$I_{91} = DC_{9\times1}(I_1)$，$I_{92} = DC_{1\times9}(I_{91})$，$add_1 = I_{32} + I_{52}$，$add_2 = add_1 + I_{72}$，$add_3 = add_2 + I_{92}$ $I_3 = Concat(I_{32}, add_1, add_2, add_3)$，$I_4 = CAB(I_3)$，$I_5 = GC_{1\times1}(I_4)$，$I_{out} = I_5 + I_{in}$，其中，$I_{in}$ 表示输入特征图，$C_{1\times1}$ 表示卷积核尺寸是1×1的标准卷积运算，I_1 表示1×1卷积运算的输出特征图。$DC_{3\times1}$，$DC_{1\times3}$，$DC_{5\times1}$，$DC_{1\times5}$，$DC_{7\times1}$，$DC_{1\times7}$，$DC_{9\times1}$，$DC_{1\times9}$ 逐一表示卷积核尺寸为3×1，1×3，5×1，1×5，7×1，1×7，9×1，1×9扩张率都是 2 的卷积运算。I_{31}，I_{32}，I_{51}，I_{52}，I_{71}，I_{72}，I_{91}，I_{92} 逐一表示 I_1，I_{31}，I_1，I_{51}，I_1，I_{71}，I_1，I_{91} 进行卷积核尺寸为3×1，1×3，5×1，1×5，7×1，1×7，9×1，1×9，扩张率为 2 的卷积运算后的输出特征图。add_1 指的是 I_{32} 与 I_{52} 的特征图融合结果，add_2 指的是 add_1 与 I_{72} 的特征图融合结果，add_3 指的是 add_2 与 I_{92} 的特征图融合结果，$Concat$ 指的是级联融合方法，I_3 指的是级联 I_{32}，add_1，add_2，add_3 的输出特征图，I_4 指的是通道注意力模块的输出特征图，$GC_{1\times1}$ 指的是卷积核尺寸为1×1的逐点分组卷积，I_5 指的是 I_4 经过 $GC_{1\times1}$ 运

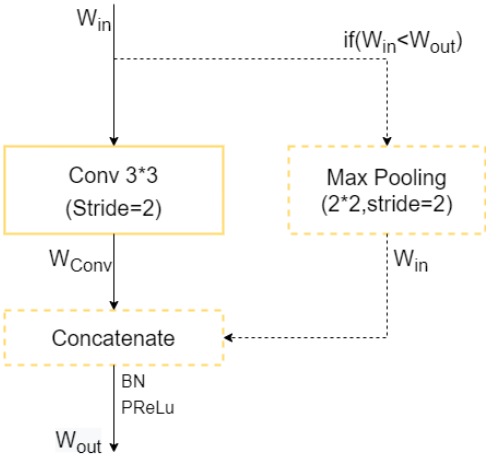

图 3.4 下采样结构图

算操作后的输出特征图，I_{out} 指的是多分支不对称卷积单元最终输出特征图。

3.2.5 整体网络架构设计

整体的网络架构使用了对称的编码-解码结构设计，在网络的最后放置了一个分类器进行像素分类和分割图的输出，网络整体结构图如图 3.1 所示。

在网络的编码器阶段，先进行初始下采样运算，将输入图像的分辨率降低至原始输入图像的一半，该下采样模块的结构图如图 3.4 所示。先对输入图像的通道数进行判断，当输入通道数小于下一模块所需的输入通道数（即该初始下采样模块的输出通道）时，对输入图像采用一个卷积核尺寸为2×2，步长为 2 的卷积进行一次最大池化，再对输入图像使用一个卷积核尺寸为3×3，步长为 2 的卷积进行标准卷积运算，最后对最大池化和标准卷积运算的输出结果采用级联操作进行融合，再归一化和非线性激活操作后，得到最终初始下采样运算的输出特征图。下采样的目的是在消除过拟合现象的同时，缩减图像分辨率，并保留住有用信息。最大池化的意义在于维持特征图像的平移、旋转和尺寸不变形的特性。初始下采样运算的处理过程可以表示为：

$$F_1 = Down(F_{in}) \tag{3.4}$$

其中，F_{in} 表示输入原始分辨率图像，$Down$ 表示初始下采样运算操作，F_1 表示初始下采样运算的输出特征图。

接着，在初始下采样运算后，连续使用三个卷积核尺寸为 3 的不对称卷积单元（第一个不对称卷积模块），可以表示为:

$$F_{13} = ACU_{K=3}(ACU_{K=3}(ACU_{K=3}(F_1))) \tag{3.5}$$

其中，F_1表示初始下采样运算的输出特征图，$ACU_{K=3}$表示$K=3$的不对称卷积单元，F_{13}表示对输入连续进行三个不对称卷积单元运算后的输出特征图。

将原始输入图像分别使用一个、两个及三个卷积核尺寸为3×3，步长为 2 的卷积操作进行平均池化运算，将其分辨率降低至$\frac{1}{2}$，$\frac{1}{4}$，$\frac{1}{8}$，再使用空间注意力模块对这三种分辨率图像进行处理后，送入主干网络与其进行特征的融合。此时的处理过程可以表示为：$Y_{11}=AvgP(F_{in})$，$Y_{21}=2*AvgP(F_{in})$，$Y_{31}=3*AvgP(F_{in})$，$Y_1=SAB(Y_{11})$，$Y_2=SAB(Y_{21})$，$Y_3=SAB(Y_{31})$，其中，F_{in}指的是原始输入图像，$AvgP$指的是卷积核尺寸为3×3，步长为 2 的平均池化运算，$*$指的是平均池化运算被执行的次数，Y_{11}，Y_{21}，Y_{31}指的是特征图大小为原始图像$\frac{1}{2}$，$\frac{1}{4}$ 和$\frac{1}{8}$的特征图，SAB指的是空间注意力模块，Y_1，Y_2，Y_3指的是SAB的输出特征图，后续须注入主干网络。

主干网络与$\frac{1}{2}$，$\frac{1}{4}$和$\frac{1}{8}$分辨率特征图融合之后，均需要采用通道注意力机制对融合后的输出进行处理。其处理过程可以表示为：$F_{c1}=Concat(F_{13},Y_1)$，$F_{CAB1}=CAB(F_{c1})$，其中，$F_{13}$是第一个不对称卷积模块的输出，$Y_1$是注入主干网络的$\frac{1}{2}$分辨率的特征图，$Concat$是级联运算，$F_{c1}$是首次特征级联的输出，$CAB$是通道注意力模块，$F_{CAB1}$是主干网络中首个通道注意力模块输出结果。

下采样运算虽然可以增大接收域，获取更广阔的上下文信息，但是它也会造成一定的损失，比如损失掉部分细节信息和边界信息，且下采样运算的次数越多，细节及边界信息损失越严重。故综合考虑后，本文的 CFSNet 仅仅采用了三次的下采样运算，获得的图像最小分辨率仅为$\frac{1}{8}$，在获得尽可能深层次的语义信息时，维持住更多的细节及边界信息。在初始下采样运算已经获得了$\frac{1}{2}$分辨率的图像后，后续两个下采样运算被依次放置在第一个和第二个通道注意力后。后续两个下采样运算采用与初始下采样运算相同算法。

编码器中的第二个不对称卷积模块由两个卷积核尺寸为 5 的不对称卷积单元组成，它被放置在第二个下采样运算的后面。而多分支不对称卷积模块被放置在第三次下采样运算后，它由三个多分支不对称卷积单元组成。则编码器剩余部分的处理过程可以表示为：$F_2=Down(F_{CAB1})$，$F_{22}=ACU_{K=5}(ACU_{K=5}(F_2))$，$F_{c2}=Concat(F_{22},Y_2)$，$F_{CAB2}=CAB(F_{c2})$，$F_3=Down(F_{CAB2})$，$F_{33}=PFCU(F_3)$，$F_{c3}=Concat(F_{33},Y_3)$，$F_{CAB3}=CAB(F_{c3})$，其中，$F_{CAB1}$、

F_{CAB2} 和 F_{CAB3} 是编码器中第一个通道注意力模块、第二个通道注意力模块和第三个通道注意力模块的输出特征图，$Down$ 是下采样运算（采用该运算后分辨率变为原来的 $\frac{1}{2}$），F_2 是第二次下采样运算的输出特征图（分辨率为 $\frac{1}{4}$），F_3 是第三次下采样运算的输出特征图（分辨率为 $\frac{1}{8}$），$ACU_{K=5}$ 表示 $K=5$ 的不对称卷积单元，F_{22} 是第二个不对称卷积模块的输出，Y_2 是经过空间注意力模块处理须与主干网络进行融合的 $\frac{1}{4}$ 分辨率的特征图，Y_3 是经过空间注意力模块处理须与主干网络进行融合的 $\frac{1}{8}$ 分辨率的特征图，$Concat$ 是级联运算，F_{c2} 是网络中第二次特征级联的输出，F_{c3} 是网络中第三次特征级联的输出，CAB 是通道注意力模块，$PFCU$ 是多分支不对称卷积模块，F_{33} 是多分支不对称卷积模块的输出。

解码器对称于编码器结构，包含两个不对称卷积模块，第一个不对称卷积模块由两个卷积核尺寸为 5 的不对称卷积单元组成，第二个不对称卷积模块由两个卷积核尺寸为 3 的不对称卷积单元组成。解码器部分的上采样算法采用的是卷积核大小为 3，步长为 2 的反卷积，每个上采样算法可以使特征图分辨率增大两倍。两个上采样算法和最后一个实现 2 倍上采样的分类器，能够在维持简易计算的同时，最大限度地恢复解码部分的信息。解码部分的计算过程如下所示：$F_4 = UP(F_{CAB3})$，$F_{42} = ACU_{K=5}(ACU_{K=5}(F_4))$，$F_{CAB4} = CAB(F_{42})$，$F_5 = UP(F_{CAB4})$，$F_{52} = ACU_{K=3}(ACU_{K=3}(F_5))$，$F_{out} = UP(F_{52})$，其中，$F_{CAB3}$ 和 F_{CAB4} 分别是编码器中第三个通道注意力模块和第四个通道注意力模块的输出特征图，UP 是上采样运算（采用该运算后分辨率变为原来的 2 倍），F_4 和 F_5 分别是第一次上采样运算和第二次上采样运算的输出特征图，F_{42} 和 F_{52} 分别是卷积核尺寸为 5 的不对称卷积模块和卷积核尺寸为 3 的不对称卷积模块的输出，$ACU_{K=5}$ 表示 $K=5$ 的不对称卷积单元，$ACU_{K=3}$ 表示 $K=3$ 的不对称卷积单元，CAB 是通道注意力模块，F_{out} 是整个网络最终输出的全分辨率分割结果图。

3.3 实验设计与结果分析

3.3.1 数据集和实施细节

（1）数据集

本章使用两个常见道路场景数据集 Cityscapes 和 Camvid 来对 CFSNet 的性能进行分析。

Cityscapes 数据集采用 19 种细分类别(Class)和 7 种粗分类别（Category）来评估精度，包含 5000 张精细标注图片和 20000 张粗略标注图片，我们使用精细标注图片来评估网络的性能。训练集中包含 2975 张图片，验证集中包含 500 张图片，测试集中包含 1525 张图片。每张图片分辨率为2048×1024，为缩减计资源，训练阶段的预处理过程中将其裁剪至1024×512进行实验，而测试时使用原分辨率大小的图片。Camvid 使用 11 种语义类别来评估精度，包含 701 张图片，其中训练集中有 367 张图片，验证集中有 100 张图片，测试集中有 233 张图片，图片原始分辨率为960×720，训练阶段的预处理过程中将其裁剪至480×360进行实验，测试时使用原分辨率大小的图片。

（2）参数设置

在 Cityscapes 数据集上，对于 CFSNet 采用随机梯度下降法（Stochastic Gradient Descent, SGD）进行训练，并将其 batch size 的大小设置为 8，采用的学习策略为“poly”学习法，其动量是 0.9，权值衰减是1×10^{-4}，学习率调整方法按照下式进行：

$$lr = lr_{initial} \times (1 - \frac{iteration}{iteration_{\max}})^{power} \tag{3.6}$$

其中，$lr_{initial}$表示起始学习率大小，$iteration$表示目前迭代次数序号，$iteration_{\max}$表示 epoch 里最大的迭代数，且设定$lr_{initial} = 4.5\times10^{-2}$， $power = 0.9$。

在 Camvid 数据集上，对于 CFSNet 采用 Adm 方法进行训练，batch size 数值同样指定为 8，动量指定为 0.9，权值衰减指定为2×10^{-4}，学习率策略同样使用“poly”学习法，只是需要令$lr_{initial} = 1\times10^{-3}$。

3.3.2 消融实验

在 Cityscapes 数据集上进行消融实验，利用训练集和验证集进行训练，利用测试集来进行性能分析，以到达证明 CFSNet 各部分设置的合理性及有效性。

（1）特征提取单元中的通道注意力模块

为了评估不对称卷积单元和多分支不对称卷积单元中加入的通道注意力模块的有效性，依次去除这两个卷积单元中的通道注意力模块，保持整体网络结构不变，观察其对于网络性能的影响，其结果如表 3.1 所示。

从表 3.1 可以看出，当网络中其他模块的结构和网络整体架构维持不变，仅在不对称卷积单元中去除掉通道注意力模块时，其参数量虽然减少了 0.02M，计算速度也提高了 8.6FPS，

表 3.1 不对称卷积单元（ACU）及多分支不对称卷积单元（MACU）中通道注意力模块（Channel Attention Block, CAB）对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
ACU(w/o Channel Attention Block)	71.1%	0.67M	85.5
MACU(w/o Channel Attention Block)	71.4%	0.69M	78.8
CFSNet	71.5%	0.69M	76.9

表 3.2 CFSNet 主干网络中空间注意力模块（Spatial Attention Block, CAB）及通道注意力模块（Channel Attention Block, SAB）对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
CFSNet(w/o Spatial Attention Block)	71.3%	0.69M	83.4
CFSNet(w/o Channel Attention Block)	70.9%	0.67M	88.9
CFSNet	71.5%	0.69M	76.9

但是其分割精度却下降了不少，降低了 0.4%mIoU，与精度下降的数值相比，其在网络参数数量和计算速度方面的提升是微不足道的。而在保持网络不变，仅仅在多分支不对称卷积单元中去除通道注意力模块时，其参数量相同，在计算速度仅提升 1.7FPS 的情况下，其分割准确度却可以有 0.1%mIoU 的改进。故综合考虑后，在 ACU 和 MACU 中均加入通道注意力模块是最佳方案。

（2）网络中的注意力模块

CFSNet 整体网络架构（主干网络）中包含了空间注意力模块和通道注意力模块这两种注意力模块，为评估这两种通道注意力模块对于 CFSNet 网络性能的影响，依次在网络中移除空间注意力模块和通道注意力模块，在移除每种注意力模块时，需保持网络一致性，实验结果如表 3.2 所示。

依据表 3.2 可知，在 CFSNet 中仅仅去除了空间注意力模块，即去除了三条注入的分支时，网络参数的大小是不变的，网络运行速度的提升也是有限的，仅仅提升了 6.5FPS 而已，但是分割精度下降却很明显，有 0.2%mIoU 之多。与移除了四个通道注意力模块后的网络相比，我们的 CFSNet 在以可抗衡的推理速度（仅 12FPS 之差）及略微较大的网络模型（0.02M 之差）的情况下，获得了 71.5%mIoU 的分割精度，比没有通道注意力模块的网络高了 0.6%mIoU 之多。故综合考虑后，在 CFSNet 中加入了三个空间注意力模块和四个通道注意力模块，这样的网络设计，能够使得网络实现在大小、分割精度和推理速度三个方面的最优均衡。

（3）MACU 中的特征融合方法

MACU 中采用等级特征融合方法来融合各卷积分支产生的特征图，目的是消除 MACU 中使用扩积造成的网格伪影现象，为证明等级特征融合方法起到了作用，将 MACU 中的特征融合方法分别替换为直接相加（add）和直接级联（Concatenate）方法，实验结果如表 3.3 所示。

表 3.3 MACU 中特征融合方法对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
MACU(add)	70.8%	0.68M	83.7
MACU(Concatenate)	70.5%	0.68M	80.2
CFSNet	71.5%	0.69M	76.9

表 3.4 ACU 中卷积核尺寸对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
k=3,3,3,3	71.1%	0.66M	94.5
k=5,5,5,5	68.2%	0.95M	61.6
CFSNet(k=3,5,5,3)	71.5%	0.69M	76.9

根据表 3.3 可知，在 MACU 中对四个卷积分支的输出特征图采用直接相加的特征融合方法时，其参数量较于 CFSNet 会少 0.01M，网络的推理速度会快 6.8FPS，但是分割精度却大幅下降，降至 70.8%mIoU，比 CFSNet 的分割精度低了 0.7%，用极少量的网络参数缩减与速度提升换取较大精度损失，是非常得不偿失的。而采用直接级联的方法对四个分支的特征图进行融合时，其网络大小与 CFSNet 相比，基本相同，仅有 0.1M 的优势而已，其推理速度也只快了 3.3FPS，这样的速度提升是非常微小的，但是分割精度却损失了 1%mIoU，这样的损失不容忽视。故为了得到性能最佳的语义分割模型，须在 MACU 中采用等级特征融合的方法来融合各分支的输出特征图。

（4）ACU 中的卷积核尺寸

CFSNet 中采用了四个不对称卷积模块，考虑到大卷积核的卷积单元及模块的感受野更大，可以接收到更加广阔的上下文信息，故在第二个和第三个不对称卷积模块中采用了卷积核尺寸为 5 的卷积，则这四个不对称卷积模块其卷积核尺寸分别为 3，5，5，3，为验证该种卷积核尺寸优势，将四个不对称卷积模块中的卷积核尺寸均指定为 3 和 5，来进行对比实验，实验结果如表 3.4 所示。

从表 3.4 可见，当不对称卷积模块中的卷积核尺寸均设定为 3 时，网络会减小 0.03M 的参数，运算速度也会提升 17.6FPS，但是分割效果却不如 CFSNet，比 CFSNet 的 mIoU 低了 0.4%，综合性能并比不上 CFSNet。当不对称卷积模块中的卷积核尺寸均固定为 5 时，需要 0.95M 的巨大计算量，网络运行速度也会被拖慢许多，只能达到 61.6FPS 的运行速度，且其分割精度也比 CFSNet 低了 3.3%，各方面性能都无法与 CFSNet 相比。故为了使得 CFSNet 具有最佳性能，须将四个不对称卷积模块的卷积核尺寸设定为 3，5，5，3。

（5）不对称卷积模块中不对称卷积单元（ACU）的个数

CFSNet 中的不对称卷积模块共有 4 个，分别包含不对称卷积单元的个数为 3，2，2，2，为了证明该不对称卷积单元个数的有效性，将其个数分别设置为 2，2，2，2，及 3，2，2，3 进行实验，实验结果如表 3.5 所示。

表 3.5 不对称卷积模块中不对称卷积单元（ACU）的个数对于网络性能的影响
（其中，number 表示不对称卷积模块中 ACU 的个数）

Model	mIoU(%)	Params(M)	Speed(FPS)
number=2,2,2,2	71.2%	0.68M	80.6
number=3,2,2,3	71.5%	0.70M	73.7
CFSNet(number=3,2,2,2)	71.5%	0.69M	76.

根据表 3.5 可知，当 CFSNet 中不对称卷积模块含有的 ACU 个数分别为 2，2，2，2 时，其网络仅仅比 CFSNet 小了 0.01M，网络推理速度也仅仅比 CFSNet 快了 3.7FPS，分割效果却不如 CFSNet 很多，小了 0.3%mIoU，因此并不是网络设计的最佳方案。当 CFSNet 中不对称卷积模块含有的 ACU 个数分别为 3，2，2，3 时，其网络可以获得与 CFSNet 相同的分割效果，但是网络参数量比 CFSNet 还大了 0.01M，运算速度也比 CFSNet 慢了 3.2FPS，其各方面性能均不如 CFSNet。根据以上所述，将网络中不对称卷积模块中 ACU 的个数设置为 3，2，2，2 是最优方法。

3.3.3 与其他先进算法的比较

在单张硬件 NVIDIA RTX 2080Ti GPU 上，采用 Pytorch 框架对 CFSNet 及其他一些比较先进的语义分割算法进行训练和测试，包括：ENet[55]，FSSNet[56]，ESPNet[57]，CGNet[58]，NDNet[59]，ContextNet[60]，EDANet[61]，ERFNet[62]，Fast-SCNN[63]，BiseNet[64]，ICNet[65]，DABNet[66]，FarSeeNet[67]，DFANet[68]，LEDNet[69]，SegNet[36]，AGLNet[70]，MSCFNet[71]，FBSNet[72]。

从表 3.6 可以看出，在 Cityscapes 测试集上，尽管 ENet[55]和 ESPNet[57]的网络结构最小，都只有 0.36M 大小的参数，但是评价分割精确度的 mIoU 却分别比 CFSNet 少了 13.2%和 11.2%，容易在分割质量上产生质的区别。网络推理速度较快的是 ESPNet[57]、EDANet[61]、Fast-SCNN[63]和 DFANet[68]，EDANet[61]在参数的数量上比 CFSNet 略低了 0.01M，但是其分割准确性却比 CFSNet 低了 4.2%mIoU，Fast-SCNN[63]的参数量是 CFSNet 的 1.61 倍，分割精度也比 CFSNet 低了 3.5%mIoU，DFANet[68]不仅分割精度比 CFSNet 低了 1.2%mIoU，网络参数数量更是 CFSNet 的 11 倍之多，在嵌入式设备上的适用度远不如 CFSNet。虽然在网络模型大小和网络推理速度方面，分别存在与 CFSNet 相抗衡的算法，但是它们综合性能无法与 CFSNet 相比，CFSNet 在这些算法中，取得了最准确的分割结果，分割精度达到了 71.5%mIoU。

从表 3.7 可以看出，在 Camvid 测试集上，ESPNet[57]尽管网络是最小的，仅有 0.36M，运行速度是最快的，高达 219.8FPS，但是其分割精度却位于倒数第二，仅有 55.6%mIoU，比 CFSNet 相差 13.2%mIoU 之多，分割效果过差，不能满足高精度语义分割的要求。ENet[55]网

表 3.6 Cityscapes 测试集上预测结果对比

Method	Pretrain	Input Size	mIoU（%）↑	Params（M）↓	Speed（FPS）↑
ENet[55]	No	512×1024	58.3	**0.36**	47.7
FSSNet[56]	-	512×1024	58.8	-	51
ESPNet[57]	No	512×1024	60.3	**0.36**	115.7
CGNet[58]	No	1024×2048	64.8	0.50	24.9
NDNet[59]	No	1024×2048	65.3	0.50	40
ContextNet[60]	No	1024×2048	66.1	0.85	79.8
EDANet[61]	No	512×1024	67.3	0.68	109.9
ERFNet[62]	No	512×1024	68.0	2.10	68
Fast-SCNN[63]	-	1024×2048	68.0	1.11	**124**
BiseNet[64]	ImageNet	768×1536	68.4	5.80	106
ICNet[65]	ImageNet	1024×2048	69.5	7.80	15.4
DABNet[66]	No	1024×2048	70.1	0.76	21.0
FarSeeNet[67]	-	512×1024	70.2	-	69
DFANet[68]	ImageNet	512×1024	70.3	7.80	100.0
LEDNet[69]	No	512×1024	70.6	0.95	57.1
CFSNet	No	512×1024	**71.5**	0.69	76.9

表 3.7 Camvid 测试集上预测结果对比

Method	Pretrain	Input Size	mIoU(%)↑	Params(M)↓	Speed(FPS)↑
ENet[55]	No	360×480	52.8	**0.36**	60.0
ESPNet[57]	No	360×480	55.6	**0.36**	**219.8**
CGNet[58]	No	360×480	65.6	0.50	66.1
EDANet[61]	No	360×480	66.4	0.68	110.3
ICNet[65]	ImageNet	720×960	67.1	7.80	27.8
DABNet[66]	No	360×480	66.4	0.76	97.8
DFANet[68]	ImageNet	720×960	64.7	7.80	120.0
LEDNet[69]	No	360×480	66.6	0.95	61.1
AGLNet[70]	ImageNet	360×480	**69.4**	1.10	90.1
MSCFNet[71]	No	360×480	69.3	1.15	-
FBSNet[72]	No	360×480	68.9	0.62	-
CFSNet	No	360×480	68.8	0.69	88.9

络参数量也只有 0.36M，但是其在网络推理速度和分割精度这两方面的表现均不如 CFSNet，运行速度比 CFSNet 慢了 28.9FPS，分割精度比 CFSNet 差了 16.0%mIoU。AGLNet[70]是近年来较流行的高精度分割算法之一，它能够实现 69.4%mIoU 的高精度分割，虽然 CFSNet 的分割精度比它略低了 0.6%mIoU，网络运行速度略慢了 1.2FPS，但其网络结构却比 CFSNet 大了 0.41M，因而 CFSNet 更满足轻量级语义分割算法的定义，更能够节省硬件设备上的计算资源。

观察图 3.5，可以看出我们的网络 CFSNet 在 Cityscapes 数据集上，能够更加准确地分割出路灯、远方汽车、路边植物等物体，而这些物体在实际场景中大多处于较远的位置，在图片中占据位置少，故分割出来的难度也较大，因而可以证实 CFSNet 能够描绘出细小物体的边界，实现精细物体的分割。据图 3.6 可知，在 Camvid 数据集上，CFSNet 主要对路灯分割

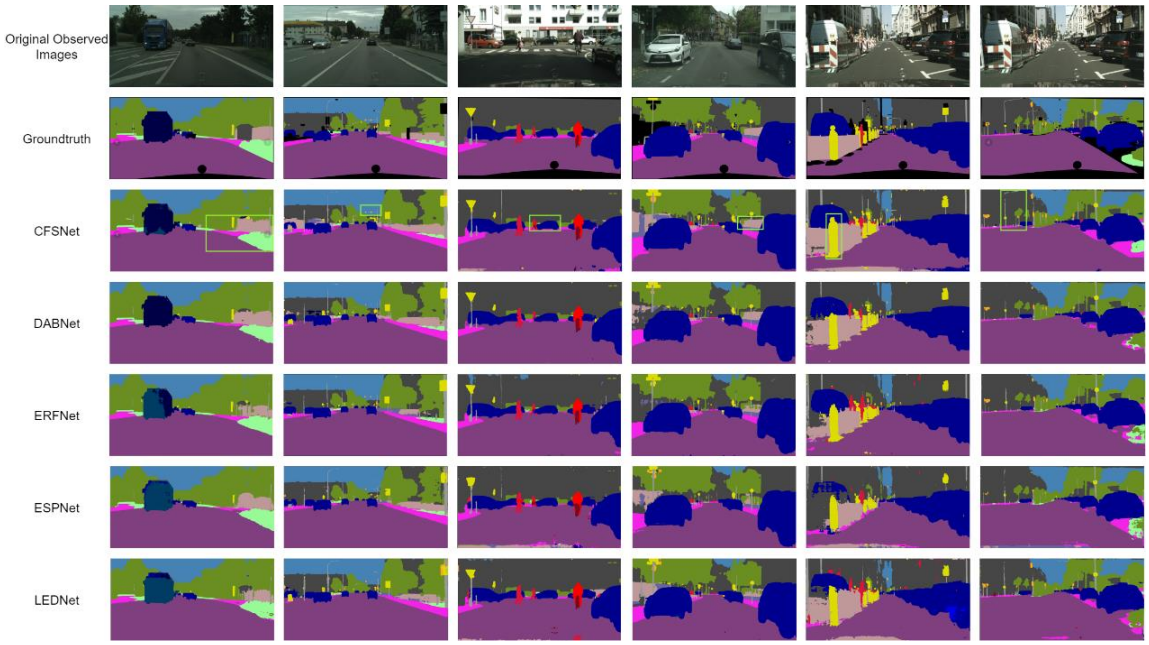

图 3.5 Cityscapes 验证集上预测结果对比图（自上向下依次为原始观察图像、真值、及 CFSNet、DABNet[66]、ERFNet[62]、ESPNet[57]和 LEDNet[69]的预测结果图）

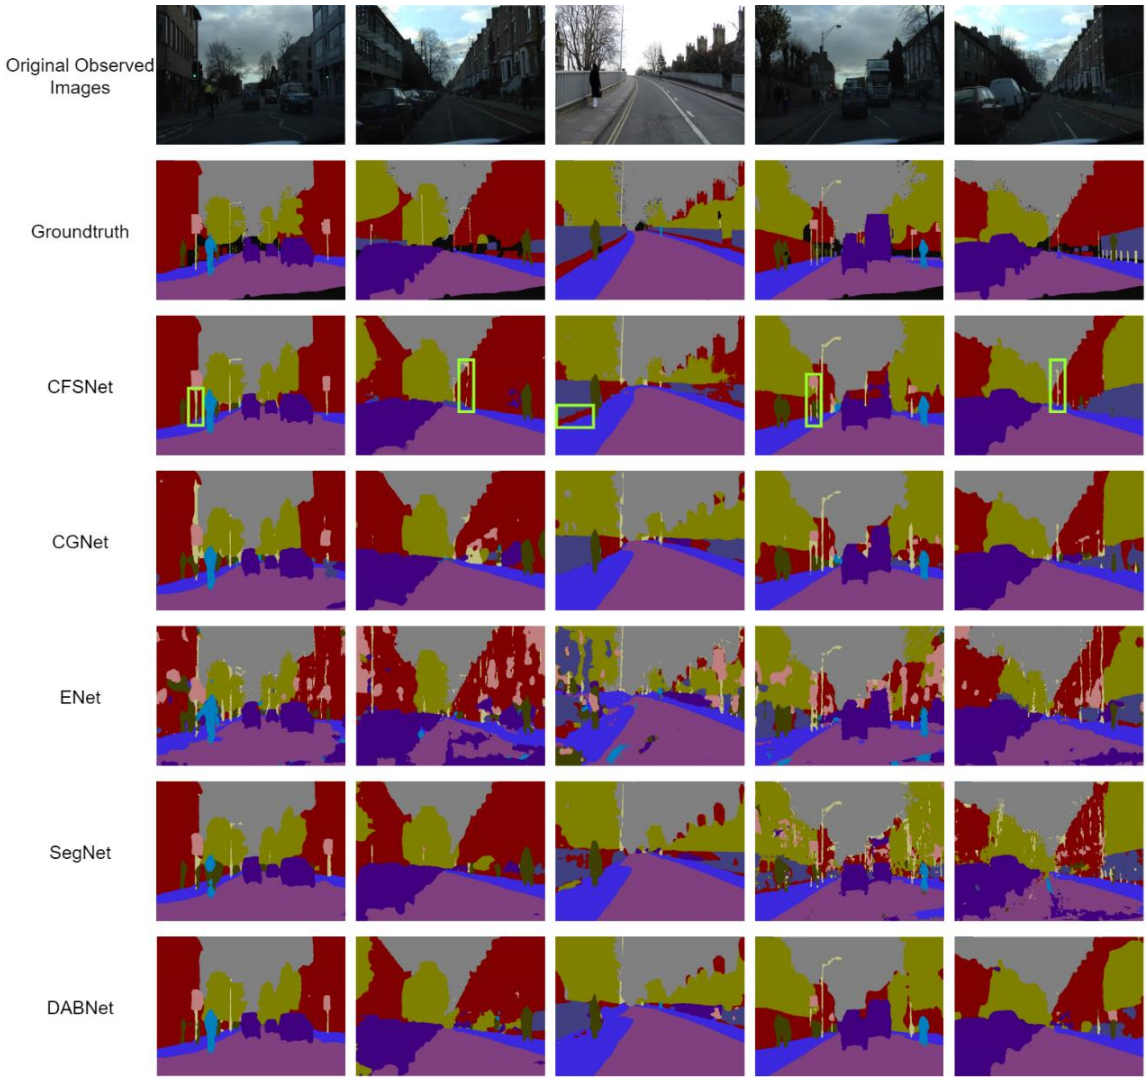

图 3.6 Camvid 测试集上预测结果对比图（自上向下依次为原始观察图像、真值、及 CFSNet、CGNet[58]、ENet[55]、SegNet[36]和 DABNet[66]的预测结果图）

效果的提升较为显著，其他网络有的会将路灯划分成其他的语义类别，而有的只能分割出一半的路灯，可以证实 CFSNet 能够提高分割结果图的可信度。

3.4 本章小结

本章提出了一个可以广泛应用于计算机视觉领域的轻量级实时语义分割方法，名为上下文聚合对称网络（CFSNet）。本章提出了由两个分解卷积组成的不对称卷积单元（ACU），其中还融入了通道注意力机制，以便更好地实现语义信息的提取。本章还提出了多分支不对称卷积单元（MACU），其由四个卷积核尺寸不同但扩张率相同的卷积分支进行特征提取，并最后采用了级联特征融入的方式来消除由使用扩张卷积所带来的网格伪影现象，也在其中融入了通道注意力机制。在所提出的不对称卷积单元和多分支不对称卷积单元的基础上，设计了四个卷积核分别为 3，5，5，3，不对称卷积单元个数分别为 3，2，2，2 的不对称卷积模块及一个多分支不对称卷积单元个数为 3 的多分支不对称卷积模块。更进一步提出了基于上下文注意力机制的网络结构，它采用了编码器与解码器相对称的简易网络结构。网络包含下采样模块、空间注意力模块、通道注意力模块、不对称卷积模块、多分支不对称卷积模块以及上采样模块。网络中包含三条注入主干网络的分支，即为原始输入图像采用空间注意力模块进行处理，并依次与主干网络相同分辨率的特征图进行级联操作，依次补全网络中特征图所逐渐缺失的边界信息和细节信息。本章使用了 Cityscapes 和 Camvid 这两种常见的语义分割数据集对 CFSNet 进行了巨量实验验证，结果表明我们的 CFSNet 能够实现在运行内存、精度和效率之间的良好权衡。

第四章 基于多尺度特征的上下文信息融合网络

4.1 引言

模式识别领域的一个重要组成部分就是语义分割，它对输入图片进行像素级别的标签化的预测。最近几年，深度卷积神经网络日益发展，将其使用到语义分割领域可以显著地提升分割的精度。然而这些卷积神经网络能够取得如此卓越的成果，其原因在于使用了极为复杂的模型设计，网络一般都具有极深的深度，亦或是极宽的宽度，因此网络的参数量很大，运行起来也需要较长的时间。但是对于许多现实应用来说，如增强现实、自动驾驶、智能监控和机器人交互等，对能够实时运行的场景理解系统的需求很高。

FCN[34]是语义分割领域最先使用的 CNN 网络结构，它采用了 VGG16[6]的基础结构，但是用卷积层代替了最后的全连接层来进行逐像素的标签预测，开创了基于 CNN 的语义分割方法的先河。U-Net[39]研发出了一种编码-解码器结构，从浅层的卷积层收集空间信息来增强深层卷积层的所提取到的特征。DeconvNet[37]使用了和编码器相对称的解码器结构，来对编码器的输出进行逐步的上采样。这两个网络的解码器都很庞大，因此网络具有高额的计算成本。Dilation10[73]堆叠了扩张率逐渐增加的扩张卷积层并建立了一个上下文模块，通过这种方式来对多尺度的上下文信息进行融合。DeepLab[74]引入了空洞空间金字塔池化（ASPP）模块，该模块采用多个具有不同扩张率的并行的扩张卷积分支来充分进行图像的多尺度特征表示。Dilation10[73]中的上下文模块和 DeepLab[74][75][76]中的 ASPP 模块都需要耗费大量的计算资源，运行时间极长。ENet[55]使用了 ResNet[7]的结构设计，是第一批用于语义分割的网络，但是它为了缩减计算量，减少了网络中卷积层的个数。ESPNet[57]中开发了一种高效的空间金字塔（ESP）模块，并且在 ESP 模块的最前端采用了逐点卷积以降低计算资源的消耗。ENet[55]和 ESPNet[57]在很大程度上提高了网络运行的效率，并且对硬件设备内存要求较低，但却以降低分割精确度为代价。ICNet[65]和 BiseNet[64]能够在性能和速度之间实现一定的平衡，但是其各方面指标仍有进一步的提升空间。在进行密集连接的网络中，DenseNet[77]在图像分类领域中的展现出优异的成绩，并被研究学者逐渐应用至语义分割领域中。FC-DenseNet[78]使用了 DenseNet[77]作为它的编码器部分，使用了传统的跳过连接，并在其基础上，加入了解码器部分，设计出基于全卷积的 DenseNet[77]。而 DenseNet[77]又被作为主干网络，被应用至 SDN[79]中，SDN 中还额外使用了堆叠的反卷积架构。这些方法只是简单地使用了 DenseNet[77]，但是并没有对它进行优化，且由于其复杂的网络结构，导致计算成本进一步增加。因此，本章设

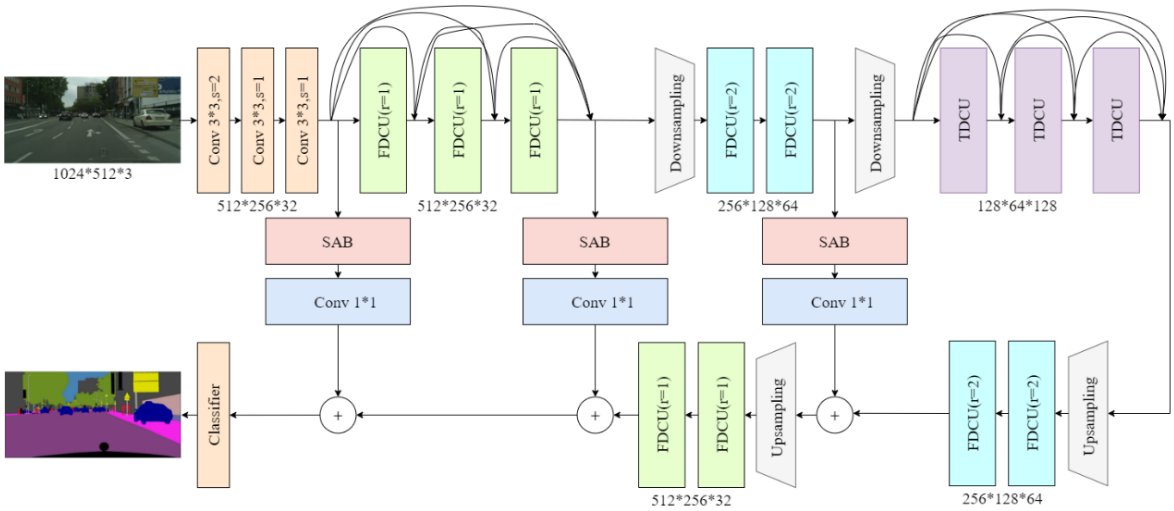

图 4.1 EMCANet 网络结构图

计出了一种可实现实时语义分割的高效多尺度上下文聚合网络（Efficient Muti-scale Context Aggregation Network, EMCANet）。EMCANet 是一种高性能的以实现现实应用为目标的语义分割网络，具备高准确度，高运算速度和小型号网络特点。本章所提出的 EMCANet 所具备的创新点主要包括以下三点：

（1）提出了进行特征提取的分解扩张卷积单元（FDCU）和三分支分解扩张卷积单元（TDCU）。FDCU 以分解卷积为基础，采用了两个3×3卷积，将其进行了分解，并在第二个3×3卷积所形成的分解卷积中加入了扩张率，使其形成分解扩张卷积，以高效提取大接收域信息。所提出的 TDCU 包含三条卷积分支，均为分解卷积，且其卷积核尺寸相同，但扩张率大小不相同，并且融入了深度可分离卷积。TDCU 中三条卷积分支互相融合，边界信息和语义信息互相补充，能够最大限度地实现特征信息的交互，提取到细节信息更加丰富的特征图。

（2）受 DenseNet 中层级密集连接的启发，EMCANet 中的第一个分解扩张卷积模块和三分支分解扩张卷积模块中使用了密集连接的方式。也就是说，将这些特征提取模块的输入和其新学习到的特征连接到一起，形成最终的输出。这种密集连接方式在提高网络处理效率的同时，可以使网络具备更大的接收域，采用密集连接的卷积模块的层次越深，其接收域就更大。

（3）根据所提出的 FDCU 和 TDCU，精心设计了分解扩张卷积模块和三分支分解扩张卷积模块，并在此基础上，结合密集连接方式和通道注意力机制，设计出了可以提取多尺度上下文信息的高效多尺度上下文聚合网络 EMCANet，EMCANet 采用 Pythorch 框架实现，采用单张 RTX2080Ti 进行训练和测试，参数量仅为 0.78M，但在语义分割常用的道路场景数据集 Cityscapes 和 Camvid 上，却分别以 78.7FPS 和 85.4FPS 的运行速度，获得了 71.9%mIoU 和 69.4%mIoU 的分割精度，分割效果十分显著。

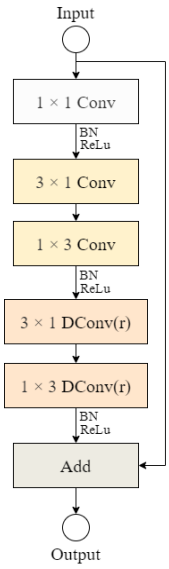

图 4.2 分解扩张卷积单元（FDCU）结构图

4.2 基于多尺度特征的上下文信息融合网络

4.2.1 分解扩张卷积单元

分解扩张卷积单元（Factorized Dilated Convolution Unit, FDCU）基于分解卷积，即不对称卷积，它由一个逐点卷积层和两对由3×3卷积分解而来的分解卷积组成，其结构图如图 4.2 所示。逐点卷积位于 FDCU 的最前端，其卷积核尺寸为1×1，主要作用是进行通道数目的变换，将通道维度变为原来的$\frac{1}{4}$，这样就可以极大地减少网络结构所需要的参数量并缩减计算资源。分解卷积是将一个标准的二维卷积运算转换为两个一维卷积运算的和，大大减小了计算的复杂性，可以将此过程表示为：

$$\sum_{i=-M}^{M}\sum_{j=-N}^{N} W(i,j)l(x-i,y-j) = \sum_{i=-M}^{M} W_x(i)(\sum_{j=-N}^{N} W_y(j)l(x-i,y-j)) \tag{4.1}$$

其中，l 表示二维图像，W 表示二维卷积卷积核，W_x 表示沿着 x 维度的一维卷积核，W_y 表示沿着 y 维度的一维卷积核。可以算出，当卷积核尺寸为 3 的时候，使用分解卷积，其参数数量和计算量将比使用原来的二维卷积减少 33%，而分割性能基本保持不变。

FDCU 的第二对分解卷积还结合了扩张卷积。扩张卷积是在每个维度的两个连续的卷积值之间进行补 0 操作，它可以在保持网络参数数量不变的情况下，增加卷积核的接收域。当一个 $k \times k$ 的卷积核的扩张率设定为 r 时，其接收域大小可以表示为：

$$(r(n-l)+1)\times(r(n-l)+1) \tag{4.2}$$

FDCU 整体的处理过程可以表示为：

$$y_{FDCUout} = \rho(C_{1\times3,r}(C_{3\times1,r}(C_{1\times3}(C_{3\times1}(C_{1\times1}(x_{FDCUin}))))) + x_{FDCUin}) \tag{4.3}$$

其中，x_{FDCUin} 表示 FDCU 的输入，$x_{FDCUout}$ 表示 FDCU 的输出，$C_{m\times n}$ 表示卷积核尺寸为 $m\times n$ 的卷积，$C_{m\times n,r}$ 表示卷积核尺寸为 $m\times n$ 且扩张率为 r 的卷积，ρ 表示 ReLU 非线性激活函数。

4.2.2 三分支分解扩张卷积单元

三分支分解扩张卷积单元（Three-branch Factorized Dilated Convolution Unit, TDCU）由三条卷积分支组成，每条卷积分支都是分解扩张卷积，三条卷积分支的分解卷积核大小均为 3×1 和 1×3，但是这三条分支卷积的扩张率并不相同，从左到右依次为 2，5，9，逐渐递增，目的是为了获取到多尺度的特征地图，且扩张率越大，表明可以获取到的特征地图尺度越大，即其接收域越大，其结构图如图 4.3 所示。TDCU 中还采用了深度可分离卷积，深度可分离卷积分为两部分，一部分是逐点卷积，另一部分是深度方向卷积，和常规的卷积操作比起来，它的参数数量及计算成本都比较低。TDCU 中采用的是 1×1 的逐点卷积和 3×1 及 1×3 的深度方向卷积，其中，3×1 及 1×3 的深度方向卷积是由 3×3 深度方向卷积分解而来的。

假设输入的通道数为 n_{in}，输出的通道数为 n_{out}，输入特征图大小为 $w\times h$，padding 的大小为 p，当特征提取过程中使用的是标准的 3×3 卷积时，特征提取所需要的参数量为式（4.4）所示，计算量为式（4.5）所示。

$$3\times3\times n_{in}\times n_{out} \tag{4.4}$$

$$3\times3\times(w-3+2p+1)\times(h-3+2p+1)\times n_{in}\times n_{out} \tag{4.5}$$

当特征提取过程中使用的是逐点卷积核深度方向可分离卷积时，逐点卷积所需参数量如式（4.6）所示，计算量如式（4.7）所示，深度方向卷积所需参数量如式（4.8）所示，计算量如式（4.9）所示。

$$1\times1\times n_{in}\times n_{out} \tag{4.6}$$

$$1\times1\times w\times h\times n_{in}\times n_{out} \tag{4.7}$$

$$3\times3\times n_{out} \tag{4.8}$$

$$3\times3\times(w-3+2p+1)\times(h-3+2p+1)\times n_{out} \tag{4.9}$$

而深度可分离卷积是逐点卷积和深度方向卷积的合并运算，故其所需的参数量为式（4.10）所

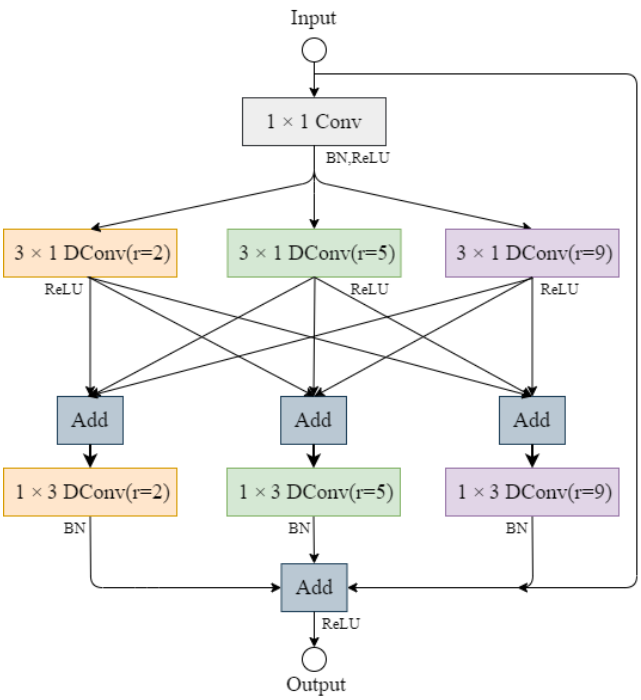

图 4.3 三分支分解扩张卷积单元（TDCU）结构图

示，计算量为式（4.11）所示。与使用标准卷积相比，其减少的参数量如式（4.12）所示，减少的计算量如式（4.13）所示。

$$1\times1\times n_{in}\times n_{out}+3\times3\times n_{out} \tag{4.10}$$

$$1\times1\times w\times h\times n_{in}\times n_{out}+3\times3\times(w-3+2p+1)\times(h-3+2p+1)\times n_{out} \tag{4.11}$$

$$(8n_{in}-9)\times n_{out} \tag{4.12}$$

$$(9(n_{in}-1)(w+2p-2)(h+2p-2)-whn_{in})\times n_{out} \tag{4.13}$$

当特征提取过程中使用的由3×3卷积分解而来的3×1和1×3分解卷积时，卷积核尺寸为3×1的卷积所需的参数量为式（4.14）所示，计算量为式（4.15）所示，卷积核尺寸为1×3的卷积所需的参数量为式（4.16）所示，计算量为式（4.17）所示，总参数量为式（4.18）所示，总计算量为式（4.19）所示。

$$3\times1\times n_{in}\times n_{out} \tag{4.14}$$

$$3\times1\times(w-3+2p+1)\times(h-3+2p+1)\times n_{in}\times n_{out} \tag{4.15}$$

$$1\times3\times n_{in}\times n_{out} \tag{4.16}$$

$$1\times3\times(w-3+2p+1)\times(h-3+2p+1)\times n_{in}\times n_{out} \tag{4.17}$$

$$6n_{in}n_{out} \tag{4.18}$$

$$6(w-3+2p+1)(h-3+2p+1)n_{in}n_{out} \tag{4.19}$$

与使用标准的3×3卷积相比，其减少的参数量如式（4.20）所示，减少的计算量如式（4.21）所示。

$$3n_{in}n_{out} \tag{4.20}$$

$$3(w-3+2p+1)(h-3+2p+1)n_{in}n_{out} \tag{4.21}$$

TDCU 中融合了深度可分离卷积和分解卷积，故其可减少的参数量为式（4.12）与式（4.20）之和，可表示为式（4.22）所示，可减少的计算量为式（4.13）与式（4.21）之和，可表示为式（4.23）所示。

$$(8n_{in}-6)n_{out} \tag{4.22}$$

$$((12n_{in}-9)(w+2p-2)(h+2p-2)-whn_{in})n_{out} \tag{4.23}$$

可以看出，TDCU 在参数量减少和计算量降低方面的成果显著，获得了其他很多特征提取单元难以获得的效果。

为了实现三条卷积分支之间的信息互享，在每条卷积分支的3×1和1×3分解卷积中间增加了融合操作，以实现特征之间的交互和上下文信息之间的相互补充。最后，在 TDCU 的尾部采用 add 运算，对三条卷积分支所提取到的特征图进行一个融合，以实现通道信息共享及交互。TDCU 中还使用了经典的残差结构，这样可以确保本地信息能够充分地融合上下文信息。TDCU 整体的处理过程可以表示为：

$$x_b = C_{1\times1}(\rho(x_{TDCUin})) \tag{4.24}$$

$$y_1 = C_{1\times3,r=2}(C_{3\times1,r=2}(x_b)+C_{3\times1,r=5}(x_b)+C_{3\times1,r=9}(x_b)) \tag{4.25}$$

$$y_2 = C_{1\times3,r=5}(C_{3\times1,r=2}(x_b)+C_{3\times1,r=5}(x_b)+C_{3\times1,r=9}(x_b)) \tag{4.26}$$

$$y_3 = C_{1\times3,r=9}(C_{3\times1,r=2}(x_b)+C_{3\times1,r=5}(x_b)+C_{3\times1,r=9}(x_b)) \tag{4.27}$$

$$y_{TDCUout} = \rho(y_1+y_2+y_3+x_{TDCUin}) \tag{4.28}$$

其中，x_{TDCUin}表示 TDCU 的输入，$y_{TDCUout}$表示 TDCU 的输出，x_b表示1×1逐点卷积的输出，y_1，y_2，y_3表示 TDCU 中三条卷积分支的输出，$C_{m\times n}$表示卷积核尺寸为$m\times n$的卷积，r表示卷积的扩张率，ρ表示的是 ReLU 非线性激活函数。

4.2.3 密集连接

EMCANet 中用到了密集连接的连接方式，第一个分解扩张卷积模块和三分支分解扩张卷积模块中各个卷积单元的连接方式为密集连接方式，即每个卷积模块将其输入和新学习到的特征连接在一起，形成最后的输出。这种密集连接的方式可以提高卷积提取模块的处理效率，因为每个卷积单元仅仅需要获取少量的新特征而已。并且，越深层次的卷积层其接收域越大。对于两个卷积核尺寸均为3×3的连续卷积层，其接收域大小与一个卷积核尺寸为5×5的卷积相同，对于三个卷积核尺寸为3×3的连续卷积层，其接收域大小与一个卷积核尺寸为7×7的卷积相同。故密集连接将从每个卷积单元里学习得来的特征连接起来，这些卷积单元的接收域大小各不相同，使得 EMCANet 能够聚集多尺度的上下文信息，在保持参数量和计算量不变的情况下，获得良好的分割性能。

4.2.4 语义信息分支

深度卷积神经网络中每个阶段的卷积层具有不同的作用和功效，前端卷积层能够维持住边界信息和细节信息，但是不能获得高级的抽象信息，后端卷积层的语义信息丰富，但是空间信息不足，仅仅能够预测出大致的分割结果，只有充分利用前端卷积层的信息和后端卷积层的信息，才能获得最为准确的分割结果。设计语义分支的目的在于获取高级语义信息，该分支通道的信息容量低。空间金字塔池化所示最新流行起来的获取大接收域和多尺度上下文信息的方法。虽然复杂网络其分割精度较高，但是它也会导致巨大的计算资源消耗，使其与现实应用的适配率并不高。BiseNet[64]中使用了双分支结构，但是它是基于需要预训练的 ResNet[7]，故其网络结构庞大，且不能实现端到端的训练。本章提出的 EMCANet 中的语义信息分支却能够在保持小网络参数量和低计算资源消耗的同时，获取大接收域内的信息，获得更加丰富的语义信息。

语义信息分支的初始模块采用了三个卷积核尺寸为3×3的卷积，其中第一个3×3卷积的步长为 2，可以将输入图像的分辨率变为原来的$\frac{1}{2}$，起到了初步下采样的作用。下采样操作可以在缩减网络计算量的同时，使得图像包含更多的空间信息。但是下采样的次数越多，边界信息和细节信息的丢失也会越严重，导致粗略的分割结果，且图像分辨率过小，特征提取过程也会很难进行。因而，在斟酌之后，本章在语义信息分支中仅使用了两次下采样操作，一次下采样操作，将使输入图像的分辨率变至原来的$\frac{1}{2}$，故网络中分辨率最小的特征图是原始

图像分辨率的$\frac{1}{8}$而已。下采样操作采用的运算过程如图 3.4 所示。需要对输入通道数目进行判断，当输入通道数目大于或等于输出通道数时，可以直接采用步长为 2，卷积核尺寸为3×3的卷积，进行下采样，当输入通道数目小于输出通道数目时，还需要对输入特征图进行一个最大池化的操作，将其输出结果与卷积输出结果相级联，得到最终需要输出的特征图。

4.2.5 细节信息分支

在 EMCANet 进行语义信息提取的时候，会造成细节信息的损耗，且提取到的语义信息越抽象，细节信息的损耗就会越严重，两者呈现出一种互相排斥的关系。为了补充 EMCANet 在提取语义信息过程中造成的空间信息丢失，因此在网络中加入了三条细节信息分支，以确保网络能够获得精确的分割结果。

在 EMCANet 的第一个分解扩张卷积模块前后分别放置一个细节分支，在第二个分解扩张卷积模块后也放置了一个细节分支，共三条细节分支。细节分支由一个空间注意力模块（Spatial Attention Block, SAB）和一个卷积核大小为1×1的逐点卷积组成，其中最核心的部分是空间注意力模块。空间注意力模块旨在加强空间信息特征的表达，它会在信道维度上，对特征图进行最大池化及平均池化，再使用标准卷积将最大池化和平均池化的结果进行融合，最后使用非线性激活函数进行激活，最终获取到强调重点空间特征，抑制非必要空间特征的特征图。其处理过程可以进行如下表述：

$$M_s = \sigma(C_{k\times k}(\{f_{AvgPool}(X), f_{MaxPool}(X)\})) \tag{4.29}$$

其中，X 表示输入特征图，$f_{AvgPool}$ 表示平均池化，$f_{MaxPool}$ 表示最大池化，$C_{k\times k}$ 表示卷积核尺寸为$k\times k$的卷积运算，σ 表示非线性激活函数，M_s 表示空间注意力模块最终输出的特征图。

4.2.6 整体网络架构设计

EMCANet 基于编码-解码结构，其网络结构图如图 4.1 所示。编码部分包括初始模块，两个下采样模块，扩张率分别为 1 和 2 的两个分解扩张卷积模块（其中，第一个分解扩张卷积模块包含 3 个分解扩张卷积单元，第二个分解扩张卷积模块包含 2 个分解扩张卷积单元）及由三个三分支分解扩张卷积单元组成的三分支分解扩张卷积模块。初始模块由三个3×3的卷积组成，第一个卷积步长为 2，可以对原始图像进行 2 倍下采样，剩下两个3×3卷积的作用在于对输入图像进行初步的特征提取。初始模块的处理过程可以表示为：

$$F_1 = C_{3\times3,s=1}(C_{3\times3,s=1}(C_{3\times3,s=2}(F_{in}))) \tag{4.30}$$

其中，$C_{k\times k,s=m}$ 表示卷积核大小为 $k\times k$，步长为 m 的卷积，F_{in} 表示 EMCANet 的输入图像，F_1 表示初始模块的输出特征图。

在初始模块后，放置了第一个细节信息分支及进行密集连接的第一个分解扩张卷积模块，分别可以表示为：

$$F_{s1} = C_{1\times1}(SAB(F_1)) \tag{4.31}$$

$$F_2 = FDCU(F_1) \tag{4.32}$$

其中，F_1 表示初始模块的输出特征图，SAB 表示空间注意力模块，$C_{k\times k}$ 表示卷积核大小为 $k\times k$ 的卷积，F_{s1} 表示第一条细节信息分支的输出，$FDCU$ 表示进行密集连接的第一个分解扩张卷积模块，F_2 表示进行密集连接的第一个分解扩张卷积模块的输出。

进行密集连接的第一个分解扩张卷积模块后放置了第二个细节信息分支及第一个下采样模块，下采样之后紧跟着第二个分解扩张卷积模块，分别可以表示为：

$$F_{s2} = C_{1\times1}(SAB(F_2)) \tag{4.33}$$

$$F_3 = FDCU(Down(F_2)) \tag{4.34}$$

其中，F_2 表示第一个分解扩张卷积模块的输出，SAB 表示空间注意力模块，$C_{k\times k}$ 表示卷积核大小为 $k\times k$ 的卷积，F_{s2} 表示第二条细节信息分支的输出，$Down$ 表示下采样运算，$FDCU$ 表示第二个分解扩张卷积模块，F_3 表示第二个分解扩张卷积模块的输出。

第二个分解扩张卷积模块后放置了第三个细节信息分支及第二个下采样模块，下采样之后紧跟着进行密集连接的三分支分解扩张卷积模块，分别可以表示为：

$$F_{s3} = C_{1\times1}(SAB(F_3)) \tag{4.35}$$

$$F_4 = TDCU(Down(F_3)) \tag{4.36}$$

其中，F_3 表示第二个分解扩张卷积模块的输出，SAB 表示空间注意力模块，$C_{k\times k}$ 表示卷积核大小为 $k\times k$ 的卷积，F_{s3} 表示第三条细节信息分支的输出，$Down$ 表示下采样运算，$TDCU$ 表示进行密集连接的三分支分解扩张卷积模块，F_4 表示进行密集连接的三分支分解扩张卷积模块的输出。

解码器部分包括两个上采样模块及两个扩张率分别为 2，1，分解扩张卷积单元个数均为 2 的分解扩张卷积模块及最后的分类器。三条细节信息分支依次与第三个分解扩张卷积模块的输出、第四个分解扩张卷积模块的输出及第二次信息融合的输出相连。解码器部分的运算过程依次可以表示为：

$$F_5 = F_{s3} + FDCU(Up(F_4)) \tag{4.37}$$

$$F_6 = F_{s2} + FDCU(Up(F_5)) \tag{4.38}$$

$$F_{out} = Clssifier(F_{s1} + F_6) \tag{4.39}$$

其中，F_4 表示进行密集连接的三分支分解扩张卷积模块的输出，F_5 表示第三个分解扩张卷积模块的输出，F_6 表示第四个分解扩张卷积模块的输出，F_{s3} 表示第三条细节信息分支的输出，F_{s2} 表示第二条细节信息分支的输出，F_{s1} 表示第一条细节信息分支的输出，Up 表示上采样运算，$FDCU$ 表示分解扩张卷积模块，$Classifier$ 表示分类器，F_{out} 是整个网络最终输出的全分辨率分割结果图。

4.3 实验设计与结果分析

4.3.1 数据集

在两个常用的道路场景数据集 Cityscapes 和 Camvid 上对 EMCANet 进行训练和测试。

4.3.2 参数设置

EMCANet 采用 Pytorch 框架进行网络模型的搭建，采用单张 RTX2080Ti GPU 来训练和测试，CUDA 的型号为 11.1，训练过程中采用的损失函数为交叉熵损失函数。在 Cityscapes 数据集上，使用动量为 0.9 的随机梯度下降法（Stochastic Gradient Descent, SGD）来训练，权重衰减率为1×10^{-4}，初始学习率为4.5×10^{-2}，采用 Poly 学习率变化策略，epoch 数量设置为 1000，批处理大小设定为 8。在 Camvid 数据集上，采用动量为 0.9 的 Adam 算法来训练，权重衰减值定为2×10^{-4}，设定初始学习率为1×10^{-3}，同样采用 Poly 学习率变化策略，epoch 数量设置为 1000，批处理大小设定为 8。

表 4.1 细节信息分支对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
EMCANet(w/o SAB and Conv1×1)	69.8%	0.76M	83.3
EMCANet	71.9%	0.78M	78.7

表 4.2 TDCU 中特征交互对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
TDCU(w/o feature fusion)	70.5%	0.78M	80.1
EMCANet	71.9%	0.78M	78.7

4.3.3 消融实验

（1）细节信息分支

EMCANet 中包含了三条细节信息分支，连接了编码器部分的细节信息至解码器同分辨率的位置，可以弥补在语义信息提取过程中损失的空间信息，实现更加精准地分割。为了验证这三条细节信息分支在网络中所起到的效果，去除网络中细节信息分支部分，并保持网络的其他部分不变，观察网络各方面性能的变化，实验结果如表 4.1 所示（其中，EMCANet(w/o SAB and Conv1×1)表示不包含细节信息分支的网络）。

从表 4.1 可以看出，当网络中没有了三条细节信息分支时，其网络运行速度会增大 4.6FPS，参数量也会减小 0.02M，但是分割的精度会大幅下降，降低了 2.1%mIoU 之多，总得看来，用大幅的精度损失换取微量的速度提升和参数降低是得不偿失的，故失去细节信息分支的网络与带细节分支的 EMCANet 相比起来，其综合性能较差。

（2）TDCU 中的特征交互

TDCU 中在 3×1 和 1×3 这两个分解卷积之间进行了相互连结的特征交互，以实现多尺度特征的充分融合，三条扩张率不同的卷积分支提取到的特征可以相互补充，使得彼此的空间信息更加丰富，提取到的语义信息更加高级抽象。为了证明 TDCU 中特征交互的有效性，将其特征交互部分移除，每个 3×1 卷积只和与自己扩张率相同的 1×3 卷积连接，观察其对于 EMCANet 性能的影响，实验结果如表 4.2 所示（其中，TDCU(w/o feature fusion)表示 TDCU 中不带特征交互的 EMCANet）。

观察表 4.2 可知，当 TDCU 中不带特征交互操作时，网络结构的大小保持不变，推理速度也相差不大，只比我们的 EMCANet 快了 1.4FPS，但是分割准确度却相差较大，有 1.4%mIoU 之差，足以造成图像中精细物体的语义类别判断错误，因此，在网络速度提升并不明显的情况下，TDCU 中带特征交互操作的 EMCANet 是最优选择。

（3）TDCU 中卷积的扩张率

EMCANet 中将 TDCU 中三条分支分解卷积扩张率依次设置为 2，5，9，为了证明该分解

表 4.3 TDCU 中卷积扩张率对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
r=2,4,8	71.8%	0.78M	84.9
r=3,5,7	71.7%	0.78M	76.6
EMCANet(r=2,5,9)	71.9%	0.78M	78.7

表 4.4 分解扩张卷积模块扩张率对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
R=1,1,1,1	71.4%	0.78M	98.5
R=2,2,2,2	70.8%	0.78M	69.3
EMCANet(R=1,2,2,1)	71.9%	0.78M	78.7

卷积扩张率设置的合理性，将其扩张率设置分别设置为 2 的幂次方即 2，4，8 及单数等差序列 3，5，7 进行对比，保持网络其他部分不变，观察扩张率对于网络各方面性能的影响，实验结果如表 4.3 所示（其中，r 表示 TDCU 中分解卷积的扩张率）。

从表 4.3 可以看出，当 TDCU 中三条分支分解卷积的扩张率分别设定为 2，4，8 和 3，5，7 及 2，5，9 时，网络结构的大小保持不变，只是扩张率为 2，4，8 时，网络推理速度会比我们的 EMCANet 快了 6.2FPS，但是却是以分割准确度为代价的，分割精度会下降 0.1%mIoU，而当扩张率为 3，5，7 时，网络的推理速度和分割精度都不能和我们的 EMCANet 相比，不但推理速度比 EMCANet 慢了 2.1FPS，精度也比 EMCANet 低了 0.2%mIoU，故经权衡后，我们发现采用分解卷积扩张率为 2，5，9 的 TDCU 作为 EMCANet 中的特征提取模块是可以实现网络最佳性能的方案。

（4）分解扩张卷积模块的扩张率

EMCANet 中共有四个分解扩张卷积模块，其扩张率分别为 1，2，2，1。第二个第三个分解卷积模块采用稍大一些的扩张率，主要目的在于提取更大接收域内的信息。为了证明该种扩张率方案的有效性，将这四个分解扩张卷积模块的扩张率分别设置为 1，1，1，1 和 2，2，2，2 进行对比实验，实验结果如表 4.4 所示（其中，R 表示分解扩张卷积模块的扩张率）。

从表 4.4 可以看出，分解扩张卷积模块的扩张率为 1，1，1，1 及 2，2，2，2 和 1，2，2，1 时，网络参数量都是相同的，差别仅在另外两个指标上。当其扩张率为 1，1，1，1 时，虽然网络运行速度比我们的 EMCANet(R=1,2,2,1)快了 19.8FPS，但是分割效果却比不上我们的 EMCANet，精度差了 0.5%mIoU，在微略的运行速度提升和较大幅度的精度下降情况下，我们选择了高精度的分割方案，即 EMCANet。而当分解扩张卷积模块的扩张率分别为 2，2，2，2 时，其网络运行速度比 EMCANet 慢了 9.4FPS，分割精度也比 EMCANet 低了 1.1%mIoU，其性能在 EMCANet 面前，没有任何竞争优势。故在对比之后，选择了扩张率分别为 1，2，2，1 的分解扩张卷积模块置入 EMCANet 中。

（5）密集连接

表 4.5 密集连接对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
EMCANet(w/o dense connection)	71.1%	0.74M	103.5
EMCANet	71.9%	0.78M	78.7

EMCANet 中第一个分解扩张卷积模块及三分支分解扩张卷积模块采用了密集连接的方式来进行连接，这种连接方式可以在不改变卷积核尺寸并保持网络模型大小不变的情况下，收集到多尺度的上下文信息。为了证实该种连接方式具有的高性能，在保持网络其他结构不变的情况下，移除上述两个特征提取模块中的密集连接，将其改为单向单分支的常规前向传播连接方式进行对比实验，实验结果如表 4.5 所示（其中，EMCANet(w/o dense connection)表示不包含任何密集连接的网络）。

根据表 4.5 可知，当 EMCANet 中第一个分解扩张卷积模块及三分支分解扩张卷积模块不采用密集连接方式时，其网络会比采用密集连接的网络小 0.05M，且模型的推理速度也比采用密集连接的网络快了 24.8FPS，只是分割的效果比不上 EMCANet，比 EMCANet 低了 0.8%mIoU。在轻微的网络缩小和推理增快前，较高的精度损失仍然是不容忽视的，故我们选择带密集连接的 EMCANet 作为最终网络。

4.3.4 与其他先进算法的比较

将 EMCANet 与一些主流的语义分割算法同时在单张硬件 NVIDIA RTX 2080Ti GPU 上进行训练，对其常见的三种性能评价指标：平均交并比（mIoU）、参数量（Parameters）及推理速度（Speed）等进行比较，评估各方法综合性能。

表 4.6 显示的是各语义分割算法在 Cityscapes 测试集上的结果，从中可以看出，CGNet[58]和 NDNet[59]在网络结构轻量化方面凭借着 0.5M 的微量参数占据了绝对优势，但是它们均存在着网络推理速度过慢的问题，CGNet[58]的推理速度仅为 EMCANet 的$\frac{1}{3}$，NDNet[59]的推理速度也比 EMCANet 慢了 1.9 倍之多，且它们的分割精度也不能与 EMCANet 相比，CGNet[58]的分割精确度仅能达到 64.8%mIoU，比 EMCANet 低了 7.1%mIoU，NDNet[59]的分割精确度为 65.3%mIoU，比 EMCANet 低了 6.6%mIoU。BCPNet[83]的网络推理速度是表中所有网路中最快的，达到了 250FPS，网络也比 EMCANet 小了 0.17M，但是在分割准确度方面，却凭借着 68.4%mIoU，远低于 EMCANet 至 3.5%mIoU。显然，EMCANet 在考虑上述三种指标的情况下，实现了各方面性能的良好权衡。图 4.4 显示的是各算法在 Cityscapes 验证集上的分割结果图，包括 EMCANet、ERFNet[62]、ESPNet[57]、LEDNet[69]和 DABNet[66]。从图中可以看出，EMCANet 在交通信号灯和栅栏等精细物体的分割上，展现出了明显的分割优势。

表 4.6 Cityscapes 测试集上预测结果对比

Method	Pretrain	Input Size	mIoU（%）↑	Params（M）↓	Speed（FPS）↑
SQNet[80]	-	1024×2048	59.8	-	17
CGNet[58]	No	1024×2048	64.8	**0.50**	24.9
NDNet[59]	No	1024×2048	65.3	**0.50**	40
ESPNetv2[81]	-	512×1024	66.2	-	80
EDANet[61]	No	512×1024	67.3	0.68	109.9
ADSCNet[82]	-		67.5	-	77
ERFNet[62]	No	512×1024	68.0	2.10	68
Fast-SCNN[63]	-	1024×2048	68.0	1.11	124
BiseNet[64]	ImageNet	768×1536	68.4	5.80	106
BCPNet[83]	-	512×1024	68.4	0.61	**250**
ICNet[65]	ImageNet	1024×2048	69.5	7.80	15.4
DABNet[66]	No	1024×2048	70.1	0.76	21.0
FarSeeNet[67]	-	512×1024	70.2	-	69
DFANet[68]	ImageNet	512×1024	70.3	7.80	100.0
LEDNet[69]	No	512×1024	70.6	0.95	57.1
CFSNet(第三章)	No	512×1024	71.5	0.69	76.9
EMCANet(本章)	No	512×1024	**71.9**	0.78	78.7

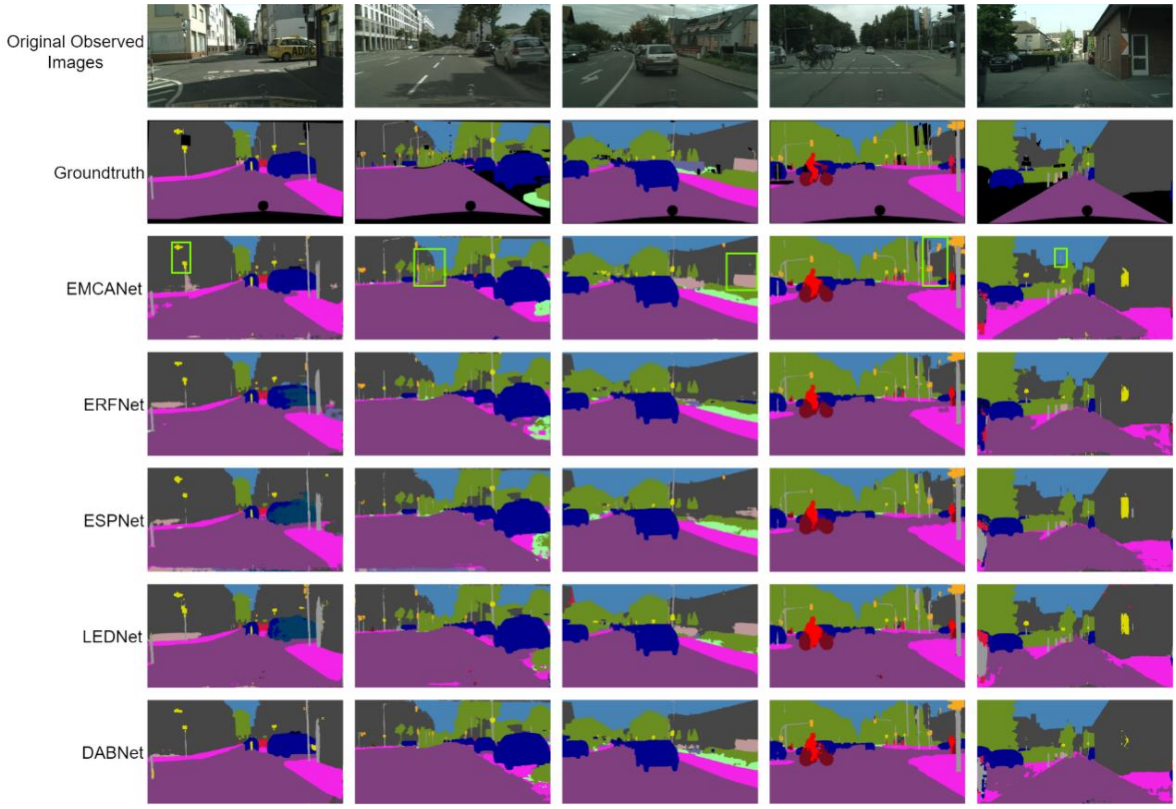

图 4.4 Cityscapes 验证集上预测结果对比图（自上向下依次为原始观察图像、真值、及 EMCANet、ERFNet[62]、ESPNet[57]、LEDNet[69]和 DABNet[66]的预测结果图）

表 4.7 显示的是各语义分割算法在 Camvid 测试集上的结果，可以看出，网络结构最小的是 FBSNet[72]，仅有 0.62M，但是它的分割精度却比我们的 EMCANet 低了 0.5%mIoU。推理速度最快的网络是 DFANet[68]，它可以达到 120FPS 的推理速度，但它不但在分割精度方面

表 4.7 Camvid 测试集上预测结果对比

Method	Pretrain	Input Size	mIoU(%)↑	Params(M)↓	Speed(FPS)↑
SegNet[36]	ImageNet	360×480	55.6	29.50	-
FCN-8s[34]	ImageNet	-	57.0	134.50	-
Dilation8[74]	ImageNet	-	65.3	140.80	-
EDANet[61]	No	360×480	66.4	0.68	110.3
ICNet[65]	ImageNet	720×960	67.1	7.80	27.8
DABNet[66]	No	360×480	66.4	0.76	97.8
DFANet[68]	ImageNet	720×960	64.7	7.80	**120.0**
LEDNet[69]	No	360×480	66.6	0.95	61.1
AGLNet[70]	ImageNet	360×480	**69.4**	1.10	90.1
MSCFNet[71]	No	360×480	69.3	1.15	-
FBSNet[72]	No	360×480	68.9	**0.62**	-
CFSNet(第三章)	No	360×480	68.8	0.69	88.9
EMCANet(本章)	No	360×480	**69.4**	0.78	85.4

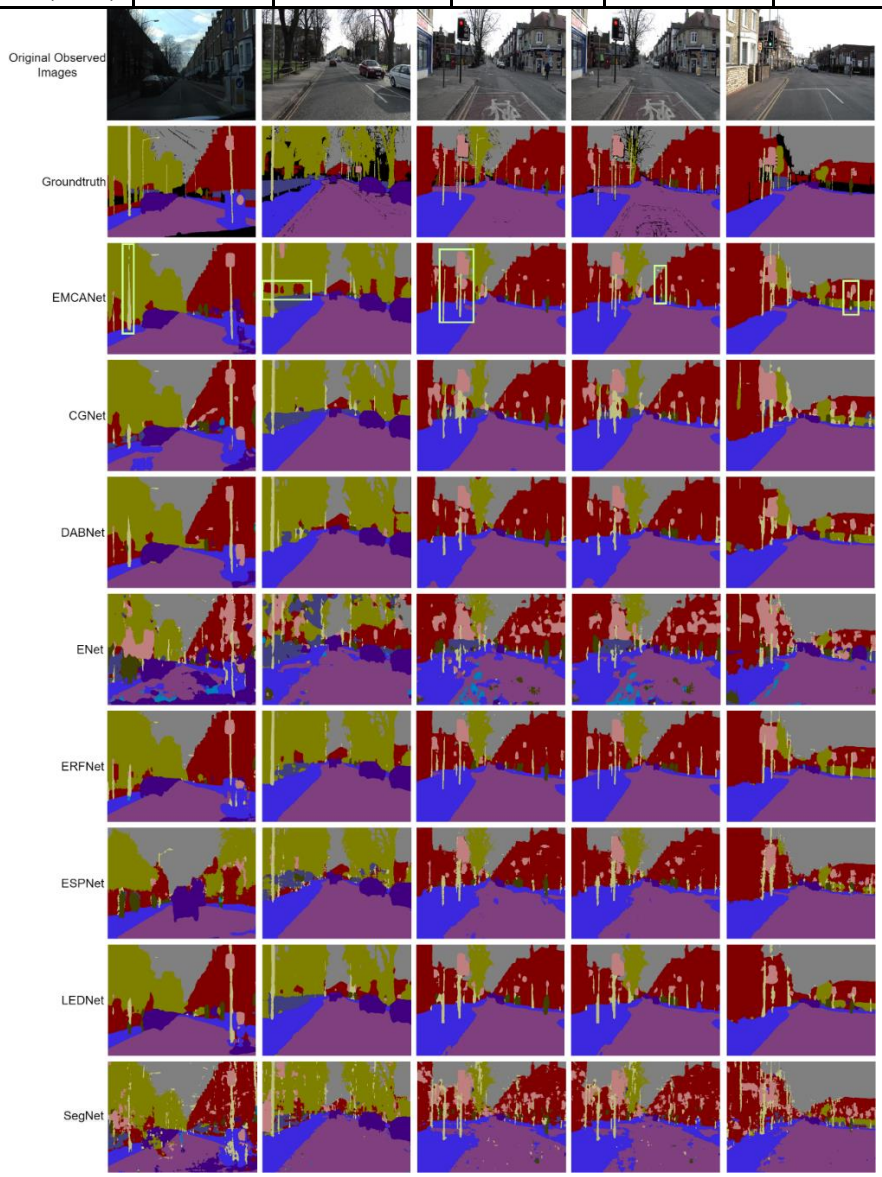

图 4.5 Camvid 测试集上预测结果对比图（自上向下依次为原始观察图像、真值、及 EMCANet、CGNet[58]、DABNet[66]、ENet[55]、ERFNet[62]、ESPNet[58]、LEDNet[69]和 SegNet[36]的预测结果图）

比 EMCANet 低 4.7%，其网络结构更是 EMCANet 的十倍之大。在分割准确度方面，表现最好的是 AGLNet[70]和 EMCANet，但是 AGLNet[70]的网络比 EMCANet 大了 0.32M，网络运行速度也比 EMCANet 慢了 4.7FPS。尽管 CFSNet 在 Camvid 数据集上网络运行速度比 EMCANet 快了 3.5FPS，参数量少了 0.09M，但是分割精度比 EMCANet 低了 0.6%mIoU，在 Cityscapes 数据集上，EMACNet 在分割精度和网络运行速度方面，表现也更好。故总得说来，EMCANet 在众多语义分割算法中，和 CFSNet 势均力敌，能够实现各方面性能的良好平衡。

图 4.5 显示的是各算法在 Camvid 验证集上的分割结果图，包括 EMCANet、CGNet[58]、DABNet[66]、ENet[55]、ERFNet[62]、ESPNet[58]、LEDNet[69]和 SegNet[36]。图中显示，EMCANet 能够实现路灯和交通信号灯的准确分割，这是其他分割算法所难以实现的。

4.4 本章小结

本章提出了一种高效的多尺度上下文轻量级聚合网络用于实时语义分割，名为 EMCANet。本章首先介绍了两种特征提取单元，分解扩张卷积单元和三分支分解扩张卷积单元，然后阐述了网络采用密集连接和三条细节信息分支的原因，最后阐述了 EMCANet 的整体网络架构，最后通过一系列的实验设计验证了 EMCANet 的有效性。EMCANet 中的密集连接在不增大网络规模的情况下，扩大了特征提取过程中的接收域，并且能够实现多尺度的特征提取，而细节信息分支能够补充在提取高级抽象语义信息过程中所损失的空间信息。实验结果表明，EMCANet 能够在满足轻量化的定义下，实现运算效率和分割精度的良好平衡，达成了预期要求，特别是在道路场景分割数据集 Cityscapes 和 Camvid 上都显示出了其卓越的性能。

第五章 基于 CNN 和 Transformer 的高效实时语义分割网络

5.1 引言

现阶段，基于卷积神经网络的语义分割方法层现叠出，已经取得了显著的研究成果，但是这些方法仍然存在着网络庞大或者计算资源消耗大的问题，很多难以应用到现实硬件设备中，如何在保持分割精度的同时，有效地缩小网络和节约计算资源已经成为语义分割领域的新兴研究方向。现有的语义分割方法大多数基于全卷积神经网络，分为编码器和解码器两个部分。编码器的作用在于提取图像特征，解码器的作用在于对提取到的特征进行逐像素的分类。编码器部分是整个网络中的核心部分，由多层卷积累加而成，其中的下采样操作，可以降低图像的分辨率，使得网络获取到大接收域内的语义信息。全卷积神经网络用于语义分割的优势在于可以实现的跨空间共享，从而保持网络的简易型，其劣势在于接收域受限，不能对远程依赖关系进行建模，因而无法提取到全局语义信息。于是，研究者们提出了扩张卷积[44][74]、空间金字塔[84]等方法来增大接收域，还有很多学者在全卷积网络中引入了各种注意力机制来学习全局特征，但是会耗费过多计算资源。近些年来，Transformer[85]注意力机制逐渐流行起来，它可以建模全局任意位置之间的远程依赖关系，并且在经过规模很大的预训练之后，模型能够获得优异成果。但是在图像处理领域中，Transformer[85]的计算复杂度与图像大小呈现平方关系，且切片式的图像输入方式，使得它无法对局部结构进行关联，不能定位低分辨率图像。然而，卷积神经网络能够很好地提取到低分辨率图像的信息，对空间信息进行很好地保留。故如何将 Transformer[85]与 CNN 相结合，设计出模型小、速度快、性能高的轻量级实时语义分割网络成为了学者们炙手可热的问题。本章基于 CNN 和 Transformer[85]的基本框架，设计出了一个高效的实时语义分割网络 EBSSNet（Efficient Bilateral Semantic Segmentation Network），它所具备的创新点主要包括以下三点：

（1）提出了一种新的卷积特征提取单元，名为双边特征提取单元（Bilateral Feature Extraction Unit, BFEU）。BFEU 采用了双分支的特征提取结构，左边的分支采用的是逐深度分解卷积，右边的分支采用的是逐深度分解扩张卷积，并且两条分支采用了特征融合操作，以实现信息共享。

（2）EBSSNet 中基于编码-解码结构，并且引入了 Transformer[85]注意力机制，在 Transformer[85]模块前后各放置了一个卷积核大小为1×1的卷积，用来进行通道数的变换，Transformer[85]注意力机制被放置在了编码器和解码器中间，以学习全局特征。输入图像由

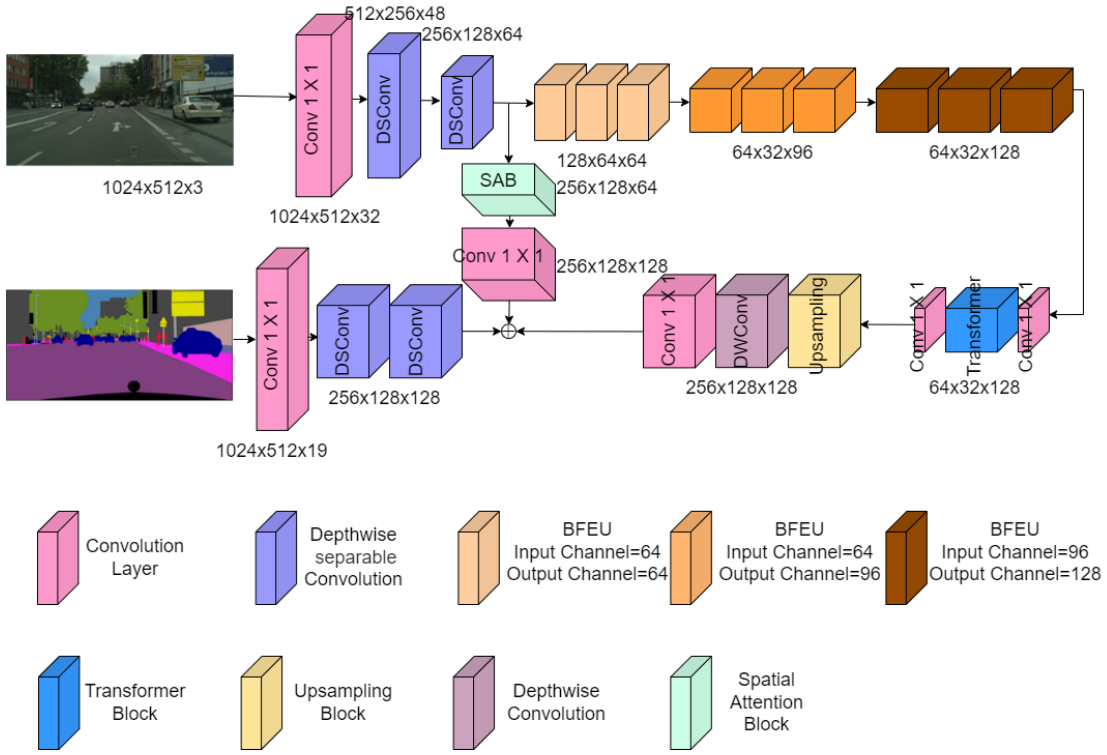

图 5.1 EBSSNet 网络结构图

CNN 进行特征提取，而后特征图被转换为序列，由 Transformer[85]建模全局特征，建模后的嵌入特征被输入解码器中以生成原始分辨率大小的分割结果图。

（3）采用单张 RTX3090Ti GPU 对 EBSSNet 进行训练，其参数量仅为 0.76M，却能够在 Cityscapes 数据集上以 81.6FPS 的推理速度，获得 71.6%mIoU 的分割精度，在 Camvid 数据集上的推理速度达到了 90.5FPS，分割精度达到了 69.0%mIoU，表现出了其优异的性能。

5.2 基于 CNN 和 Transformer 的高效实时语义分割网络

5.2.1 双边特征提取单元

双边特征提取单元（Bilateral Feature Extraction Unit, BFEU）整体上采用了残差结构，可以在保持网络大小不变的同时，收集到更多的上下文信息，其结构图如图 5.2 所示。特征图进入 BFEU 后，先采用一个卷积核大小为3×3的标准卷积，对其进行初步特征提取，同时缩减通道的数目，将其变为原通道数的$\frac{1}{2}$，以减少该单元所需计算量及参数量。然后左边分支采用了3×1的逐深度分解卷积，用于收集本地信息，右边分支采用的是3×1的逐深度分解扩张卷积，用于收集大接收域内的上下文信息。而后，两条分支采用 *add* 运算进行特征融合，目的是为了实现特征共享，使得局部信息与上下文信息互相补充。特征融合之后，左边分支使用1×3逐深度分解卷积继续进行本地信息的特征提取，右边分支使用1×3逐深度分解扩张卷积继续进

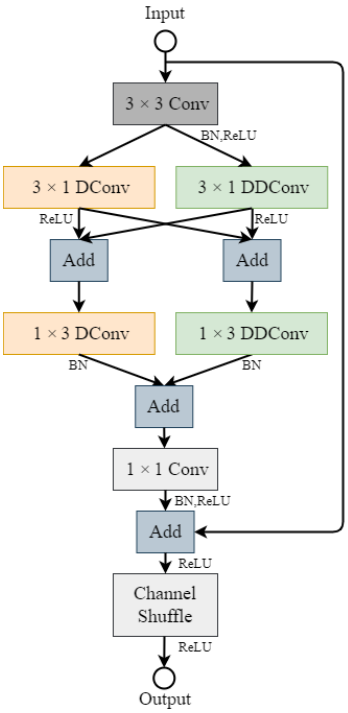

图 5.2 双边特征提取单元（BFEU）结构图

行上下文信息的特征提取。接着，两条分支提取到的特征进行相加操作后，送入逐点卷积进行运算，以实现通道信息的充分融合。BFEU 的尾部包含了一个通道混洗运算，可以很好地避免通道间信息彼此孤立的现象出现，增强通道间语义信息的共享。上述一系列操作可以表示：

$$y_1 = C_{1\times3}(C_{3\times1}(C_{3\times3}(x_{BFEUin})) + C_{3\times1,r}(C_{3\times3}(x_{BFEUin}))) \tag{5.1}$$

$$y_2 = C_{1\times3,r}(C_{3\times1}(C_{3\times3}(x_{BFEUin})) + C_{3\times1,r}(C_{3\times3}(x_{BFEUin}))) \tag{5.2}$$

$$y_{BFEUout} = T_{shuffle}(C_{1\times1}(y_1 + y_2) + x_{BFEUin}) \tag{5.3}$$

其中，x_{BEFUin} 表示 BEFU 的输入，$C_{m\times n}$ 表示卷积核大小为 $m\times n$ 的卷积，$C_{m\times n,r}$ 表示卷积核大小为 $m\times n$，扩张率为 r 的扩张卷积，y_1 和 y_2 分别表示左右两条卷积分支的输出，$T_{shuffle}$ 表示通道混洗运算，$y_{BEFUout}$ 表示 BEFU 的输出。

5.2.2 Transformer 注意力机制

Transformer 注意力机制基于自我关注的原理，目前是自然语言处理领域中的最佳结构。而后众多学者们慢慢将其引入至模式识别研究方向中。它能够很好地提取输入图像的全局特征，然而若只采用 Transformer 处理图像的话，会损失图像大量的本地细粒度细节信息，因此如何将 CNN 和 Transformer 结合起来进行图像处理，成为目前图像处理领域中亟待解决的最新问题。

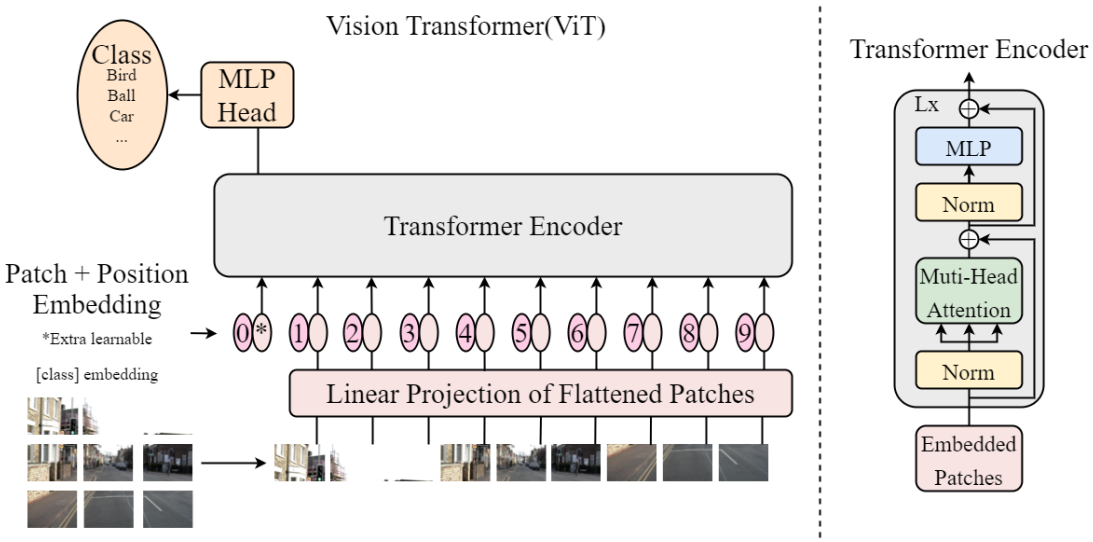

图 5.3 Vision Tranformer（ViT）结构图

谷歌在 2020 年创新出了 Transformer 应用于图像分类中的模型，称为 ViT(Vision Tranformer)[89]，其结构图如图 5.3 所示。ViT 包括了 Linear Projection、Transformer Encoder 及 MLP Head 三个组成部分。Transformer 模块规定了其输入格式必须为二维矩阵 token，而能够实现图像转换成这种格式的是 Linear Projection，即 Embedding 层，由连续的卷积层组成，负责将输入图像切割成指定大小的 Patches。Linear Projection 卷积层的输出 token 再加上 class token 和 Position Embedding，就可以输入至 Transformer Encoder 进行处理了。Transformer Encoder 由 Layer Norm、Multi-Head Attention、Dropout/DropPath 及 MLP 四部分组成，重复堆叠了多个 Encoder Block。MLP Head 可以由 Linear、tanh 激活函数和 Linear 组成，也可以仅仅包含 Linear 这一个部分，其作用在于从众多 token 中抽取出 class token，得到最终所需的分类结果。

5.2.3 整体网络架构设计

EBSSNet 整体上采用的是编码-解码结构，用到了标准卷积、深度方向可分离卷积、由双边特征提取单元组成的双边特征提取模块、Transformer 模块、上采样模块和逐深度卷积等，其网络结构图如图 5.1 所示，主干网络中各部分具体信息如表 5.1 所示。与 EMCANet 相同，EBSSNet 中也加入了细节信息分支。输入图像先采用逐点卷积，然后采用两个连续的卷积核大小为3×3，步长为 2 的深度方向可分离卷积，得到特征图的分辨率为输入图像的$\frac{1}{4}$。编码器中共包含了三个由 BFEU 组成的双边特征提取模块，每个双边特征提取模块中均包含三个 BFEU，第一个双边特征提取模块中每个 BFEU 最后的逐点卷积输出通道数设置为 64，第二个双边特征提取模块中每个 BFEU 最后的逐点卷积输出通道数设置为 96，第三个双边特征提

表 5.1 EBSSNet 主干网络中各部分具体信息（其中，Conv2D 表示标准卷积，DSConv 表示深度方向可分离卷积，Upsampling 表示上采样，DWConv 表示逐深度卷积，c 表示输出通道数，n 表示卷积核尺寸，s 表示第一个卷积单元中卷积的步长）

Input	Block	c	n	s
1024×512×3	Conv2D	32	1	1
1024×512×32	DSConv	48	3	2
512×256×48	DSConv	64	3	2
256×128×64	BFEU	64	-	2
128×64×64	BFEU	96	-	2
64×32×96	BFEU	128	-	1
64×32×128	Conv2D	16	1	1
64×32×16	Transformer	16	-	-
64×32×16	Conv2D	128	1	1
64×32×128	Upsampling	128	3	-
256×128×128	DWConv	128	3	1
256×128×128	Conv2D	128	1	1
256×128×128	DSConv	128	3	1
256×128×128	DSConv	128	3	1
256×128×128	Conv2D	19	1	1

取模块中每个 BFEU 最后的逐点卷积输出通道数设置为 128。且第一个双边特征提取模块中的第一个 BFEU 中所有的卷积步长均设置为 2，这样在进行语义信息提取的同时，也将图像分辨率降至原始图像的$\frac{1}{8}$，第二个双边特征提取模块中的第一个 BFEU 中所有的卷积步长也都设置为 2，得到特征图的分辨率为原始图像的$\frac{1}{16}$，这样的设计能够在保持网络结构是轻量型的同时，收集到尽可能大的感受野内的信息。最后的双边特征提取模块进一步提取高级抽象信息后，将所得特征图先采用逐点卷积进行通道数的缩减，以减轻 Transformer 模块的计算负担，然后送入 Transformer 模块进行图像全局特征的建模，建模后的特征图采用逐点卷积将其通道数进行二次变换，以恢复成原始通道的数目。

与 CFSNet 和 EMCANet 不同，EBSSNet 的解码器与编码器呈现出的是一种非对称的关系。EBSSNet 解码器的首端是上采样运算，可以对特征图进行 4 倍的上采样，分类器部分对特征图又进行了 4 倍的上采样，这样可确保分割结果图与原始图像保持相同分辨率。现有的语义分割模型，其上采样方法分为两种，一种是逐步进行 2 倍的上采样，另一种是直接上采样到原始分辨率大小，而 EBSSNet 所采用的这种将上采样运算拆解为两部分的方法，兼具了上述两种上采样方法的优势，能够在不增加计算负担的情况下，最大限度地恢复图像空间信息。解码器部分，对特征图进行 4 倍上采样之后，分别采用了卷积核大小为3×3的逐深度卷积和一个逐点卷积对特征图进行处理，如此简单的卷积添加可以确保网络的运行效率。EBSSNet 中包含了一条细节信息分支，与 EMACNet 相同，该细节信息分支由一个空间注意

力模块和一个逐点卷积组成，细节信息分支的设置可以弥补网络在提取高级语义信息时所造成的空间信息的损失。该细节信息分支的输出与逐点卷积的输出采用了简单相加的方式进行融合，融合后的特征图将被送入分类器进行处理。我们发现，在特征融合之后加入少量卷积层，可以提高分割的准确性，于是将 EBSSNet 的分类器设置成了三个卷积层，前两个卷积层均为深度方向可分离卷积，最后一个卷积层就是卷积核大小为1×1的反卷积，其输出为与原始图像分辨率大小相同的分割结果图。

5.3 实验设计与结果分析

5.3.1 数据集

采用 Cityscapes 数据集和 Camvid 数据集对 EBSSNet 进行训练和测试。

5.3.2 参数设置

本章 EBSSNet 的搭建基于 Pytorch 框架，依赖硬件平台 RTX3090Ti GPU，CUDA 型号为 11.1。为了减少网络计算量和内存使用，训练预处理过程中，将 Cityscapes 和 Camvid 数据集的图片分别裁剪至512×1024和360×480大小，测试时用原始分辨率大小图片。两个数据集中的图片在训练前期，用均值及方差法实施归一化，还需要使用随机翻转及 0.5-2.0 之间尺度变换进行数据增强。训练时，两个数据集采用损失函数均为交叉熵损失函数，学习率变化策略均为“Poly”变化策略，均用 1000 个 epoch 来进行训练。学习率可通过以下方式计算获得：

$$lr = lr_{initial} \times (1 - \frac{iteration}{iteration_{\max}})^{power} \tag{5.4}$$

其中，$lr_{initial}$表示起始学习率大小，$iteration$表示目前迭代次数序号，$iteration_{\max}$表示 epoch 里最大的迭代数，且设定$power = 0.9$，在 Cityscapes 数据集上进行训练时，令$lr_{initial} = 4.5\times10^{-2}$，在 Camvid 数据集上进行训练时，令$lr_{initial} = 1\times10^{-3}$。且对于 Cityscapes 数据集，采用随机梯度下降法（Stochastic Gradient Descent, SGD）进行训练，权重衰减值为1×10^{-4}，批处理大小设为 6。对于 Camvid 数据集，采用 Adam 法进行训练，权重衰减值为2×10^{-4}，批处理大小设为 8。

表 5.2 通道混洗对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
EBSSNet(w/o Channel Shuffle)	71.5%	0.76M	82.0
EBSSNet	71.6%	0.76M	81.6

表 5.3 Transformer 对于网络性能的影响

Model	mIoU(%)	Params(M)	Speed(FPS)
EBSSNet(w/o Transformer)	68.9%	0.74M	92.2
EBSSNet	71.6%	0.76M	81.6

5.3.3 消融实验

（1）通道混洗操作

相比于 CFSNet 及 EMCANet 的特征提取单元，EBSSNet 的特征提取单元中加入了通道混洗操作，以防止出现通道间信息互相孤立的现象，实现通道信息的共享。为了证实通道混洗操作的有效性，将移除了通道混洗操作的 BFEU 置入网络中，并对此网络进行训练和测试，将最终的测试结果与我们的 EBSSNet 测试结果进行对比，对比结果如表 5.2 所示。

表 5.2 显示，当 EBSSNet 中的 BFEU 包含通道混洗操作时，能够在保持网络大小不变，推理速度仅下降 0.4FPS 的情况下，实现 0.1%mIoU 的分割精度提升，足以说明通道混洗操作能够以微乎其微的速度下降换取网络性能增长。

（2）Transformer 注意力模块

为了验证 Transformer 能够建模图像的全局特征，实现网络性能的提升，将网络中的 Transformer 注意力模块移除，并同时移除其前后两个用于进行通道变换的逐点卷积，在 Cityscapes 数据集上进行实验，将其分割效果与含有 Transformer 注意力模块的 EBSSNet 进行对比，评估 Transformer 的有效性，实验结果如表 5.3 所示。

从表 5.3 可以看出，在网络中加入 Transformer 注意力模块后，参数量增加了 0.02M，运行速度低了 10.6FPS，但是却可以实现 2.7%mIoU 的分割精度增长，证实了 Transformer 注意力机制对于全局上下文信息的提取是非常有效的，能够高效实现网络性能的提升。

5.3.4 实验结果对比与分析

表 5.4 显示了 DABNet[66]、FBSNet[72]、MSCFNet[71]及第三章提出的 CFSNet、第四章提出的 EMCANet 和本章的 EBSSNet 在 Cityscapes 测试集上的预测结果，从表中可以看出，计算量最小的是 FBSNet[72]，仅为 9.7G，其网络参数量也是其中最小的，运行速度也是其中最快

表 5.4 Cityscapes 测试集上预测结果对比

Method	Pretrain	Input Size	GPU	FLOPs(G)↓	mIoU(%)↑	Params(M)↓	Speed(FPS)↑
DABNet[66]	No	2048×1024	RTX1080Ti	-	70.1	0.76	27.7
FBSNet[72]	No	1024×512	RTX2080Ti	**9.70**	70.9	**0.62**	**90**
MSCFNet[71]	No	1024×512	Titan XP	17.10	**71.9**	1.15	50
CFSNet (第三章)	No	1024×512	RTX2080Ti	13.5	71.5	0.69	76.9
EMCANet (第四章)	No	1024×512	RTX2080Ti	14.7	**71.9**	0.78	78.7
EBSSNet（本章）	No	1024×512	RTX3090Ti	15.2	71.6	0.76	81.6

表 5.5 Camvid 测试集上预测结果对比

Method	Pretrain	Input Size	mIoU(%)↑	Params(M)↓	Speed(FPS)↑
DABNet[66]	No	480×360	66.4	0.76	**97.8**
FBSNet[72]	No	480×360	68.9	**0.62**	-
MSCFNet[71]	No	480×360	69.3	1.15	-
CFSNet(第三章)	No	480×360	68.8	0.69	88.9
EMCANet(第四章)	No	480×360	**69.4**	0.78	85.4
EBSSNet（本章）	No	480×360	69.0	0.76	90.5

的，但是其分割精度比 EBSSNet 低了 0.7%mIoU，这足以产生效果明显不同的分割结果图。MSCFNet[71]的分割精度和 EMCANet 的分割精度是其中最高的，但是 MSCFNet[71]的计算量是所有网络中最大的，比 EBSSNet 大了 1.9G，网络参数量也比 EBSSNet 多了 0.39M，网络推理速度也远不及 EBSSNet，相差了 31.6FPS 之多。

在第三章提出的 CFSNet、第四章提出的 EMCANet 和本章的 EBSSNet 这三种网络中，CFSNet 在分割准确度和网络推理速度方面都不占优势，但是它的计算量最小，只有 13.5G，网络结构也最小，仅有 0.69M，是最符合轻量化定义的分割模型。EMCANet 的计算量和网络推理速度均介于 CFSNet 和 EBSSNet 之间，但是在 Cityscapes 上能够获得最精确的分割结果，分割精确度高达 71.9%mIoU，是分割性能最好的模型。EBSSNet 因为融入了 Transformer 注意力机制，故计算量较大，但是计算量也仅超出 CFSNet1.7G，参数量介于 CFSNet 与 EMCANet 之间，仅仅比 CFSNet 多了 0.07M 而已，在 GPU 为 RTX3090Ti 的情况下，其推理速度能够达到 81.6FPS，其分割精确度也能够达到 71.6%mIoU，足以获得精确的分割效果图。

表 5.5 显示了 DABNet[66]、FBSNet[72]、MSCFNet[71]及第三章提出的 CFSNet、第四章提出的 EMCANet 和本章的 EBSSNet 在 Camvid 测试集上的预测结果，从表中可以看出，网络参数量最小的是 FBSNet[72]，但是其分割精度比 EBSSNet 低了 0.1%mIoU，在以精度为导向的实时分割中，EBSSNet 更加适用。网络推理速度最快的是 DABNet[66]，可以达到 97.8FPS，它在网络参数量与 EBSSNet 相同的情况下，运算速度比 EBSSNet 高了 7.3FPS，但是分割精度却

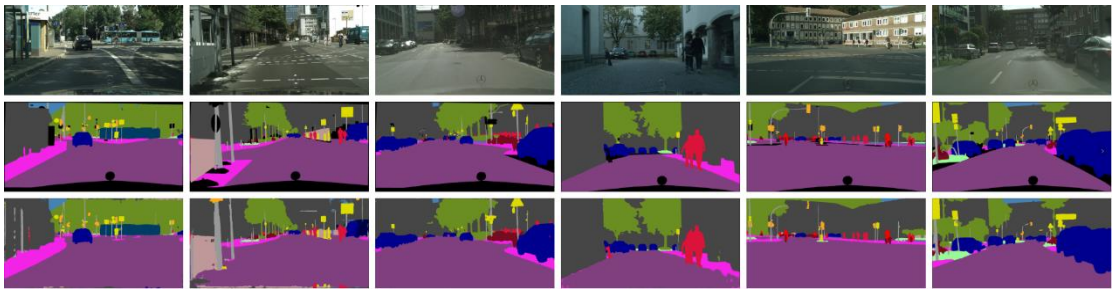

图 5.4 EBSSNet 在 Cityscapes 验证集上预测结果图（自上向下依次为原始观察图像、真值及 EBSSNet 的预测结果图）

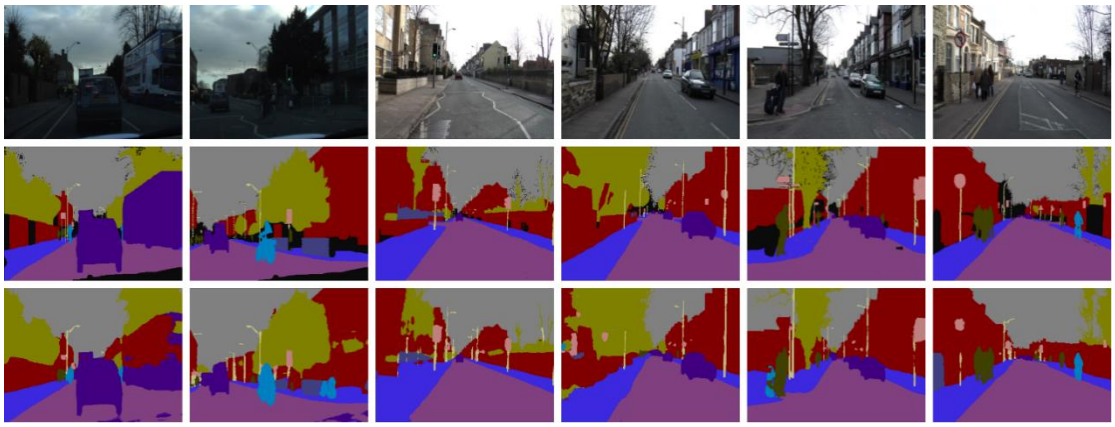

图 5.5 EBSSNet 在 Camvid 测试集上预测结果图（自上向下依次为原始观察图像、真值及 EBSSNet 的预测结果图）

比 EBSSNet 低了 3.6%mIoU，故 EBSSNet 在运算速度和分割精度之间的平衡能力更强。

在 CFSNet、EMCANet 和 EBSSNet 这三个网络中，CFSNet 参数量最小，仅为 0.69M，EMCANet 分割精度最高，达到 69.4%mIoU。而 EBSSNet 推理速度是三者中最快的，为 90.5FPS，其分割精度介于 CFSNet 和 EMCANet 之间，仅仅比 EMCANet 低了 0.4%mIoU。

通过以上分析，可以得出在 Cityscapes 和 Camvid 数据集上，EBSSNet 均能够实现参数量、推理速度和分割精度的完美权衡。

图 5.4 显示的是 EBSSNet 在 Cityscapes 验证集上的可视化分割效果，图 5.5 显示的是 EBSSNet 在 Camvid 测试集上的可视化分割效果，第一排均为原始观察图像，第二排均为真值，第三排均为 EBSSNet 的预测结果图。

5.4 本章小结

目前绝大多数的语义分割方法依赖的都是卷积神经网络作为基本框架，然而由于卷积的重心是卷积核内的像素，只能收集本地信息，不能注意到全局信息，故该种方法会导致图像远程上下文信息的缺失，Transformer 能够建模全局特征，能够很好地弥补只有卷积神经网络的语义分割方法的缺陷。基于这种考虑，本章提出了一种基于 CNN 和 Transformer 的高效实时语义分割网络，名为高效双边语义分割网络 EBSSNet。本章首先介绍了 EBSSNet 中的特征

提取单元-双边特征提取单元 BFEU 和计算机视觉领域大火的 Transformer 结构 ViT，然后阐述了 EBSSNet 整体网络架构，最后通过实验验证了 EBSSNet 有效性。在 Cityscapes 和 Camvid 这两个数据集上的实验结果表明，EBSSNet 能够在保持高效率，低运算成本的情况下，对图像实现精准分割。在与第三章的 CFSNet 及第四章的 EMCANet 的对比中，也显现出它特有优势。

第六章 总结与展望

6.1 总结

计算机视觉领域中的一个关键组成部分，就是图像语义分割，它需要对输入图像进行像素级别的分割，轻量级实时语义分割就是在一般语义分割的基础上，研究出可以在小存储量、计算资源受限的现实设备上快速得到推理结果的分割网络。文章的绪论部分先论述了轻量级实时语义分割网络的研究背景及意义，并且还介绍了一些传统图像分割方法和基于卷积神经网络的图像语义分割方法。虽然基于卷积神经网络的语义分割方法在近些年来取得了突破性的研究成果，但是如何设计出一种高效率、低运算成本、性能优越的语义分割网络仍然是该领域的重点及难点问题。针对以上问题，本文对轻量级实时语义分割方法进行了大量的研究和改进，设计了三种轻量级实时语义分割网络，并在 Cityscapes 和 Camvid 这两个常用的道路场景数据集上，对其进行了充分的实验，验证了它们卓越的性能。

（1）研究并提出了一种基于上下文聚合的实时语义分割网络 CFSNet。CFSNet 中包括了通道注意力机制、空间注意力机制、不对称卷积单元和多分支不对称卷积单元等，并基于不对称卷积单元搭建出了四个不对称卷积模块，基于多分支不对称卷积单元搭建了多分支不对称卷积模块，最后采用了对称的编码解码结构，利用空间注意力模块、上述两种特征提取模块及通道注意力模块，完成了网络的搭建。该网络将分辨率不同的原始图像分三次注入主干网络中，补充了网络的空间信息，实现了上下文信息的聚合。两种注意力机制的使用，能够在保持网络大小，耗费计算资源不变的情况下，有效提升网络性能。在两个基准数据集上的消融实验和对比实验表明，CFSNet 在参数量仅为 0.69M 的前提下，能够在 RTX2080Ti GPU 上，分别以 76.9FPS 和 88.9FPS 的速度推理 Cityscapes 和 Camvid 中的图像，且其分割精确度分别达到了 71.5%mIoU 和 68.8%mIoU，其表现超出了很多现有的轻量级语义分割网络。

（2）研究并提出了一种基于多尺度特征的上下文信息融合网络 EMCANet。EMCANet 在 CFSNet 的基础上，更关注空间信息的损耗和多尺度信息的收集，实现了分割精度的进一步提升。在设计过程 EMCANet 的过程中，首先构建了分解扩张卷积单元和三分支分解扩张卷积单元，然后基于这两个特征提取单元构建出了分解扩张卷积模块和三分支分解扩张卷积模块，第一个分解扩张卷积模块和三分支分解扩张卷积模块中融入了密集连接的连接方式，以在不增加网络参数量和计算量的同时，收集到多尺度的上下文信息，并且可以有效扩大卷积核的接收域。最后基于以上两种特征提取模块设计出了该网络。网络中还引入了三条细节信息分

支，主要作用在于弥补在编码过程中进行高级语义信息提取时所造成的空间信息的损失。基本卷积单元中用到了通道注意力机制，细节信息分支中用到了空间注意力机制，注意力机制的使用可以对本地特征的依赖关系进行建模。在两个基准数据集上的实验表明，EMCANet 能够很好地实现计算量、参数量、运行速度和分割准确度的平衡，它仅用到了 0.78M 的网络参数，却能够在 Cityscapes 数据集上以 78.7FPS 的速度进行图像推理，分割精度高达 71.9%mIoU，在 Camvid 数据集上以 85.4FPS 的速度进行图像推理，分割精度高达 69.4%mIoU。

（3）研究并提出了一种基于 CNN 和 Transformer 的高效实时语义分割网络 EBSSNet。考虑到 CNN 只能建模局部特征的依赖关系，而 Transformer 却可以对全局特征的依赖关系进行建模，故将二者结合以获得高性能的分割网络。在设计 EBSSNet 的过程中，首先提出了双边特征提取单元来进行基本特征提取，然后基于此单元，搭建了三个双边特征提取模块，结合 Transformer 注意力机制和细节信息分支后，精心设计了整体的网络结构。考虑到高分辨率图像采用 Transformer 处理时，会造成大量的计算负担，故采用 Transformer 对特征图处理前，先进行通道压缩，在特征图经过 Transformer 处理后，再恢复至原通道数。EBSSNet 的上采样过程分两步进行，可以在不增加计算负担的情况下，最大限度恢复图像细节信息，其分类器也与 CFSNet 和 EMCANet 不同，包含了三个卷积层，原因在于网络特征融合之后，加入卷积层，可以提高分割精确度。实验证实，EBSSNet 具有优越的性能，参数量仅为 0.76M，在单张 RTX3090Ti GPU 上，它在 Cityscapes 数据集上推理速度高达 81.6FPS，分割精度为 71.6%mIoU，在 Camvid 数据集上推理速度高达 90.5FPS，分割精度为 90.5%mIoU。

6.2 展望

本文着眼于语义分割的特定方向，即轻量级实时语义分割方向，并给出了自己的些许见解，提出了基于上下文聚合的实时语义分割网络、基于多尺度特征的上下文信息融合网络和基于 CNN 和 Transformer 的高效实时语义分割网络。大量的实验证实，这三种语义分割网络较其他语义分割网络而言，实现了大幅度的性能改进和提升。但是这些网络仍然存在一些有待优化和改进的地方：

（1）数据集方面。Cityscapes 和 Camvid 数据集是本文三种轻量级实时语义分割网络用到的唯二数据集，而且仅仅用到了这两个数据集中精细标注的训练集，因此当输入图像和数据集中的训练图片差别过大时，网络分割性能大幅下降。故可以采用半监督的方式或者无监督的方式，来提高网络泛化能力。

（2）网络改进方面。本文的三种语义分割网络，CFSNet 和 EMCANet 为纯卷积神经网

络，EBSSNet 为卷积神经网络与 Transformer 的融合，下一步可以将模式识别领域的一些其他先进算法如强化学习（Graph Networks）及生成对抗网络（Generative Adversarial Networks, GAN）等应用到网络中。

（3）实际应用方面。本文设计的三种轻量级实时语义分割网络均能够实现效率、网络大小和分割精度的完美平衡，但是并没有运用到实际场景中，下一步需要研究如何将这些网络与现实硬件设备相结合。

参考文献

[1] Lecun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.

[2] Kaymak Ç, Uçar A. A brief survey and an application of semantic image segmentation for autonomous driving[J]. Handbook of deep learning applications, 2019: 161-200.

[3] Minaee S, Boykov Y Y, Porikli F, et al. Image segmentation using deep learning: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021.

[4] Breiman L J M L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.

[5] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.

[6] Feily M, Shahrestani A, Ramadass S. A Survey of BotNet and BotNet Detection[C]// Thrid International Conference on Emerging Security Information, Systems and Technologies. IEEE Computer Society, 2009: 268-273.

[7] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]// Computer Vision and Pattern Recognition. IEEE, 2016: 770-778.

[8] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural Network[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc, 2012: 1097-1105.

[9] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2015: 1-9.

[10] Kanade T. A theory of Origami world [J]. Artificial Intelligence, 1980, 13(3): 279-311.

[11] Sermanet P, Eigen D, Zhang X, et al. OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks[J]. Eprint Arxiv, 2013.

[12] Lee H, Pham P T, Yan L, et al. Unsupervised feature learning for audio classification using convolutional deep belief networks[J]. Advances in Neural Information Processing Systems, 2009: 1096-1104.

[13] Fouhey D F, Gupta A, Hebert M. Data-Driven 3D Primitives for Single Image Understanding[C]// IEEE International Conference on Computer Vision. IEEE, 2013: 3392-3399.

[14] Schwing A G, Fidler S, Pollefeys M, et al. Box in the Box: Joint 3D Layout and Object Reasoning from Single Images[C]// IEEE International Conference on Computer Vision. IEEE, 2013: 353-360.

[15] Gupta A, Efros A A, Hebert M. Blocks World Revisited: Image Understanding Using Qualitative Geometry and Mechanics[C]// Computer Vision – ECCV 2010. Springer Berlin Heidelberg, 2010: 482-496.

[16] Huffman D A. Impossible objects as nonsense sentences[J]. Machine intelligence, 1971, 6(1): 295-323.

[17] Zhang Y, Song S, Tan P, et al. PanoContext: A whole-room 3D context model for panoramic scene understanding[C]// Computer Vision–ECCV 2014. Springer International Publishing, 2014: 668-686.

[18] Gupta A, Hebert M, Kanade T, et al. Estimating spatial layout of rooms using volumetric reasoning about objects and surfaces[J]. Advances in Neural Information Processing Systems, 2010: 1288-1296.

[19] Haralick R M, Shapiro L G. Image segmentation techniques[J]. Computer vision, graphics, and Pattern Recognition, 2013: 564-571.

[20] Wang H Y, Pan D L, Xia D S. A Fast Algorithm for Two-dimensional Otsu Adaptive Threshold Algorithm[J]. ACTA AUTOMATICA SINICA, 2005, 33(9):969-970.

[21] 曹力, 史忠科. 基于最大熵原理的多阈值自动选取新方法[J]. 中国图像图形学报, 2002, 7(5): 461-465.

[22] 乔韡韡, 吴成茂. 二维最大类间交叉熵阈值分割法[J]. 西北大学学报:自然科学版, 2008, 38(3): 374-378.

[23] Wang Y P, Lee S L. Scale-space derived from B-splines[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(10): 1040-1055.

[24] Elder J H, Zucker S W. Local scale control for edge detection and blur estimation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(7): 699-716.

[25] Hong L, Wan Y, Jain A. Fingerprint image enhancement: algorithm and performance evaluation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(8): 777-789.
[26] Yang L, Wu X, Zhao D, et al. An improved Prewitt algorithm for edge detection based on noised image[C]//2011 4th International congress on image and signal processing. IEEE, 2011, 3: 1197-1200.
[27] Rosenfeld A. The max Roberts operator is a Hueckel-type edge detector[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1981(1): 101-103.
[28] Marr D, Hildreth E. Theory of edge detection[J]. Proceedings of the Royal Society of London. Series B. Biological Sciences, 1980, 207(1167): 187-217.
[29] 刘仲民, 王阳, 李战明, 等. 基于简单线性迭代聚类和快速最近邻区域合并的图像分割算法[J]. 吉林大学学报: 工学版, 2018, 48(6): 1931-1937.
[30] 陆剑锋, 林海, 潘志庚. 自适应区域生长算法在医学图像分割中的应用[J]. 计算机辅助设计与图形学学报, 2005, 17(10): 2168-2173.
[31] 陈方昕. 基于区域生长法的图像分割技术[J]. 科技信息, 2008(15): 58-59.
[32] Zhang C, Xue Z, Zhu X, et al. Boosted random contextual semantic space based representation for visual recognition[J]. Information Sciences, 2016, 369: 160-170.
[33] Chen Z, Wang L, Wu W, et al. Monitoring plastic-mulched farmland by Landsat-8 OLI imagery using spectral and textural features[J]. Remote Sensing, 2016, 8(4): 353.
[34] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 3431-3440.
[35] Zeiler M D, Taylor G W, Fergus R. Adaptive deconvolutional networks for mid and high level feature learning[C]//2011 international conference on computer vision. IEEE, 2011: 2018-2025.
[36] Badrinarayanan V, Handa A, Cipolla R. SegNet: A Deep Convolutional Encoder-Decoder Architecture for Robust Semantic Pixel-Wise Labelling[J]. Computer Science, 2015.
[37] Noh H, Hong S, Han B. Learning Deconvolution Network for Semantic Segmentation[C]// IEEE International Conference on Computer Vision. IEEE Computer Society, 2015: 1520-1528.
[38] Hong S, Noh H, Han B. Decoupled Deep Neural Network for Semi-supervised Semantic Segmentation[J]. Computer Science, 2015.
[39] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer International Publishing, 2015: 234-241.
[40] Arbelaez P, Ponttuset J, Barron J, et al. Multiscale Combinatorial Grouping[C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2014: 328-335.
[41] Eigen D, Fergus R. Predicting Depth, Surface Normals and Semantic Labels with a Common Multi-scale Convolutional Architecture[C]// International Conference on Computer Vision. IEEE Computer Society, 2015: 2650-2658.
[42] Lin G, Shen C, Van Den Hengel A, et al. Efficient piecewise training of deep structured models for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 3194-3203.
[43] Chen L C, Papandreou G, Kokkinos I, et al. Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs[J]. Computer Science, 2016(4): 357-361.
[44] Holschneider M, Kronland-Martinet R, Morlet J, et al. A real-time algorithm for signal analysis with the help of the wavelet transform[C]//Wavelets: Time-Frequency Methods and Phase Space Proceedings of the International Conference, Marseille, France, December 14–18, 1987. Springer Berlin Heidelberg, 1990: 286-297.

[45] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
[46] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014, 15(1): 1929-1958.
[47] Everingham M, Eslami S M A, Van Gool L, et al. The pascal visual object classes challenge: A retrospective[J]. International journal of computer vision, 2015, 111: 98-136.
[48] Hussain Raza S, Grundmann M, Essa I. Geometric context from videos[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 3081-3088.
[49] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. Springer International Publishing, 2014: 740-755.
[50] Brostow G J, Shotton J, Fauqueur J, et al. Segmentation and recognition using structure from motion point clouds[C]//Computer Vision–ECCV 2008: 10th European Conference on Computer Vision, Marseille, France, October 12-18, 2008, Proceedings, Part I 10. Springer Berlin Heidelberg, 2008: 44-57.
[51] Brostow G J, Fauqueur J, Cipolla R. Semantic object classes in video: A high-definition ground truth database[J]. Pattern Recognition Letters, 2009, 30(2): 88-97.
[52] Cordts M, Omran M, Ramos S, et al. The cityscapes dataset for semantic urban scene understanding[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 3213-3223.
[53] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.
[54] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
[55] Paszke A, Chaurasia A, Kim S, et al. Enet: A deep neural network architecture for real-time semantic segmentation[J]. arXiv preprint arXiv: 1606.02147, 2016.
[56] Zhang X, Chen Z, Wu Q J, et al. Fast semantic segmentation for scene perception[J]. IEEE Transaction on Industrial Informatics, 2018, 15(2): 1183-11.
[57] Mehta S, Rastegari M, Caspi A, et al. Espnet: Efficient spatial pyramid of dilated convolutions for semantic segmentation[C]//Proceedings of the european conference on computer vision (ECCV). 2018: 552-568.
[58] Wu T, Tang S, Zhang R, et al. Cgnet: A light-weight context guided network for semantic segmentation[J]. IEEE Transactions on Image Processing, 2020, 30: 1169-1179.
[59] Yang Z, Yu H, Fu Q, et al. Ndnet: Narrow while deep network for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(9): 5508-5519.
[60] Poudel R P, Bonde U, Liwicki S, et al. Contextnet: Exploring context and detail for semantic segmentation in real-time[J]. arXiv preprint arXiv: 1805.04554, 2018.
[61] Lo S Y, Hang H M, Chan S W, et al. Efficient dense modules of asymmetric convolution for real-time semantic segmentation[C]//Proceedings of the ACM Multimedia Asia. 2019: 1-6.
[62] Romera E, Alvarez J M, Bergasa L M, et al. Erfnet: Efficient residual factorized convnet for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 19(1): 263-272.
[63] Poudel R P, Liwicki S, Cipolla R. Fast-scnn: Fast semantic segmentation network[J]. arXiv preprint arXiv: 1902.04502, 2019.
[64] Yu C, Wang J, Peng C, et al. Bisenet: Bilateral segmentation network for real-time semantic segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 325-341.
[65] Zhao H, Qi X, Shen X, et al. Icnet for real-time semantic segmentation on high-resolution images[C]//Proceedings of the European Conference on computer vision (ECCV). 2018: 405-420.

[66] Li G, Yun I, Kim J, et al. Dabnet: Depth-wise asymmetric bottleneck for real-time semantic segmentation[J]. arXiv preprint arXiv: 1907.11357, 2019.
[67] Zhang Z, Zhang K. Farsee-net: Real-time semantic segmentation by efficient multi-scale context aggregation and feature space super-resolution[C]//2020 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2020: 8411-8417.
[68] Li H, Xiong P, Fan H, et al. Dfanet: Deep feature aggregation for real-time semantic segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9522-9531.
[69] Wang Y, Zhou Q, Liu J, et al. Lednet: A lightweight encoder-decoder network for real-time semantic segmentation[C]//2019 IEEE international conference on image processing (ICIP). IEEE, 2019: 1860-1864.
[70] Zhou Q, Wang Y, Fan Y, et al. AGLNet: Towards real-time semantic segmentation of self-driving images via attention-guided lightweight network[J]. Applied soft computing, 2020, 96: 1066 82.
[71] Gao G, Xu G, Yu Y, et al. Mscfnet: a lightweight network with multi-scale context fusion for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(12): 25489-25499.
[72] Gao G, Xu G, Li J, et al. FBSNet: A fast bilateral symmetrical network for real-time semantic segmentation[J]. IEEE Transactions on Multi-media, 2022.
[73] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1511.07122, 2015.
[74] Chen L C, Papandreou G, Kokkinos I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 834-848.
[75] Chen L C, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation[J]. arXiv preprint arXiv: 1706.05587, 2017.
[76] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.
[77] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
[78] Jégou S, Drozdzal M, Vazquez D, et al. The one hundred layers tiramisu: Fully convolutional densenets for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 11-19.
[79] Fu J, Liu J, Wang Y, et al. Stacked deconvolutional network for semantic segmentation[J]. IEEE Transactions on Image Processing, 2019.
[80] Treml M, Arjona-Medina J, Unterthiner T, et al. Speeding up semantic segmentation for autonomous driving[J]. 2016: 1-7.
[81] Mehta S, Rastegari M, Shapiro L, et al. Espnetv2: A light-weight, power efficient, and general purpose convolutional neural network[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9190-9200.
[82] Wang J, Xiong H, Wang H, et al. ADSCNet: asymmetric depthwise separable convolution for semantic segmentation in real-time[J]. Applied Intelligence, 2020, 50(4): 1045-1056.
[83] Hao S, Zhou Y, Guo Y, et al. Bi-direction context propagation network for real-time semantic segmentation[J]. arXiv preprint arXiv: 2005.11034, 2020.
[84] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.
[85] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Proceedings of the Advances in Neural Information Processing Systems, 2017: 5998-6008.
[86] 刘环宇. 基于卷积神经网络的图像全景分割[D]. 浙江大学, 2019.

[87] 宁民权. 基于混合神经网络的医学图像分割研究与应用[D]. 重庆大学, 2021.
[88] 邵硕. 基于改进的 U-Net 模型的医学图像语义分割方法研究[D]. 江南大学, 2022.
[89] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv: 2010.11929, 2020.

附录 1 攻读硕士学位期间撰写的论文

[1]张梦纯，于悦，徐大伟，高广谓，基于多尺度上下文聚合的高效实时语义分割网络，计算机与数字工程，已录用。

附录 2 攻读硕士学位期间申请的专利

[1] 张梦纯，高广谓，徐国安，吴飞，岳东. 上下文聚合网络以及基于该网络的图像实时语义分割方法，202210486074.5，2022.5.06。

附录 3 攻读硕士学位期间参加的科研项目

（1）国家自然科学基金，基于空间一致性的低质量人脸图像识别研究 (61972212)；

（2）省重点实验室开放课题，基于空间一致性的跨域图像重建与识别 (KJS2274)。

致谢

时光飞逝，一转眼，三年的研究生生涯即将结束，而我多年来的求学历程也将画上句号。依稀记得，收到研究生录取通知书时，心中满怀着对读研生活期待，踏进校门之后，研一时却倍感迷茫与孤单。随着慢慢与舍友，与师兄师姐同门们熟络起来，这种感觉也逐渐消失了，随之而来的便是科研的压力。好在有了导师和师兄的耐心指导，让我渐渐对自己的研究方向产生了浓厚的兴趣，并发表了文章。这三年，在学会了专业知识、掌握了专业技能之余，我还收获了难忘的同门情谊以及师生情谊。在此，我想对曾经给予我帮助的人致以诚挚的感谢！

首先，我要感谢我的父母，他们无条件地支持我考研、读研，研究生期间，在我迷茫和困顿时候，告诉我可以放慢脚步，调整自己，劳逸结合，张弛需有度，并且负担我的学费和生活费，让我能够专心学习，有了他们这个坚实的后盾，我才能一往无前地奋斗与前行。

其次，我要感谢我的导师高广谓老师，在我刚接触语义分割这个研究方向时，不知道如何入手，是他教会了我如何进行有效科研，并鼓励我遇到问题时，及时和同门交流，向师兄请教。在后期论文的撰写和修改过程中，也给出了很多指导和建议，正是高老师的这些指导，让我才能够在学术上有一些成果，顺利毕业。

最后，我要感谢我自己，在遇到困难时候，绝不放弃，能够及时调整好自己的状态，始终保持饱满的热情去迎接学习和生活中的挑战，通过持之以恒的努力取得了今天的成果。

研究生生涯即将结束，在未来的日子里，希望自己能够无畏风雨，砥砺前行，再接再厉。最后，再次诚挚地感谢所有帮助过我的家人、同学、老师和朋友们！