单位代码：10293　密　级：

# 南京邮电大学

# 专业学位硕士论文

论文题目：基于高效注意力机制的实时语义分割研究

| | |
|---|---|
| 学　　号 | 1221056129 |
| 姓　　名 | 徐大伟 |
| 导　　师 | 高广谓 |
| 专业学位类别 | 电子信息硕士 |
| 类　　型 | 全日制 |
| 专业（领域） | 电子信息 |
| 论文提交日期 | 2023.04 |

# Research on Real-Time Semantic Segmentation Based on Efficient Attention Mechanisms

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of Master of Electronic Information

By

Dawei XU

Supervisor: Prof. Guangwei Gao

April 2023

# 南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号：_____ 研究生签名：_____ 日期：_____

# 南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名：_____ 导师签名：_____ 日期：_____

# 摘要

近年来，随着计算机视觉技术的迅猛发展，图像语义分割作为备受关注的研究热点，已经在多个领域展现出了巨大的潜力和价值。特别是在自动驾驶、医疗影像、农业环境监测等实际应用场景中，语义分割技术的落地应用变得愈发重要。卷积神经网络的广泛运用为语义分割任务带来了显著的性能提升，但同时也存在许多挑战。许多现有的语义分割方法虽然在分割效果上取得了不错的成绩，但往往通过增加模型复杂度来实现，忽略了硬件资源消耗和推理延迟等问题。针对这些挑战，本文基于深度卷积神经网络，提出了一系列轻量级实时语义分割模型，旨在兼顾算法精度、推理速度和模型参数量，具体研究内容如下：

(1) 为了在较低的参数量的情况下提升分割精度，本文提出了基于双分支信息融合的高效实时语义分割网络 (DFNet)。DFNet 中采用深度可分离卷积、空洞卷积、分解卷积组成了上下文信息融合模块作为特征提取单元，该模块可以通过扩展感受野以获取上下文信息，并且采用双分支融合的结构，实现了上下文信息的融合。DFNet 采用双分支的整体网络结构，其中细节分支配备了空间注意力机制负责提取浅层空间信息，语义分支搭配了通道注意力机制提取深层的语义信息，最后将双分支信息进行融合。DFNet 的模型参数量仅有 0.66M，在单张 RTX2080Ti GPU 上进行训练和测试，在 Cityscapes 和 CamVid 数据集上的 mIoU 分别为 71.2%和 68.43%。

(2) 针对单一特征尺度不能满足高精度识别性能要求的问题，提出了一种多尺度上下文信息融合网络 (MFNet)。具体来说，MFNet 采用非对称的编码器-解码器架构，在编码部分基于空洞卷积和分解卷积设计了多尺度特征提取与融合模块，以在参数量不变的情况下提取多尺度信息。在解码部分采用多尺度信息融合模块以减少上采样后信息的丢失。在单张 RTX2080Ti GPU 上进行训练和测试，模型参数量为 0.89M，在 Cityscapes 数据集上的推理速度为 87FPS，mIoU 达到 71.6%，在 Camvid 数据集上推理速度为 94FPS，mIoU 达到 68.92%。

(3) 针对卷积神经网络无法提取全局上下文信息的问题，提出了一种 CNN 和 Transformer 相结合的轻量级语义分割网络 (LCTNet)。网络中的高效 Transformer 模块可以在使用较低参数量的情况下建模全局特征的依赖关系。LCTNet 的基本特征提取单元为三分支特征提取单元，并在其中引入了细节信息提取单元，用于弥补 Transformer 模块无法提取细节信息的问题。LCTNet 的参数量为 0.96M，在单张 RTX2080Ti GPU 上进行训练和测试，在 Cityscapes 数据集上是推理速度达到 85FPS，分割精度为 71.9%，在 Camvid 数据集上是推理速度达到 100FPS，分割精度为 69.21%。

综上，本文设计了三种轻量级实时语义分割网络，结合了 Transformer 和卷积神经网络，

并且采用了空洞卷积、分解卷积、深度可分离卷积、空间注意力机制以及通道注意力机制等方法，实现了分割精度、模型大小以及推理速度之间的平衡。通过大量实验验证，这些网络在实际应用中表现出色，具备在现实硬件系统中应用的潜力。

**关键词:实时语义分割，注意力机制，上下文信息融合，Transformer，卷积神经网络**

# Abstract

Abstract: In recent years, with the rapid development of computer vision technology, image semantic segmentation, as a highly regarded research hotspot, has demonstrated tremendous potential and value in multiple domains. Particularly in practical application scenarios such as autonomous driving, medical imaging, and agricultural environment monitoring, the deployment of semantic segmentation technology has become increasingly crucial. The widespread use of convolutional neural networks has significantly boosted the performance of semantic segmentation tasks. However, numerous challenges persist. While many existing semantic segmentation methods have achieved impressive segmentation results, they often do so by increasing model complexity, overlooking issues such as hardware resource consumption and inference latency. Addressing these challenges, this paper proposes a series of lightweight real-time semantic segmentation models based on deep convolutional neural networks, aiming to balance algorithm accuracy, inference speed, and model parameter count. The specific research contributions are as follows:

(1) To enhance segmentation accuracy under a lower parameter count, this paper proposes the Efficient Real-Time Semantic Segmentation Network (DFNet) based on dual-branch information fusion. DFNet employs depthwise separable convolution, dilated convolution, and decomposed convolution to form a context information fusion module as the feature extraction unit. This module extends the receptive field to capture contextual information and utilizes a dual-branch fusion structure to integrate contextual information. DFNet adopts a dual-branch overall network structure, where the detail branch equipped with spatial attention mechanism is responsible for extracting shallow spatial information, and the semantic branch paired with channel attention mechanism extracts deep semantic information, with the final fusion of the dual-branch information. DFNet has a model parameter count of only 0.66M and achieves mIoU of 71.2% and 68.43% on the Cityscapes and CamVid datasets, respectively, trained and tested on a single RTX2080Ti GPU.

(2) Addressing the issue of single-feature scale inability to meet high-precision recognition performance requirements, a Multi-Scale Context Information Fusion Network (MFNet) is proposed. Specifically, MFNet adopts an asymmetric encoder-decoder architecture. In the encoding part, a multi-scale feature extraction and fusion module based on dilated convolution and decomposed convolution is designed to extract multi-scale information under constant parameters. In the decoding part, a multi-scale information fusion module is used to reduce the loss of information after

upsampling. Trained and tested on a single RTX2080Ti GPU, MFNet has a model parameter count of 0.89M, achieves an inference speed of 87FPS and mIoU of 71.6% on the Cityscapes dataset, and an inference speed of 94FPS and mIoU of 68.92% on the Camvid dataset.

(3) Addressing the inability of convolutional neural networks to extract global context information, a Lightweight Semantic Segmentation Network Combining CNN and Transformer (LCTNet) is proposed. The efficient Transformer module in the network can model global feature dependencies with lower parameter counts. The basic feature extraction unit of LCTNet is a three-branch feature extraction unit, incorporating a detail information extraction unit to compensate for the Transformer module's inability to extract detail information. LCTNet has a parameter count of 0.96M and achieves an inference speed of 100FPS with a segmentation accuracy of 71.9% on the Cityscapes dataset, and an inference speed of 85FPS with a segmentation accuracy of 69.21% on the Camvid dataset, trained and tested on a single RTX2080Ti GPU.

In summary, this paper designs three lightweight real-time semantic segmentation networks, combining Transformer and convolutional neural networks, and employing methods such as dilated convolution, decomposed convolution, depthwise separable convolution, spatial attention mechanism, and channel attention mechanism to achieve a balance between segmentation accuracy, model size, and inference speed. Extensive experiments validate that these networks perform excellently in practical applications, with the potential for deployment in real-world hardware systems.

**Key words: Real-time Semantic Segmentation, Attention Mechanism, Contextual Information Fusion, Transformer, Convolutional Neural Network**

# 目录

第一章 绪论 ..... 1
1.1 研究背景及意义 ..... 1
1.2 语义分割研究现状 ..... 2
1.2.1 传统的图像语义分割算法 ..... 2
1.2.2 基于卷积神经网络的图像语义分割算法 ..... 4
1.3 研究目的及论文章节安排 ..... 5
第二章 相关背景知识介绍 ..... 7
2.1 卷积神经网络基础理论 ..... 7
2.1.1 卷积层 ..... 7
2.1.2 激活函数层 ..... 10
2.1.3 池化层 ..... 12
2.1.4 全连接层 ..... 12
2.2 注意力机制 ..... 13
2.2.1 通道注意力 (channel attention) ..... 13
2.2.2 空间注意力 (special attention) ..... 14
2.2.3 Transformer ..... 16
2.3 语义分割评价标准 ..... 16
2.4 本章小结 ..... 17
第三章 基于双分支信息融合的高效实时语义分割网络 ..... 18
3.1 引言 ..... 18
3.2 模型方法 ..... 19
3.2.1 网络结构 ..... 19
3.2.2 上下文信息融合模块 ..... 21
3.2.3 注意力机制 ..... 23
3.3 实验设计与结果分析 ..... 23
3.3.1 实验方案 ..... 23
3.3.2 消融实验 ..... 24
3.3.3 与其他方法的比较 ..... 26
3.4 本章小结 ..... 27
第四章 基于多尺度上下文信息融合的实时语义分割网络 ..... 29
4.1 引言 ..... 29
4.2 模型方法 ..... 30
4.2.1 特征提取单元 ..... 30
4.2.2 多尺度特征提取与融合模块 ..... 32
4.2.3 特征信息融合模块 ..... 33
4.2.4 多尺度信息融合模块 ..... 34
4.2.5 整体网络结构设计 ..... 35
4.3 实验设计与结果分析 ..... 36
4.3.1 数据集 ..... 36
4.3.2 参数设置 ..... 36
4.3.3 消融实验 ..... 37
4.3.4 与其他方法比较 ..... 40
4.4 本章小结 ..... 40
第五章 融合 CNN 与 Transformer 的轻量级语义分割网络 ..... 41

5.1 引言 ..... 41
5.2 模型方法 ..... 42
5.2.1 三分支特征提取单元 ..... 42
5.2.2 细节信息提取单元 ..... 44
5.2.3 高效 Transformer 模块 ..... 44
5.2.4 像素注意力机制 ..... 45
5.2.5 整体网络结构 ..... 46
5.3 实验设计与结果分析 ..... 47
5.3.1 数据集 ..... 47
5.3.2 参数设置 ..... 47
5.3.3 消融实验 ..... 47
5.3.4 与其他方法比较 ..... 49
5.4 本章小结 ..... 50
第六章 总结与展望 ..... 51
6.1 总结 ..... 51
6.2 展望 ..... 52
参考文献 ..... 54
附录 1 攻读硕士学位期间撰写的论文 ..... 58
附录 2 攻读硕士学位期间申请的专利 ..... 59
附录 3 攻读硕士学位期间参加的科研项目 ..... 60
致谢 ..... 61

# 第一章 绪论

## 1.1 研究背景及意义

近年来，随着 5G 传输技术、芯片技术以及智能设备技术的迅速发展，人工智能技术越来越多地落地应用，显著提高了生产效率并改善了我们的生活质量。伴随着计算机算力的不断提升和海量数据集的涌现，深度学习 (Deep Learning) 得到了飞速发展。与传统的机器学习方法不同，深度学习无需人工准备各种特征数据或事先规划好训练参数。它能够自动处理和学习海量数据，并提取出更高级别的特征。在这个过程中，深度学习模型能够自动生成和调整参数，具有操作简单、效果优异等诸多优势。

计算机视觉作为人工智能的重要领域，深度学习为其提供了众多优秀的解决方案。计算机视觉主要分为图像分类 (Image Classification)、目标检测 (Object Detection) 和图像分割 (Image Segmentation) 三大部分。图像分类根据图像中反映的不同特征，按类别将图像区域进行区分。目标检测则识别图像中物体的位置和类别信息。图像分割则根据不同类别对图像进行像素级分类。目前，图像分割[1, 2]是计算机视觉领域最为热门的研究方向之一，主要分为语义分割 (Semantic Segmentation) 和实例分割 (Instance Segmentation[3, 4]) 两类。语义分割通过将图像中的每个像素分配到预定义的类别中，实现对图像的语义理解，如人、车、树等不同类别的像素标记。而实例分割不仅对像素进行类别标记，还能够区分同一类别中不同的物体实例，为每个物体分配唯一的标识符，使得每个物体都能够被独立地识别和分割，进而更加准确地理解图像内容。在实际应用中，语义分割的应用范围更广泛，例如在自动驾驶,医疗影像以及环境监测等领域。

在自动驾驶领域[5-7]，语义分割起着关键作用。目前自动驾驶已经成为目前汽车市场最为火热的技术，而语义分割则是实现自动驾驶的关键。通过车载摄像头采集的实时图像数据，语义分割技术能够精准地将场景进行分割处理，识别出道路、车辆、行人等不同类别的对象及其精确边界[8, 9]。这为自动驾驶系统提供了重要的环境感知能力，使得汽车能够实现交通信号灯识别、车道保持、行人车辆避障等关键功能，从而实现自动驾驶的安全与可靠性。最近几年，自动驾驶已经成为各大车企的“角斗场”，华为和赛里斯联合推出的问界 M9，已经可以实现高效的辅助驾驶以及自动泊车，进一步推动了语义分割技术在自动驾驶领域的发展。

在医疗影像领域[10]，语义分割技术通过对医学影像数据的分割处理，实现了诸如病变区域定位、器官分割、病灶检测等功能[11, 12]。利用医疗影像设备如 MRI、CT 等采集的图像数

据，语义分割技术能够准确地识别出图像中的不同组织结构或病变区域，为医生提供了重要的诊断辅助信息。通过该技术，医生可以更准确地定位和量化病灶，从而提高了医学影像诊断的准确性和效率。此外，语义分割还可用于手术导航、治疗规划等医疗应用中，为医生提供精准的操作指导，优化治疗方案，提升治疗效果。

同样在环境监测及农业领域[13-15]，语义分割技术也扮演着重要角色。通过航拍无人机或卫星获取的高分辨率图像数据，语义分割技术能够准确地识别出不同类型的地物或植被，如水体、森林、农田等，并对其进行精细的分割与分类[16, 17]。这种技术应用可以帮助实现环境监测与资源管理，监测水质变化、植被覆盖情况、土壤类型等，为环境保护和生态恢复提供数据支持。同时，在农业领域，语义分割技术可用于农田的土壤分析、作物生长监测、病虫害检测等，帮助农民优化农业生产管理，提高农作物产量和质量。随着技术的不断发展，语义分割在环境监测及农业中的应用前景广阔，将为实现可持续发展和精准农业注入新的动力。

目前，随着卷积神经网络的引入和芯片计算性能的不断提升，语义分割技术取得了迅速的发展。然而，随着语义分割应用场景的扩大，对其性能，参数量和推理速度等方面提出了更为严格的要求。特别是在自动驾驶等边缘设备应用中，鉴于边缘设备性能的有限，我们迫切需要轻量级的语义分割网络，能够在确保模型性能的前提下降低模型的参数量，提高推理速度。目前，一些高性能的语义分割模型拥有不错的分割精度却忽视了模型的参数量，而专为边缘设备设计的模型虽然减少了参数和计算量，但准确率却有所欠缺。因此，在如自动驾驶等场景中，如何在保证高准确率的前提下，降低模型参数量及计算量，成为当前语义分割技术亟待突破的关键挑战。

综上所述，随着技术的发展，语义分割的出现可以极大提高生产效率，改善人们生活，同时语义分割还存在瓶颈需要我们去突破。

## 1.2 语义分割研究现状

### 1.2.1 传统的图像语义分割算法

传统的语义分割方法主要分为以下四种：

(1) 基于阈值的分割方法

传统的图像语义分割算法中，基于阈值的分割方法[18, 19]是一种简单而有效的技术。它通过设定一个阈值来区分图像中的不同区域。首先，将图像的像素值与预先设定的阈值进行比较，像素值大于阈值的被认为属于一类，而小于阈值的则被认为属于另一类。通过这种方式，

图像被划分为不同的区域，每个区域具有相似的像素值特性。这种方法简单易用，适用于许多场景下的图像分割任务，例如背景与前景的分离、目标检测等。然而，基于阈值的分割方法容易受到光照变化、噪声干扰等因素的影响，且需要手动调整阈值，对于复杂场景的分割效果可能不理想。

(2) 基于边缘检测的分割方法

基于边缘检测[20, 21]的传统图像语义分割算法将图像中的边缘信息视为主要特征，通过检测图像中像素值的梯度变化来确定对象的边界。这些算法通常采用边缘检测器，如 Sobel 算子[22]、Canny 算子[23]等，来识别图像中的边缘。首先，算法计算图像中每个像素的梯度值，并将其与预设的阈值进行比较，以确定是否为边缘。接着，根据边缘连接和区域生长等技术，将边缘像素连接成连续的边界，从而实现图像的分割。然而，这种方法容易受到噪声和纹理等因素的影响，对于复杂背景和目标边界不清晰的情况下，分割效果可能不尽如人意。

(3) 基于区域的分割方法

基于区域的分割方法[24]将图像中的像素聚类为具有相似特征的区域，以实现图像的分割。这种方法首先根据像素的属性（如颜色、纹理等）将图像分成不同的区域，然后通过合并或分割这些区域来得到最终的分割结果。其中，经典的区域分割算法包括基于区域增长的方法[25, 26]、基于分水岭的方法[27]等。基于区域增长的方法从种子像素开始，逐步扩展到相邻像素，直到满足某些相似性准则为止，形成一个区域。而基于分水岭的方法则将图像视为地形图，通过模拟水从低处流向高处的过程来实现图像的分割。尽管基于区域的分割方法能够有效处理复杂背景和目标不连续的情况，但在处理目标重叠或边界模糊的情况下可能会出现分割不准确的问题。

(4) 基于机器学习的分割方法

基于机器学习的图像分割方法利用机器学习算法从图像数据中学习特征和分割规则，以实现自动分割图像的目标和背景等不同部分。这些方法通常采用监督学习或无监督学习的方式进行训练。在监督学习中，首先需要准备标记好的训练数据，包括图像及其对应的像素级标签。然后，通过训练一个分类器或回归器来学习图像中不同区域的特征和分割规则，以实现像素级别的分割。在无监督学习中，算法则通过对图像进行聚类或密度估计等技术，自动发现图像中的不同区域，并将其分割出来。常用的机器学习算法包括支持向量机、随机森林、混淆矩阵等[28, 29]。尽管基于机器学习的图像分割方法具有较强的自适应能力和泛化能力，但需要大量的标记数据进行训练，并且对参数调优和模型选择等方面要求较高。

总的来说，这些传统方法在处理简单场景和特定应用时可能效果良好，但在处理复杂场景和多样性图像时可能表现不佳。

### 1.2.2 基于卷积神经网络的图像语义分割算法

卷积神经网络最早运用于 Alexander Waibel 1987 年提出的时间延迟网络 (Time Delay Neural Network, TDNN)。该网络应用于语音识别，效果超越了当时主流的算法。1998 年，Yann LeCun 等人提出了 LeNet[30]，是最早用于手写数字识别的卷积神经网络之一。LeNet 采用了卷积层、池化层和全连接层的结构，为后续 CNN 的发展奠定了基础。2012 年，Alex Krizhevsky 等人提出了 AlexNet[31]，该模型在 ImageNet 大规模视觉识别挑战赛 (ILSVRC)[32] 中大获成功。AlexNet 采用了更深的网络结构和更多的参数，利用 GPU 进行高效训练，极大地推动了卷积神经网络的发展，从此卷积神经网络成为计算机视觉领域的“新宠”。

2014 年，Long 等人提出了全卷积网络 (FCN)[33]，这是第一个将卷积神经网络用于像素级别语义分割的模型。FCN 将传统的卷积神经网络中的全连接层替换为全卷积层，使得网络能够接受任意尺寸的输入图像，并输出相同尺寸的语义分割结果。FCN 通过上采样操作来恢复分辨率，并通过跳跃连接来融合不同层级的语义信息，实现了端到端的像素级别语义分割。

2015 年，Ronneberger 等人提出了 U-Net[34]，该模型结构呈 U 型，提出了编码器-解码器结构，编码器负责提取图像特征并降低分辨率，而解码器负责恢复分辨率并生成语义分割结果。该结构通过将特征图的上采样和下采样进行连接，实现了从低级别到高级别的特征传播，使得模型能够在保留细节信息的同时实现语义分割，提高了分割精度，尤其适用于医学图像等需要高分辨率分割的场景。

2017 年，Hengshuang Zhao 等人提出了 PSPnet(Pyramid Scene Parsing Network)[35],该网络首次引入了金字塔池化模块，用于捕获不同尺度上的语义信息。这个模块将输入特征图划分成不同尺度的网格，并对每个网格中的特征进行池化，以获取全局和局部的语义信息。同时 PSPNet 将空洞卷积应用于图像语义分割中，通过扩大卷积核的感受野，增加了每个像素点的视野范围，有助于理解图像中的上下文信息，提高分割的性能。

随后注意力机制开始出现于深度学习中，并被逐渐应用于计算机视觉领域。注意力机制最早由“Attention is all you need”[36]提出，在机器翻译任务中取得了显著的成功。该模型注意力机制被广泛地应用于输入序列与输出序列之间的交互，使得模型能够动态地对输入序列的不同部分分配不同的注意力权重。在 NLP 领域，注意力机制的引入使得模型能够更好地捕捉长距离的依赖关系，同时降低了模型复杂度和训练成本。在“Attention is all you need”提出之后，注意力模块在计算机视觉领域，特别是与图像相关的任务中得到了越来越多的应用，同时也越来越多地应用于语义分割领域，取得了不错的效果。 JI Fu 等在 2019 年提出的 DANet[37]就采用了注意力机制应用于语义分割。注意力机制能够使模型集中于输入中的关键部分，

从而有效地筛选出重要信息。这有助于减少冗余信息的影响，并集中注意力于更相关的部分，提高了模型的性能和效率。

随着语义分割在边缘设备上的应用不断增多，对于轻量级、高效的模型需求日益迫切。这些模型在保持高精度的同时，需要尽可能减少参数量，以适应边缘设备有限的资源。因此，近年来，人们不再仅仅局限于模型的分割精度，开始专注于开发精简、高效的语义分割模型，通过优化网络结构和参数设计，实现了在边缘设备上部署的轻量级模型，为各种实时应用场景提供了可靠的解决方案。Adam Paszke 等人于 2016 年提出的 Enet [38]模型，该模型采用非对称的编码解码结构，拥有较大的编码层但是较小的解码器，同时采用了分解卷积核的策略，使用 $n\times1,1\times n$ 的分解卷积，这样可以减少模型大量的参数，同时可以减弱函数学习的过拟合问题。Enet 还使用了空洞卷积，增加了模型的感受野，进而提升分割精度。但是 Enet 为追求紧凑的框架而丢弃模型的最后阶段的下采样，虽然 Enet 参数量很低，分割精度确不够理想。BiseNet [39]采用了一种全新的双分支网络结构，首先是一个带有小步长的空间分支来保留空间位置信息生成高分辨率的特征图；同时设计了一个带有快速下采样率的语义分支来获取客观的感受野。在这两个模块之上引入一个新的特征融合模块将二者的特征图进行融合，实现速度和精度的平衡，但是 BiseNet 还是存在参数量较大的问题。ESPNet [40]，针对语义分割的场景进行了核心模块的设计，采用了空洞卷积金字塔来提取多尺度的特征信息，并通过巧妙的网络结构和参数压缩技术来减少模型的参数量，从而在保持高精度的同时，实现了在边缘设备上高效部署。ESPNet 还利用 HFF 技术消除了网格纹路，提高了分割质量和连续性，使其成为实时应用场景的可靠解决方案。但在一些复杂场景下，分割精度欠佳。

综上所述，卷积神经网络的出现为语义分割任务提供了良好的解决方案，提升了语义分割的精度，但是如何在分割精度和模型参数量上取得更好的平衡，值得我们进一步的研究和探索。

## 1.3 研究目的及论文章节安排

本文对工业应用、实际感知模式以及自动驾驶等领域中的实时轻量级语义分割网络模型进行了深入研究，主要基于卷积神经网络和 Transformer。在研究中，综合考虑了模型大小、运行速度和分割精度等关键指标，力求实现最佳平衡，以满足在计算和存储资源有限的实际设备上实时且准确的分割需求。全文共分为六个章节，章节结构如下所述：

第一章，绪论。本章主要讲解了图像语义分割的研究背景及意义，并且介绍了语义分割的发展进程以及研究现状。最后阐明了本文的主要研究目的以及本文的章节安排。

第二章，相关背景知识。本章节主要介绍了本文设计的模型所需的基础知识。首先介绍了卷积神经网络的基础知识，详细讲解了卷积网络中的每个层。然后讲解了注意力机制，着重描述了通道注意力，空间注意力以及 Transformer 的理论基础。最后详细介绍了语义分割评价标准。

第三章，基于双分支信息融合的高效实时语义分割网络 (DFNet)。本章节首先对该网络的整体结构进行了描述，之后再对该网络中的上下文信息融合模块详细描述，然后讲解了网络中使用到的注意力机制。最后进行实验，分别在 Cityscapes 和 CamVid 数据集上做了对比实验和消融实验。

第四章，基于多尺度上下文信息融合的实时语义分割网络 (MFNet)。第三章提出的 DFNet 缺乏多尺度特征，且单一特征尺度不能满足高精度识别性能的要求，针对这一问题，MFNet 引入了多尺度特征。本章节首先介绍了该模型的两个特征提取单元，然后讲解了多尺度特征提取与融合模块，之后对网络中使用的两个特征融合模块进行描述，随后在整体上描述该网络的算法模型。最后数据集上进行实验，验证该方法的优越性。

第五章，融合 CNN 与 Transformer 的高效实时语义分割网络 (LCTNet)。第三章提出的 DFNet 和第四章提出的 MFNet 都是以 CNN 为基础，然而 CNN 无法提取全局上下文信息。针对这一问题，LCTNet 引入了 Transformer 模块以实现全局信息建模。本章节首先介绍了专门为 CNN 与 Transformer 结合网络设计的三分支特征提取单元以及细节信息提取单元。之后介绍了高效 Transformer 模块和整体网络结构。最后在 Cityscapes 和 CamVid 数据集上进行实验，验证该方法的有效性。

第六章，总结与展望。本章对本文的研究进行总结概括，同时展望未来的研究发展方向。

# 第二章 相关背景知识介绍

## 2.1 卷积神经网络基础理论

深度学习中的卷积神经网络 (CNN) 是一种极为重要的神经网络结构，受到生物学中接收域的启发而设计。它专门用于处理具有网格结构相似性质的数据，例如图像、视频、音频和自然语言。CNN 通过一系列操作，包括卷积、非线性激活和池化等，逐层地提取输入数据中的高级语义信息。这些操作使得 CNN 能够在不同层次上捕捉到数据的特征和模式，从而有效地解决了诸如图像识别、语音识别、自然语言处理等问题。其在处理时间序列数据、图像数据等方面表现出色，成为深度学习领域中被广泛应用的关键技术之一。

### 2.1.1 卷积层

卷积层通过对输入数据与可学习的卷积核进行逐点相乘并求和的操作，提取输入数据中的局部特征。在卷积操作中，卷积核在输入数据上滑动，逐个位置与输入数据进行卷积计算，生成输出特征图，具体过程如图 2.1 所示。这一过程中，卷积核的参数通过反向传播算法进行优化，以最大程度地捕获输入数据的关键特征。最终，输出特征图中的每个值都对应着在输入数据中对应位置的卷积操作结果，从而实现了对输入数据的特征提取和抽象。具体过程可用如下公式描述：

$$F_i = \Sigma_{j=1}^{N} I_{in,j} \times K_j + b \tag{2.1}$$

其中$F_i$表示输出特征图中的一个像素值，即卷积操作的结果。$N$表示卷积核的大小。$I_{in,j}$表示输入数据中的一个像素值。$K_j$表示卷积核中的一个参数，即卷积核的权重。$b$ 是偏置项，用于调整输出特征图中的整体偏移。

在卷积过程中的输入特征图尺寸，输出特征图尺寸以及卷积核大小三者之间的映射关系可以用如下公式描述：

$$H_{\text{out}} = \frac{\left(H_{\text{in}} + 2\times p - H_k\right)}{s} + 1 \tag{2.2}$$

$$W_{\text{out}} = \frac{\left(W_{\text{in}} + 2\times p - W_k\right)}{s} + 1 \tag{2.3}$$

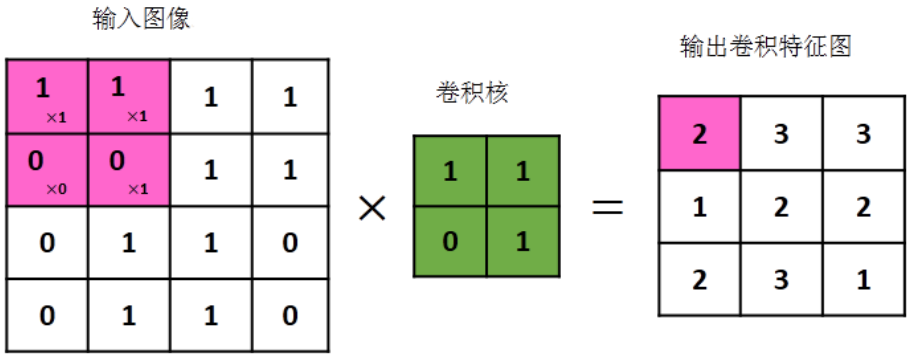


图 2.1 卷积操作示意图

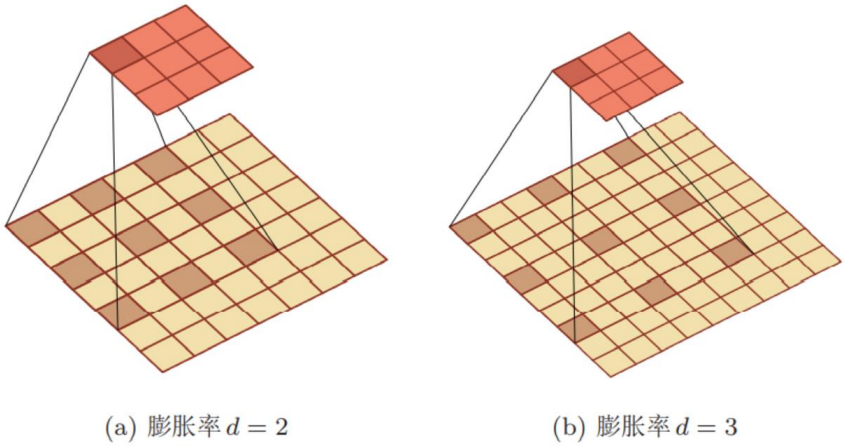


图 2.2 空洞卷积

其中 $H_{\text{in}}$，$W_{\text{in}}$ 表示输入特征图的高与宽，$H_{\text{out}}$，$W_{\text{out}}$ 表示输出特征图的高与宽，$H_k$，$W_k$ 表示卷积核的高与宽。$s$ 表示卷积核移动的步长，$p$ 表示特征图边界的补充。

随着卷积使用范围的推广，研究者因对不同场景设计出了不同的卷积类型。常见的卷积变形有：空洞卷积 (Dilated Convolution)，分组卷积 (Group Convolution) 及深度可分离卷积 (Depth-wise Convolution)。

(1) 空洞卷积

卷积神经网络需要更大的感受野以获取全局信息和上下文信息，一般是将特征图进行下采样操作以扩大感受野，然而过度下采样会降低图像分辨率、丢失细节信息，为此提出了空洞卷积操作，可以在不需要进行下采样，不增加计算成本的情况下增大感受野。具体的操作是，空洞卷积是通过在卷积核中插入间隔的零元素来扩大感受野，并且可以通过调整空洞率来调整感受野的大小。空洞卷积示意图如图 2.2。感受野的公式如下：

$$R_n = R_{n-1} + (k-1) \times \prod_{l=1}^{n-1} s_i \tag{2.4}$$

其中，$R_n$ 是当前卷积层的感受野，$R_{n-1}$ 是上一层卷积层的感受野，$s_i$ 是第 i 层卷积操作的

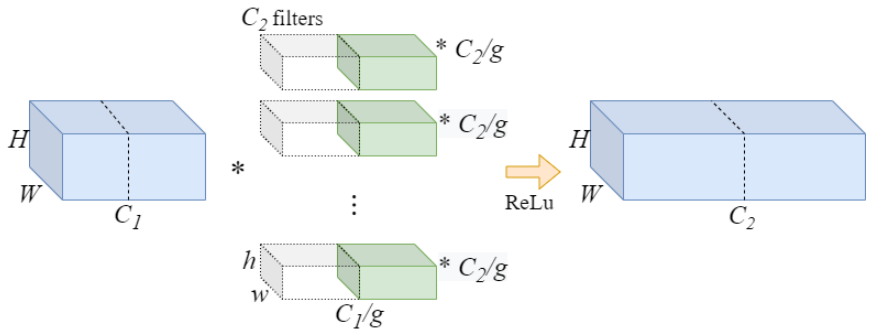


图 2.3 分组卷积示意图

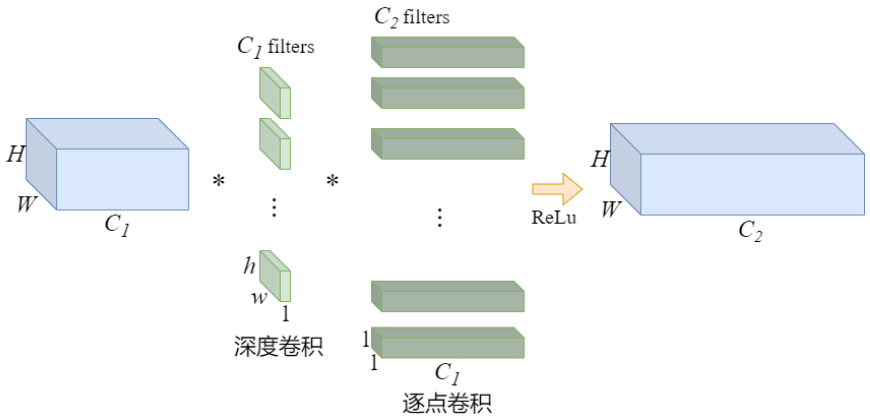


图 2.4 深度可分离卷积示意图

步长，$k$ 是指当前卷积核的尺寸。本文设计的模型中同样使用了扩张卷积，可以在保证模型轻量化的前提下扩大感受野，获取上下文信息。

(2) 分组卷积 (Group Convolution)

分组卷积最早由 Yann LeCun 等人在 AlexNet[31]模型中提出，它将输入特征图分成多个组，每个组进行独立的卷积操作，然后将各组的输出拼接在一起，从而得到最终的输出特征图。

假设输入特征图 $X$，它的尺寸为 $W \times H \times C_1$，其中 $W$ 和 $H$ 分别是输入特征图的宽度和高度，$C_{in}$ 是输入特征图的通道数。将输入特征图 $X$ 分成 $G$ 组，每个组包含 $\frac{C_1}{G}$ 个通道。因此，每个组的输入特征图可以表示为 $X^{(g)}$，其中 $(g)$ 是组的索引，范围从 1 到 $G$。每个组的输入特征图 $X^{(G)}$ 的尺寸则是 $W \times H \times \frac{C_1}{G}$。对于每个组 $g$，我们有一组卷积核 $K^{(g)}$，卷积核大小为 $K_w \times K_H \times \frac{C_1}{G}$，每个组输出特征图的大小为 $W \times H \times \frac{C_2}{G}$，其中 $C_2$ 是输出特征图的通道数。分组卷积的输出特征图 $Y$ 可以通过以下方式计算得到:

$$Y^{(g)} = X^{(g)} * K^{(g)} \tag{2.5}$$

$$Y = concat\left(Y^{(1)}, Y^{(2)}, \ldots\ldots, Y^{(G)}\right) \tag{2.6}$$

其中*表示卷积操作，最终输出特征图$Y$的尺寸为$W \times H \times C_2$。具体操作过程如图 2.3 所示。这种操作可以有效地减少参数量，用标准卷积运算时参数量为：$K_w \times K_H \times C_1 \times C_2$，使用分组卷积时需要的参数量为$G \times \left(K_w \times K_H \times \frac{C_1}{G} \times \frac{C_2}{G}\right) = K_w \times K_H \times C_1 \times C_2 \times \frac{1}{G}$，可见同等条件下分组卷积所需的参数量仅为标准卷积的$\frac{1}{G}$。

(3) 深度可分离卷积 (Depth-wise Convolution)

深度可分离卷积可以分为深度卷积 (Depthwise Convolution) 和逐点卷积 (Pointwise Convolution) 这两步操作。具体而言，深度卷积是将输入的每个通道都与一个单独的卷积核进行卷积操作，这样可以提取出每个通道的空间信息。然后，对每个通道的输出进行逐点卷积，即对每个通道的特征图应用 1x1 的卷积核，这样可以将不同通道之间的特征进行组合和整合，从而得到最终的输出特征图。假设输入特征图 $X$ 的尺寸为$W \times H \times C_1$，输出特征图的尺寸为$W \times H \times C_2$，卷积核大小为$K_w \times K_H \times C_2$，用标准卷积运算时参数量为：$K_w \times K_H \times C_1 \times C_2$，深度卷积的参数量为：$K_w \times K_H \times 1 \times C_2$，逐点卷积的参数量为：$1 \times 1 \times C_1 \times C_2$，所以深度可分离卷积的参数量与标准卷积之比为：$\frac{K_w \times K_H \times 1 \times C_2 + 1 \times 1 \times C_1 \times C_2}{K_w \times K_H \times C_1 \times C_2} = \frac{1}{C_1} + \frac{1}{K_w \times K_H}$。因此深度可分离卷积可以有效地减少了网络参数数量，提升计算效率。本文在轻量级语义分割网络中使用该卷积降低参数量，实现了模型的轻量化。深度可分离卷积的具体操作过程如图 2.4 所示。

### 2.1.2 激活函数层

激活函数层引入非线性变换可以使神经网络学习复杂的非线性关系，并且通过特征映射提取输入数据的关键特征，稳定梯度传播以更好地训练模型，并通过压缩和归一化提高网络的表达能力和泛化能力，从而更有效地适应各种学习任务。常用的激活函数有：Sigmoid，ReLU 函数，Tanh 函数，Softmax 函数。

(1) Sigmoid 函数，也称为 Logistic 函数 (图 2.5(a))，是一种常用的激活函数，其公式为：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{2.7}$$

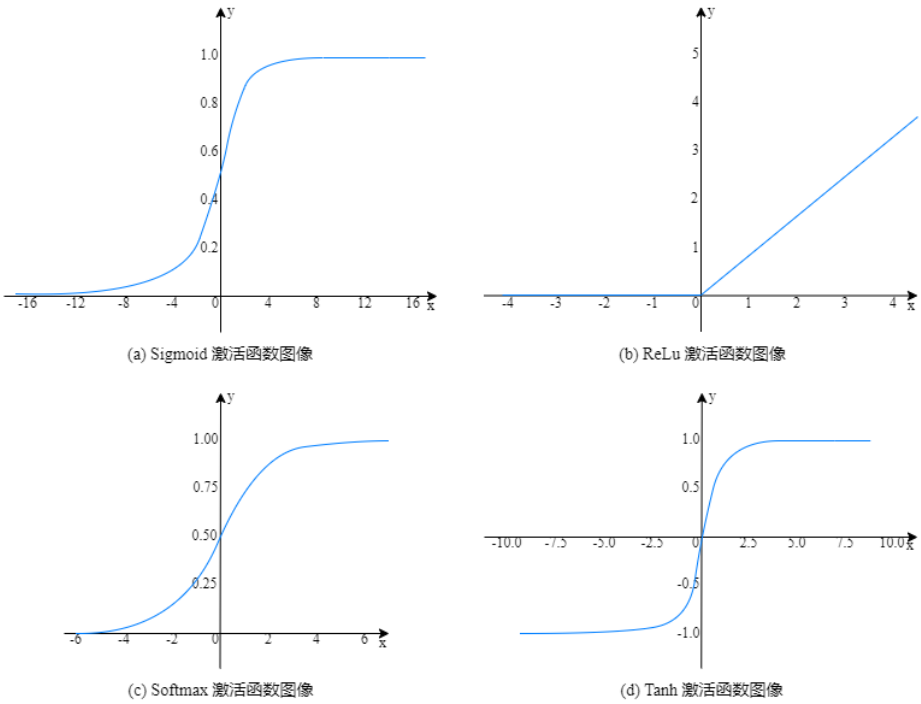


图 2.5 激活函数示意图

它将实数映射到一个区间在 $[0,1]$ 的范围内，因此常被用于将输出值解释为概率。在深度学习中，它通常用于输出层的二分类任务，其中输出值被解释为属于某一类的概率。然而，当 Sigmoid 输入值$x$较大或较小时，Sigmoid 函数的梯度会接近于 0，导致梯度消失的问题，这会影响模型的训练效果。其次，Sigmoid 函数的计算量较大，因为其包含指数运算。不过，Sigmoid 函数仍然在某些特定的场景中有其应用价值，特别是在输出层进行二分类任务时。

(2) ReLU 函数 (图 2.5(b)) 是一种常用的激活函数，它将输入$x$大于 0 时保持不变，小于 0 时置为 0。其公式为：

$$F(x) = MAX(0, x) \tag{2.8}$$

ReLU 函数的计算简单且收敛速度快，在深度学习中被广泛使用，尤其适用于隐藏层的激活函数。然而，ReLU 函数的一个缺点是在负数部分输出为零时可能导致神经元"死亡"，即在训练过程中某些神经元永远不会被激活，影响模型表现。

(3) Softmax (图 2.5(c)) 函数通常应用于神经网络的输出层，特别是在多分类问题中。其公式为：

$$F(x) = \frac{e^{x_i}}{\Sigma_i e^{x_i}} \tag{2.9}$$

其主要作用是将神经网络输出的原始分数转换为每个类别的概率。通过指数运算和归一化处理，Softmax 函数确保了所有类别的概率之和为 1，使得输出结果可以解释为对各个类别的置信度。在深度学习中，Softmax 函数被广泛用于图像分类、语音识别和自然语言处理等任

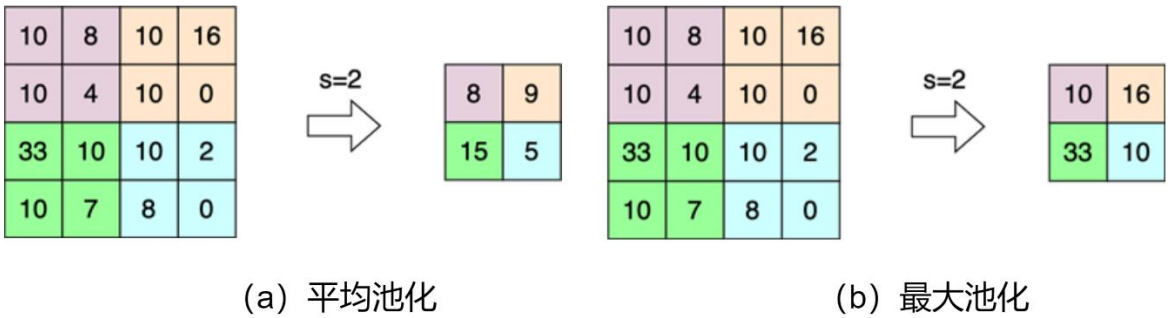


图 2.6 池化操作示意图

务，为模型的结果解释提供了便利。

(4) Tanh 函数 (图 2.5(d)) 是将实数输入映射到范围在 [-1, 1] 进行输出。其公式为：

$$Tanh(x)=\frac{\sinh(x)}{\cosh(x)}=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}} \tag{2.10}$$

与 Sigmoid 函数类似，Tanh 函数也具有将输出解释为概率的能力，但它的输出是零中心化的，即均值为 0。这种特性使得 Tanh 函数在神经网络中更加灵活，特别适用于中间层的激活函数。然而，与 Sigmoid 函数一样，Tanh 函数也容易受到梯度消失和梯度爆炸的影响，同时由于其包含指数运算，计算量也较大。尽管如此，Tanh 函数仍然在一些特定的任务中有其应用价值，特别是在需要输出范围在 [-1, 1] 的情况下。

### 2.1.3 池化层

池化层可以提取特征图的主要特征，减少模型的复杂度，但是同时也会造成细节信息丢失，分辨率降低以及模型失真等后果。常见的池化操作有平均池化 (Average Pooling) 和最大池化 (Max Pooling) 两种。

平均池化是对特征图上的特征点取平均值，它能够将特征信息均匀地分布在整个特征图中，是目前最为常见的池化方法之一。在正向传播时，平均池化需要计算范围内的平均数值，并在反向传播时将梯度均匀地传播回范围内的每个特征点。具体地，在反向传播过程中，需要将特征值逐一填充至对应的正向传播时的位置，并按照范围大小均匀地分配梯度值。最大池化则是通过在给定区域内选择最大的特征值来提取显著特征，有助于减小图像尺寸并保留重要信息。在正向传播中，它选择每个区域内的最大值；在反向传播中，它传递梯度给对应区域内的最大值位置，以更新网络参数。平均池化和最大池化的操作过程如图 2.6 所示

### 2.1.4 全连接层

前面介绍的这些操作，将原始的输入特征提取并转换成了更高级更抽象的隐藏特征。全

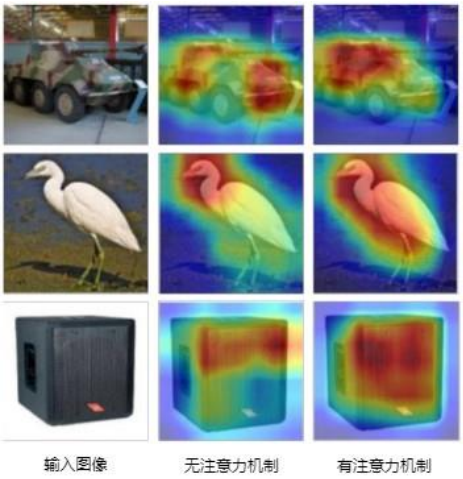


图 2.7 注意力机制效果图

连接层存在的意义是将这些抽象特征进行加权并且分类然后映射到最终的输出空间，最终形成输出。简单的说就是将卷积输出的二维特征图转化成一维的一个向量，其优点在于减少特征位置对于分类结果的影响，提高了整个网络的鲁棒性。

## 2.2 注意力机制

注意力机制 (Attention Mechanism) 是一种模仿人类视觉和认知系统的方法，它允许神经网络在处理输入数据时集中注意力于相关的部分。如图 2.7，通过引入注意力机制，神经网络能够自动地学习并选择性地关注输入中的重要信息，提高模型的性能和泛化能力。注意力机制最早由“Attention is all you need” [36]提出，并广泛应用于各种任务中以建立长距离依赖性[41-45]。随后注意力机制在计算机视觉领域，特别是图像处理方面也得到越来越多的应用。本文使用到的注意力是目前在图像处理任务中最为常用的注意力机制:通道注意力，空间注意力以及 Transformer。

### 2.2.1 通道注意力 (channel attention)

通道注意力通过全局信息汇聚和通道权重调整两个关键步骤来实现。首先，全局信息汇聚阶段从每个特征通道中提取全局信息，以便网络能够更好地理解整体图像的语义和内容。然后，在通道权重调整阶段，利用全局信息来计算每个通道的权重或重要性，这些权重会乘以相应的特征通道，以调整其对网络输出的贡献。通过这种方式，通道注意力机制能够让网络更加聚焦于重要的特征通道，并且自适应地调整它们的权重，以提高网络在特定任务上的性能表现。通道注意力已经成功应用于图像分类、目标检测、图像分割等各种图像处理任务中，并且取得了显著的性能提升。

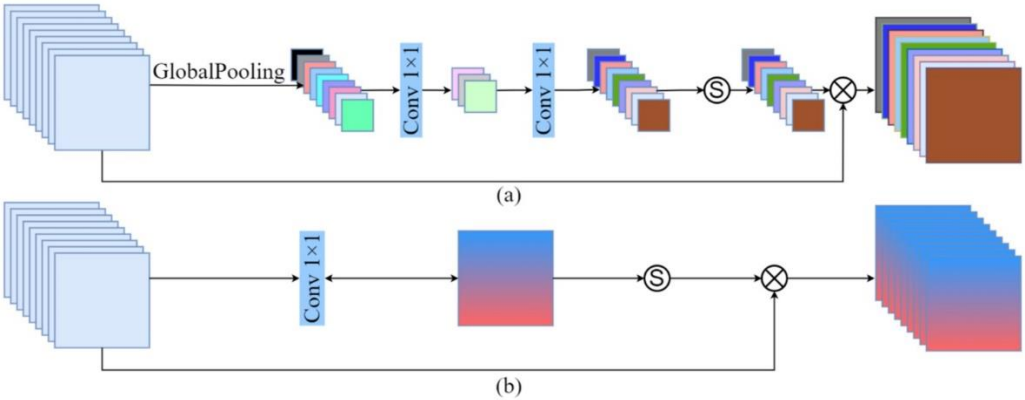


图 2.8(a) 通道注意力 (b) 空间注意力

如图 2.8(a) 所示，通道注意力机制是通过计算每个通道 channel 的重要性程度，对通道进行加权。通道注意模块通过利用特征图中通道之间的相互依赖关系，从而加强相互关联的特征响应，以提升特定语义信息的表示能力[37]。通道注意力的具体操作如图 2.8(a) 所示，假设输入特征图为 $X$，其尺寸为 $H \times W \times C$（$H,W$ 为特征图高与宽，$C$ 为通道数)。首先对特征图 $X$ 进行一次全局平均池化，得到池化后的输出 $y$，计算公式可表示为：

$$y_k = \frac{1}{w \times h} \sum_{i}^{w} \left( \sum_{j}^{h} X_k(i,j) \right) \tag{2.11}$$

其中，$y_k$ 为 $y$ 的第 $k$ 个像素，$w,h$ 为池化层大小，$X_k(i,j)$ 为 $X$ 第 $k$ 个特征在 $(i,j)$ 处的值。然后使用 sigmoid 函数作为门控机制来捕获特征通道间的相关性，公式如下：

$$f = sigmoid\left(conv1\left(\delta\left(conv1(y)\right)\right)\right) \tag{2.12}$$

其中 $conv1$ 是 $1\times1$ 卷积，将特征图 $y$ 进行降维，$\delta$ 指 Relu 函数，在被 Relu 函数激活后再采用 $conv1$ 进行升纬。最终得到输出 $F$：

$$F = f \cdot x \tag{2.13}$$

### 2.2.2 空间注意力 (special attention)

空间注意力是一种用于优化深度神经网络的技术，特别是在图像处理领域。它通过全局信息汇聚和空间权重调整两个关键步骤来实现。全局信息汇聚阶段首先从整个特征图中提取全局信息，以帮助网络更好地理解图像的空间结构和局部关系。随后在空间权重调整阶段，利用全局信息计算每个像素位置的权重或重要性，这些权重会与相应的像素值相乘，以调整其在网络输出中的贡献。通过这种方式，空间注意力机制能够让网络更加聚焦于图像的重要区域，并且自适应地调整它们的权重，以提高网络在特定任务上的性能表现。空间注意力已

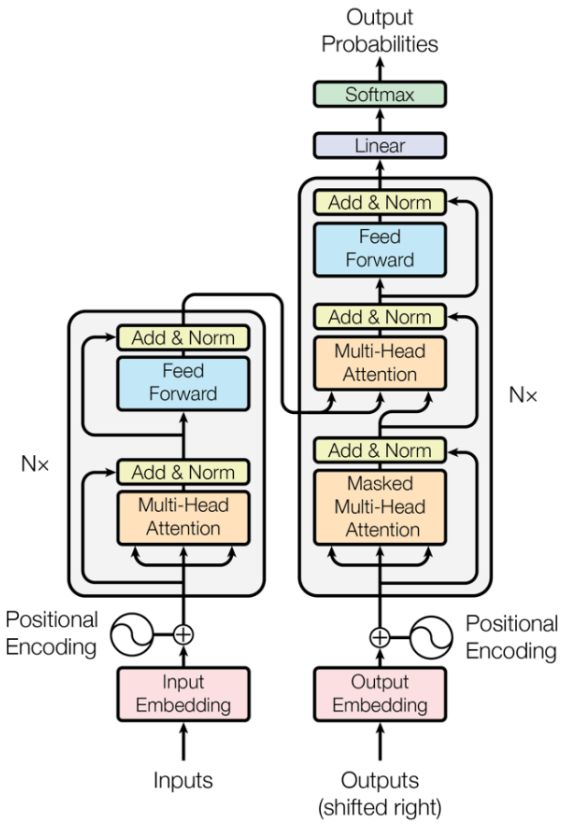


图 2.9 Transformer 网络结构示意图

被广泛应用于图像分类、目标检测、图像分割等各种图像处理任务中，并且在许多情况下都取得了显著的性能提升。

如图 2.8(b) 所示，空间注意力是使模型能够在同一通道内自适应地学习不同区域的注意力权重。空间注意力旨在通过将更广泛的上下文信息嵌入到局部特征中，以提升这些特征的表达能力和信息获取范围[37]。空间注意力在同一通道的特征图中突出和强调不同的空间位置信息。这使得网络的浅层可以提取空间信息，捕捉细粒度的空间细节。空间注意力的具体操作如图 2.8(b) 所示，假设输入特征 $X$，其尺寸为 $H \times W \times C$，分别通过最大池化操作 (MaxPool) 和平均池化操作 (AveragePool)，得到两个一维的权重向量 $H \times W \times 1$，然后将这两个权重向量进行拼接得到新的特征图空间向量 $H \times W \times 2$。使用 $1 \times 1$ 卷积再将特征图降纬到 $H \times W \times 1$，就可以得到同一通道内不同空间的权重值，权重越大表明该区域越重要。最终将该权重与输入的特征图进行相乘，这样可以使原始输入的特征图的每一空间区域都赋予权重。具体过程公式如下：

$$f = concat\left(H_{max}(X), H_{avg}(X)\right) \tag{2.14}$$

$$F = sigmoid\left(conv1(f)\right) \cdot X \tag{2.15}$$

其中 $H_{max}()$ 和 $H_{avg}()$ 分别为最大池化和平均池化操作。$f$ 为中间变量，$F$ 为最终输出。

### 2.2.3 Transformer

Transformer 最初在《Attention is All You Need》[36]取得成功，它允许模型在输入序列中动态地关注不同位置的信息。Transformer 结构示意图如图 2.9 所示。具体而言，Transformer 采用 encoder-decoder 框架，其中编码部分使用多头注意力和前馈网络。其中多头注意力可用如下公式描述：

$$\text{Attention}\left(Q,K,V\right)=\text{softmax}\left(\frac{QK^{T}}{\sqrt{d_k}}\right)V \tag{2.16}$$

其中$Q$是查询向量，$K$是键向量，$V$是值向量，$d_k$是键向量的维度。$\text{Attention}\left(Q,K,V\right)$指经过自注意力机制后得到的一个加权之后的特征向量，这里用$Z$指代，$Z=\text{Attention}\left(Q,K,V\right)$。

得到$Z$之后，进入 encoder 的下一个模块，即全连接前馈神经网络层。首先，输入向量$Z$通过一个线性变换，由输入向量的维度$d_{model}$转换为一个更高的维度$d_{off}$。这个线性变换由权重矩阵$W_1$和偏置向量$b_1$完成。然后再经历一次激活函数（非线性变化）和一次线性变换（由权重矩阵$W_2$和偏置向量$b_2$完成），同时降维到$d_{model}$。具体公式如下：

$$\text{FFN}\left(Z\right)=\max\left(0,ZW_1+b_1\right)W_2+b_2 \tag{2.17}$$

解码部分与编码部分相类似，主要区别在于解码部分多了一个 Encoder-Decoder Attention。

## 2.3 语义分割评价标准

判定语义分割技术的指标主要有分割准确度，推理速度，内存占用这三个指标。

(1) 分割准确度

分割准确度主要分为像素准确率 (pixel_accuracy) 和平均交并比 (MIoU)。其中像素准确率就是指预测像素的准确率高低的评价标准，像素准确率=预测正确像素个数/总预测像素个数。而交并比就是真实值和预测值的交集和并集之比，计算公式如下：

$$MIoU=\frac{1}{K}\sum_{i=1}^{k}\frac{P\cap G}{\text{P}\cup G} \tag{2.18}$$

其中$P$表示预测值，$G$表示真实值，$K$表示总类别个数。总体拉看，公式表示每个类别的预测值和真实值的交集除以并集，然后取平均。

(2) 推理速度

推理速度是指语义分割模型从接收图像输入到生成分割结果所需的时间，它对于实时应用场景非常重要，如自动驾驶和实时监控。高效的推理速度意味着模型能够快速准确地处理图像，支持及时的决策和反馈。这一指标受模型架构、输入图像分辨率和硬件设备性能等因素影响，优化方法包括简化模型结构、使用高效的算法和硬件加速器。

(3) 参数量

参数量是指深度学习模型中的参数总量，直接影响到模型的复杂度和精度。对于嵌入式设备、移动设备或资源受限的环境，如智能手机、自动驾驶车辆等，参数量是一个关键的考量因素。较小的参数量可以使得模型能够在资源受限的设备上运行，并降低功耗。

## 2.4 本章小结

本章首先介绍了卷积神经网络的基础理论，其中空洞卷积，深度可分离卷积以及分组卷积可以有效地降低模型参数量，之后介绍了注意力机制，分别讲解了通道注意力机制，空间注意力机制和 Transformer 的详细原理，以及这些注意力机制对于网络性能的影响。最后详细描述了本文涉及的语义分割评价标准，主要包括分割精度，推理参数和内存占用。

# 第三章 基于双分支信息融合的高效实时语义分割网络

## 3.1 引言

近年来，自动驾驶技术备受关注。在自动驾驶系统中，语义分割作为关键组成部分，使车辆能够通过车载摄像头感知周围环境，并对图像中的每个像素进行分类，以准确理解环境中各物体的变化情况。这种技术的实际应用要求模型不仅要在计算资源受限的边缘设备上展现出优异性能，还需要满足快速推理的严格要求。目前已有的实时语义分割模型可能在参数数量和推理速度方面表现出色，但往往面临着预测准确度不高的问题[38, 40, 46, 47]。而有些网络[35, 48, 49]以全卷积网络 (FCN)[33] 为基础框架取得了不错的分割效果，但是这些网络在参数量及推理速度方面难以满足实际的需求。因此，在保持预测准确性的前提下，设计一个参数更少的网络以便在边缘设备上部署，成为一个具有挑战性的课题。针对参数量和分割精度难以达到平衡的问题，本文提出了一种基于双分支信息融合的高效实时语义分割网络 (Dual-branch Fusion Network for Real-Time Semantic Segmentation,DFNet)。我们尝试采用深度可分离卷积以及分解卷积在不损失网络性能的情况下降低参数量，同时我们将空间注意力和通道注意力相结合，以融合浅层的空间信息和深层的语义信息，从而增强特征图的表示能力，提高网络最终的分割精度。主要工作如下：

(1) 本文提出了一种融合了空洞卷积和通道注意力的瓶颈结构 (图 3.3)。该模块通过扩展感受野以获取上下文信息，并且采用双分支融合和残差的结构，实现了全局上下文信息的融合，并且保持较低的参数量。我们称该模块为上下文信息融合 (Contextual Information Fusion,CIF) 模块。

(2) 本文提出了一种双分支信息融合的整体网络结构 (图 3.2)，其中一个分支具有较浅的深度，并配备了空间注意力模块用于提取空间细节信息，而另一个分支具有较深的深度，配备了通道注意力模块用于提取语义信息。最后，这两个分支的特征被融合起来，实现了浅层空间细节信息和深层语义信息的融合。我们称该网络为双分支信息融合网络(Dual-branch Fusion Network for Real-Time Semantic Segmentation ,DFNet)。

(3) 本文提出的双分支信息融合网络 (Dual-branch Fusion Network for Real-Time Semantic Segmentation, DFNet)，在 Cityscapes 和 CamVid 数据集上展现出理想的性能，而无需使用任何额外的数据增强技术。尽管模型大小仅为 0.66M，我们的网络在 Cityscapes 和 CamVid 数据集上取得了较好的分割结果，mIoU 分别达到了 71.2%和 68.43%。

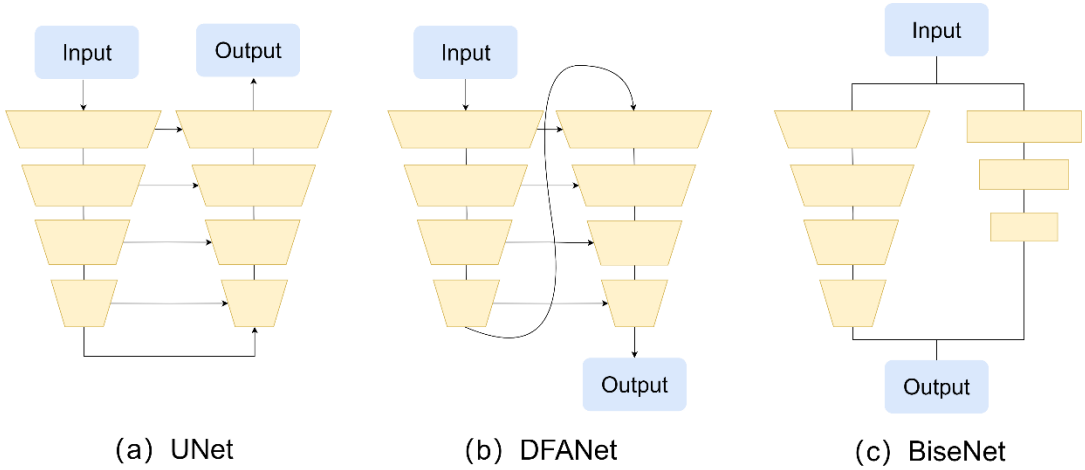


图 3.1 常用的语义分割模型主干

## 3.2 模型方法

本章节首先描述 DFNet 的整体框架，然后对里面的各个模块进行详细分析，DFNet 整体框架如图 3.2 所示。

### 3.2.1 网络结构

整体的网络结构是网络设计的重点，它直接影响着模型的性能。同时不同的结构会带来不同的优势和局限性。常用的语义分割网络主干如图 3.1 所示。图 3.1(a) 中 U-Net[34]的结构采用对称的结构，使用每个阶段都进行拼接的方式来融合特征图，但是这种结构会导致巨大的计算量。图 3.1(b) 中以 DFANet[50]为代表的特征重用结构，通过重复利用高层次特征，使模型在分割速度和分割性能之间取得了很好的平衡，但是却缺失空间细节信息。图 3.1(c) 中 BiseNet[39]提出的双分支结构则可以很好地兼顾高层次信息与空间信息。为此从 BiseNet 中获取灵感，我们设计了双分支信息融合的整体网络结构 (图 3.2)，分为语义分支和细节分支。其中语义分支负责深层语义信息的提取，另一个浅层的细节分支负责提取浅层空间细节信息，最后对两个分支的信息进行融合。具体的，DFNet 主要由上下文信息融合模块 CIF 组合而成。我们用 $I_{in}$ 表示网络模型的输入，用 $I_{out}$ 表示模型的输出。其中 $I_{in}$ 和 $I_{out}$ 的大小都为 $360\times480$ 。

我们首先将输入图像 $I_{in}$ 送入到由三个 $3\times3$ 卷积组成的初始化模块，用于提取图像的浅层特征：

$$F_{SF} = H_{conv\times3}^{3\times3}\left(I_{in}\right) \tag{3.1}$$

其中，$H_{conv}^{3\times3}$ 表示卷积核为 3 的卷积层，　$H_{conv\times3}^{3\times3}$ 表示 3 个 $3\times3$ 卷积层，$F_{SF}$ 为提取的浅层

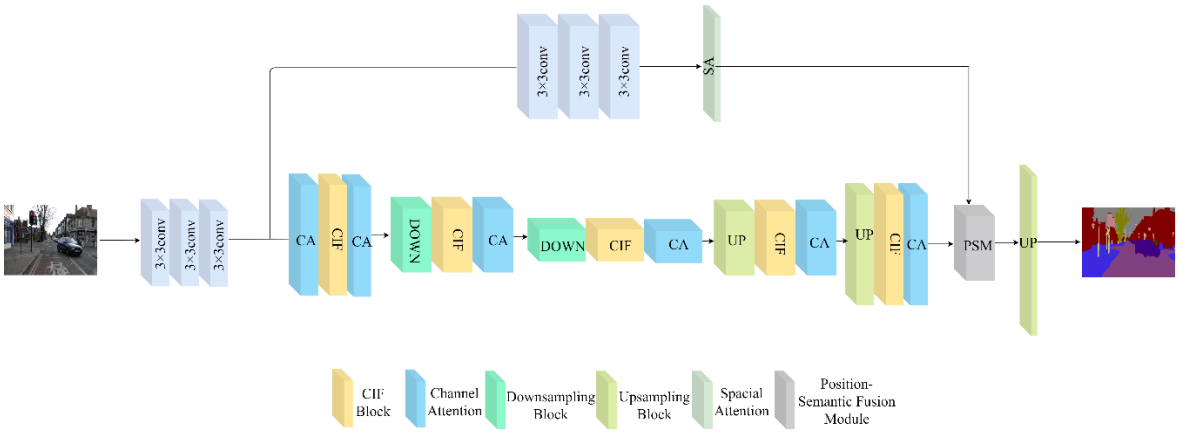


图 3.2 常用的语义分割模型主干

特征 (Shallow Feature)。

随后 $F_{SF}$ 被拆分成两份，分别被送入到细节分支和语义分支。细节分支主要由卷积层和空间注意力模块 SA(Spacial Attention) 构成，网络深度较浅，起到提取特征图中浅层空间细节信息的作用，同时空间注意力模块可以进一步突出重要的细节信息。细节分支的过程可以由如下公式表述：

$$F_{DF} = H_{SA}\left(H_{conv\times3}^{3\times3}\left(F_{SF}\right)\right) \tag{3.2}$$

其中，$H_{SA}$ 表示空间注意力模块，$F_{DF}$ 为细节分支输出的细节特征 (Detail Feature)。

语义分支包含了若干上下文信息融合模块 CIF(Context Information Fusion Module) 和通道注意力模块 CA(Channel Attention)，采用编码与解码的结构。该分支可以起到提取深层语义信息和实现上下文信息相融合的作用。在语义分支中，首先将浅层特征 $F_{SF}$ 进行下采样操作，将特征图的尺寸缩小 4 倍，以扩大感受野并获取更多上下文信息。为减少下采样时特征细节的丢失，我们采用两次下采样操作，每次将特征图缩小两倍。在每次下采样操作之后，将特征图依次送入 CIF 模块和 CA 模块，以提取语义信息并且通过利用通道之间的相互依赖性增强上下文信息的连通性。即：

$$F_{SF_{down}}'' = H_{CA}\left(H_{CIF}\left(H_{CA}\left(F_{SF}\right)\right)\right) \tag{3.3}$$

$$F_{SF_down}' = H_{CA}\left(H_{CIF}\left(H_{down}\left(F_{SF_down}''\right)\right)\right) \tag{3.4}$$

$$F_{SF_down} = H_{CA}\left(H_{CIF}\left(H_{down}\left(F_{SF_down}'\right)\right)\right) \tag{3.5}$$

其中 $H_{down}$ 表示下采样操作，$H_{CIF}$ 表示 CIF 模块，$H_{CA}$ 表示通道注意力。$F_{SF_down}$ 表示语义分支下采样之后的特征图，$F_{SF_down}''$ 和 $F_{SF_down}'$ 为中间变量。

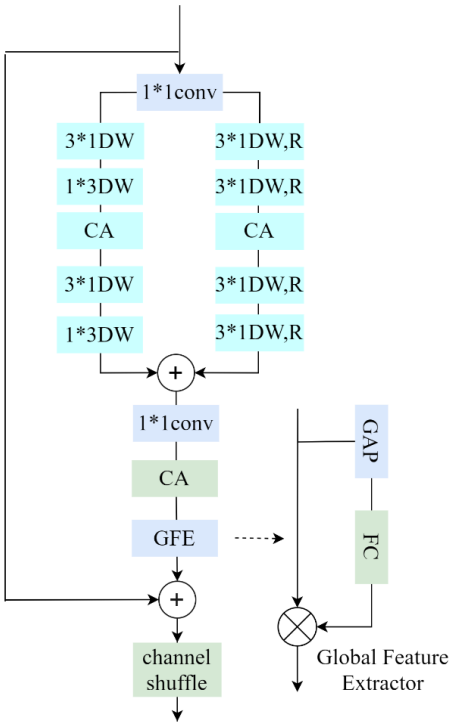


图 3.3 上下文信息融合模块 (CIF)

在得到语义信息的深层特征后，再利用上采样方法将特征图的尺寸放大 4 倍。与下采样相似，为减少特征信息的丢失，进行两次上采样，每次放大 2 倍。即：

$$F_{SF}' = H_{CA}\left(H_{CIF}\left(H_{up}\left(F_{SF_{down}}\right)\right)\right) \tag{3.6}$$

$$F_{SF} = H_{CA}\left(H_{CIF}\left(H_{up}\left(F_{SF}'\right)\right)\right) \tag{3.7}$$

其中 $H_{up}$ 表示上采样操作，$F_{SF}$ 为语义分支最终输出的特征图。具体地，语义分支部分共采用了 5 个 CIF 模块，每个 CIF 模块都由若干 CIF 单元组成，具体的单元个数分别为 5、5、16、3、3。

以往的不同特征相融合，普遍采用 concat 或者直接相加的方式。为更好地结合各部分特征，如图 3.4 所示，我们设计了细节分支和语义分支的信息融合模块 (PSM) 来实现细节特征与语义特征的融合。PSM 模块定义如下：

$$I_{out} = H_{up}\left(H_{PSM}\left(F_{DF}, F_{SF}\right)\right) \tag{3.8}$$

其中，$I_{out}$ 表示网络的最后输出结果，$H_{PSM}$ 表示 PSM 模块，将 $F_{DF}$ 与 $F_{SF}$ 相融合。

### 3.2.2 上下文信息融合模块

上下文信息融合 (Contextual Information Fusion,CIF) 模块采用了与 DABNet 类似的瓶颈网络结构。由 DABNet 可知，瓶颈结构可以减少网络模型中的参数数量[46]。此外，大量研究

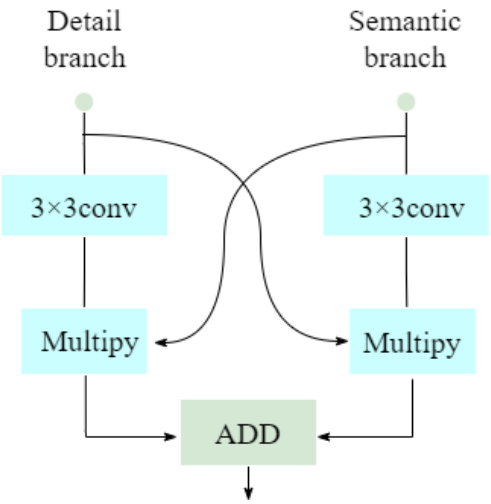


图 3.4 PSM 模块

表明上下文信息的重要性[37, 51-54]，多层次信息的结合可以显著提升预测的性能。因此，我们的 CIF 模块结构在瓶颈结构的基础上采用了双分支设计，每个分支专注于捕捉不同类型的信息。最终，两个分支提取的信息会在后续的阶段进行融合。

CIF 模块的整体架构如图 3.3 所示。其瓶颈部分采用了 1x1 卷积，以实现原始特征图通道数量的减半，从而显著降低了参数量和计算开销。随后，模块进一步呈现双分支结构。在左分支中，利用 3x1 和 1x3 的深度可分离卷积，专门捕获局部以及短距离的特征信息。深度可分离卷积的应用有效降低了模型的参数数量。右分支则采用 3x1 和 1x3 的深度可分离扩展卷积，以进一步扩大感受野，提取上下文信息。然后，两个分支的特征图相融合，达到了多层次信息的融合效果。其中扩张卷积采用不同的空洞率，将空洞率设置为 1, 2, 5, 9。

最后在 CIF 的后部，我们设计了全局特征提取器 (Global Feature Extractor,GFE) 来提取全局上下文信息，可以提高模块的全局特征提取能力。GFE 模块利用全局平均池化和全连接层，将输出视为加权向量，用于通道方向上的联合特征细化。这个过程强调有用的组成部分，同时抑制不相关的部分，实现全局上下文信息的加权聚合。完整的操作如下所示：

CIF 模块完整的过程可用如下公式表示：

$$F_l = DC_{1*3}\left(DC_{3*1}\left(f_{CAM}\left(DC_{1*3}\left(C_{1*1}\left(F_{in}\right)\right)\right)\right)\right) \tag{3.9}$$

$$F_r = DC_{r1*3}\left[DC_{r3*1}\left(f_{CAM}\left(DC_{r1*3}\left(DC_{r3*1}\left(C_{1*1}\left(F_{in}\right)\right)\right)\right)\right)\right] \tag{3.10}$$

$$F_{CIF} = f_{\text{channelshuffle}}\left(f_{gfe}\left(f_{CAM}\left(C_{1*1}\left(F_l + F_r\right)\right)\right) + F_{in}\right) \tag{3.11}$$

其中 $F_{in}$ 指 CIF 模块的输入特征图。$DC_{1*3}$ 指的是卷积核为$1\times3$的深度可分离卷积。$DC_{r1*3}$ 指的是卷积核为$1\times3$的深度可分离扩展卷积。$f_{CAM}$ 表示通道注意力模块，而 $f_{gfe}$ 表示全局上下

文提取模块。$f_{\text{channelshuffle}}$表示通道重排。$F_l$表示左分支的特征图，而$F_r$表示右分支的特征图。$F_{CIF}$表示该特征提取模块的最终输出特征图。$C_{1*1}$表示$1\times1$卷积。

### 3.2.3 注意力机制

(1) 通道注意力：高层特征的每个通道特征图可以被视为特定类别的响应，不同的语义响应彼此相关联[37]。应用通道注意力后，可以对不同通道进行加权，以强调重要的通道信息。此外，通过利用通道之间的相互依赖性，可以强调具有强语义表示的特定特征图，改善特定语义的表示并增强上下文信息的连通性。我们采用的通道注意力模块源自 ECANet[55]，它能在有限的计算资源下显著提高性能。道注意力的过程可以表示如下：

$$CA(F)=\sigma\left(f^{7\times7}\left(T\left(\text{Avg}P(F)\right)\right)\right)\times F \tag{3.12}$$

其中$F$表示输入特征，该模型使用的激活函数是 sigmoid 函数，用 σ 表示。还应用了一个卷积核大小为$7\times7$的标准卷积操作，用$f^{7\times7}$表示。$AvgP$表示该模型使用的平均池化操作，$T$表示对特征图的压缩、转换以及扩张。

(1) 空间注意力：空间注意力在同一通道的特征图中突出和强调不同的空间位置信息。这使得网络的浅层可以提取空间信息，捕捉细粒度的空间细节。我们受 CBAM [56]的启发结合了空间注意力。通过利用空间注意力，我们能够增强输入特征中重要的空间信息的表示，从而在需要捕捉空间关系的任务 (如图像识别或物体检测) 中提高性能。空间注意力的过程可以总结如下：

$$SA(F)=\sigma\left(f^{7*7}\left(concat\left[\text{Avg}P(F),\text{Max}P(F)\right]\right)\right)\times F \tag{3.13}$$

其中$concat$表示将不同的特征进行拼接操作，$MaxP$为最大池化。

## 3.3 实验设计与结果分析

### 3.3.1 实验方案

(1) 数据集

我们使用两个常用的城市街道场景数据集 Cityscape 和 CamVid 来评估 DFNet 的性能。其中 Cityscapes 包含 5000 张精细标签的图像和 19998 张粗略标签的图像。5000 张精细图像中，2975 张图像用于训练，500 张图像用于验证，1525 张图像用于测试。其图像分辨率为 1024×2048，

表 3.1 注意力机制对性能的影响

| Model | mIoU(%) | Parameters(M) |
|---|---|---|
| DFNet (w/o SAM) | 68.28 | 0.65 |
| DFNet (w/o CAM) | 67.16 | 0.65 |
| **DFNet** | **68.43** | **0.66** |

表 3.2 细节分支对性能的影响

| Model | mIoU(%) | Parameters(M) |
|---|---|---|
| DFNet (w/o detail batch) | 67.34 | 0.57 |
| **DFNet** | **68.43** | **0.66** |

表 3.3 CIF 模块空洞率的影响 (r 表示空洞率)

| Model | mIoU(%) | Parameters(M) |
|---|---|---|
| DFNet (r=1,1,1,1) | 67.73 | 0.66 |
| DFNet (r=2,4,8,16) | 68.22 | 0.66 |
| **DFNet (r=1,2,5,9)** | **68.43** | **0.66** |

分为 19 个语义类别。Camvid 数据集分辨率为 720×960，语义类别为 11。它包含 701 张图像，其中 367 张图像用于训练，101 张图像用于验证集，233 张图像用于测试。

(2) 参数设置

对于 Cityscapes 数据集，我们采用 momentum 为 0.9，权重衰减为$1\times10^{-4}$的 SGD(随机梯度下降) 优化算法来进行端到端的训练，并将 batchsize 设置为 4。该数据集使用 poly 学习率策略，将初始学习率设置为$4.5\times10^{-2}$，权重衰减为$1\times10^{-4}$，power 设置为 0.9。

对于 Camvid 数据集，我们采用了 Adam 优化方法，momentum 为 0.9，权重衰减为$2\times10^{-4}$，batchsize 为 8。该数据集使用初始学习率为$1\times10^{-3}$，power 为 0.9 的 poly 学习率策略。

在上述数据集上进行图像训练时，学习率是根据迭代次数进行调整的，并使用特定的公式进行计算。这些细节对于理解模型的架构以及如何训练以在这些数据集上获得准确的结果至关重要。同时，学习率会随着迭代次数的增加而改变，可以根据以下公式进行计算：

$$\mathrm{lr} = lr_{initial} \times \left(1 - \frac{iteration}{max_iteration}\right)^{0.9} \tag{3.14}$$

其中$lr_{initial}$指的是初始学习率。

### 3.3.2 消融实验

(1) 注意力机制的影响

为了评估使用注意力机制的有效性，我们分别将空间注意力模块和通道注意力模块去除，

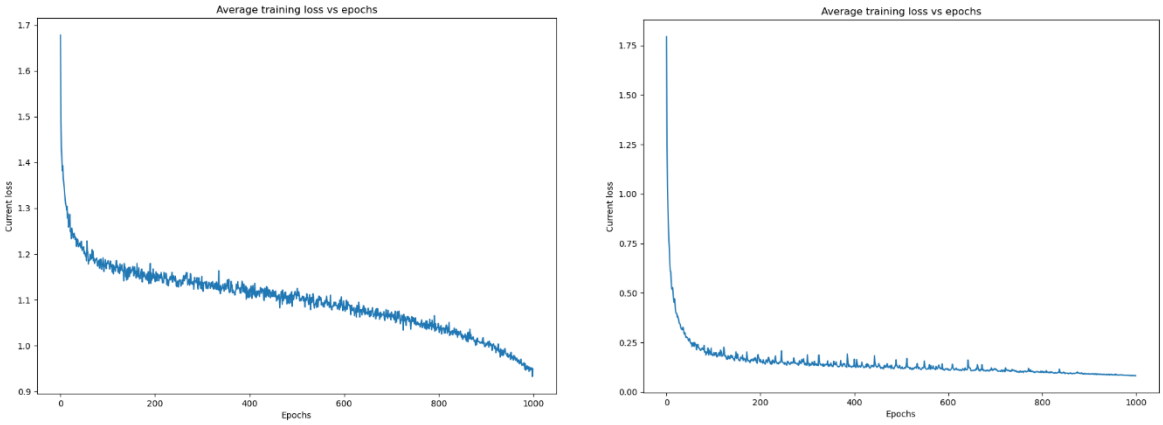


（a）Cityscapes 数据集训练损失曲线　　（b）CamVid 数据集训练损失曲线

图 3.5 损失函数-迭代次数曲线图

保持其他网络部分不变，在相同训练策略下在 CamVid 数据集上进行训练并比较。表 3.1 中第一个模型在原网络的基础上去除空间注意力模块，第二个模型则去除通道注意力模块，第三个模型则是原网络。从表 3.1 可以观察出，在使用空间以及通道注意力模块时 MFNet 的性能优于去除注意力的情况，且只有微量的参数量增加。这表明引入注意力机制可以以微量的参数量增大，获取更大的语义分割准确性。

(2) 细节分支的影响

为了证明细节分支有效性，即浅层细节信息对于网络性能的有效性，我们设计了一个模型变种进行比较。为了单纯去除细节分支，保留 PSM 模块，我们仅将细节分支上的卷积与空间注意力模块去除，使其无法通过卷积与空间注意力提取浅层细节信息。表 3.2 中，第一个模型是去除细节分支后的模型变种，第二个模型是原模型，在 CamVid 数据集上进行比较。从表 3.2 可以观察出，在不使用细节分支的情况下，性能下降明显，可见浅层细节信息的重要性。该实验证明，在模型中引入细节分支，即将深层语义信息与浅层细节信息相融合，可以显著提升网络性能。

(3) CIF 模块空洞率的影响

CIF 模块中扩展卷积不同的空洞率对模型预测结果有不同的影响。为验证该结论，并得出最优空洞率，我们设计了三个模型。第一个模型 CIF 中 4 个扩展卷积空洞率分别为 1,1,1,1。第二个模型空洞率设置为 2 的幂，即 2,4,8,16。第三个模型即原模型，空洞率设置为 1,2,5,9。该模型在 CamVid 数据集上进行比较。

从表 3.3 中可以看出，在 CamVid 数据集上，空洞率为 1,2,5,9 的模型精确度最优。该实验表明，CIF 模块中空洞率的不同会对模型精确度造成影响，且当空洞率设置为 1,2,5,9 时，模型可以取得最优性能。

表 3.4 Cityscapes 测试集上的预测结果

| 方法 | 时间 | 输入图像尺寸 | Params(M) | Speed(FPS) | mIoU(%)↑ |
|---|---|---|---|---|---|
| SegNet[57] | 2017 | 640×360 | 29.5 | 17 | 57.0 |
| ENet[38] | 2016 | 512×1024 | 0.36 | 135 | 58.3 |
| SQNet[58] | 2016 | 1024×2048 | 16.25 | 17 | 59.8 |
| ESPNet[40] | 2018 | 512×1024 | 0.36 | 113 | 60.3 |
| NDNet [59] | 2021 | 1024×2048 | 0.5 | 40 | 65.3 |
| ESPNet-v2 [60] | 2019 | 512×1024 | 0.66 | 80 | 66.2 |
| ERFNet [52] | 2017 | 512×1024 | 2.10 | 42 | 68.0 |
| BCPNet [61] | 2020 | 512×1024 | 0.61 | 250 | 68.4 |
| CFPNet [62] | 2021 | 1024×2048 | 0.55 | 30 | 70.1 |
| FPENet [63] | 2019 | 512×1024 | 0.40 | 55 | 70.1 |
| LEDNet [64] | 2018 | 512×1024 | 0.94 | 40 | 70.6 |
| SGCPNet [65] | 2022 | 1024×2048 | 0.61 | 103 | 70.9 |
| DFANet [50] | 2019 | 1024×2048 | 7.80 | 100 | 71.3 |
| MSCFNet [66] | 2021 | 512×1024 | 1.15 | 50 | 71.9 |
| STDC1-50 [67] | 2021 | 512×1024 | 8.40 | 87 | 71.9 |
| FPANet [68] | 2021 | 512×1024 | 14.10 | - | 72.0 |
| DFNet(ours) | 2023 | 512×1024 | 0.66 | 50 | 71.2 |

表 3.5 Camvid 测试集上的预测结果

| 方法 | 时间 | 输入图像尺寸 | Params(M) | Speed(FPS) | mIoU(%)↑ |
|---|---|---|---|---|---|
| ENet [38] | 2016 | 360×480 | 0.36 | 61 | 51.3 |
| SegNet [57] | 2017 | 360×480 | 29.50 | 29 | 55.6 |
| DFANet [50] | 2019 | 720×960 | 7.80 | 120 | 64.7 |
| BiseNet-v1 [39] | 2018 | 720×960 | 5.80 | 116 | 65.6 |
| DABNet [46] | 2019 | 360×480 | 0.76 | - | 66.4 |
| FDDWNet [69] | 2020 | 360×480 | 0.80 | 79 | 66.9 |
| ICNet [70] | 2018 | 720×960 | 26.50 | 28 | 67.1 |
| LBN-AA [71] | 2021 | 720×960 | 6.20 | 39 | 68.0 |
| DFNet(ours) | 2023 | 360×480 | 0.66 | 70 | 68.43 |

### 3.3.3 与其他方法的比较

我们将 DFNet 在 Cityscapes 和 CamVid 数据集上和多个模型进行了比较。如表 3.4 和表 3.5 所示，DFNet 分别在 Cityscapes 和 CamVid 数据集上取得了 68.43%和 71.2%的性能。在 Cityscapes 数据集的比较中，DFNet 与 SGCPNet[65]相比仅多了 0.05M 的参数，但性能提高了 0.3%。此外，尽管参数比 LEDNet[64]少且推理速度更快，DFNet 的性能却比 LEDNet 高 0.6%。MFNet 在模型大小、推理速度和分割准确性之间取得了良好的平衡。图 3.4 和图 3.5 展示了在 Cityscapes 和 CamVid 数据集上与一些相关方法的比较，更加直观地验证了 DFNet 的有效性。

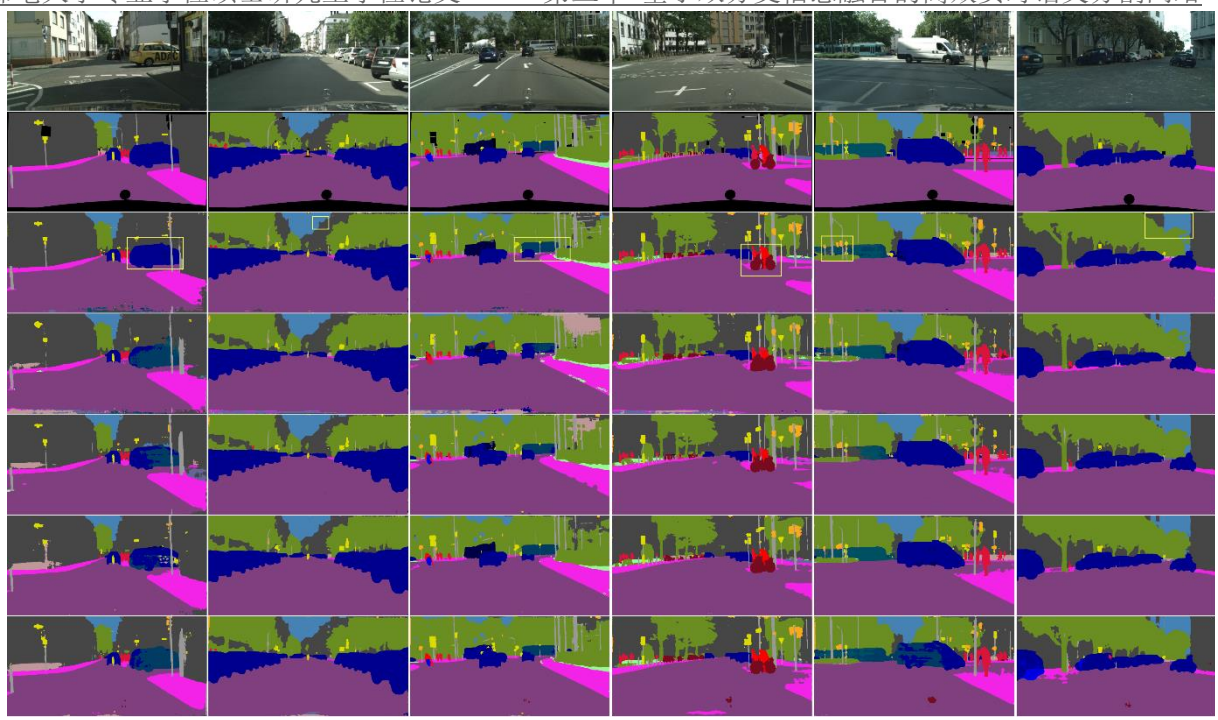

图 3.4 Cityscapes 测试集的比较结果。从上到下依次是：原始图像、真实值、DFNet、ESPNet、ERFNet、DABNet 和 LEDNet 的分割结果。

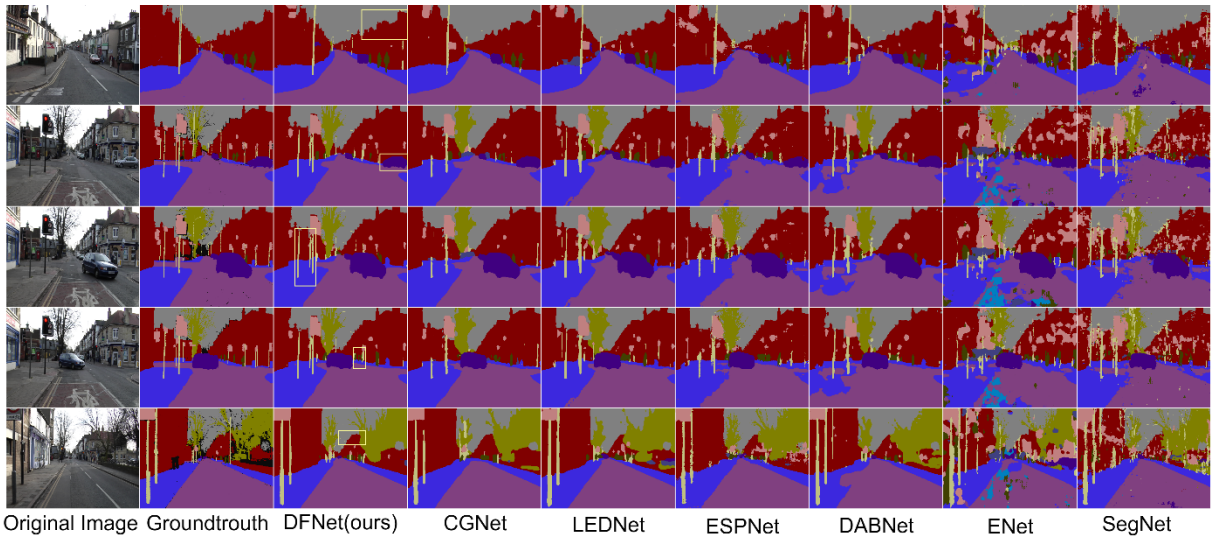


图 3.5 Camvid 测试集的比较结果。从左到右依次是原始图像、真实值、以及 DFNet、CGNet、LEDNet、ESPNet、DABNet、ENet、SegNet

## 3.4 本章小结

在本章中，我们提出了一种用于实时语义分割的双分支融合网络 (DFNet)。我们模型设计着重于在预测准确性、模型大小和推理速度之间实现平衡。我们提出的 CIF 模块利用了空洞卷积和通道注意力，可以扩大感受野并提取深层的语义信息。大量研究表明不同层次的信息融合可以增强网络的精度。因此，我们设计一个双分支 (细节分支和语义分支) 的整体网络

结构和一个空间信息和语义信息的融合模块 (PSM)。细节分支网络深度较浅，适用于提取浅层空间信息，而语义分支网络深度较深，适用于提取深层语义信息。最后，通过 PSM 将语义信息和空间信息进行融合。

# 第四章 基于多尺度上下文信息融合的实时语义分割网络

## 4.1 引言

随着技术的飞速发展，语义分割技术在越来越多的场景中得到应用。然而，这些场景往往对边缘设备的计算资源有限，并要求模型具备快速推理速度和高精度预测。因此，语义分割模型的设计需要在保持参数量和计算量低的前提下，尽可能提高模型的精度。Enet [38]采用了残差网络的结构设计，通过紧凑的编码解码结构实现了较小的参数量和较快的推理速度。然而，由于减少了卷积层的数量，导致模型精度偏低。DANet [37]模型引入了双注意力机制，能够更好地捕捉全局和局部信息。但是该模型缺乏多层次信息的融合，导致特征信息的丰富性不足。Bisenet [39]采用双分支的结构，实现了底层细节信息与高层语义信息的融合，性能表现良好。但是由于较深的网络结构，计算量巨大。在卷积神经网络中，随着网络深度的增加，能够提取更多深层次的语义特征，从而提高模型性能，但是这也会增加网络的计算量，并可能导致丢失大量边界信息。因此未来的研究方向应该致力于设计更加高效的模型结构，兼顾参数量、计算量和精度，以满足不同场景的需求。可能的方向包括结合注意力机制与残差网络，以及利用轻量级网络结构和多尺度信息融合的方法来提高模型性能。本文第三章中的 DFNet 采用了双分支融合并且结合了注意力机制与残差网络取得了不错的效果。但是 DFNet 缺乏多尺度信息的融合，由于物体尺寸的不确定性，单一特征尺度不能满足高精度识别性能的要求，增加多尺度可以进一步提升精度。为了在网络计算量和精度之间取得更好的平衡，我们提出了用于实时语义分割的多尺度特征信息融合网络 (Multi-Scale Feature Fusion Network，MFNet)。该网络同样采用双分支的结构，并且引用了多尺度信息融合注意力机制，以进一步丰富特征信息。在确保精度优异的前提下，MFNet 能够有效减少模型的计算量。本章设计的 MFNet 主要贡献有以下三点：

(1) 提出了多尺度特征提取与融合 (MEF) 模块，MEF 模块以深层特征提取单元 (DEU) 为基础进行多尺度特征的提取。在该模块中，通道数随着网络层的加深逐步减少，从而使浅层具有足够的通道用小的感受野来编码细节信息，而具有更大感受野的高层更关注高级语义信息，较少的通道数可以避免信息冗余。同时 MEF 模块中设置了跳跃连接 (skip-path) 将每个阶段的特征进行拼接，进一步丰富特征信息。

(2) 提出了多尺度信息融合 (MIF) 模块，改进了解码部分。如图 4.5，MIF 使用空间注意力模块，上采样模块以及 sigmoid 激活函数，将上采样后的特征信息与特征提取阶段的信息

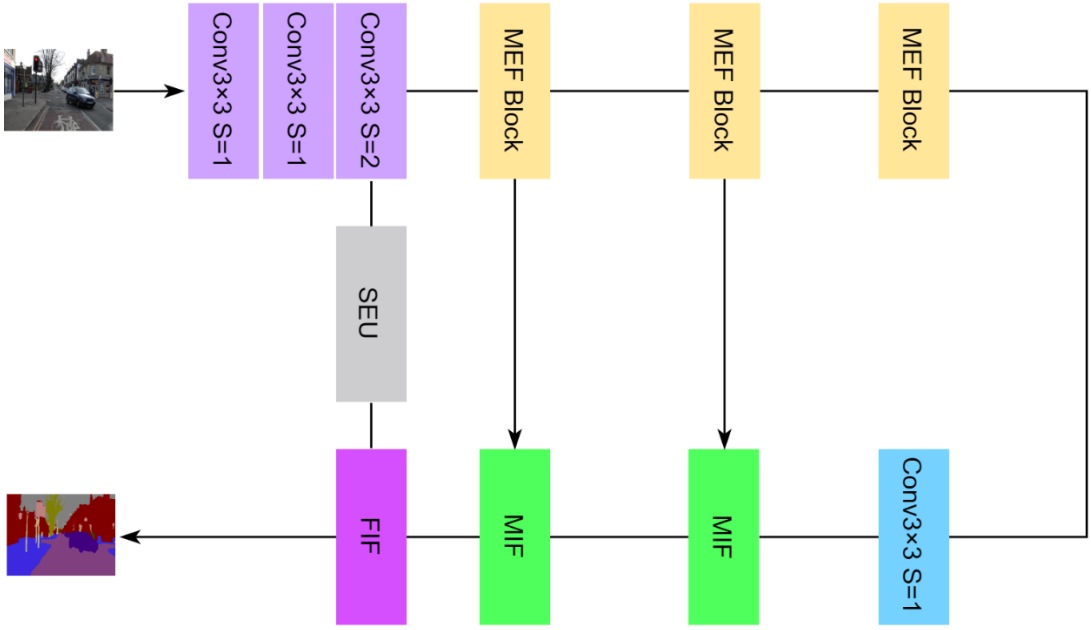


图 4.1 MFNet 整体网络框架

融合，可以解决上采样后特征图细节信息受损的问题，提高网络性能。

(3) 提出了多尺度上下文信息融合的轻量级网络 (MFNet)，在 Cityscapes 和 CamVid 数据集上表现出色，尽管模型大小仅为 0.89M，MFNet 在 Cityscapes 和 CamVid 数据集上取得了较好的分割结果，mIoU 分别为 71.6%和 68.92%。

## 4.2 模型方法

### 4.2.1 特征提取单元

(1) 深层特征提取单元：针对深层次的语义信息，本章设计了深层特征提取单元 (Deep Feature Extraction Unit,DEU)，用于语义分支提取深层特征信息。本单元吸纳了第三章 DFNet 中 CIF 单元的优点，采用了左右双分支的特点，一条分支负责提取短距离的局部特征信息，另一条负责扩大感受野提取远距离的上下文信息。如图 4.2(a) 所示，本单元采用瓶颈结构的设计，在单元的最前端采用通道拆分的方法，将输入的特征图通道分成两个低纬度支路，每个支路只有一半的输入通道数。这样可以大大减少模型的计算量，同时可以保留特征信息，提高系统容错率。在双分支结构处，采用了卷积分解这一策略，也就是将 $K\times K$ 的卷积分解成 $K\times 1$ 及 $1\times K$ 这两个卷积，这样可以在保证效果的前提下降低模型参数。其中左分支将两个深度可分离卷积分解成两对 $1\times 3$ 和 $3\times 1$ 的深度卷积提取局部特征信息。右分支则将两个带扩展的深度卷积进行同样的分解，以扩大感受野从而来提取远距离的上下文信息。之后使用 concate 将两个分支的特征图进行融合，将通道数恢复成初始状态，并且采用通道注意力模块，

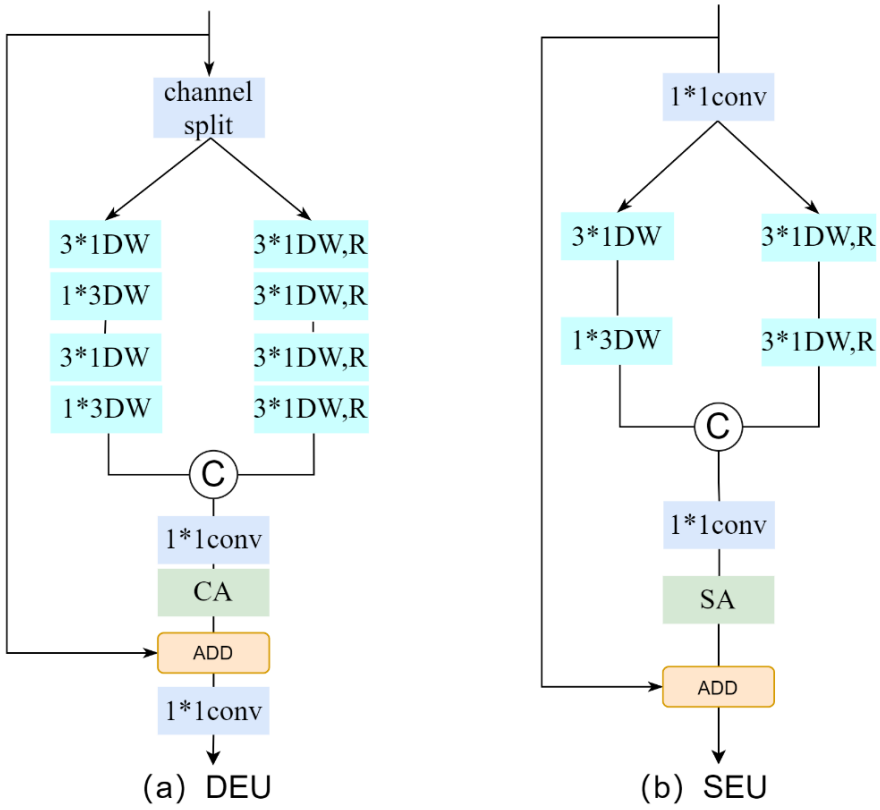


图 4.2 深层特征提取单元 (DEU) 和浅层特征提取单元 (SEU)

来强调重要的特征信息并抑制噪声干扰。最终在单元输出前设置一个1×1卷积，用以后续按照需求改变最终输出的特征图通道数。以上操作，公式如下：

$$X_1, X_2 = C_{sp}\left(X_{in}\right) \tag{4.1}$$

$$X_l = C_{dw1\times3}\left(C_{dw3\times1}\left(C_{dw1\times3}\left(C_{dw3\times1}\left(X_1\right)\right)\right)\right) \tag{4.2}$$

$$X_r = C_{ddw1\times3}\left(C_{ddw3\times1}\left(C_{ddw1\times3}\left(C_{ddw3\times1}\left(X_1\right)\right)\right)\right) \tag{4.3}$$

$$X_c = \mathrm{Concat}\left[X_l, X_r\right] \tag{4.4}$$

$$X_{\mathrm{out}} = C_{1\times1}\left(X_{\mathrm{in}} + CAM\left(C_{1\times1}\left(X_c\right)\right)\right) \tag{4.5}$$

其中 $C_{dw3\times1}$，$C_{dw1\times3}$ 表示深度分解卷积，$C_{ddw1\times3}$，$C_{ddw3\times1}$ 表示带空洞的深度分解卷积，$C_{sp}$ 表示通道拆分操作，$CAM$ 表示通道注意力模块。

(2) 浅层特征提取单元：当网络深度不断增加时有利于语言信息的提取，但是浅层的细节信息会逐步丢失。为了解决这个问题，我们专门设计了浅层细节信息提取单元 (Shallow Feature Extraction Unit,SEU) 用于细节分支以提取细节信息。如图 4.2(b) 所示，浅层信息提取单元采用更浅的网络层设计。在单元最前端同样采用通道拆分的方法将特征图拆分到双分支进行特征提取。左右分支相较于双分支特征提取单元减少了两个分解卷积。最后使用位置注

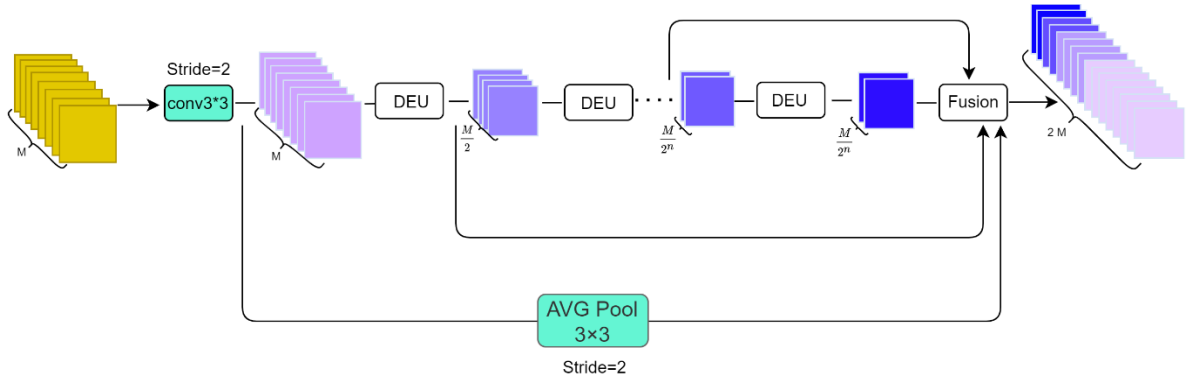


图 4.3 多尺度特征提取与融合 (MEF) 模块

意力模块对细节信息进行加权和抑制噪声。具体操作公式如下：

$$X_l = C_{dw1\times3}\left(C_{dw3\times1}\left(C_{1\times1}\left(\mathrm{X}\right)\right)\right) \tag{4.6}$$

$$X_r = C_{ddw1\times3}\left(C_{ddw3\times1}\left(C_{1\times1}\left(\mathrm{X}\right)\right)\right) \tag{4.7}$$

$$X_c = \mathrm{Concat}\left[X_l, X_r\right] \tag{4.8}$$

$$X_{\mathrm{out}} = \left(X_{\mathrm{in}} + CAM\left(C_{1\times1}\left(X_c\right)\right)\right) \tag{4.9}$$

### 4.2.2 多尺度特征提取与融合模块

在语义分割任务中，由于物体尺寸的不确定性，单一特征尺度不能满足高精度识别性能的要求，我们需要注重可扩展的感受野和多尺度信息[67]。原始的多尺度方法[72]将原图缩放成不同大小和尺寸，经过相同参数的网络结构后，得到不同尺寸的输出，然后将这些输出进行融合，得到多个尺度特征图，从而得到最后的输出。这种多尺度方法显著提高了性能，但是代价是需要在不同尺度下计算每一层的特征响应，这增加了计算的复杂性和成本。Spp[73]和Aspp[48]则提出可以通过对提取的卷积特征进行重采样，来准确且高效地分类任意尺度的区域。由 SPP 和 ASPP 的多尺度方式中获得灵感，我们设计了全新的多尺度特征提取与融合 (Multi-scale feature extraction and fusion，MEF) 模块。如图 4.3 所示，在该模块中，我们使用 DEU 作为基本的特征提取单元，其中模块中第一个单元处设置卷积步长为 2 的 $3\times3$ 卷积，将特征图尺寸降为原来的 1/2。MEF 模块中通道数随着网络层的加深而减少，可以使低层具有足够的通道用小的感受野来编码细节信息，具有更大感受野的高层则专注于高级语义信息，较少的通道数可以避免信息冗余。假设给定 MEF 模块输入的通道数 $M$，设定该模块输出的通道数为 $2M$，第 $i$ 个块中卷积层的滤波器数量为 $\frac{2M}{2^i}$，最后一个卷积层的通道数量与前一个卷积层

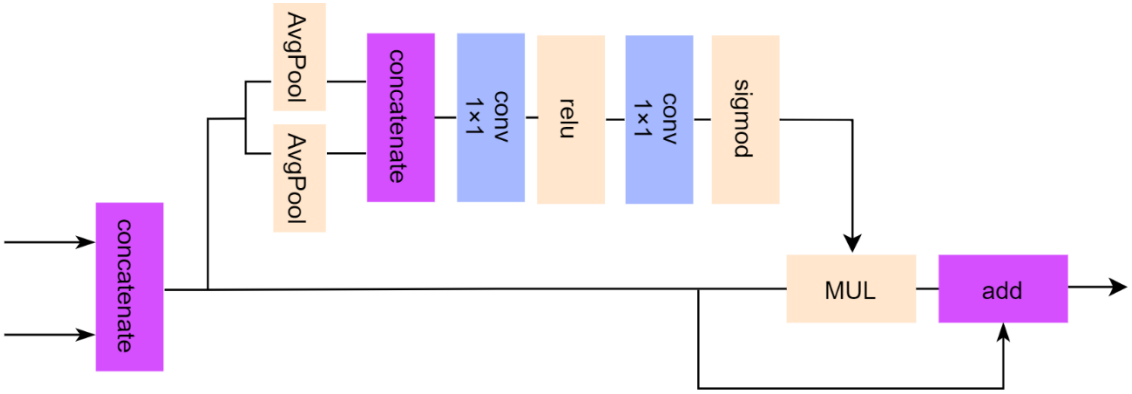


图 4.4 特征信息融合 (FIF) 模块

相同，最终将每个阶段的特征图通过跳跃连接 (skip-path) 进行拼接可以使模块输出特征图通道数为 $2M$ 。

我们在 MEF 中不同阶段的 DEU 中的空洞卷积设置不同扩张率。由于在语义分割任务中低层次的网络层更适合编码细粒度的信息，我们在 MEF 模块中靠前的位置设置较小的空洞率，这样可以用较小的感受野提取细节信息。在高层次网络层，即 MEF 模块中靠后的位置设置较大的扩张率，用较大的感受野提取高层次信息。同时不同阶段使用不同的空洞率可以避免格栅效应。具体的扩张率设置如表 4.1 所示。MEF 模块的操作过程可用公式表示：

$$x_1 = C_{3\times3}\left(x_0\right) \tag{4.10}$$

$$x_i = DEU_i\left(x_{i-1}\right) \tag{4.11}$$

$$x_{out} = \mathrm{concat}\left(x_1, x_2, \ldots, x_n\right) \tag{4.12}$$

其中 $DEU_i$ 表示第 $i$ 个 $DEU$ 操作， $x_{i-1}$， $x_i$ 为其输入和输出， $x_0$ 为 MEF 模块的输入特征.

### 4.2.3 特征信息融合模块

将网络浅层细节信息和深层语义信息进行融合，采用直接元素相加或者特征拼接是最常见也是最简单的方法。但是因为两条路径上的特征表示的层次不同，一条路径捕获了图像中的细节信息，而另一条路径捕获了深层的语义信息，直接相加或拼接会造成信息丢失或混淆。因此，我们提出了特征信息融合 (Feature Information Fusion，FIF) 模块来融合这些特征。具体而言，我们将平均池化分解为在水平和垂直两个维度上的池化操作，对特征信息进行全局平均池化时采用一对一维方法。两个特征信息分别为 $X_1 \in R^{C\times H\times W}$ 和 $X_2 \in R^{C\times H\times W}$ ，拼接之后为特征信息 $X \in R^{C\times H\times W}$ 。我们使用大小分别为 (H,1) 和 (1,W) 的平均池化层将特征信息$X$进行编码，得到两个方向的注意力图，其中一个方向负责捕获远距离的依赖关系，另一个方向则

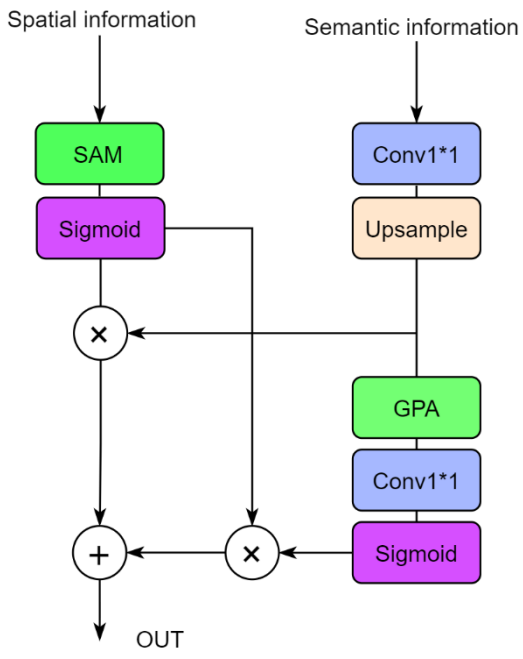


图 4.5 多尺度信息融合 (MIF) 模块

保留了精确的位置信息。FIF 模块具体如图 4.4 所示，以上操作具体公式如下：

$$F = C_{1\times1}\left(\left[f^{H}_{\text{AvgPool}}(X), f^{W}_{\text{AvgPool}}(X)\right]\right) \tag{4.13}$$

其中 $f^{H}_{\text{AvgPool}}$ 表示沿着 $H$ 方向上的平均池化操作，$f^{w}_{\text{AvgPool}}$ 则表示沿着 $W$ 方向。在对特征 $X$ 进行一对一维平均池化之后，将两个方向的特征进行拼接，并且进行 $1\times1$ 卷积操作将通道数恢复。接下来，我们参考类似于 SENet[74]的方式，我们对池化后的特征计算一个特征向量，该权重向量可以重新调整特征的权重，这就相当于我们可以选择并组合各种特征，以便最终得到更好的表示。具体操作公式如下：

$$Y = X + \left(X \times \sigma\left(C_{1\times1}\left(Relu(F)\right)\right)\right) \tag{4.14}$$

其中 $Y$ 表述最终的输出特征图。

### 4.2.4 多尺度信息融合模块

大多数现有方法在解码阶段采用简单的双线性插值方法来上采样特征图像，但是这种方式通常会丢失浅层细节，导致分割效果不佳。为解决以上问题，我们在解码处设计了多尺度信息融合 (Multi-scale Information Fusion，MIF) 模块。如图 4.5 所示，MIF 模块有效地在不同阶段集成了空间信息和语义信息。右分支先通过 $1\times1$ 卷积将语义信息的通道数减半，然后将其上采样到两倍的图像分辨率。在通道维度上对特征图进行全局平均池化，以获取它们的全局值。特征图继续通过 $1\times1$ 卷积和激活函数来归一化每个通道的权重。左分支中低级的空间信

息则经过空间注意力模块处理以保留更多的空间细节信息，然后经过激活函数生成空间注意力权重。空间注意力值分别与高级输入特征的归一化权重和通道注意力值相乘。最后，两个值按元素相加得到各个解码器组件的最终输出。MIF 模块的具体操作流程可以用以下方程描述：

$$X_{\text{sigmoid}}^{sp} = \sigma\left(\text{SAM}\left(X_{sp}\right)\right) \tag{4.15}$$

$$X_{\text{sigmoid}}^{se} = \sigma\left(C_{1\times1}\left(\text{GAP}\left(\text{Upsample}\left(C_{1\times1}\left(X_{se}\right)\right)\right)\right)\right) \tag{4.16}$$

$$X_{\text{out}}^{sp} = X_{\text{sigmoid}}^{sp} \times \left(\text{Upsample}\left(C_{1\times1}\left(X_{sp}\right)\right)\right) \tag{4.17}$$

$$X_{\text{out}} = X_{\text{out}}^{sp} + X_{\text{sigmoid}}^{sp} \times X_{\text{sigmoid}}^{se} \tag{4.18}$$

其中 $X_{sp}$， $X_{se}$ 分别表示输入的空间信息和语义信息， $X_{\text{sigmoid}}^{sp}$ 表示空间信息经过 sigmoid 函数处理后的特征图， $X_{\text{sigmoid}}^{se}$ 表示语义信息经过 sigmoid 函数处理后的特征图， $\sigma$ 表示 sigmoid 激活函数， GAP 表示全局平均池化。

### 4.2.5 整体网络结构设计

网络整体采用 SegNet 提出的编码解码结构。整个网络可以分为三部分，初始模块，编码模块和解码模块。

(1) 初始模块

初始模块采用了三个 3×3 卷积层，第一个卷积层的步长设置为 2，以便在初始阶段有效地捕获特征。与其他模型不同的是，该初始块仅进行一次降采样操作，以确保空间信息的有效保留。作为双分支网络的分界点，初始块有助于促进语义信息与空间信息之间的关联，同时为后续的特征融合奠定了基础。

(2) 编码部分

如图 4.1 所示，我们在编码部分使用了三个多尺度特征提取与融合模块(MEF)，由于 MEF 模块同时具有下采样的功能，编码部分省略了下采样模块。具体而言，每个 MEF 模块可将特征图进行下采样，尺寸缩小一半，通道数增加一倍，扩大感受野，以收集更多的上下文信息。同时增加通道数可以丰富特征信息，提高网络的泛化能力，减少过拟合风险。然而，减小特征图的分辨率会导致空间边界信息的丢失。考虑到这些因素，我们只进行三次下采样，每次下采样仅将尺寸缩小一半。三个 MEF 模块中的 DEU 个数是不同的。第一阶段的 MEF 模块设置 3 个 DEU，第二阶段使用 5 个 DEU，第三阶段使用 10 个 DEU。每个阶段的空洞率也不同，具体如表 4.1。

表 4.1 MEF 模块中空洞率设置

| MEF 模块 | 空洞率 |
|---|---|
| 1 | r=1, 2,5 |
| 2 | r=1, 1, 2, 2,5 |
| 3 | r=1,2,5,7,9,2,5,7,9,17 |

表 4.2 训练参数设置

| 数据集 | Cityscape | Camvid |
|---|---|---|
| 批次大小 | 4 | 6 |
| 损失函数 | 交叉熵损失函数 (CrossEntropy Loss) | |
| 优化方法 | SGD（随机梯度下降,动量 0.9） | Adam（动量 0.9） |
| 权重衰减 | $1\times10^{-4}$ | $2\times10^{-4}$ |
| 初始学习率 | $4.5\times10^{-2}$ | $1\times10^{-3}$ |
| 学习率变化策略 | Poly | |

(3) 解码部分

如图 4.1 所示，首先使用一个3×3卷积将解码部分输出的特征图不同通道的特征进行融合。然后使用 MIF 模块重复使用第二和第三阶段的特征，并对它们进行上采样，以提高图像分辨率。之后使用 FIF 模块融合浅层的细节信息和深层的语义信息。最后上采样操作将特征图像恢复到原始图像的分辨率。

## 4.3 实验设计与结果分析

### 4.3.1 数据集

(1)Cityscapes 数据集是一个包含大量城市街景图像的数据集。它包括 2975 张用于训练、500 张用于验证和 1525 张用于测试的图像，共计 5000 张街景照片。该数据集的分辨率为 1024×2048，并且有 30 种标记对象，但只有 19 种用于语义分割。

(2)CamVid 是一个从驾驶汽车视角收集的道路场景数据集。它包括 367 张用于训练、101 张用于验证和 233 张用于测试的图像，共计 701 张从视频中提取的带有标注的图像。CamVid 数据集的分辨率为 720×960，并且有 32 种标记对象，但只有 11 种用于语义分割。

### 4.3.2 参数设置

本章网络模型采用Pytorch深度学习框架进行搭建，并且使用单张RTX 2080Ti进行训练，

表 4.3 SEU 对性能的影响

| Model | mIoU(%) | Parameters(M) | Speed(FPS) |
|---|---|---|---|
| MFNet (w/o SEU) | 67.86 | 0.82 | **98** |
| MFNet (conv+SAM) | 68.46 | 0.84 | 89 |
| **MFNet(SEU)** | **68.92** | **0.89** | 94 |

表 4.4 FIF 模块对性能的影响

| Model | mIoU(%) | Parameters(M) | Speed(FPS) |
|---|---|---|---|
| MFNet (Add) | 68.31 | 0.87 | **101** |
| MFNet (concat) | 68.42 | 0.87 | 100 |
| MFNet (PSM) | 68.58 | 0.88 | 98 |
| **MFNet(FIF)** | **68.92** | **0.89** | 94 |

表 4.5 MEF 模块中的多尺度特征对性能的影响

| Model | mIoU(%) | Parameters(M) | Speed(FPS) |
|---|---|---|---|
| MFNet (w/o Multi-scale) | 67.78 | 0.85 | **111** |
| **MFNet** | **68.92** | **0.89** | 94 |

CUDA 版本为 11.1。MFNet 在 Cityscapes 和 CamVid 数据集上的详细训练参数如表 4.2 所示，其中学习率实时变化，可通过公式 $lr_{initial} \times \left(1-\frac{iteration}{max_iteration}\right)^{0.9}$ 计算得到。两个数据集训练的 Epoch 都为 1000。

### 4.3.3 消融实验

在本节中，我们依次在 Camvid 数据集上对每个模块进行消融实验，以验证这些模块的有效性。

(1) 浅层信息提取单元 (SEU)

SEU 是我们设置在细节分支中用于提取浅层信息的单元。为了验证其有效性，我们设置了两个对照实验与原本的模块进行对比。第一个实验我们将 SEU 完全去除，第二个实验我们用第三章细节分支中的模块（三个普通卷积和一个空间注意力模块）替代 SEU 单元。最终结果如表 4.3 所示，SEU 完全去除后参数量下降 0.07M，但是精度下降了 1.06%，同样如果用第三章细节分支中的模块代替 SEU，虽然参数量下降了 0.05M，分割精度却损失 0.46%，由此可知 SEU 可以有效提高模型性能。

(2) FIF 模块

FIF 模块是专门用于对浅层细节信息和深层语义信息进行融合的。为了验证该模块的有效性，我们设置了三个对照实验与具有 FIF 模块的模型进行对比。其中第一个和第二个实验我们方便用简单的相加 (ADD) 和拼接 (Concat) 替换 FIF，第三个实验我们用第三章中的

表 4.6 Cityscapes 测试集上的预测结果

| Method | Pretrain | Input Size | mIoU(%)↑ | Params(M)↓ | Speed(FPS)↑ |
|---|---|---|---|---|---|
| SQNet[58] | - | 1024×2048 | 59.8 | - | 17 |
| CGNet [53] | No | 1024×2048 | 64.8 | **0.50** | 24.9 |
| NDNet [59] | No | 1024×2048 | 65.3 | **0.50** | 40 |
| ESPNetv2 [60] | - | 512×1024 | 66.2 | - | 80 |
| EDANet[75] | No | 512×1024 | 67.3 | 0.68 | **109.9** |
| ERFNet [52] | No | 512×1024 | 68.0 | 2.10 | 68 |
| Fast-SCNN[76] | - | 1024×2048 | 68.0 | 1.11 | 124 |
| BiseNet [39] | ImageNet | 768×1536 | 68.4 | 5.80 | 106 |
| ICNet [70] | ImageNet | 1024×2048 | 69.5 | 7.80 | 15.4 |
| DABNet [46] | No | 1024×2048 | 70.1 | 0.76 | 21.0 |
| FarSeeNet[77] | - | 512×1024 | 70.2 | - | 69 |
| DFANet [50] | ImageNet | 512×1024 | 70.3 | 7.80 | 100.0 |
| LEDNet [64] | No | 512×1024 | 70.6 | 0.95 | 57.1 |
| DFNet(第三章) | No | 512×1024 | 71.2 | 0.66 | 50.0 |
| MFNet(本章) | No | 512×1024 | **71.6** | 0.89 | 87 |

表 4.7 Camvid 测试集上预测结果对比

| Method | Pretrain | Input Size | mIoU(%)↑ | Params(M)↓ | Speed(FPS)↑ |
|---|---|---|---|---|---|
| SegNet [57] | ImageNet | 360×480 | 55.6 | 29.50 | - |
| FCN-8s[28] | ImageNet | - | 57.0 | 134.50 | - |
| Dilation8[48] | ImageNet | - | 65.3 | 140.80 | - |
| EDANet[75] | No | 360×480 | 66.4 | 0.68 | 110.3 |
| ICNet [70] | ImageNet | 720×960 | 67.1 | 7.80 | 27.8 |
| DABNet [46] | No | 360×480 | 66.4 | 0.76 | 97.8 |
| DFANet [50] | ImageNet | 720×960 | 64.7 | 7.80 | **120.0** |
| LEDNet [64] | No | 360×480 | 66.6 | 0.95 | 61.1 |
| AGLNet[78] | ImageNet | 360×480 | **69.4** | 1.10 | 90.1 |
| MSCFNet[66] | No | 360×480 | 69.3 | 1.15 | - |
| FBSNet[79] | No | 360×480 | 68.9 | **0.62** | - |
| DFNet(第三章) | No | 360×480 | 68.43 | 0.66 | 70 |
| MFNet (本章) | No | 360×480 | 68.92 | 0.89 | 94 |

PSM 模块替代 FIF。最终结果如表 4.4 所示，当用 Add 和 concat 替换 FIF 模块后，参数量下降 0.02M，分割精度分别下降 0.61%和 0.50%，而用第三章中的 PSM 模块时参数量仅下降 0.01M，分割精度下降 0.34%，这证实了 FIF 模块在网络中发挥着重要作用。

(3) MEF 模块中的多尺度特征

MEF 模块负责网络中多尺度特征的提取和融合。为了验证该模块的有效性，即多尺度特征对于网络性能的有效性，我们设置了一个对照实验来进行对比。我们将 MEF 模块中的跳跃连接去除，只是单纯将同样数量的 DEU 单元进行叠加组成一个模块替换 MEF，模块中的通道数不发生变化。具体结果如表 4.5 所示，当去除 MEF 模块中的跳跃连接，即 MEF 中的多

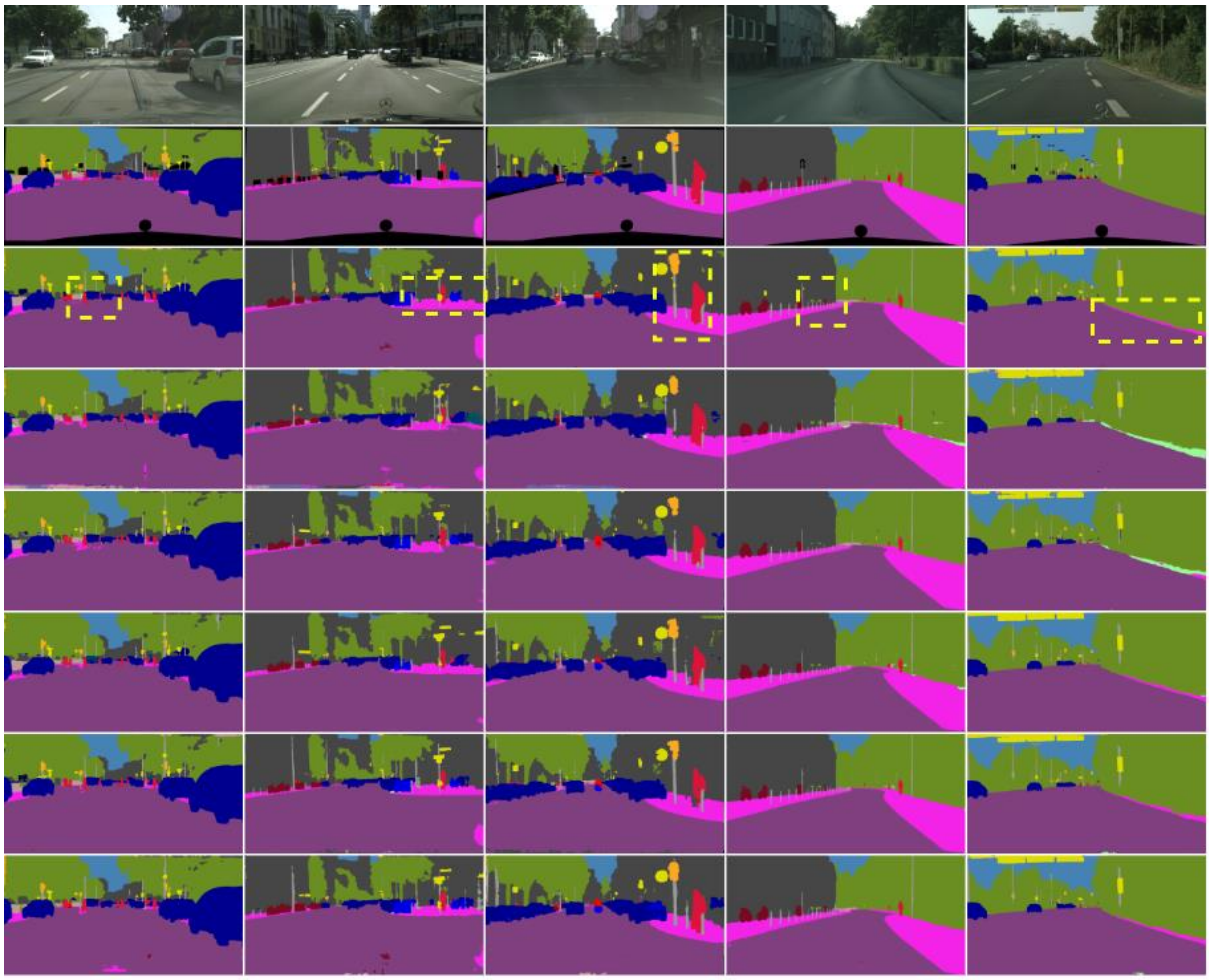

图 4.4 Cityscapes 数据集上预测结果对比图（自上向下依次为原始输入图像、标准图像、MFNet、ESPNet [40]、ERFNet [52]、DABNet [46]、NDNet[59]和 LEDNet[64]的预测结果图）

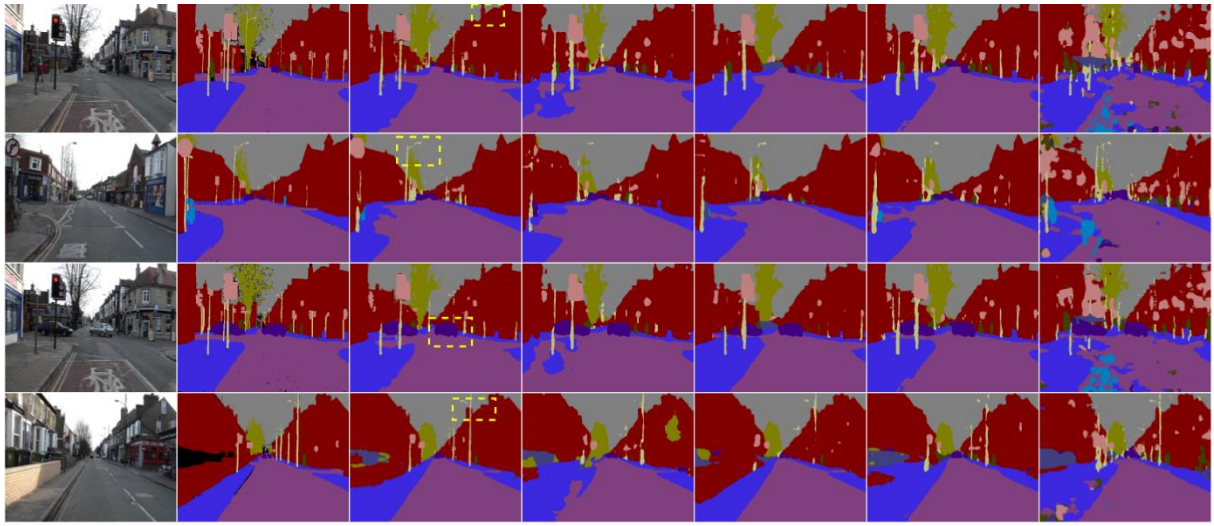

图 4.5 Camvid 数据集上预测结果对比图（自左向右依次为原始输入图像、标准图像、MFNet、DABNet [46]、CGNet [53]、LEDNet [64]和 ENet[38]的预测结果图）

尺度性之后，模型的推理速度提升了 17FPS，提升参数量下降了 0.4M，但是模型的分割精度损失达到了 1.15%。从该实验得出结论，MEF 模块中的多尺度特征虽然造成了推理速度以及参数量的损失，但是极大提高了分割性能。

### 4.3.4 与其他方法比较

我们将 MFNet 与一些主流网络进行比较，为了公平地比较我们将 MFNet 以及一些主流语义分割网络在同一张 RTX2080ti GPU 上进行训练，并且对平均交并比 (mIoU)、参数量 (Parameters) 以及推理速度 (Speed) 这三大指标进行对比，综合评价其性能。

(1) Cityscapes 数据集上结果对比

如表 4.6 所示是 MFNet 在 Cityscapes 数据集上与一些常见网络的定量比较，由表可见本章的 MFNet 在保持较低参数量的情况下，可以取得优异的性能。从“参数量”的角度看，CGNet[53]与 NDNet[59]参数量最低，仅有 0.5M，但是精确度分别比 MFNet 低了 6.8%与 6.3%，这在分割领域是一个巨大的差距。同样与本文第三章的 DFNet 比较，虽然 MFNet 的在参数量上有较大的增长，但是分割精度提升了 0.4%，同时推理速度也有提升。从“推理速度”角度看，虽然不及 DFANet[50]等网络，但是 MFNet 的分割精度明显优于这些网络，且 87FPS 在一众方法中处于中等位置。图 4.4 显示的是各算法在 Cityscapes 数据集上的分割结果图。

(1) Camvid 数据集上结果对比

在 Camvid 数据集上进行对比可以验证网络在小分辨率图片上的训练效果。表 4.7 显示了 MFNet 与一些常见网络在 Camvid 数据集上的定量比较。从表中可以看出， MFNet 的分割精度表现优异，与参数量相近的模型相比性能明显更优。图显示的是各算法在 Camvid 数据集上的分割结果图。图 4.5 显示了各算法在 Camvid 数据集上的分割结果图。

## 4.4 本章小结

本章我们提出了基于多尺度上下文信息融合的实时语义分割网络 MFNet。我们首先介绍两个特征提取单元，深层特征提取单元 (DEU) 和浅层特征提取单元 (SEU)，这两个单元分别针对深层语义信息和浅层空间信息进行特征提取。然后提出了多尺度特征提取与融合模块用于网络编码部分，以及两个特征融合模块 FIF 和 MIF。最后从整体框架介绍了网络的结构。经过实验表明 MFNet 最终可以取得优异的分割效果，并且可以在参数量和分割精度间取得平衡。同时通过消融实验证实我们设计的多尺度模块可以增加分割精度。

# 第五章 融合 CNN 与 Transformer 的轻量级语义分割网络

## 5.1 引言

自从全卷积网络 (FCN)[33] 被提出以来，现有的语义分割模型一直将其视为改进的原型。然而，这种基于 CNN 的模型的感受野是有限的，因此无法学习远程依赖关系，这不利于提取全局语义信息，全局信息对于密集型任务如语义分割而言却是极其重要的。为了克服这一局限性，一些方法提出了使用大型卷积核[80]、扩张卷积[48]，多尺度融合[35]等方式来扩展感受野获取。例如我们第三章中的 DFNet 使用了扩张卷积来扩大感受野，第四章的 MFNet 使用多尺度融合的方法来增强上下文信息，都取得了不错的效果。但是始终受限于卷积的形式，无法对全局信息建模，建立远程依赖关系。Transformer 的出现打破了这一局限性。近些年来伴随着 Transformer 在 NLP 领域的成功，越来越多的方法尝试将 Transformer 运用于计算机视觉领域。研究人员开始尝试完全移除卷积，探索仅使用 Transformer 的模型，可以对序列之间的长距离依赖关系进行建模，并捕获序列中任何位置的关系。与以往基于 CNN 的方法不同，Transformer 不仅在全局上下文建模方面很强大，而且在大规模预训练的情况下在下游任务上取得了良好的结果[36]。2020 年谷歌提出 Visual Transformer(ViT) 的模型[81]，它使用带有位置嵌入的二维图像块作为输入进行图像识别任务。然而，与 CNN 相比，ViT 的缺点在于必须在大型数据集上进行预训练。2021 年 SETR[82]首次将 Transformer 引入语义分割领域，但是模型的计算量以及参数量太大。因为许多计算机视觉任务，特别是语义分割任务，需要在像素级别进行密集的预测，这对于高分辨率图像上的 Transformer 来说很难处理，因为其自注意力的计算复杂度与图像大小成二次关系，所以这造成了基于 Transformer 的模型都是重模型，需要大量的计算量及参数量。此外，当 Transformer 用于图像处理领域时，二维图像被切片并作为一维序列输入模型，从而打破了局部结构之间的连接，并且仅在所有阶段关注全局上下文。因此，低分辨率特征缺乏详细的定位信息，无法通过直接上采样到全分辨率有效恢复，导致分割结果粗糙。所以尽管 Transformer 可以实现全局信息建模，但它无法提取精细的空间细节。相反，CNN 有优秀的局部特征挖掘能力，可以很好地弥补了这些精细的空间细节。因此，一些方法尝试将 CNN 与 Transformer 结合起来处理语义分割任务。例如，在医学图像分割领域，TransUNet [83]、TransBTS[84]和 TransFuse[85]取得了令人满意的结果。受此启发，我们提出了一种融合 CNN 和 Transformer 的轻量级实时语义分割模型 (LCTNet)，来解决 Transformer 参数量过大以及缺乏细节信息的问题。LCTNet 所具备的贡献有以下三点：

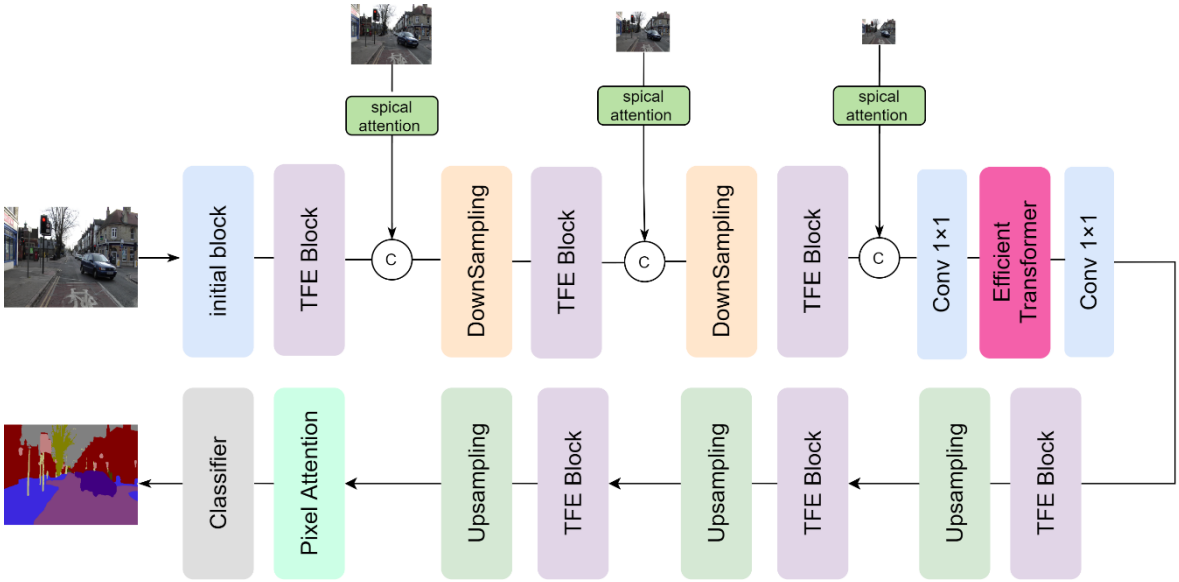


图 5.1 LCTNet 网络结构图

(1) 提出了一种全新的特征提取单元，名为三分支特征提取单元，该单元主要由深度可分离卷积和空洞卷积组成，相较于第三章和第四章的特征提取模块，该模块具有更小的参数量和计算量，同时更具备细节信息的提取能力。

(2) 将 CNN 与 Transformer 相结合，在编码与解码结构的交汇处引入高效的 Transformer 模块 (ET)。整个网络首先在解码部分使用卷积操作提取特征图的空间细节信息，同时对特征图进行下采样。然后下采样的特征图重塑为序列输入到 Transformer 模块，提取全局范围内的上下文信息。

(3) 融合 CNN 与 Transformer 的轻量级语义分割网络 (LCTNet)，如图 5.1 所示，在 Cityscapes 和 CamVid 数据集上展现出优异的性能。我们将 LCTNet 在 RTX2080Ti GPU 上进行训练，虽然模型参数量仅为 0.96M，却在 Cityscapes 和 CamVid 数据集上取得了突出的分割结果，mIoU 分别为 71.9%和 69.21%。

## 5.2 模型方法

### 5.2.1 三分支特征提取单元

我们设计了轻量级的三分支特征提取单元 (Three-Branch Feature Extraction Unit, TFE)。如图 5.2 所示，该模块采用了 ResNet 的思想，整体上采用了残差结构。由于本章的网络中使用了 Transformer 结构，考虑到其较大的参数量及计算量，三分支特征提取单元采用较浅的网络结构以平衡参数量。具体的，首先使用1×1卷积对特征图进行降维，将通道数降为原来的二分之一，以减少计算量和参数量。该方法同时也会损失一部分精度，但是后续三分支的特征

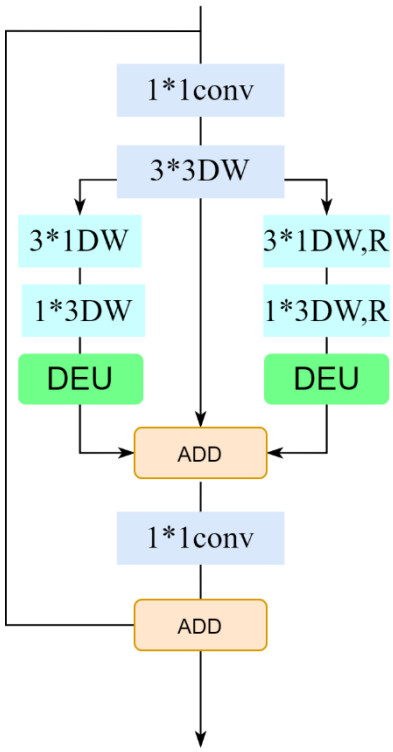


图 5.2 三分支特征提取单元 (TFE)

图叠加，可以获得更好的效果。同时由于通道减少，在1×1卷积之后采用3×3的扩展卷积，适当增加网络层参数，同时获得更大的感受野，以捕获更广范围的上下文信息。

在接下来的两个分支中，使用1×3和3×1分解卷积以减少参数量。其中一个分支负责获取局部与短距离的特征。另一分支使用带扩张率的分解卷积，以从更大的感受野中获取上下文信息。随后两分支使用细节信息提取单元 (Detail Information Extraction Unit,DEU)，对细节信息进行加权和提取，有助于 TFE 单元更好地提取细节信息。最后将两个低维度分支和中间特征融合，并输入到下面的1×1逐点卷积中，将特征图的通道数恢复为输入特征图的通道数。该单元可用如下公式表述：

$$f' = DC_{3*3}\left(C_{1*1}\left(x\right)\right) \tag{5.1}$$

$$f_l = DFU\left(DC_{1*3}\left(DC_{3*1}\left(f'\right)\right)\right) \tag{5.2}$$

$$f_r = DFU\left(DC_{r1*3}\left(DC_{r3*1}\left(f'\right)\right)\right) \tag{5.3}$$

$$F = C_{1*1}\left(f_l + f' + f_r\right) + x \tag{5.4}$$

其中 $f'$，$f_l$，$f_r$ 表示过程中的中间变量，$f_l$，$f_r$ 分别代表左右分支的输出，$DFU$ 表示细节信息提取单元的操作，$DC_{1*3}$ 指的是卷积核为1×3的深度可分离卷积。$DC_{r1*3}$ 指的是卷积核为1×3的深度可分离扩展卷积。$x$ 表示输入该单元的特征图，$F$ 表示该单元最终输出特征图。

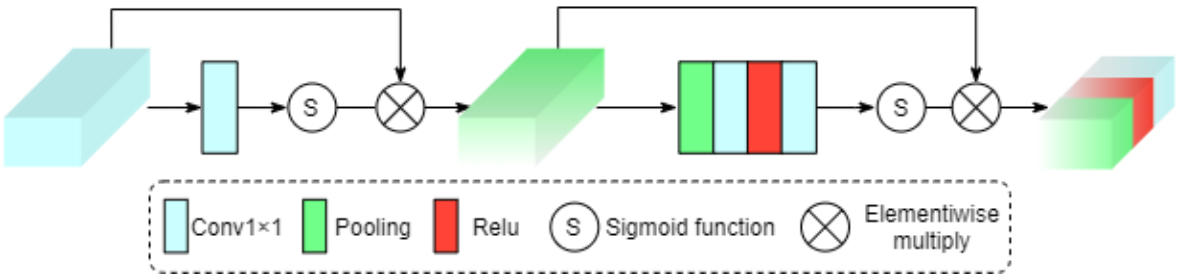


图 5.3 细节信息提取单元 (DEU)

### 5.2.2 细节信息提取单元

由于本章设计是融合 CNN 与 Transformer 的网络，CNN 应该更加专注于特征图的细节信息以实现性能的最大化。因此我们专门设计了细节信息提取单元 (Detail Information Extraction Unit,DEU)，使特征提取单元更好地提取细节信息。具体如图 5.3 所示，前半部分使用1×1卷积和 sigmoid 激活函数，可以对输入特征的同一通道内的信息进行加权，对重要的细节信息进行突出，同时抑制无用信息。后半部分引入了最大池化以及 Relu 激活函数，对不同的通道的信息进行加权，强调通道中的有效信息。具体公式如下：

$$f' = \sigma(C_{1\times1}(x)) \cdot x \tag{5.5}$$

$$f = C_{1\times1}\left(relu\left(C_{1\times1}\left(MaxP\left(f'\right)\right)\right)\right) \cdot f' \tag{5.6}$$

### 5.2.3 高效 Transformer 模块

Transformer 最早应用于机器翻译和自然语言处理 (NLP) 领域获得了成功，证实了其相较于普通卷积的局部信息获取，具有强大的全局上下文建模能力和迁移学习能力。近年来越来越多的研究开始将 Transformer 应用于图像处理领域，特别是 TransUNet[83]、TransBTS[84]等研究将 Transformer 使用于语义分割网络，获得了显著的效果，证实了 Transformer 在语义分割任务上的有效性。然而，由于语义分割的输入特征一般为高分辨率的图像，以往的大多数 Transformer 通常需要巨大的 GPU 运算成本。在这里我们由 ESRT[86]获得灵感，为模型引入高效的 Transformer 模块 (Efficient Transformer,ET)。同时为了进一步减少参数量，我们放弃了多个 ET 的级联，只使用单个 ET 作为 Transformer 模块嵌入到整个网络中。如图 5.1 所示，我们将 ET 放置于编码部分与解码部分之间，可以用较低的运算成本获取全局上下文信息。

如图 5.4，ET 为了减轻参数量只使用标准编码器中的编码部分，编码部分由一个高效多头注意力 (EMHA) 和一个多层感知机 (MLP) 组成。ET 与普通 Transformer（图 5.4(a)）的

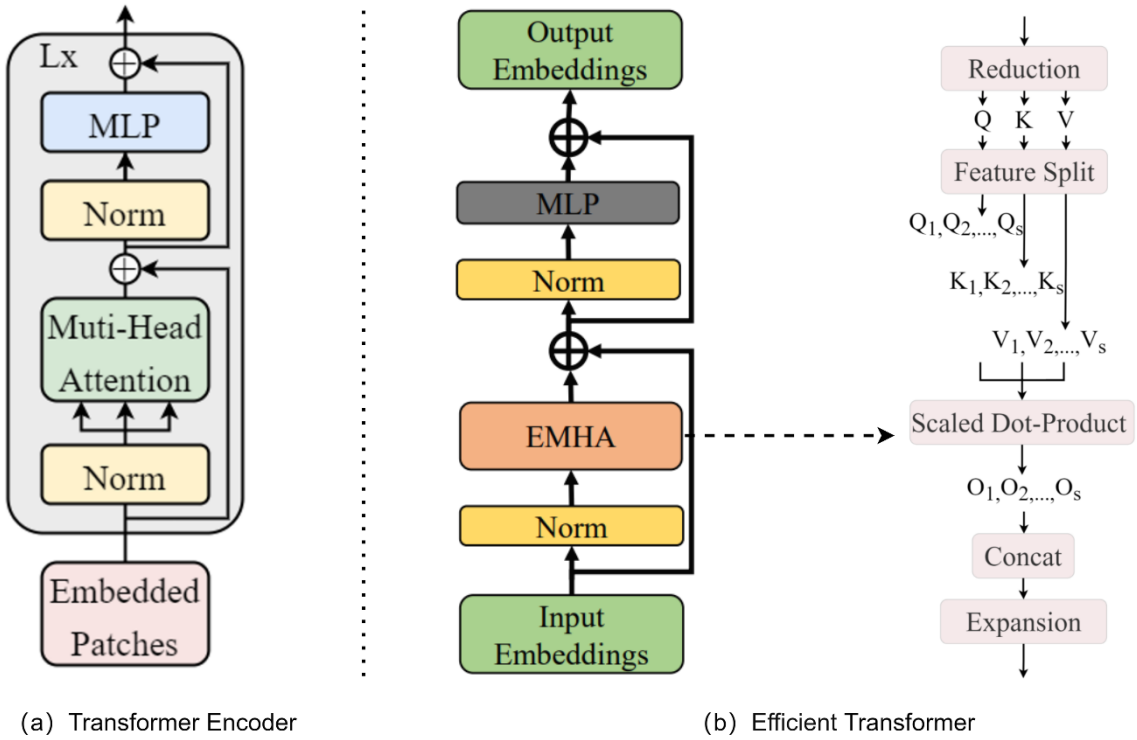


图 5.4 Transformer 示意图

区别主要是对原始 Transformer 中的 MHA 改进成高效的多头注意力 (EMHA)，在对输入进行层归一化后，EMHA 引入了一个 Reduction 层，将通道数减半以减少计算量。接着使用一个线性层将特征图映射到查询 (Q)、键 (K) 和值 (V) 矩阵中。在扩展的 EMHA 中，Q、K 和 V 被分成多个片段，然后对每个片段进行缩放点积注意力操作。最终，将得到的输出连接起来形成整体输出。整个过程依赖于分组卷积的思想，即将大矩阵拆分成小矩阵进行计算，然后合并结果，从而降低计算量。最后，通过扩展层恢复通道数。EMHA 的架构如图 5.4(b) 所示，其中缩放点积注意力 (Scaled Dot-Product) 操作是定义模型中的核心计算操作，用于处理输入的 Q、K 和 V 的关系。具体过程可用如下公式表示：

$$F_i = softmax\left(\frac{QK^T}{\sqrt{d}}\right)V \tag{5.7}$$

其中 $F_i$ 表示 Scaled Dot-Product 的最后的输出，$d$ 表示嵌入维度，嵌入维度指的是这个连续型空间的维度大小。

### 5.2.4 像素注意力机制

像素注意力 (Pixel Attention, PA) 机制是一种根据不同像素位置处特征的重要性学习权重的机制。它为每个像素位置动态地分配权重，以反映其在图像中的重要程度。与传统的注

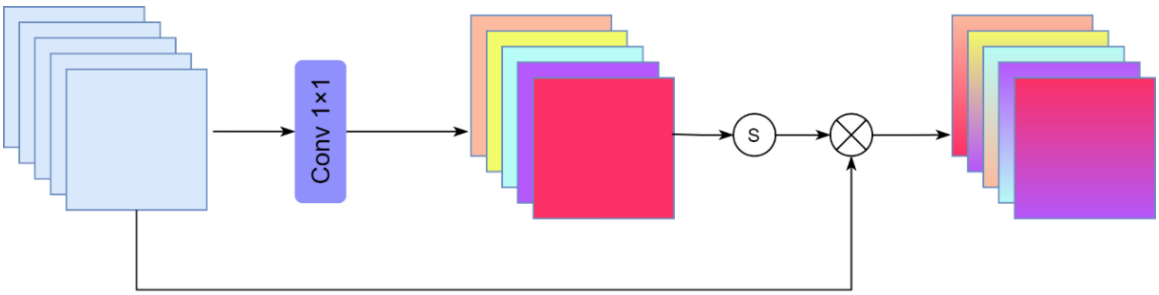


图 5.5 像素注意力示意图

意力机制不同，像素注意力使得每个通道具有相同的权重，但在同一通道内不同的像素位置设置不同的权重。这种机制使得模型能够更加聚焦于图像中的局部细节，尤其是边缘和纹理等重要特征。因此，通过添加像素注意力机制，可以增强模型对图像边缘细节信息的感知能力，从而提高语义分割的性能和准确度。具体的操作步骤可以参考图 5.5，像素注意力机制的数学表达如下：

$$y = \sigma\left(C_{1\times1}\left(x\right)\right)\cdot x \tag{5.8}$$

其中 $x$ 表示输入特征，$y$ 表示像素注意力模块的输出，$\sigma$ 表是 sigmoid 激活函数。

### 5.2.5 整体网络结构

LCTNet 整体上采用的是对称的编码-解码结构，由标准卷积，深度可分离卷积，空洞卷积，像素注意力机制，高效 Transformer 模块，三分支特征提取单元，上下采样模块等构成，LCTNet 的网络结构图如图 5.1 所示。

(1) 编码:编码部分首先使用三个 $3\times3$ 卷积作为初始化模块，其中第一个卷积步长为 2 将输入图像进行二倍下采样，降低分辨率以减小网络计算量。另外两个卷积步长为 1，进行初步的特征提取。之后使用 TFE 模块与下采样结合的方式，在编码部分设置了三个 TFE 模块以及两个下采样模块。其中每个 TFE 模块由多个 TFE 单元堆叠而成，第一个 TFE 模块我们设置了 3 个 TFE 单元，第二个模块设置了 8 个单元，第三个设置了 12 个，这样可以更好的获得参数量与分割精度的平衡。下采样操作降低图像分辨率可以增大感受野，但是同时也会丢失细节空间信息，损失边界分辨率，因此下采样操作每次只将特征图缩小 1/2，最终两个下采样模块以及初始模块只将原始特征图下采样为原来的 1/8。在编码器结尾部分我们设置 Transformer 模块，由于 Transformer 所需计算量较大，为了减轻 Transformer 模块的参数量和计算量，在特征图进入 Transformer 模块前使用 $1\times1$ 卷积将特征图降为 64。在 Tansformer 模块提取完全局特征之后再使用 $1\times1$ 卷积将通道数恢复。解码部分三个 TFE 模块我们都设置了 3

个 TFE 单元。同时我们在编码部分使用了远程快捷连接，该操作可以增加网络的多尺度性，进一步丰富网络的边缘细节信息。

(2) 解码:解码部分主要包含两个 TFE 模块和三个上采样模块。解码部分的两个 TFE 模块中单元个数都设置 3。上采样模块采用双线性插值的方式，每次只将特征图放大 2 倍，最终将特征图分辨率恢复为原来大小，这样可以减少解码是信息的丢失。在解码部门结尾处我们使用了像素注意力机制，有助于最终对边缘细节进行恢复，提高最终的分割精度。

## 5.3 实验设计与结果分析

### 5.3.1 数据集

本章使用 Cityscapes 和 CamVid 两个数据集对 LCTNet 进行实验。其中 Cityscapes 数据每张图像的尺寸为 1024×2048，并包含行人、道路、车辆等 19 个分类用于语义分割评估。该数据集共有 5000 张精细标注图像，其中 2075 张用于训练，500 张用于验证，1525 张用于测试。CamVid 数据集则包含 701 张 720×960 的城市道路图像，共有 11 个类别，其中 367 张用于训练，101 张用于验证，233 张用于测试。

### 5.3.2 参数设置

LCTNet 使用 PyTorch 深度学习框架进行搭建，使用单张 RTX2080Ti GPU 进行网络模型的训练和对比实验，CUDA 版本为 11.1，训练过程中的损失函数采用交叉熵损失函数。对于 Cityscapes 数据集的实验，我们将初始学习率调整为$4.5\times10^{-2}$，采用动量为 0.9，权重衰减为$1\times10^{-4}$的 SGD（随机梯度下降）优化算法来进行端到端的训练，采用 Poly 学习率变化策略，epoch 数量设置为 1000，同时批处理大小(batch size)设置为 4。

对于 Camvid 数据集的实验，我们采用动量为 0.9，权重衰减为$2\times10^{-4}$的 Adam 算法来进行训练，并将初始学习率设置为$1\times10^{-3}$，采用 Poly 学习率变化策略，epoch 数量设置为 1000，同时批处理大小(batch size)设置为 6。

### 5.3.3 消融实验

我们在 Camvid 数据集上对 LCTNet 进行消融实验，分别对像素注意力模块，细节信息提取单元，高效 Transformer 模块进行验证。

表 5.1 像素注意力模块对网络性能的影响

| Model | mIoU(%) | Params(M) | Speed(FPS) |
|---|---|---|---|
| LCTNet(w/o PA module) | 68.96 | 0.96 | 100 |
| LCTNet | 69.21 | 0.96 | 100 |

表 5.2 细节信息提取单元 (DIE) 对网络性能的影响

| Model | mIoU(%) | Params(M) | Speed(FPS) |
|---|---|---|---|
| LCTNet(w/o DIE) | 68.03 | 0.93 | 102 |
| LCTNet | 69.21 | 0.96 | 100 |

表 5.3 高效 Transformer(ET) 模块对网络性能的影响

| Model | mIoU(%) | Params(M) | Speed(FPS) |
|---|---|---|---|
| LCTNet(w/o ET module) | 66.45 | 0.85 | 113 |
| LCTNet | 69.21 | 0.96 | 100 |

(1) 像素注意力模块的影响

相比于 DFNet 和 MFNet,我们首次在网络中引入了像素注意力机制。这样可以使得模型能够更加聚焦于图像中的局部细节，尤其是边缘和纹理等细节，从而提高分割准确性。为了验证该像素注意力模块在网络中的有效性，我们移除了网络中的像素注意力模块进行训练和测试，并将最终的测试结果与 LCTNet 进行对比，对比结果如表 5.1 所示。

表 5.1 中数据显示，当 LCTNet 使用像素注意力模块时参数量不变，推理速度不变，但是分割精度却得到了 0.15%的提升。这证明了 LCTNet 中使用像素注意力模块可以带来网络性能的提升，同时几乎不带来参数量的增加。

(2) 细节信息提取单元 (DIE) 的影响

本章我们针对 CNN 与 Transformer 结合的网络创造性地设计了细节信息提取单元以提高网络性能。为了验证其有效性，我们将网络每个 TFE 单元中的 DIE 去除，然后在 Camvid 数据集上进行训练和测试，并将结果与 LCTNet 进行对比。如表 5.2 所示，DIE 单元仅带来了 0.03M 参数量的增加，但是网络性能却提升了 1.18%，由此证实了 DIE 单元对于 LCTNet 的有效性。

(3) 高效 Transformer 的影响

Transformer 可以通过建立全局上下文依赖性来提升网络性能。为了验证 Transformer 的有效性，我们将网络中的 ET 模块移除，同时也移除 ET 模块前后的两个1×1卷积。将移除模块后的网络在 Camvid 数据集上进行训练和测试，并将最终的测试结果与 LCTNet 进行对比。对比结果如表5.3所示，网络中增加ET模块增加了0.11M的参数量，同时推理速度下降13FPS，但是获得了将近 2.76%的性能提升。该消融实验证实了 ET 模块可以很大程度地提高 LCTNet 的性能。

表 5.4 Cityscapes 数据集上预测结果对比

| Method | Pretrain | Input Size | mIoU(%)↑ | Params(M)↓ | Speed(FPS)↑ |
|---|---|---|---|---|---|
| DABNet[46] | No | 512×1024 | 70.1 | 0.76 | 27.7 |
| FBSNet[79] | No | 512×1024 | 70.9 | **0.62** | **90** |
| MSCFNet [66] | No | 512×1024 | **71.9** | 1.15 | 50 |
| DFNet(第三章) | No | 512×1024 | 71.2 | 0.66 | 50 |
| MFNet(第四章) | No | 512×1024 | 71.6 | 0.89 | 87 |
| LCTNet（本章） | No | 512×1024 | **71.9** | 0.96 | 85 |

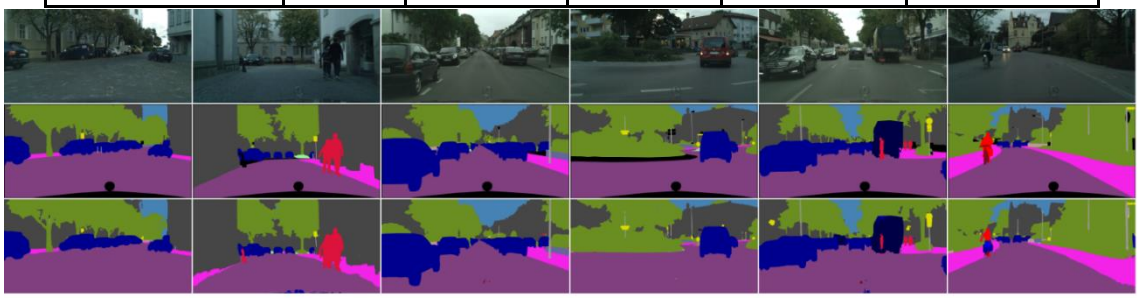

图 5.6 Cityscapes 数据集上分割效果对比图（自上向下依次为原始输入图像、标准图像、LCTNet 的预测结果图）

表 5.5 Camvid 数据集上预测结果对比

| Method | Pretrain | Input Size | mIoU(%)↑ | Params(M)↓ | Speed(FPS)↑ |
|---|---|---|---|---|---|
| DABNet[46] | No | 360×480 | 66.4 | 0.76 | 97.8 |
| FBSNet[79] | No | 360×480 | 68.9 | **0.62** | - |
| MSCFNet [66] | No | 360×480 | **69.3** | 1.15 | - |
| DFNet（第三章） | No | 360×480 | 68.43 | 0.66 | 70 |
| MFNet（第四章） | No | 360×480 | 68.92 | 0.89 | 94 |
| LCTNet（本章） | No | 360×480 | 69.21 | 0.96 | **100** |

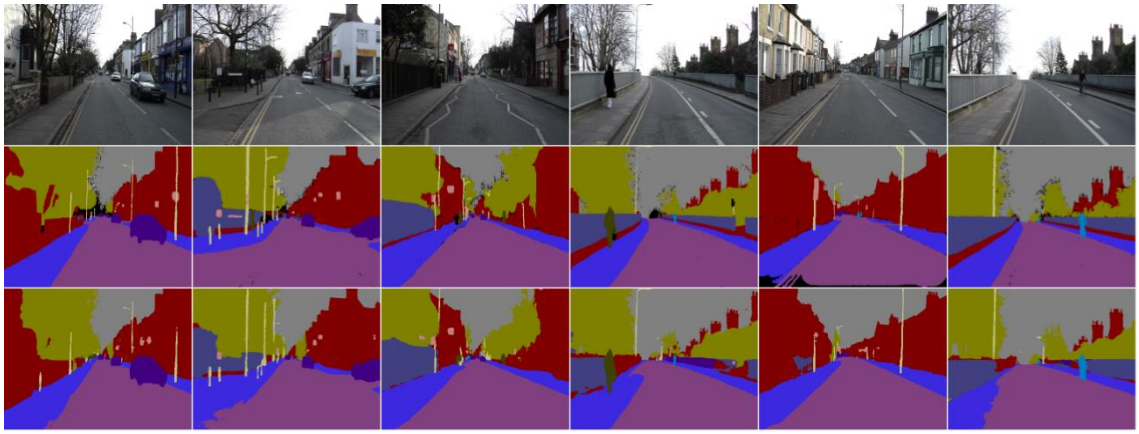

图 5.7 Camvid 数据集上分割效果对比图（自上向下依次为原始输入图像、标准图像、LCTNet 的预测结果图）

### 5.3.4 与其他方法比较

表 5.4 显示了本章的 LCTNet 和 DABNet [46]，FBSNet [79]，MSCFNet [66]以及 DFNet(第三章)，MFNet(第四章)在 Cityscapes 数据集上的分割结果对比。从表 5.4 中可以看出，MSCFNet

的分割精度最高，但是其参数量最大且推理速度较慢。本章提出的 LCTNet 虽然引入了高效 Transformer，参数量依旧保持在 1M 以内。我们在第三章提出的 DFNet，第四章提出的 MFNet 以及本章提出的 LCTNet 相较于其他网络都取得了不错的分割效果，并且在参数量，推理速度和性能之间取得了不错的平衡。由于第四章的 MFNet 相较于第三章的 DFNet 引入了多尺度的特征，增强了上下文信息的融合，所以在分割性能上有所上升，获得了 0.4%的提升。本章提出的 LCTNet 则由于引入了高效 Transformer 模块对全局上下文信息进行建模，在性能上超过了 DFNet 和 LCTNet，分别提升了 0.7%和 0.3%。表 5.5 显示了这些网络在 Camvid 数据集上的测试结果，LCTNet 在低分辨率图像的情况下以及可以保持优异的分割精度，虽然比 MSCFNet 低了 0.09%，但是参数量少了 0.19M。图 5.6 和图 5.7 分别是这些网络在 Cityscapes 数据集和 Camvid 数据集上的可视化分割效果。

## 5.4 本章小结

当前大多数的语义分割网络还是以卷积神经网络为主，但是由于卷积操作的局限性，无法获得全局上下文信息。当前火热的 Transformer 开始应用于语义分割，但是普通的 Transformer 存在参数量和计算量过大的问题，同时单纯使用 Transformer 会造成细节信息的缺失。本章设计了一种融合 CNN 与 Transformer 的轻量级语义分割网络，名为 LCTNet。本章设计了三分支特征提取单元 TEF 为 LCTNet 提取特征图的空间细节信息，解决了 Transformer 缺乏细节的问题。同时我们在本章提出了轻量级的高效 Transformer 模块，相较于普通的 Transformer 舍去了解码部分，改进了多头注意力模块，减轻了计算量和参数量。最后通过实验证明了该网络可以取得优异的分割效果，并且通过消融实验证实了高效 Transformer 模块的有效性。

# 第六章 总结与展望

## 6.1 总结

图像语义分割作为计算机视觉领域的关键组成部分，在自动驾驶、医疗影像、环境监测以及农业应用等领域中发挥着重要作用。随着越来越多的实际应用场景对语义分割技术的需求增加，许多场景中的设备计算性能有限。鉴于边缘设备性能的限制，迫切需要轻量级的语义分割网络，以在保持模型性能的同时降低参数量、提高推理速度。目前，一些高性能的语义分割模型往往忽视了模型的计算量，而专为边缘设备设计的模型虽然减少了参数和计算量，但准确率却有所欠缺。针对以上问题，本文对语义分割网络进行改进，设计了三个轻量级的语义分割网络。通过在 Cityscapes 和 CamVid 两个数据集上的训练和测试，这些网络均取得了优异的效果。

(1) 我们提出了基于双分支信息融合的高效实时语义分割网络 DFNet。DFNet 中采用了深度可分离卷积，空洞卷积，分解卷积，空间注意力机制以及通道注意力机制，使网络在保证性能的前提下降低模型参数量。我们为 DFNet 设计了上下文信息融合模块作为特征提取单元，该模块采用瓶颈结构融合了空洞卷积和通道注意力，通过扩展感受野以获取上下文信息，并且采用双分支融合和残差的结构，实现了上下文信息的融合。DFNet 采用双分支的整体网络结构，其中一条浅层分支配备了空间注意力模块负责提取浅层空间细节信息，名为细节分支，另一条深层分支搭配了通道注意力模块提取深层的语义信息，名为语义分支。最后我们设计了 PSM 模块对两个分支的特征信息进行融合并输出。DFNet 在 Cityscapes 和 CamVid 数据集上均展现出卓越的性能。DFNet 在没有任何额外的数据增强技术的情况下，在 Cityscapes 和 CamVid 数据集上取得了较好的分割结果，mIoU 分别为 71.2%和 68.43%，同时模型大小仅为 0.66M。

(2) 我们提出了基于多尺度上下文信息融合的实时语义分割网络 MFNet。相较于 DFNet，MFNet 更关注多尺度特征的提取与融合，在分割精度上取得了进一步提升。MFNet 依旧采用 DFNet 的双分支结构，我们设计了深层特征提取单元 DEU 以及深层特征提取单元 SEU 分别用于语义分支和细节分支。我们首先介绍了多尺度特征提取与融合模块 (MEF block)。MEF 模块以 DEU 单元为基础，旨在实现多尺度特征的提取。在该模块中，随着网络层的加深，通道数逐步减少。这一设计使得低层能够具备足够的通道来编码细节信息，而高层则更专注于捕捉高级语义信息，减少的通道数有助于避免信息冗余。同时，MEF 模块中还设置了跳跃连

接 (skip-path)，以便将每个阶段提取的特征进行拼接，从而进一步丰富特征信息。提出了 MIF 模块，改进了解码部分，使解码部分区别于编码部分。MIF 使用空间注意力模块，上采样模块以及 sigmoid 激活函数，将上采样后的特征信息与特征提取阶段的信息融合，可以解决上采样后特征图细节信息受损的问题，提高网络性能。MFNet 参数量仅为 0.89M，但在 Cityscapes 数据集上的图像推理速度达到 87FPS，同时分割精度 mIoU 高达 71.6%。在 camvid 数据集上的图像推理速度达到 94FPS，分割精度 mIoU 高达 68.92%。

(3) 我们提出了融合 CNN 与 Transformer 的轻量级语义分割网络 LCTNet。我们首先提出了一种全新的特征提取单元，名为三分支特征提取单元。该单元主要由深度可分离卷积和空洞卷积组成。与 DFNet 和 MFNet 的特征提取模块相比，该模块具有更小的参数量和计算量，同时具备更强的细节信息提取能力。同时引入了高效的 Transformer 与 CNN 相结合，对全局上下文信息进行建模。LCTNet 在 Cityscapes 和 CamVid 数据集上展现出优异的性能。我们将 LCTNet 在 RTX2080Ti GPU 上进行训练，虽然模型参数量仅为 0.96M，却在 Cityscapes 和 CamVid 数据集上取得了突出的分割结果，mIoU 分别为 71.9%和 69.21%。

## 6.2 展望

本文针对轻量级语义分割领域给出了一些见解和改进思路，提出了基于双分支信息融合的高效实时语义分割网络，基于多尺度上下文信息融合的实时语义分割网络以及融合 CNN 与 Transformer 的轻量级语义分割网络。大量的实验证实了我们设计的这些模型具有理想性能。但是这些网络仍然存在一些问题：

(1) 数据集方面，本文都是在 Cityscapes 和 Camvid 这两个数据集上进行训练和测试，虽然在这两个数据集上取得不错的效果，但是如果使用全新场景的图片会导致性能下降。并且 Cityscapes 和 Camvid 都是经过精细标注的数据集，我们的网络都是全监督的方式下进行训练。因此为了提高网络的泛化能力，在多场景下保持精确的分割效果，我们后续可以使用半监督或者无监督的方式进行训练。

(2) 网络改进方面，本文使用了空洞卷积、深度可分离卷积等全新的卷积形式，在第五章设计的 LCTNet 中也尝试使用了最近火热的 Transformer 模块。但是还有很多在其他领域取得不错效果的方法未曾在语义分割领域使用，我们下一步可以尝试更多全新的方法，例如深度强化学习，生成对抗式网络 (GAN)，Mamba 等。

(3) 实际应用方面，虽然本文设计的网络已经在参数量和分割精度方面取得了不错的平衡，理论上可以在边缘设备上进行应用并取得不错的效果。但是这些网络仅仅只是在实验室

数据集上进行测试，下一步需要在实际应用场景中进行测试，根据更多实际场景中的变量对语义分割网络进行改进。

# 参考文献

[1] Minaee S, Boykov Y, Porikli F, et al. Image segmentation using deep learning: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(7): 3523-42.

[2] Kaymak Ç, Uçar A. A brief survey and an application of semantic image segmentation for autonomous driving [J]. Handbook of Deep Learning Applications, 2019: 161-200.

[3] Bolya D, Zhou C, Xiao F, et al. Yolact: Real-time instance segmentation[C]. Proceedings of the IEEE International Conference on Computer Vision, 2019: 9157-9166.

[4] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8759-8768.

[5] 刘云翔, 管钎汛, 石艳娇. 基于语义分割的复杂驾驶场景障碍物检测[J]. 计算机仿真, 2023, 40(12): 167-71+231.

[6] 罗芯. 面向自动驾驶的语义分割与目标检测多任务模型研究[D]. 浙江大学, 2023.

[7] 张佳琪, 袁骏, 惠永科, 等. 基于自动驾驶道路场景的语义分割方法研究[J]. 机械工程与自动化, 2023, (06): 15-8.

[8] Lv Q, Sun X, Chen C, et al. Parallel complement network for real-time semantic segmentation of road scenes [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(5): 4432-44.

[9] 郭心悦, 韩星宇, 习超, 等. 基于非对称卷积的多车道线检测方法[J]. 计算机工程与设计, 2024, 45(02): 428-35.

[10] 张啸言. 基于图像语义分割的视网膜血管医学影像分割研究[D]. 华南理工大学, 2020.

[11] Luo X, Wang G, Song T, et al. MIDeepSeg: Minimally interactive segmentation of unseen objects from medical images using deep learning[J]. Medical Image Analysis, 2021, 72: 102102.

[12] Feng R, Zheng X, Gao T, et al. Interactive few-shot learning: Limited supervision, better medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2021, 40(10): 2575-88.

[13] 杜鹏飞, 黄媛, 高欣娜, 等. 基于语义分割的复杂背景下黄瓜叶部病害严重程度分级研究[J]. 中国农机化学报, 2023, 44(11): 138-47.

[14] 向宇杰, 向元平. 基于UNet+Swin-Transformer的西瓜叶片病害识别的研究[J]. 软件工程, 2024, 27(01): 55-7+73.

[15] 刘文定, 田洪宝, 谢将剑, 等. 基于全卷积神经网络的林区航拍图像虫害区域识别方法[J]. 农业机械学报, 2019, 50(03): 179-85.

[16] 高鹏远. 基于改进 Deeplab-v3+的土地覆盖分类[J]. 测绘与空间地理信息, 2024, 47(03): 150-2.

[17] 刘琦, 杨小华, 陈柏行, 等. 基于 Transformer 的成都市地物分类技术[J]. 地理空间信息, 2023, 21(12): 51-3.

[18] Wang H-Y, Pan D-l, Xia D-S. A fast algorithm for two-dimensional Otsu adaptive threshold algorithm[J]. Acta Automatica Sinica, 2007, 33(9): 968-71.

[19] Ying-ming H, Feng Z. Fast algorithm for two-dimensional otsu adaptive threshold algorithm[J]. Journal of Image and Graphics, 2005, 10(4): 484-8.

[20] Elder J H, Zucker S W. Local scale control for edge detection and blur estimation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(7): 699-716.

[21] Wang Y-P, Lee S L. Scale-space derived from B-splines[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(10): 1040-55.

[22] Hong L, Wan Y, Jain A. Fingerprint image enhancement: algorithm and performance evaluation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(8): 777-89.

[23] Canny J. A computational approach to edge detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1986, (6): 679-98.

[24] 刘仲民, 王阳, 李战明, 等. 基于简单线性迭代聚类和快速最近邻区域合并的图像分割算法[J]. 吉林大学学报, 2018, 48(6): 1931-7.
[25] 陈方昕. 基于区域生长法的图像分割技术[J]. 科技信息, 2008, (15): 58-9.
[26] 陆剑锋, 林海, 潘志庚. 自适应区域生长算法在医学图像分割中的应用[J]. 计算机辅助设计与图形学学报, 2005, 17(10): 2168-73.
[27] 王国权, 周小红, 蔚立磊. 基于分水岭算法的图像分割方法研究[J]. 计算机仿真, 2009, (5): 255-8.
[28] Hasituya, Chen Z, Wang L, et al. Monitoring plastic-mulched farmland by Landsat-8 OLI imagery using spectral and textural features[J]. Remote Sensing, 2016, 8(4): 353.
[29] Zhang C, Xue Z, Zhu X, et al. Boosted random contextual semantic space based representation for visual recognition[J]. Information Sciences, 2016, 369: 160-70.
[30] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-324.
[31] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]. Proceedings of the Advances in Neural Information Processing Systems, 2012: 1097-1105.
[32] Russakovsky O, Deng J, Su H, et al. Imagenet large scale visual recognition challenge[J]. International Journal of Computer Vision, 2015, 115: 211-52.
[33] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3431-3440.
[34] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]. Proceedings of the Medical Image Computing and Computer-assisted Intervention, 2015: 234-241.
[35] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2881-2890.
[36] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Proceedings of the Advances in NeuralInformation Processing Systems, 2017: 5998-6008.
[37] Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 3146-3154.
[38] Paszke A, Chaurasia A, Kim S, et al. Enet: A deep neural network architecture for real-time semantic segmentation[J]. arXiv preprint arXiv:160602147, 2016.
[39] Yu C, Wang J, Peng C, et al. Bisenet: Bilateral segmentation network for real-time semantic segmentation[C]. Proceedings of the European Conference on Computer Vision, 2018: 325-341.
[40] Mehta S, Rastegari M, Caspi A, et al. Espnet: Efficient spatial pyramid of dilated convolutions for semantic segmentation[C]. Proceedings of the European Conference on Computer Vision, 2018: 552-568.
[41] Tang J, Hong R, Yan S, et al. Image annotation by k nn-sparse graph-based label propagation over noisily tagged web images[J]. ACM Transactions on Intelligent Systems and Technology, 2011, 2(2): 1-15.
[42] Tang J, Jin L, Li Z, et al. RGB-D object recognition via incorporating latent data structure and prior knowledge [J]. IEEE Transactions on Multimedia, 2015, 17(11): 1899-908.
[43] Lin G, Shen C, Van Den Hengel A, et al. Efficient piecewise training of deep structured models for semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 3194-3203.
[44] Lin Z, Feng M, Santos C N d, et al. A structured self-attentive sentence embedding[J]. arXiv preprint arXiv:170303130, 2017.
[45] Shen T, Zhou T, Long G, et al. Disan: Directional self-attention network for rnn/cnn-free language understanding[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2018, 32(1).
[46] Li G, Yun I, Kim J, et al. Dabnet: Depth-wise asymmetric bottleneck for real-time semantic segmentation[J]. arXiv preprint arXiv:190711357, 2019.
[47] Poudel R P, Bonde U, Liwicki S, et al. Contextnet: Exploring context and detail for semantic segmentation in

real-time[J]. arXiv preprint arXiv:180504554, 2018.
[48] Chen L-C, Papandreou G, Kokkinos I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(4): 834-48.
[49] Li X, Liu Z, Luo P, et al. Not all pixels are equal: Difficulty-aware semantic segmentation via deep layer cascade[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3193-3202.
[50] Li H, Xiong P, Fan H, et al. Dfanet: Deep feature aggregation for real-time semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 9522-9531.
[51] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
[52] Romera E, Alvarez J M, Bergasa L M, et al. Erfnet: Efficient residual factorized convnet for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 19(1): 263-72.
[53] Wu T, Tang S, Zhang R, et al. Cgnet: A light-weight context guided network for semantic segmentation[J]. IEEE Transactions on Image Processing, 2020, 30: 1169-79.
[54] Yu C, Gao C, Wang J, et al. Bisenet v2: Bilateral network with guided aggregation for real-time semantic segmentation[J]. International Journal of Computer Vision, 2021, 129: 3051-68.
[55] Chen L-C, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation[J]. arXiv preprint arXiv:170605587, 2017.
[56] Ding H, Jiang X, Shuai B, et al. Context contrasted feature and gated multi-scale aggregation for scene segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2393-2402.
[57] Badrinarayanan V, Kendall A, Cipolla R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-95.
[58] Treml M, Arjona-Medina J, Unterthiner T, et al. Speeding up semantic segmentation for autonomous driving[C]. Proceedings of the Advances in Neural Information Processing Systems Workshop - MLITS, 2016:1-7
[59] Yang Z, Yu H, Fu Q, et al. NDNet: Narrow while deep network for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(9): 5508-19.
[60] Mehta S, Rastegari M, Shapiro L, et al. Espnetv2: A light-weight, power efficient, and general purpose convolutional neural network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 9190-9200.
[61] Hao S, Zhou Y, Guo Y, et al. Bi-direction context propagation network for real-time semantic segmentation[J]. arXiv preprint arXiv:200511034, 2020
[62] Lou A, Loew M. Cfpnet: Channel-wise feature pyramid for real-time semantic segmentation[C]. Proceedings of the IEEE International Conference on Image Processing, 2021: 1894-1898.
[63] Liu M, Yin H. Feature pyramid encoding network for real-time semantic segmentation[J]. arXiv preprint arXiv:190908599, 2019.
[64] Wang Y, Zhou Q, Liu J, et al. Lednet: A lightweight encoder-decoder network for real-time semantic segmentation[C]. Proceedings of the IEEE International Conference on Image Processing, 2019: 1860-1864.
[65] Hao S, Zhou Y, Guo Y, et al. Real-time semantic segmentation via spatial-detail guided context propagation[J]. IEEE Transactions on Neural Networks and Learning Systems, DOI: 10.1109/TNNLS.2022.3154443, 2022.
[66] Gao G, Xu G, Yu Y, et al. MSCFNet: A lightweight network with multi-scale context fusion for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 25489-99.
[67] Fan M, Lai S, Huang J, et al. Rethinking bisenet for real-time semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2021: 9716-9725.

[68] Wu Y, Jiang J, Huang Z, et al. FPANet: Feature pyramid aggregation network for real-time semantic segmentation[J]. Applied Intelligence, 2022, 52(3): 3319-36.

[69] Liu J, Zhou Q, Qiang Y, et al. FDDWNet: a lightweight convolutional neural network for real-time semantic segmentation[C]. Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing, 2020: 2373-2377.

[70] Zhao H, Qi X, Shen X, et al. Icnet for real-time semantic segmentation on high-resolution images[C]. Proceedings of the European Conference on Computer Vision, 2018: 405-420.

[71] Dong G, Yan Y, Shen C, et al. Real-time high-performance semantic image segmentation of urban street scenes [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(6): 3258-74.

[72] Chen L C, Yang Y, Wang J, et al. Attention to scale: Scale-aware semantic image segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 3640-3649.

[73] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-16.

[74] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141.

[75] Lo S Y, Hang H M, Chan S W, et al. Efficient dense modules of asymmetric convolution for real-time semantic segmentation[C]. Proceedings of the ACM International Conference on Multimedia in Asia, 2019: 1-6.

[76] Poudel R P, Liwicki S, Cipolla R. Fast-scnn: Fast semantic segmentation network[J]. arXiv preprint arXiv:190204502, 2019.

[77] Zhang Z, Zhang K. Farsee-net: Real-time semantic segmentation by efficient multi-scale context aggregation and feature space super-resolution[C]. Proceedings of the IEEE International Conference on Robotics and Automation, 2020: 8411-8417.

[78] Zhou Q, Wang Y, Fan Y, et al. AGLNet: Towards real-time semantic segmentation of self-driving images via attention-guided lightweight network[J]. Applied Soft Computing, 2020, 96: 106682.

[79] Gao G, Xu G, Li J, et al. FBSNet: A fast bilateral symmetrical network for real-time semantic segmentation[J]. IEEE Transactions on Multimedia, 2023, 25: 3273-3283.

[80] Peng C, Zhang X, Yu G, et al. Large kernel matters--improve semantic segmentation by global convolutional network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4353-4361.

[81] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:201011929, 2020.

[82] Zheng S, Lu J, Zhao H, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2021: 6881-6890.

[83] Chen J, Lu Y, Yu Q, et al. Transunet: Transformers make strong encoders for medical image segmentation[J]. arXiv preprint arXiv:210204306, 2021.

[84] Wang W, Chen C, Ding M, et al. Transbts: Multimodal brain tumor segmentation using transformer[C]. Proceedings of the Medical Image Computing and Computer-Assisted Intervention, 2021: 109-119.

[85] Zhang Y, Liu H, Hu Q. Transfuse: Fusing transformers and cnns for medical image segmentation[C]. Proceedings of the Medical Image Computing and Computer Assisted Intervention, 2021: 14-24.

[86] Lu Z, Li J, Liu H, et al. Transformer for single image super-resolution[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2022: 457-466.

# 附录 1 攻读硕士学位期间撰写的论文

[1]徐大伟，邱杨杨，万徐杰，高广谓，基于双分支信息融合的高效实时语义分割网络，计算机与数字工程，已录用。

# 附录 2 攻读硕士学位期间申请的专利

[1] 徐大伟，高广谓，吴飞，岳东. 基于双重注意力机制网络的实时语义分割方法，202310392423.1，2023.04.13，2023.07.14；

# 附录 3 攻读硕士学位期间参加的科研项目

(1) 国家自然科学基金，基于空间一致性的低质量人脸图像识别研究 (61972212)；

(2) 省重点实验室开放课题，基于空间一致性的跨域图像重建与识别 (KJS2274)。

# 致谢

在即将结束的研究生学习生涯中，我要衷心感谢导师高广谓老师。在整个研究生阶段，他的悉心指导和严谨的科研态度使我受益匪浅。他不仅在学术上给予我启发和支持，更在人生规划上给予了宝贵的建议和指导。我也要感谢所有在我学习和生活中给予我帮助的家人，师长和同学，是你们的支持和鼓励让我度过了这段美好的时光。无论是学业上的困难还是生活中的挑战，你们的陪伴都给予了我巨大的力量。最后我也要感谢自己在这个过程中的努力和坚持。在面对困难和挑战时，我学会了勇敢和坚韧，这种品质将伴随我一生。愿未来的道路上，我能继续保持这份努力和执着，迎接更多的挑战，创造更加美好的未来。