

单位代码： 10293 密 级： _____

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于深度上下文特征协同的轻量级语义分割研究

学	号	1223055930
姓	名	王海生
导	师	谢九成、高广谓
专业学位类别		电子信息硕士
类	型	全日制
专业（领域）		电子信息
论文提交日期		2026 年 5 月

Research on Lightweight Semantic Segmentation Based on Deep Contextual Feature Collaboration

Thesis Submitted to Nanjing University of Posts and
Telecommunications for the Degree of
Master of Electronic Information



By

Haisheng Wang

Supervisor: Prof. Jiucheng Xie, Prof. Guangwei Gao

May 2026

南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号： 1223055930 研究生签名： 王海生 日期： _____

南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名： 王海生 导师签名： _____ 日期： _____

摘要

图像语义分割是计算机视觉领域的核心基础任务，旨在为图像每个像素分配语义标签，实现像素级场景精细解析。近年来，该技术在自动驾驶、智能监控、遥感影像分析等领域广泛应用，是支撑智能系统环境感知的关键技术。深度学习技术的快速发展极大推动了语义分割的性能提升，但现有高精度模型多通过加深加宽网络增强表征，导致参数量与计算量急剧膨胀，难以在移动设备等资源受限平台实时部署。针对这一问题，本文围绕轻量级实时语义分割网络的精度与效率协同优化展开研究，提出三种高效网络架构，具体内容如下：

(1) 为解决轻量级语义分割中局部细节建模与全局语义一致性难以兼顾的核心矛盾，本文构建了多尺度混合 Mamba 语义分割网络 MHMNet。该网络打破了纯卷积或纯状态空间模型的单一建模范式，将卷积的局部空间归纳偏置与 Mamba 的线性复杂度全局建模能力深度融合，通过统一的架构设计实现了多尺度局部特征提取与长距离语义依赖的协同建模。实验表明，该模型仅需 0.77M 参数量，在 Cityscapes 数据集上取得 71.5% mIoU，同时保持 173 FPS 的实时推理速度；在 CamVid 数据集上斩获 69.50% mIoU，推理帧率维持在 292FPS，在保障实时性的前提下实现了分割精度的显著跃升。

(2) 针对现有轻量级模型在复杂城市场景中边界刻画模糊、视觉相似类别易混淆且计算开销过高的问题，本文提出了协同注意力增强型轻量级语义分割网络 CoANet。该网络以极致轻量化为设计目标，通过多维度注意力机制的协同作用定向增强模型的特征表达能力，在不显著增加计算量的前提下有效弥补了紧凑模型的表征缺陷。实验结果显示，该模型参数量仅为 0.67M，在 Cityscapes 数据集上跑出 190 FPS 的高速推理表现，同时取得 71.7% mIoU；在 CamVid 数据集上更是达到 320 FPS 的极致帧率，对应分割精度为 69.67% mIoU，完成了参数量与推理速度的双重极致压缩。

(3) 为突破纯空间域建模的局限性并解决多分支结构带来的计算冗余问题，本文设计了频率感知上下文语义分割网络 FACNet。该网络采用纯单分支高效推理框架，创新性地引入频域信息参与特征表达过程，通过空间-频域协同建模机制提升模型对复杂干扰场景的鲁棒性，同时从根本上避免了多分支结构带来的额外计算开销。实验表明，该模型以 0.84M 参数量，在 Cityscapes 数据集上实现了 72.1% mIoU 的领先水平，推理速度可达 106 FPS；在 CamVid 数据集上取得 69.75% mIoU，推理帧率为 198 FPS，在复杂光照、运动模糊等干扰场景下仍展现出优异的鲁棒性与泛化能力。

关键词：轻量级语义分割，Mamba，多尺度特征，注意力机制，上下文信息

Abstract

Image semantic segmentation is a core fundamental task in the field of computer vision, which aims to assign semantic labels to each pixel in an image and achieve pixel-level fine-grained scene parsing. In recent years, this technology has been widely applied in autonomous driving, intelligent surveillance, remote sensing image analysis and other fields, serving as a key technology supporting environmental perception of intelligent systems. The rapid development of deep learning technology has greatly promoted the performance improvement of semantic segmentation. However, most existing high-precision models enhance feature representation by deepening and widening network structures, leading to a sharp increase in parameters and computational complexity, which makes it difficult to achieve real-time deployment on resource-constrained platforms such as mobile devices. To address this issue, this paper focuses on the collaborative optimization of accuracy and efficiency for lightweight real-time semantic segmentation networks, and proposes three efficient network architectures. The specific contents are as follows:

To solve the core contradiction that local detail modeling and global semantic consistency are difficult to balance in lightweight semantic segmentation, this paper constructs a multi-scale hybrid Mamba semantic segmentation network (MHMNet). This network breaks the single modeling paradigm of pure convolutional or pure state space models, deeply integrates the local spatial inductive bias of convolution with the linear-complexity global modeling capability of Mamba, and realizes the collaborative modeling of multi-scale local feature extraction and long-distance semantic dependency through a unified architecture design. Experimental results show that the model only requires 0.77M parameters, achieving 71.5% mIoU on the Cityscapes dataset while maintaining a real-time inference speed of 173 FPS. On the CamVid dataset, it achieves 69.50% mIoU with an inference frame rate of 292 FPS, realizing a significant improvement in segmentation accuracy while ensuring real-time performance.

Aiming at the problems of blurred boundary depiction, easy confusion of visually similar categories and excessive computational overhead of existing lightweight models in complex urban scenes, this paper proposes a collaborative attention-enhanced lightweight semantic segmentation network (CoANet). With extreme lightweight as the design goal, this network directionally enhances the feature representation capability of the model through the synergistic effect of multi-dimensional attention mechanisms, and effectively compensates for the representation defects

of compact models without significantly increasing the computational cost. Experimental results demonstrate that the model has only 0.67M parameters, achieving a high inference speed of 190 FPS and 71.7% mIoU on the Cityscapes dataset. On the CamVid dataset, it even reaches an extreme frame rate of 320 FPS with a corresponding segmentation accuracy of 69.67% mIoU, completing the dual extreme compression of parameters and inference speed.

To break through the limitations of pure spatial domain modeling and solve the computational redundancy problem caused by multi-branch structures, this paper designs a frequency aware contextual semantic segmentation network (FACNet). This network adopts a pure single-branch efficient inference framework, innovatively introduces frequency domain information into the feature expression process, improves the model's robustness to complex interference scenes through the spatial-frequency domain collaborative modeling mechanism, and fundamentally avoids the additional computational overhead caused by multi-branch structures. Experimental results show that with 0.84M parameters, the model achieves a leading level of 72.1% mIoU on the Cityscapes dataset with an inference speed of 106 FPS. On the CamVid dataset, it achieves 69.75% mIoU with an inference frame rate of 198 FPS, and still exhibits excellent robustness and generalization ability under interference scenes such as complex illumination and motion blur.

Key words: Lightweight Semantic Segmentation, Mamba, Multi-scale Features, Attention Mechanism, Contextual Information

目录

第一章 绪论	1
1.1 研究背景及意义	1
1.2 语义分割研究现状	3
1.2.1 传统图像语义分割方法	3
1.2.2 基于深度学习的图像语义分割方法.....	4
1.3 主要研究内容	6
1.4 论文章节安排	7
第二章 相关背景知识介绍	9
2.1 卷积神经网络理论基础	9
2.1.1 卷积层	9
2.1.2 激活函数层	13
2.1.3 池化层	15
2.1.4 全连接层	16
2.2 注意力机制	16
2.2.1 通道注意力	17
2.2.2 空间注意力	18
2.3 语义分割评价标准	18
2.4 语义分割数据集	20
2.4.1 Cityscapes 数据集	20
2.4.2 Camvid 数据集.....	21
2.5 本章小节	21
第三章 基于多尺度混合 Mamba 的轻量级语义分割网络	23
3.1 引言	23
3.2 基于多尺度混合 Mamba 的轻量级语义分割网络	25
3.2.1 整体网络架构	25
3.2.2 多分支特征聚合模块	25
3.2.3 混合视觉状态空间模块	27
3.2.4 自适应门控特征分割头	30
3.3 实验设计与结果分析	31
3.3.1 数据集与实验参数设置	31
3.3.2 消融实验	32
3.3.3 与其它方法的比较	34
3.4 本章小结	36
第四章 基于协同注意力机制的轻量级语义分割网络.....	38
4.1 引言	38
4.2 基于协同注意力机制的轻量级语义分割网络.....	40
4.2.1 整体网络结构	40
4.2.2 通道聚合多尺度注意力模块	41
4.2.3 三级上下文融合模块	43
4.2.4 选择性嵌入分割头	45
4.2.5 其他模块	46
4.3 实验设计与结果分析	47
4.3.1 数据集与实验参数设置	47
4.3.2 消融实验	47

4.3.3 与其它方法的比较	51
4.4 本章小结	53
第五章 用于高效语义分割的频率感知上下文网络.....	54
5.1 引言	54
5.2 用于高效语义分割的频率感知上下文网络.....	55
5.2.1 整体网络结构	55
5.2.2 空间精炼下采样单元	56
5.2.3 频率感知上下文模块	58
5.2.4 跨尺度特征融合模块	61
5.3 实验设计与结果分析	62
5.3.1 数据集与实验参数设置	62
5.3.2 消融实验	62
5.3.3 与其他方法的比较	65
5.4 本章小结	67
第六章 总结与展望	69
6.1 总结	69
6.2 展望	70
参考文献	72
附录 A 攻读硕士学位期间撰写的论文.....	78
附录 B 攻读硕士学位期间参加的科研项目	79
致谢	80

第一章 绪论

1.1 研究背景及意义

步入新世纪以来，人工智能技术已从理论探索阶段逐步迈向产业化落地，尤其在 5G 通信、边缘计算及异构芯片等基础设施的协同推动下，智能感知系统正深刻重塑着现代社会的生产范式与生活形态。作为本轮技术革新的核心驱动力，深度学习凭借其强大的特征表征能力，突破了传统模式识别依赖人工设计特征的局限，为视觉信息的高效解析提供了新的技术路径。与基于统计学习的传统方法相比，深度神经网络通过端到端的训练机制与多层次语义抽象，能够在海量数据中自主挖掘更具判别力的结构化特征，从而有效支撑复杂场景下的智能决策任务。

计算机视觉作为人工智能感知层的关键组成部分，其核心使命在于赋予机器理解与解析视觉世界的能力。依据信息抽象程度的递进，该领域通常划分为图像分类^[1]、目标检测^[2]及图像分割^[3-4]三个层次。其中，图像分类关注全局语义的判别，目标检测在识别类别的基础上引入空间定位，而图像分割则要求模型对每个像素赋予语义标签，实现对场景的精细化解构。在分割任务中，语义分割与实例分割构成了两大主流方向：前者致力于将图像划分为若干具有特定语义含义的同质区域，后者则在语义标注的基础上进一步区分同类物体的不同个体。相较之下，语义分割因其对场景结构的普适解析能力，在工业界与学术界均展现出更为广阔的应用前景。

近年来，随着深度学习理论与硬件加速平台的协同演进，语义分割技术在诸多垂直行业中逐步从实验室走向工程化部署。在医学影像分析^[5]领域，语义分割构成了从宏观解剖结构到微观病理特征定量解析的技术基石。通过对计算机断层扫描（CT）、磁共振成像（MRI）及正电子发射断层扫描（PET-CT）等多模态影像数据进行逐像素的语义类别指派，该技术能够将复杂的解剖结构解构为可量化的组织分布图——系统可以精确区分灰质与白质界面、勾勒肿瘤浸润边界、量化心肌灌注缺损区域以及识别微小的肺结节轮廓。这种像素级的精细解析能力，为临床医师执行病灶负荷评估、手术边界规划以及疗效纵向追踪提供了客观的量化依据，构成了现代计算病理学与影像组学分析的算法基础。

在自动驾驶技术的感知体系^[6]中，语义分割扮演着不可或缺的基础性角色。通过对车载摄像头捕获的图像帧实施逐像素的类别标注，该技术能够将复杂的交通场景解构为结构化的语义信息——系统可以精确区分车道边界、人行横道、交通标志牌以及各类动态交通参与者

（包括行人、各类机动车辆）的轮廓与空间占位。这种像素级的精细感知能力，为上层决策模块执行路径规划、行为预测以及轨迹生成提供了关键的环境数据支撑，构成了智能驾驶系统理解物理世界并与之交互的视觉基石。近年来，全球范围内的主流车企与科技公司正以前所未有的力度推动感知技术的工程化落地，语义分割作为其中关键环节，在最新一代的智驾系统中得到了广泛应用与验证。以特斯拉为例，其于 2025 年 10 月向北美用户推送的 FSD V14 版本，通过深度融合 xAI 的 Grok 大模型，构建了“视觉-语义-决策”的端到端融合架构，使系统不仅能识别像素类别，更能理解如施工临时信号灯等复杂场景的语义内涵。在国内市场，小鹏汽车于 2025 年发布的第二代 VLA（视觉-语言-动作）大模型，以近一亿段真实视频数据训练，通过视觉核心的语义理解实现极限场景的覆盖，推动了 L4 级智驾量产。此外，针对非结构化道路与极端天气等复杂场景的感知鲁棒性问题，学术界与产业界亦持续推动模型架构的轻量化设计与域自适应算法的协同优化。通过引入多尺度特征融合机制与边缘感知损失函数，新一代语义分割网络能够在车道标线缺失、光照突变以及动态遮挡严重的恶劣交通环境中保持较高的推理实时性与空间精度。

在遥感对地观测领域^[7]，语义分割扮演着将原始像素阵列转化为地理语义地图的核心转换角色。通过对光学卫星、合成孔径雷达（SAR）及无人机平台获取的高分辨率影像实施逐像元的地物类别标注，该技术能够将复杂的地表覆盖格局解译为结构化的专题信息——系统可以精准界定建设用地与耕地边界、区分不同作物种植结构、识别水域面积动态变化以及评估森林砍伐或灾后损毁程度。这种像元级的精细解译能力，为国土资源调查、精准农业管理及环境变化监测提供了高时效性的空间数据支撑，构成了地理国情监测与数字孪生地球构建的视觉认知基础。

尽管语义分割技术在理论突破与应用拓展方面取得了长足进步，其在实际部署中仍面临若干关键挑战。当前主流的高精度分割模型往往依赖复杂的网络结构与海量计算资源，难以在算力受限的边缘设备上实现实时推理。另一方面，面向特定场景设计的轻量化模型虽在计算效率上有所优化，但其分割精度与泛化能力仍有待提升。此外，现有方法在应对复杂光照变化、遮挡干扰及跨域迁移等现实场景时，模型的鲁棒性与适应性仍显不足。因此，如何在保持高精度分割能力的前提下，实现模型结构的轻量化与推理效率的优化，已成为推动语义技术迈向更广泛应用的关键科学问题。

综上所述，语义分割作为连接底层视觉特征与高层语义理解的重要桥梁，其在推动人工智能系统感知能力边界扩展方面具有不可替代的作用。随着应用场景的不断拓展与任务需求的日益复杂，开展面向高效、鲁棒与轻量化的语义分割方法研究，不仅具有重要的理论价值，亦将为智能驾驶、工业视觉及消费电子等领域的落地应用提供坚实的技术支撑。

1.2 语义分割研究现状

1.2.1 传统图像语义分割方法

图像分割作为计算机视觉领域的奠基性任务之一，其研究可追溯至二十世纪六十年代中期。Roberts 于 1965 年引入的边缘检测算子，首次实现了基于计算机的图像区域划分。此后数十年间，研究者从不同理论视角出发，发展出多样化的分割策略。依据其建模思路与数学基础的差异，传统图像语义分割方法可归纳为以下四种典型范式：

（1）基于阈值的图像分割方法

作为一类经典的低层视觉处理技术，基于阈值的分割方法依据图像灰度直方图特征，通过选取最优灰度门限实现目标与背景的分离。其基本原理是将每个像素的灰度值与预设判决门限进行比较，依据比较结果将像素划分至不同类别。阈值选取既可采用人工设定的固定值，也可采用如 Otsu 算法^[8]等通过统计特性自动确定全局最优阈值的自适应策略。该类方法在目标与背景对比度明显、光照稳定的场景中具有良好的应用效果，如文档图像二值化^[9]等领域。然而，其局限性在于仅依赖单一灰度统计特征，对光照不均和噪声干扰较为敏感。对于包含复杂纹理的自然图像，由于缺乏空间上下文信息，难以获得准确且连贯的分割结果。

（2）基于区域的图像分割方法

区域级分割方法^[10]关注像素间的空间邻近性与特征相似性，旨在构建具有语义一致性的连通区域。该类方法利用图像的局部空间信息，依据颜色、纹理等属性的同质性准则对图像平面进行划分。区域生长范式从选取的种子像素出发，将满足相似性条件的邻域像素逐步归并；分裂合并范式则通过递归分裂不满足一致性度量的区域，再合并属性相似的相邻子块完成分割。分水岭算法是该类方法的典型代表，它将梯度图像视为地形表面，通过模拟浸水过程确定分割边界。这类方法能有效利用空间上下文约束，生成闭合且连续的区域边界。但其性能高度依赖于相似性准则的定义，且易出现过分割或欠分割问题，在处理弱边界或渐变区域时稳定性有待提升。

（3）基于图论的图像分割方法

基于图论的分割方法^[11]将图像映射为带权无向图，通过数学优化框架求解像素划分问题。具体而言，图的节点对应像素或超像素，边的权重量化相邻节点在特征空间中的相似度，从而将图像分割转化为图的最优划分问题。其目标是在全局范围内寻找边的集合，使得子图内部相似性最大、子图间相似性最小，且满足预设代价函数的极值条件。归一化割算法通过引入子图规模作为归一化因子，避免了传统最小割易产生孤立点分割的缺陷；图割算法则常结

合能量最小化框架，通过最大流/最小割算法高效求解标签分配。该类方法能够将图像全局结构纳入考量，并在数学框架下求得最优解。然而，其计算复杂度较高，且在图的构建方式与代价函数设计上仍依赖先验知识。

（4）基于聚类的图像分割方法

聚类分割方法^[12]将图像分割视作特征空间中的无监督学习过程。首先将像素映射为由灰度、色彩、纹理及空间坐标构成的高维特征空间，每个像素对应一个样本点；随后应用聚类算法依据相似性度量将样本点划分为若干紧凑且分离的簇；最后将同一簇内的像素映射回图像平面，获得分割结果。K 均值聚类通过迭代优化簇内误差平方和寻找数据内在结构，均值漂移算法则通过概率密度梯度搜索自动确定聚类数目和位置。该类方法无需标记数据，能够自适应发现图像中的统计模式，对多类别分割具有天然优势。但其性能易受特征选择和初始聚类中心影响，在纹理复杂或色彩分布重叠的场景中，单纯依赖特征空间距离难以有效区分不同语义区域。

1.2.2 基于深度学习的图像语义分割方法

（1）基于卷积神经网络的语义分割方法

在深度学习技术推动下，语义分割完成了从手工设计特征向数据驱动表征的范式转换。卷积神经网络（Convolutional Neural Networks, CNN）凭借其层次化特征学习能力，通过端到端监督训练机制自动提取图像的语义信息与空间结构，确立了作为现代语义分割基准模型的学术地位。全卷积网络（Fully Convolutional Network, FCN^[13]）是该领域的里程碑式工作，其核心在于将分类网络的全连接层替换为卷积层，解除输入尺寸约束，并通过转置卷积（Transposed Convolution）与跨层连接首次实现端到端像素级预测。然而该架构仍存在局限，表现为上采样过程细节恢复能力不足，且固定感受野难以应对目标尺度剧烈变化。

针对上述局限，学术界从多角度展开研究。UNet^[14]采用对称编码器-解码器结构，通过跳跃连接融合多级特征，在医学影像分割中展现出优异性能。DeepLab^[15-17]系列引入空洞卷积（Dilated Convolution）扩展感受野，其空洞空间金字塔池化（Atrous Spatial Pyramid Pooling, ASPP）模块通过并行多采样率卷积捕获多尺度上下文，后续版本通过编码器-解码器架构重构实现了精度与细节的更优平衡。PSPNet^[18]提出金字塔池化模块（Pyramid Pooling Module, PPM），聚合多子区域上下文信息以增强全局场景理解。HRNet^[19]则开辟新范式，全程维持高分辨率特征表达，并通过多尺度并行交互实现精准边界保持。

在架构演进之外，研究者从多维度探索性能提升。DRFNet^[20]通过设计双分支头结构分别

优化细节信息与上下文信息，实现精细化分割。面向实时应用场景，STDC^[21]重新审视双分支结构的计算冗余，移除空间分支以提高处理效率。其骨干采用渐减通道数的策略，并在每个阶段内通过密集拼接融合多尺度特征以高效捕获语义；同时引入训练阶段的细节引导分支，借助边缘监督信号强化空间细节学习，从而在不增加推理开销的前提下，实现了分割精度与速度的更优权衡。PIDNet^[22]借鉴 PID 控制器的比例-积分-微分控制思想，引入三条并行分支分别处理全局上下文、细节响应与边界信息。此外，条件随机场（Conditional Random Fields, CRF^[23]）通过全局像素关联修正局部预测误差，边界感知损失（Boundary-Aware Loss^[24]）则引导网络关注边界区域分类准确性。

基于 CNN 的语义分割方法的发展历程印证了从全卷积网络到多尺度特征融合架构的演进逻辑。尽管现有模型在特征抽象能力与细节保持之间逐步实现了更优权衡，但在实时性与精度协同优化、长尾数据分布下的鲁棒学习，以及跨域场景迁移时的泛化稳定性等方面，仍存在亟待解决的技术瓶颈。

（2）基于 Transformer^[25]和 Mamba^[26]的语义分割方法

随着 Transformer 架构向计算机视觉领域的渗透，语义分割的全局上下文建模能力迎来范式革新。基于自注意力机制，Transformer 能够有效捕获长距离像素依赖，突破了卷积神经网络感受野的固有局限。针对语义分割任务，研究者从不同角度探索了 Transformer 的适配与优化。CrossFormer^[27]设计了一种轻量级 Transformer 网络，通过多尺度上下文信息的显式建模，提升了对复杂场景中尺度多变目标的分割准确性。TopFormer^[28]则聚焦于全局语义与精细空间细节的融合，在保持推理效率的同时增强了模型对挑战性场景的适应性，特别适用于资源受限或实时应用环境。为进一步平衡精度与效率，MatchFormer^[29]提出分层交错注意力 Transformer 架构，在编码器各阶段交替融合自注意力特征提取与交叉注意力特征匹配，构建匹配感知的分层特征学习范式，同时通过高效注意力设计降低计算开销，提升了低纹理场景下的匹配鲁棒性。

除纯 Transformer 架构外，注意力机制也被广泛集成于 CNN 中以增强特征表示。Coordinate Attention^[30]通过水平和垂直方向的池化操作捕获全局空间依赖，提升了对目标区域的精准聚焦能力。DANet^[31]则并行建模空间与通道维度的注意力图，通过捕获互补依赖关系，在细小目标分割与细节恢复任务上取得显著增益。Lawin Transformer^[32]进一步提出大窗口注意力机制，在平衡效率的同时捕获更丰富的多尺度上下文。

近年来，状态空间模型（State Space Models, SSM）因其在长序列建模中的线性复杂度优势而受到关注^[33]。结构化状态空间序列模型（Structured State Space Sequence Model, S4^[34]）将连续状态方程离散化并引入结构化参数化，为深度学习中的高效长程依赖建模奠定了理论

基础。在此基础上, Mamba 进一步提出数据驱动的状态选择机制, 使模型能够根据输入特征动态调整状态更新路径, 在保持线性计算复杂度的前提下显著提升了特征表达能力。视觉领域的拓展工作 Vision Mamba^[35]与 VMamba^[36]通过引入交叉扫描与多向扫描策略, 将一维状态空间建模适配至二维图像结构, 有效捕获视觉任务中的复杂空间依赖。

上述进展推动了 SSM 在语义分割中的探索。VM-UNet^[37-38]将视觉状态空间模块嵌入经典编解码框架, 实现区域间长程依赖的有效建模。RS3Mamba^[39]采用双分支网络结构协同建模局部细节特征与全局语义信息, 在高分辨率遥感图像分割中取得显著性能提升。MAFMamba^[40]则进一步引入自适应多尺度融合机制, 通过全局-局部增强与基于交叉注意力的特征融合, 优化了高分辨率遥感影像的分割精度。尽管上述工作证明了状态空间模型在语义分割中的潜力, 但如何在统一网络框架内协同建模全局依赖与局部细节特征, 仍缺乏系统的架构设计与机制层面的探索, 这为轻量化语义分割模型的性能提升留下了重要的研究空间。

1.3 主要研究内容

本文围绕轻量化实时语义分割网络的精度与效率协同优化问题展开研究, 深入分析影响模型性能的核心因素, 系统梳理了现有方法的技术瓶颈与发展趋势, 探索能够在低计算开销下实现精准分割的架构设计方法。所有实验基于 PyTorch 框架完成, 使用 NVIDIA RTX 2080Ti GPU 与 NVIDIA RTX 3090 GPU 进行模型训练与测试, 确保实验的高效实施与结果的可复现性。本文的主要工作如下:

(1) 构建了基于多尺度混合 Mamba 的轻量级语义分割网络。针对卷积神经网络局部感受野受限、Transformer 自注意力二次计算复杂度高、纯状态空间模型空间结构建模能力不足的问题, 将 CNN 局部空间归纳偏置与 Mamba 线性复杂度全局建模能力有机融合, 设计多分支特征聚合模块、混合视觉状态空间模块与自适应门控特征分割头, 实现局部细节与全局语义的协同建模。

(2) 研究并设计基于协同注意力机制的轻量级语义分割网络。针对紧凑模型特征表征能力不足、传统跨尺度融合易引发语义冲突、视觉相似类别易混淆的问题, 以轻量级残差块构建高效骨干网络, 设计通道聚合多尺度注意力模块、三级上下文融合模块与选择性嵌入分割头, 在极低参数量下实现多维度注意力的协同增强。

(3) 提出用于高效语义分割的频率感知上下文网络。针对传统下采样高频信息不可逆丢失、纯空间域建模对复杂干扰鲁棒性差、跨尺度融合存在语义鸿沟的问题, 采用纯单分支高效推理框架, 设计空间精炼下采样单元、频率感知上下文模块与跨尺度特征融合模块, 通过




图 1.1 主要章节组织架构示意图

空间-频域协同建模提升模型在恶劣条件下的分割性能。

1.4 论文章节安排

本文共分为六个章节，各章节的主要内容安排如下：

第一章，绪论。首先阐述图像语义分割的研究背景与应用价值，分析传统方法、基于 CNN、Transformer 及 Mamba 的语义分割方法的研究现状与现存问题，明确本文的核心研究目标，最后介绍本文的主要研究内容与整体章节安排。

第二章，相关背景知识介绍。系统介绍卷积神经网络的理论基础，包括卷积层、激活函数层、池化层及全连接层的基本原理与改进形式；阐述注意力机制的核心思想，重点介绍通道注意力与空间注意力的实现方式；说明语义分割任务的常用评价标准，并详细介绍 Cityscapes 与 CamVid 两个核心数据集的构成与特点。

第三章，基于多尺度混合 Mamba 的轻量级语义分割网络。首先分析现有全局建模方法的局限性，然后详细介绍 MHMNet 的整体网络架构，主要讲述多分支特征聚合模块、混合视觉状态空间模块与自适应门控特征分割头的设计原理与实现细节，最后通过消融实验与对比实验验证所提方法的有效性。

第四章，基于协同注意力机制的轻量级语义分割网络。首先分析紧凑模型在特征表征与融合方面的不足，然后详细介绍 CoANet 的整体网络结构，重点阐述通道聚合多尺度注意力模块、三级上下文融合模块与选择性嵌入分割头的设计思路，最后通过实验验证该方法在参数量与推理速度方面的极致优势。

第五章，用于高效语义分割的频率感知上下文网络。首先分析纯空间域建模的局限性，然后详细介绍 FACNet 的整体网络架构，重点描述空间精炼下采样单元、频率感知上下文模块与跨尺度特征融合模块的设计方法，最后通过实验验证该方法在复杂干扰场景下的鲁棒性与分割精度优势。

第六章，总结与展望。全面总结本文的主要研究工作与创新成果，分析现有方法的不足之处，并从模型架构优化、学习范式拓展与垂直应用场景适配三个方面对未来的研究方向进行展望。

第二章 相关背景知识介绍

2.1 卷积神经网络理论基础

卷积神经网络（CNN）是一种受生物视觉系统感受野机制启发而设计的前馈深度学习架构，其核心设计理念在于通过局部连接、权值共享及空间下采样等机制，高效处理具有网格结构的高维数据，如图像、视频等视觉输入。该网络通过层级化的特征提取与抽象过程，逐步将底层像素信息转化为高层语义表示，从而为图像分类、语义分割、目标检测等复杂视觉任务提供有力的特征支撑。其基本结构由多个功能各异的模块协同构成：卷积层负责局部特征的检测与提取，激活函数层引入非线性变换以增强模型表达能力，池化层实现特征图的空间降维与信息聚合，全连接层则完成高层特征的全局整合与决策映射。各组件相互配合，形成了从底层边缘纹理到高层语义概念的渐进式特征学习流程，构成了现代计算机视觉模型的理论基础与技术基石。

2.1.1 卷积层

卷积层是卷积神经网络中的核心构建模块，其主要功能在于通过可学习的卷积核自适应地提取输入数据的局部空间特征。在卷积操作过程中，卷积核以固定的滑动步长在输入特征图上遍历，对每一个局部感受野内的像素值与卷积核的对应权重进行逐元素相乘并累加，同时引入偏置项以调整输出特征图的整体偏移，最终生成二维输出特征图，其过程如图 2.1 所示。该操作本质上是将输入数据映射到更高层次的特征表示，为后续网络层提供更丰富的语义信息。卷积核的参数通过反向传播算法在训练过程中不断优化，从而使得网络能够自动学习到对目标任务最具判别性的特征模式。

具体地，对于输入特征图 X 和尺寸为 $k \times k$ 的卷积核 W ，输出特征图在位置 (i, j) 处的值 $y(i, j)$ 可由以下离散卷积（实际为互相关）运算得到：

$$y(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} W(m, n) \cdot X(i+m, j+n) + b, \quad (2.1)$$

其中 $W(m, n)$ 表示卷积核在 (m, n) 处的权重， b 为偏置项。

输出特征图的尺寸取决于输入尺寸、卷积核大小、步长以及填充策略。设输入特征图的




图 2.1 标准卷积示意图




图 2.2 标准卷积示意图

高度和宽度分别为 H_{in} 和 W_{in} ，卷积核的尺寸为 k （通常取正方形，即 $k = H_k = W_k$ ），步长为 S ，填充大小为 P ，则输出特征图的高度 H_{out} 和宽度 W_{out} 可分别由以下公式计算：

$$H_{out} = \frac{H_{in} + 2P - k}{S} + 1, \quad (2.2)$$

$$W_{out} = \frac{W_{in} + 2P - k}{S} + 1, \quad (2.3)$$

上述公式中，填充 P 通常用于保持边界信息或控制输出尺寸，当步长 $S > 1$ 时，输出尺寸会相应缩小，从而实现特征图的下采样。通过合理配置这些超参数，卷积层能够灵活地调整特征图的维度，以适应不同层次的特征提取需求。

随着卷积神经网络在复杂视觉任务中的广泛应用，传统卷积操作在计算效率、感受野范围及参数量控制等方面的局限逐渐凸显。为突破这些瓶颈，研究者相继提出多种卷积变体，其中空洞卷积^[41]（Dilated Convolution）、分组卷积^[42]（Grouped Convolution）和深度可分离卷积^[43]（Depthwise Separable Convolution）是代表性的改进方式。

（1）空洞卷积

空洞卷积是为了解决标准卷积中感受野扩展与空间分辨率保持的固有矛盾而提出的改进卷积形式。如图 2.2，通过在卷积核元素之间引入空洞（即零值填充），空洞卷积能在不增加参




图 2.3 分组卷积示意图




图 2.4 深度可分离卷积示意图

数量与计算量的前提下直接扩大卷积核的覆盖范围，从而实现对更大区域上下文信息的有效捕获。

具体而言，空洞卷积引入扩张率 r (Dilation Rate) 这一超参数，用于控制卷积核中各权重在输入特征图上的采样间隔。当 $r=1$ 时，空洞卷积退化为标准卷积；当 $r>1$ 时，卷积核中相邻权重之间相隔 $r-1$ 个像素位置，使得尺寸为 $k \times k$ 的卷积核实际覆盖的区域有效扩大。设输入特征图为 X ，卷积核权重为 W ，偏置为 b ，则空洞卷积在输出坐标 (i, j) 处的值 $Y(i, j)$ 可由以下公式表示：

$$Y(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} W(m, n) \cdot X(i + m \cdot r, j + n \cdot r) + b, \quad (2.4)$$

式中， m, n 为卷积核内部的遍历索引， r 为扩张率， b 为偏置项。通过调整 r 的取值，可在不损失特征图分辨率的前提下灵活调节感受野尺度，这对于语义分割、目标检测等需要密集预测的任务尤为重要。

进一步地，空洞卷积的感受野递推关系可描述为：若第 n 层卷积的步长为 s_n ，卷积核尺寸为 k ，则该层感受野 R_n 与上层感受野 R_{n-1} 满足

$$R_n = R_{n-1} + (k-1) \cdot \prod_{i=1}^{n-1} s_i, \quad (2.5)$$

其中 $\prod_{i=1}^{n-1} s_i$ 表示之前所有层步长的累积。该公式表明，空洞卷积通过引入扩张率间接增大了等效卷积核尺寸，从而在深层网络中实现感受野的快速扩张。实际应用中，常采用并行或级联的不同扩张率空洞卷积（如空洞空间金字塔池化）以捕获多尺度上下文，进一步提升模型对目标尺度变化的适应性。

（2）分组卷积

分组卷积作为标准卷积的一种衍生形式，最早由 AlexNet^[44]引入以应对多 GPU 并行训练时的显存限制，随后被证明在降低计算复杂度、增强特征多样性以及改善模型泛化能力方面具有显著效果。其核心思想是将输入特征图与输出特征图按通道维度划分为若干相互独立的组，每组内分别执行标准卷积操作，最终将各组输出的特征图沿通道方向拼接，形成完整的输出特征图，其过程详见图 2.3。

设输入特征图的尺寸为 $H \times W \times C$ ，卷积核尺寸为 $k \times k$ ，输出通道数为 N ，分组数为 g 。

分组卷积将输入通道和卷积核均分为 g 组，每组独立执行标准卷积，其运算可表示为：

$$Y_i = X_i * W_i, \quad i = 1, 2, \dots, g, \quad (2.6)$$

其中 $X_i \in \mathbb{R}^{H \times W \times \frac{C}{g}}$ 为输入的第 i 组通道， $W_i \in \mathbb{R}^{k \times k \times \frac{C}{g} \times \frac{N}{g}}$ 为第 i 组卷积核， $Y_i \in \mathbb{R}^{H \times W \times \frac{N}{g}}$ 为第 i 组输出特征图。最终输出 $Y \in \mathbb{R}^{H \times W \times N}$ 由各组输出沿通道维度拼接而成：

$$Y = \text{Concat}(Y_1, Y_2, \dots, Y_g). \quad (2.7)$$

从参数量和计算量角度看，分组卷积的参数量仅为标准卷积的 $1/g$ ，计算量亦成比例减少，这使得分组卷积成为构建轻量级网络（如 ResNeXt^[45]、MobileNet^[46]等）的关键技术之一。此外，由于每组卷积独立学习，不同组之间可以捕获不同的特征模式，从而提升特征的多样性；同时，分组结构隐式引入了稀疏连接，具有一定的正则化效果，有助于缓解过拟合。

在实际应用中，分组数 g 是一个可调超参数，平衡模型容量与计算效率。当 $g=1$ 时，分组卷积退化为标准卷积；当 $g=C=N$ 时，则演变为深度卷积，即每个输入通道单独进行卷积，输出通道数与输入通道数相同，为后续深度可分离卷积奠定了基础。

（3）深度可分离卷积

深度可分离卷积通过将标准卷积分解为深度卷积与逐点卷积（Pointwise Convolution）两

个独立步骤，在保持特征表达能力的同时有效降低参数量与计算复杂度。如图 2.4 所示，深度卷积对输入特征图的每个通道独立执行空间卷积，用于提取单通道内的局部特征；逐点卷积则采用 1×1 卷积核对各通道输出进行线性组合，实现跨通道的信息融合。设输入特征图尺寸为 $H \times W \times C_1$ ，输出通道数为 C_2 ，卷积核尺寸为 $k \times k$ ，则标准卷积参数量为 $k^2 \times C_1 \times C_2$ ，而深度可分离卷积的参数量为： $k^2 \times C_1 + C_1 \times C_2$ ，二者之比如下所示：

$$\frac{K^2 \times C_1 + C_1 \times C_2}{K^2 \times C_1 \times C_2} = \frac{1}{C_2} + \frac{1}{K^2}. \quad (2.8)$$

由于实际应用中 C_2 通常较大，参数量可近似缩减至标准卷积的 $1/K^2$ ，从而在保证模型性能的前提下实现轻量化设计，适用于资源受限场景下的语义分割等任务。

2.1.2 激活函数层

为增强卷积神经网络的非线性表征能力，在卷积层之后通常引入激活函数（Activation Function），以打破单纯由线性变换构成的映射关系。若网络仅由多层卷积堆叠而成，其本质仍为一系列仿射变换的复合，无法有效拟合复杂的输入输出映射，限制了模型对高维语义信息的建模能力。激活函数通过引入非线性因素，使网络具备逼近任意复杂函数的能力，是深层网络得以有效训练的关键组件之一。如图 2.5 所示，当前研究中广泛应用的激活函数主要包括 Sigmoid、Tanh、ReLU 及其变体 LeakyReLU 等。

Sigmoid 函数是一种经典的饱和型激活函数，其数学形式为：

$$\sigma(x) = \frac{1}{1 + e^{-x}}. \quad (2.9)$$

该函数将任意实数输入映射至 $(0,1)$ 区间内，具有平滑连续且单调可导的特性，适用于二分类问题的输出层。然而，Sigmoid 函数存在固有缺陷：当输入绝对值较大时，函数值趋于饱和，导数趋近于零，导致深层网络在反向传播过程中梯度难以有效传递，进而引发梯度弥散（Vanishing Gradient）问题。此外，其输出非零中心化，可能使得后续层的输入分布发生偏移，影响优化效率。

Tanh 函数（双曲正切函数）可视为 Sigmoid 函数的缩放平移版本，其表达式如下所示：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}. \quad (2.10)$$

Tanh 将输入映射至 $(-1,1)$ 区间，具备零中心化特性，有助于缓解非零均值输出导致的优




图 2.5 激活函数曲线图

化偏移问题。其导数取值范围为 $(0,1]$ ，相较于 Sigmoid 在一定程度上改善了梯度衰减程度，但在输入饱和区域导数仍趋近于零，因此在深层网络中仍存在潜在的梯度弥散风险。

ReLU (Rectified Linear Unit) 函数是目前深度神经网络中最常用的激活函数之一，其定义形式为：

$$ReLU(x) = \max(0, x). \quad (2.11)$$

该函数在正区间保持线性输出，导数为常数 1，有效避免了正区间内的梯度饱和问题，显著提升了深层网络的训练收敛速度。同时，ReLU 的稀疏激活性使得部分神经元输出为零，增强了网络的特征选择能力。然而，ReLU 在负区间输出恒为零，导致对应神经元在反向传播过程中梯度无法更新，一旦陷入该状态则难以恢复，即“神经元死亡” (Dying ReLU) 现象。

为缓解 ReLU 在负半轴梯度为零的问题，LeakyReLU 函数引入非零斜率，其形式定义为：

$$LeakyReLU(x) = \begin{cases} x & , x > 0 \\ \alpha x & , x \leq 0 \end{cases}. \quad (2.12)$$

其中 α 为较小的正常数 (通常取 0.01)。该设计使负区间仍保留微弱梯度，允许对应神经元在训练过程中持续更新，从而在一定程度上避免神经元失活。LeakyReLU 在保持 ReLU 正区间线性优势的同时，提升了负区间的信息利用率，适用于对特征完整性要求较高的深层网络结构。




图 2.6 池化操作示意图

2.1.3 池化层

在卷积神经网络中，池化层（Pooling Layer）通常承接于卷积层之后，其主要功能是对特征图进行空间维度的下采样操作。通过将特征图划分为若干局部区域，并以特定聚合函数对每个区域内的响应进行归纳统计，池化层能够有效压缩特征图的空间尺寸，从而降低后续网络层的计算负载与参数量。与此同时，池化操作通过对局部邻域内的特征进行聚合，增强了模型对输入在平移、旋转等轻微形变下的鲁棒性，并起到抑制噪声、缓解过拟合的作用。

目前应用最为广泛的池化方式主要包括最大池化（Max Pooling）与平均池化（Average Pooling）两种，二者计算过程如图 2.6 所示。最大池化通过选取池化窗口内的最大值作为该区域的输出响应，其过程可形式化描述为：

$$Y(i, j) = \max_{m=0}^{k-1} \max_{n=0}^{k-1} X(i \cdot s + m, j \cdot s + n), \quad (2.13)$$

其中 X 为输入特征图， Y 为池化后输出， k 表示池化窗口尺寸， s 为滑动步长。该操作倾向于保留区域内最显著的特征响应，能够有效捕捉图像的边缘、纹理等判别性信息，因而在网络的中间层应用较为普遍。然而，由于仅保留单一最大值，池化窗口内的其余信息被完全舍弃，可能导致局部特征的丢失。

平均池化则对池化窗口内的所有元素计算算术平均值作为输出，其表达式如下：

$$Y(i, j) = \frac{1}{k \times k} \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} X(i \cdot s + m, j \cdot s + n). \quad (2.14)$$

相较于最大池化，平均池化能够更全面地保留区域内的整体响应强度，减少信息损失，同时通过均值运算起到平滑特征的作用，有助于抑制局部噪声的干扰。由于其能够保持特征的全局统计信息，平均池化常被用于网络深层或全局池化层中，以聚合特征并输送给后续分类器。




图 2.7 (a) 通道注意力 (b) 空间注意力

2.1.4 全连接层

全连接层通常置于卷积神经网络的末端，其主要作用是将前层提取的分布式特征映射至样本标记空间，实现分类或回归等高层任务。该层采用全局连接机制，将上一层输出的每个特征单元与当前层所有神经元建立权重关联，从而完成对高阶语义信息的非线性组合与全局抽象。

在实际结构中，全连接层需将卷积层或池化层输出的二维特征图展开为一维特征向量，再通过密集连接进行加权求和与激活变换。这一过程本质上是对前层局部特征进行全局整合，将网络学习到的特征表示转换至最终的输出空间，为分类器提供判别依据。

尽管全连接层在特征聚合与决策分类方面具有不可替代的作用，但其密集连接特性也带来了参数冗余度高、计算开销大的问题。为缓解这一局限，实际应用中常采用卷积操作等效实现，例如利用 1×1 卷积或尺寸匹配的全局卷积替代传统全连接层。此外，Dropout、权重正则化及网络剪枝等技术的引入，也有效提升了全连接层的参数效率与泛化能力。

2.2 注意力机制

注意力机制的设计灵感源自对人类视觉系统选择性聚焦行为的模拟，其核心思想在于引导模型在处理输入信息时动态关注与任务高度相关的关键区域，同时抑制无关或冗余特征的干扰。该机制在深度学习领域的系统性应用可追溯至 Vaswani 等人于 2017 年提出的

Transformer 架构^[47]，其中提出的自注意力机制为后续各类注意力变体的发展奠定了理论基础。在计算机视觉任务中，注意力机制通过为特征图的不同位置或通道分配自适应权重^[48]，使网络能够依据上下文信息对特征表示进行选择性地增强与重新校准，从而提升模型对关键语义信息的捕获能力。相较于传统卷积操作所采用的固定权重模式，注意力机制具备更强的灵活性与上下文感知能力，能够在空间、通道及多尺度等多个维度上实现特征的重标定与优化。近年来，注意力机制已被广泛应用于图像分类、目标检测、语义分割等各类视觉任务中，成为提升网络表达能力的重要技术手段。本节将围绕注意力机制的基本原理展开，并重点介绍通道注意力机制与空间注意力机制两种典型实现方式。

2.2.1 通道注意力

空间注意力机制的核心在于对特征图的空间维度进行差异化响应调节，使网络能够依据不同位置的信息重要程度动态调整其特征表达。该机制通过聚合通道维度上的特征响应，生成反映各空间位置显著性的权重分布，进而对原始特征进行重校准。具体而言，空间注意力首先采用多种池化策略沿通道方向对特征进行压缩，以获取每个空间位置的整体响应强度和局部显著特征，形成具有互补信息的空间描述。随后，通过卷积操作对这些空间描述进行融合与非线性映射，学习出能够反映空间重要性的二维权重图。该权重图与输入特征图逐元素相乘，实现对不同空间位置的差异化增强或抑制。通过这种空间维度的自适应调节，网络能够更有效地聚焦于目标结构，提升对空间布局的建模能力，在语义分割、目标检测等需要精细空间信息的任务中发挥了重要作用。

如图 2.7 (a) 所示，通道注意力模块的具体操作流程如下：设输入特征图为 X ，其尺寸为 $H \times W \times C$ ，首先对每个通道施加全局平均池化，得到通道描述符 Z ：

$$Z = GAP(X), \quad (2.15)$$

其中 $GAP(\cdot)$ 表示全局平均池化操作。该描述符经过两个连续的 1×1 卷积层进行非线性变换，第一个卷积层通过降维通道数以降低参数量，经 ReLU 激活后再由第二个卷积层恢复至原始通道数 C 。最后通过 Sigmoid 函数获得通道权重向量 S ，公式如下：

$$S = \sigma(\text{Conv}_2(\text{ReLU}(\text{Conv}_1(Z)))), \quad (2.16)$$

其中 Conv_x 表示 1×1 卷积， $\sigma(\cdot)$ 为 Sigmoid 激活函数。最终输出 F 由原始特征图与通道权重逐通道相乘得到：

$$F = X \cdot S. \quad (2.17)$$

通过该机制，网络能够强化对关键语义通道的关注，提升特征表达的判别能力。

2.2.2 空间注意力

空间注意力机制侧重于定位特征图中具有判别性的空间区域，通过生成二维空间权重图对重要位置进行增强，同时抑制背景噪声。该机制首先沿通道维度聚合空间信息，利用不同池化方式提取各位置的特征响应强度，进而通过卷积融合与非线性激活学习空间位置的权重分布。最终将空间权重图与原始特征图逐元素相乘，实现对空间特征的自适应调整。这一机制能够使网络聚焦于目标区域，提升对空间结构的敏感性，在复杂场景任务中表现出显著优势。

空间注意力操作流程如图 2.7 (b) 所示，对于输入特征图 X ，首先分别沿通道维度进行全局最大池化和全局平均池化，得到两个空间特征描述图，用以捕获各位置的最大响应与平均响应。随后将这两个描述图沿通道拼接，形成一个包含丰富空间信息的特征图。接着，通过一个 1×1 卷积层对拼接后的特征进行融合并降维至单通道，再经 Sigmoid 激活函数生成空间注意力权重图。最后，将该权重图与原始输入特征图逐元素相乘，得到经过空间增强的输出特征图 F 。上述过程可描述为如下形式：

$$f = \text{Concat}(\text{GMP}(X), \text{GAP}(X)), \quad (2.18)$$

$$F = \sigma(\text{conv}_1(f)) \cdot X, \quad (2.19)$$

上式中， $\text{GMP}(\cdot)$ 为全局最大池化操作， $\text{Concat}(\cdot)$ 表示沿通道维度拼接。

2.3 语义分割评价标准

为全面衡量语义分割模型的性能表现，通常从分割精确度、推理速度及模型复杂度三个关键维度进行综合评估。

(1) 分割精确度

分割精确度是衡量语义分割模型预测结果与真实标注之间一致性的核心指标，其评估主要基于像素级别的分类准确性。在语义分割任务中，最常用的精确度评价指标包括交并比 (Intersection over Union, IoU) 及其衍生形式平均交并比 (mean Intersection over Union, mIoU)，二者分别从类别独立和全局平均的角度对模型性能进行量化。

并比用于评估模型对单一类别分割结果的准确程度，其定义为模型预测为该类别的区域与真实标注中该类别的区域之间的交集与并集的比值。具体而言，对于某一类别，记真正例

(True Positive, TP) 为预测正确且真实标注也为该类的像素数量, 假正例 (False Positive, FP) 为预测为该类但真实标注非该类的像素数量, 假负例 (False Negative, FN) 为真实标注为该类但预测未覆盖的像素数量, 则 IoU 的计算公式可表示为:

$$IoU = \frac{TP}{TP + FP + FN}, \quad (2.20)$$

该指标综合反映了模型对目标区域的定位精度与完整性, 值域为[0,1], 数值越大表示预测区域与真实区域的重合度越高。

平均交并比则是在所有类别上对 IoU 取平均, 以整体评估模型在包含背景在内的所有类别上的分割性能。假设数据集中包含背景在内共有 $k+1$ 个类别, mIoU 的计算过程如下所示:

$$mIoU = \frac{1}{k+1} \sum_{i=0}^k IoU_i, \quad (2.21)$$

其中 IoU_i 表示第 i 个类别的交并比值。mIoU 作为语义分割领域最主流的评价标准, 能够全面反映模型对不同类别目标的综合分割能力, 被广泛应用于各类分割任务的性能对比与模型选优中。

(2) 推理速度

除了分割精度之外, 模型的实时处理能力同样是评估其性能的关键维度之一。在自动驾驶、视频监控等对延迟敏感的应用场景中, 模型必须在有限时间内完成对输入图像的分割推理, 这对算法的运算效率提出了严苛要求。衡量这一能力的常用指标是帧率 (Frames Per Second, FPS), 其定义为模型每秒能够处理的图像数量。FPS 数值越高, 表明模型在单位时间内可完成更多次推理, 实时性越强。实际中, FPS 受硬件平台、输入分辨率及模型结构复杂度共同影响, 且往往与分割精度存在权衡: 高精度深层模型计算量大导致帧率偏低, 而轻量化实时模型则可能牺牲部分精度以换取更快的处理速度。因此, 根据具体任务需求合理平衡精度与速度, 是实现语义分割模型落地应用的关键考量。

(3) 模型复杂度

模型复杂度通常通过浮点运算次数 (Floating Point Operations, FLOPs) 与参数量 (Parameters) 两个指标进行衡量。FLOPs 用于评估模型执行一次前向推理所需的计算量, 其数值大小反映了模型对硬件算力的需求, 与卷积层数量、特征图尺寸及卷积核大小等因素密切相关。参数量则指模型中所有可学习参数的总和, 包括卷积层与全连接层的权重及偏置项, 决定了模型所占用的存储空间, 通常以百万为单位计量。一般而言, FLOPs 与参数量共同决定了模型在资源受限环境下的部署可行性, 二者往往与分割精度和推理速度存在权衡关系。



图 2.8 数据集部分示例图

2.4 语义分割数据集

语义分割任务的发展与进步离不开各类公开数据集的支撑。当前主流的数据集主要面向城市场景驾驶、日常生活场景及物体上下文理解等不同应用方向。其中，PASCAL VOC^[49]是早期最具影响力的通用场景语义分割数据集，包含 20 个前景类别及背景类，为分割模型提供了基础的验证平台。MSCOCO^[50]数据集在通用物体检测基础上扩展了分割标注，涵盖 80 个物体类别与 91 种材料类别，图像场景丰富且标注精细，适用于复杂日常场景下的上下文理解任务。ADE20K^[51]数据集则以其室内外场景多样性和类别丰富性著称，覆盖 150 个语义类别，为模型在复杂自然环境下的泛化能力提供了严苛评测依据。本文所提出的轻量级语义分割网络主要基于 Camvid^[52]与 Cityscapes^[53]数据集进行训练与性能评估，以下将对这两个数据集的基本情况进行介绍。图 2.8 展示了两个数据集中的部分图像。

2.4.1 Cityscapes 数据集

Cityscapes 是目前语义分割领域最具权威性的城市场景数据集之一，其设计目标是为自动驾驶环境下的视觉感知任务提供标准化的评测基准。该数据集由梅赛德斯-奔驰研究院、马克斯·普朗克研究所等多个机构联合发布，依托 50 个不同城市采集的真实街景影像构建了多维度、多场景的样本库。数据采集过程充分考虑了环境因素的多样性，涵盖了不同季节、光照条件及天气状况下的道路场景，为模型在实际应用中的泛化能力提供了严苛的测试环境。其统一的采集设备与标注流程确保了数据的一致性与可比性，从源头上避免了不同来源数据带来的分布偏移问题。

在数据构成方面, Cityscapes 提供了两个层次的标注质量: 其一为 5000 张精细标注图像, 每张图像均经过像素级的人工语义标注, 分辨率统一为 1024×2048 , 能够清晰呈现道路、车辆、行人、交通标志等目标的边缘细节; 其二为 20000 张粗糙标注图像, 适用于需要大规模数据预训练的场景。精细标注部分按照标准划分为 2975 张训练图像、500 张验证图像及 1525 张测试图像, 保证了模型训练与评估的规范性。在语义类别定义上, Cityscapes 共标注了 34 个细分类别, 涵盖地面、建筑、交通设施、自然景物、车辆、行人等多个层级。为便于模型性能的统一对比, 学术界通常采用其中 19 个具有明确语义含义的类别作为主要评估对象。模型在测试集上的预测结果需提交至官方在线评估服务器进行计算, 以保证评测过程的公平性与标准化。该数据集的发布极大推动了自动驾驶场景理解技术的发展, 已成为学术界与工业界广泛采用的标准评测平台。

2.4.2 Camvid 数据集

作为语义分割领域较早公开的街景数据集之一, CamVid (Cambridge-driving Labeled Video Database) 由剑桥大学于 2008 年发布, 旨在为道路场景理解与自动驾驶感知研究提供标准化的评估基准。该数据集从真实驾驶视角拍摄的视频序列中提取并筛选出 701 张高质量图像, 每张图像均经过像素级精细标注, 分辨率为 720×960 , 能够较为清晰地呈现城市道路环境中的各类目标结构。

在数据划分方面, CamVid 将标注图像划分为训练集、验证集与测试集三个部分, 分别包含 367 张、101 张及 233 张图像, 这一划分方式在后续研究中被广泛沿用, 便于不同模型之间的性能对比。数据集涵盖的语义类别依据道路场景的实际构成进行定义, 共包含 11 个常用类别, 涉及道路、建筑物、车辆、行人、交通标志、树木、天空等典型城市交通元素。相较于后续发布的大规模数据集, CamVid 的图像总量虽然相对有限, 但其标注质量较高且场景多样性良好, 能够反映不同光照、天气及交通条件下的道路分布特征, 因而在轻量化模型验证及算法快速迭代中仍保持较高的使用频率。

作为早期语义分割数据集之一, CamVid 的发布为自动驾驶场景下的像素级理解任务奠定了重要基础, 其类别定义与评估方式也被后续数据集所借鉴。该数据集至今仍是衡量语义分割算法在道路场景下基础性能的重要参考基准之一。

2.5 本章小节

本章首先介绍了卷积神经网络的基本理论, 重点介绍了卷积层、激活函数层、池化层及

全连接层等核心模块，并分析了空洞卷积、分组卷积及深度可分离卷积等改进结构的作用。在此基础上，阐述了注意力机制的基本原理，介绍了通道注意力与空间注意力两种典型实现方式。最后，针对语义分割任务，概述了常用的评价指标及 Cityscapes、CamVid 两个数据集的基本情况，为后续章节的模型设计与实验分析奠定基础。

第三章 基于多尺度混合 Mamba 的轻量级语义分割网络

3.1 引言

语义分割作为自动驾驶系统中环境感知与场景理解的基础任务，其核心目标是为输入图像中的每个像素赋予精确且一致的语义标签，从而为路径规划、行为预测及复杂城市场景下的安全决策等下游模块提供细粒度的感知线索。由于自动驾驶系统通常部署在资源受限的嵌入式平台，其对实时推理能力、运行稳定性及计算效率提出了严格要求。因此，在有限的计算预算下实现高精度的语义分割，已成为该领域一个关键且具有挑战性的研究问题。

深度学习的快速发展推动了基于 CNN 的方法在实时语义分割场景中的广泛应用。受益于卷积算子的局部感受野和固有的空间归纳偏置，这类方法在计算效率和模型鲁棒性方面展现出显著优势。例如，BiSeNetV2^[54]引入了双分支架构，将高层语义理解与底层边界细节建模分离，通过轻量级模块设计显著提升了推理速度。DDRNet^[55]提出了一种双分辨率并行架构，其中高分辨率分支保留细粒度的空间结构信息，而低分辨率分支则执行高效的语义建模，从而在不影响实时性能的前提下，增强了对道路结构和物体轮廓的表征。然而，这些基于 CNN 的方法固有地受限于卷积算子的固定局部感受野，这限制了它们建模长距离依赖和跨区域语义一致性的能力。因此，在大规模城市场景中，它们容易产生语义碎片化和全局连贯性不足的问题。

为弥补 CNN 全局建模能力的局限，基于自注意力机制的 Transformer 架构被逐步引入语义分割领域，为长距离依赖建模提供了新范式。SegFormer^[56]采用分层 Transformer 编码器，通过多阶段特征抽象来捕获长距离依赖，并结合轻量级解码器设计，在精度与效率之间取得了良好平衡。SegNext^[57]通过简化和重构多尺度上下文聚合方式，进一步解决了 Transformer 在实时场景下的高计算成本问题，在保留全局建模能力的同时大幅降低了模型复杂度。然而，自注意力机制本身具有二次方计算复杂度，在处理高分辨率输入时会导致可观的计算和内存开销，从而限制了基于 Transformer 的模型在真实自动驾驶系统中的实际部署。

近来，状态空间模型（State Space Models, SSMs）作为一种前景广阔的高效长距离依赖建模方法崭露头角。通过引入选择性结构状态空间序列模型（Selective Structured State Space Sequence Model, S6），Mamba^[58]在保持线性计算复杂度的同时，实现了对长序列依赖关系的有效建模，在表达能力和推理效率之间取得了平衡。与 Transformer 相比，Mamba 在高分辨率特征建模方面展现出更优的计算可扩展性，为轻量级、实时城市场景语义分割提供了新的




图 3.1 MHMNet 整体网络结构

研究方向。然而，由于多尺度特征表示不足以及局部空间结构建模能力有限，直接将状态空间模型应用于视觉语义分割仍面临挑战，需要有效结合卷积网络的空间归纳先验知识。

在复杂的城市场景中，轻量级语义分割在严格的参数和实时性约束下面临着基本困境。精确描绘边界、薄层结构和小物体需要强大的局部空间先验知识和多尺度表示，而全局一致的预测则需要有效的长距离依赖建模。然而，单纯强化局部多分支设计容易耗尽有限的模型容量，而基于注意力的全局模块通常会带来过高的计算和内存开销。因此，一个有效的轻量级框架应当将高效的多尺度局部编码与可扩展的全局上下文传播统一起来，以同时提升细节和整体语义。受上述分析启发，本章提出了一种多尺度混合 Mamba 网络（Multi-scale Hybrid Mamba Network , MHMNet），这是一个轻量级语义分割框架，它在统一架构中协同整合了 CNN 的局部空间归纳偏置与 Mamba 状态空间模型的高效长距离依赖建模能力。该网络的主要贡献概括如下：

（1）提出了一种多尺度混合特征编码机制，通过在编码器中引入多分支特征聚合模块（Multi-branch Feature Aggregation Block , MFAB）。MFAB 通过多路径交互促进了高效的局部特征提取和跨尺度融合，使得在复杂城市场景中，不同感受野的空间信息能够得到更有效的利用。

（2）设计了一个混合 Mamba 解码模块，该模块将状态空间建模与局部特征处理机制相结合。此模块实现了局部细节与全局上下文语义的协同建模，在保持线性计算复杂度的同时，增强了全局语义一致性。

（3）提出了自适应门控特征分割头（Adaptive Gated Feature SegHead , AGFS），通过引入通道级门控机制来自适应地选择解码后的特征。该模块有效抑制了噪声引起的通道干扰，并强调了判别性特征对最终分割预测的贡献，进一步提高了轻量化设置下的分割精度和运行稳定性。

3.2 基于多尺度混合 Mamba 的轻量级语义分割网络

3.2.1 整体网络架构

如图 3.1 所示, MHMNet 遵循 UNet 的设计范式, 采用非对称架构, 由图像预处理模块、主干编码器、基于混合视觉状态空间模块 (Hybrid Visual State Space Module, HVSS) 的解码器以及自适应门控特征分割头 (AGFS) 组成。

对于给定的输入图像 $I \in \mathbb{R}^{3 \times H \times W}$, 模型首先应用一个预处理卷积模块, 将其通道维度扩展至 8, 构建初始特征表示, 得到特征图 $I' \in \mathbb{R}^{8 \times H \times W}$ 。编码器由四个顺序堆叠的编码块组成。每个块包含两个连续的卷积单元, 每个单元包括一个 3×1 卷积、一个 1×3 卷积和一个多分支特征聚合模块 (MFAB)。该组件利用多核卷积和注意力机制, 将空间特征提取与通道变换解耦, 从而在保持足够感受野的同时, 以轻量级的参数规模捕获跨层次、多维度的细节特征。在前三个编码块之后应用了 Patch Merging (PM) 操作, 将空间分辨率减半, 通道维度加倍, 以通过下采样聚合特征。

解码器与编码器镜像对称, 同样包含四个阶段。每个解码器块由一个 3×3 深度可分离卷积后接一个 HVSS 模块组成。深度可分离卷积执行轻量级特征变换, 而 HVSS 模块通过结合局部卷积先验与状态空间建模, 联合建模全局和局部上下文。为补偿下采样过程中的空间细节损失, 采用跳跃连接, 通过逐元素相加的方式, 直接融合来自对应编码器阶段的特征。在最后三个解码阶段的开始, 应用 Patch Expanding (PE) 操作, 以逐步恢复空间分辨率并重建高分辨率特征图。

最后, 解码器输出经过门控特征选择分割头处理, 该部分将特征通道映射到目标类别数 C , 同时进一步优化分割性能, 生成最终的预测图 $P \in \mathbb{R}^{C \times H \times W}$ 。

3.2.2 多分支特征聚合模块

现有的语义分割方法已在编码器阶段广泛采用多尺度特征提取来增强上下文表示。然而, 其中大多数方法主要关注不同感受野下的空间尺度聚合, 在很大程度上忽略了通道维度语义与空间维度之间的显式交互建模。这导致多尺度特征往往无法被充分解耦和协同利用。在复杂的城市场景中, 不同尺度的物体通常伴随着显著的结构变化和语义层级改变, 单纯进行尺度堆叠或顺序融合容易引入特征冗余或抑制判别性线索。受上述观察启发, 我们提出了一个




图 3.2 多分支特征聚合模块 (MFAB)

多分支特征聚合模块 (MFAB)，该模块在编码器阶段引入多路径特征建模和跨维度交互，以联合编码多尺度空间特征和通道维度语义信息，从而增强模型输出的可判别性和鲁棒性。

MFAB 如图 3.2 所示。给定一个输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ ，模块首先应用层归一化 (Layer Normalization) 以稳定特征分布，然后沿着通道维度将归一化后的特征均匀分割为四个子特征：

$$[X_1, X_2, X_3, X_4] = \text{Split}(\text{LN}(X)), \quad (3.1)$$

其中每个子特征 $X_i \in \mathbb{R}^{\frac{C}{4} \times H \times W}$ 负责建模互补的特征特性。具体来说，前两个分支引入了基于注意力的特征调制，以建模互补的依赖关系。第一个分支采用通道注意力机制来捕获全局的通道间关系，并自适应地重新校准不同通道的重要性；而第二个分支则结合了空间注意力机制，以显式建模空间相关性并强调信息量大的区域。此过程可表示为：

$$\tilde{X}_1 = A_{ch}(X_1), \quad (3.2)$$

$$\tilde{X}_2 = A_{sp}(X_2), \quad (3.3)$$

其中 $A_{ch}(\cdot)$ 和 $A_{sp}(\cdot)$ 分别表示通道注意力算子和空间注意力算子， $\tilde{X}_1$ 和 $\tilde{X}_2$ 代表经过注意力机制重新加权后的增强特征图。第三和第四分支分别采用核大小为 3×3 和 5×5 的深度可分离卷积，以较低的计算开销捕获不同感受野下的局部上下文信息：

$$\tilde{X}_3 = \text{DSConv}_{3 \times 3}(X_3), \quad (3.4)$$

$$\tilde{X}_4 = \text{DSConv}_{5 \times 5}(X_4), \quad (3.5)$$

所有分支的增强特征沿通道维度拼接后，经由一个轻量级 MLP 进行变换，以实现跨通道信息交互与非线性特征重组，最终通过残差连接得到模块的输出。此过程公式表示如下：

$$F = \text{Concat}(\tilde{X}_1, \tilde{X}_2, \tilde{X}_3, \tilde{X}_4), \quad (3.6)$$

$$Y = X + MLP(F). \quad (3.7)$$

从机制角度来看, MFAB 通过将输入分割为并行的子分支来强制执行互补的特征特化。通道注意力执行全局语义重校准, 在抑制冗余通道的同时放大类别判别性响应; 空间注意力提供位置敏感的调制, 以强调信息区域并锐化边界相关线索。与此同时, 多核深度卷积以不同的感受野聚合局部上下文, 以较低成本捕获尺度相关的结构。这三部分协同作用, 共同形成一个紧凑且富有表达力的表示。

3.2.3 混合视觉状态空间模块

当前的轻量级语义分割方法在城市场景中仍表现出明显的局限性。基于卷积的模型受限于有效感受野增长缓慢的问题, 难以在低对比度区域或语义边界模糊的区域建立足够的长距离依赖, 进而影响整体场景理解。基于注意力的模型虽然能够捕获全局上下文, 但其计算成本随图像分辨率显著增长, 导致在实时应用中难以平衡精度与效率。此外, 一些线性复杂度的全局建模方法, 例如基于直接序列化的操作, 在应用于图像时可能会削弱固有的二维空间结构, 从而降低对小物体和细粒度细节的判别能力。

针对上述问题, 我们基于 Mamba 高效的全局建模范式, 进一步提出了一种混合视觉状态空间模块 (HVSS), 旨在轻量级网络框架内构建更鲁棒、更具判别性的全局语义表示。与依赖单一序列建模或简单方向扫描的状态空间设计不同, HVSS 将局部卷积建模与二维状态空间建模有机整合。该设计在保持线性时间复杂度和硬件友好计算的同时, 有效增强了跨区域语义交互。

HVSS 模块如图 3.3 (a) 所示。在每个解码器阶段, 由一个 3×3 深度可分离卷积生成的特征图, 记为 $X \in \mathbb{R}^{C \times H \times W}$, 首先通过 LayerNorm 进行归一化以稳定特征分布。随后, 它经过一个线性投影, 将通道维度扩展至原始大小的两倍, 以增加表示能力。扩展后的特征进一步通过一个 3×3 卷积和 SiLU 激活函数处理, 以增强局部空间线索, 之后被送入混合二维选择性扫描 (Hybrid 2D Selective Scan, HSS2D) 模块进行全局上下文与局部结构的联合建模, 生成增强特征:

$$X_1 = HSS2D(SiLU(Conv_{3 \times 3}(Linear(X)))), \quad (3.8)$$

此处, $Conv_{n \times n}(\cdot)$ 表示 $n \times n$ 卷积, $Linear(\cdot)$ 代表线性变换。

为保留输入的原始信息, 我们引入一个并行的辅助分支, 该分支应用线性投影后接激活




图 3.3 (a) 混合视觉状态空间模块(HVSS) (b) 自适应门控特征分割头(AGFS)

函数，以生成互补特征：

$$X_2 = SiLU(Linear(X)), \quad (3.9)$$

两个分支通过逐元素相乘进行融合，融合后的表示被投影回原始通道维度，并通过残差连接与输入相加：

$$X_{out} = X + Linear(X_1 \odot X_2), \quad (3.10)$$

其中 $\odot$ 表示逐元素相乘。此设计在利用 HSS2D 捕获全局依赖的同时，保留了局部空间结构，实现了全局-局部特征增强。它提高了复杂背景下的判别能力，并保持了计算效率，为城市道路场景分割中的低对比度区域提供了有效的表示。

HSS2D 作为 HVSS 模块的核心组件，遵循一种混合建模范式，将卷积的局部空间建模能力与状态空间模型的长距离依赖建模能力有机集成。具体来说，输入特征 F_{in} 首先通过通道分割 (Channel Split) 操作沿通道维度划分成两个子空间。第一个是局部增强分支 F_1 ，它依次应用核大小为 3×3 、 5×5 和 7×7 的多尺度卷积，逐步聚合局部纹理和边界线索，然后采用残差连接形成稳定的局部增强表示 F'_1 。第二个是全局建模分支 F_2 ，它被送入 SS2D，以线性复杂度捕获长距离依赖和全局上下文，生成 F'_2 。最后，两个分支的特征通过通道拼接进行集成，得到输出 F_{out} ，从而在一个统一的框架内实现局部细节与全局语义的互补融合，并缓解了仅

依赖纯卷积或纯序列建模所带来的表示局限性。该过程可表述如下：

$$F_1, F_2 = \text{Split}(F_{in}), \quad (3.11)$$

$$\tilde{F}_1 = \text{Conv}_{7 \times 7}(\text{Conv}_{5 \times 5}(\text{Conv}_{3 \times 3}(F_1))), \quad (3.12)$$

$$F'_1 = F_1 + \tilde{F}_1, \quad (3.13)$$

$$F'_2 = \text{SS2D}(F_2), \quad (3.14)$$

$$F_{out} = \text{Concat}(F'_1, F'_2). \quad (3.15)$$

SS2D 是用于全局依赖建模的基础状态空间单元。其目标是将二维特征图转换为多向序列，通过状态空间模型在序列域进行全局交互，然后将处理后的序列重新映射回原始空间布局。

具体而言，给定输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ ，SS2D 首先应用扫描扩展（scan expanding），通过从左至右、从右至左、从上至下、从下至上四个方向遍历特征图，以获得序列表示 $x \in \mathbb{R}^{C \times L}$ ，其中 $L = H \times W$ 表示序列长度。此操作使网络能够从不同方向角度捕获嵌入在空间结构中的潜在全局语义关系。

在获得序列后，SS2D 采用 S6 状态空间模块进行高效的长距离建模。在此过程中，对输入序列应用三个独立的线性投影，以生成离散化步长 Δ 、输入投影系数 B 和输出投影系数 C ：

$$\Delta, B, C = \text{Linear}_i(x) \quad , \quad i = 1, 2, 3, \quad (3.16)$$

根据状态空间模型的离散化过程，状态转移矩阵 $\bar{A}$ 和离散化后的输入映射矩阵 $\bar{B}$ 按如下方式计算：

$$\bar{A} = \exp(\Delta A), \quad (3.17)$$

$$\bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I) \cdot \Delta B, \quad (3.18)$$

其中 $\exp(\cdot)$ 表示矩阵指数， I 是单位矩阵。潜在状态 h_t 随时间逐步累积语义依赖，通过下式递归更新状态并计算输出：

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t, \quad (3.19)$$

$$y_t = Ch_t + Dx_t, \quad (3.20)$$

其中 D 是一个可学习的输入残差项，用于在构建全局依赖的同时保留局部信息。将所有时间步的输出连接起来，即得到完整的序列输出：

$$y = [y_1, y_2, \dots, y_t, \dots, y_L]. \quad (3.21)$$

最后，扫描合并（scan merging）过程将四个方向的序列输出重新映射回二维特征图，随后进行方向对齐与聚合，以获得最终输出 $Y \in \mathbb{R}^{C \times H \times W}$ 。通过结合扫描扩展、基于 S6 的序列建模和扫描合并，SS2D 以线性复杂度建立了全局上下文交互，同时保持了对底层空间结构的有效表示。

上述 SS2D 递归过程通过 Mamba 风格的选择性扫描核（selective scan kernel）完成计算。具体来说，状态更新和输出累积是通过一个优化的扫描算子计算的，该算子使用与输入相关的系数，而不是显式地形成转移矩阵或计算矩阵指数项。这种实现方式保留了预定的离散状态空间动态特性，同时提供了数值稳定且硬件高效的执行过程，其计算量与序列长度呈线性关系。

3.2.4 自适应门控特征分割头

在语义分割中，主干网络生成的高层特征图蕴含着丰富的语义信息；然而，这些特征图在通道维度上对最终预测的贡献是不平等的。某些通道可能编码了与特定类别高度相关的、极具判别性的模式，而其他通道则可能主要捕获了冗余的背景响应或与任务无关的噪声。因此，直接使用所有通道进行预测，会因非判别性特征的干扰而制约模型的能力，尤其是在处理具有模糊边界或外观变化剧烈的物体时，这一问题更为突出。

为解决此问题并生成精确的像素级分割图，本章设计了一种自适应门控特征分割头（Adaptive Gated Feature SegHead, AGFS），如图 3.3 (b) 所示。其核心思想是利用全局上下文信息对输入特征进行校准，并采用一个轻量级网络动态地增强信息量丰富的通道，同时抑制冗余或含噪声的通道。这种门控机制使网络能够自适应地评估通道重要性并动态地重新调整特征响应，从而提高分割精度和边界保真度。

给定一个输入特征图 $F_{in} \in \mathbb{R}^{C \times H \times W}$ ，所提出的 AGFS 模块构建一个内容自适应的门控信号，以在预测前对特征响应进行重新加权。具体而言，首先通过全局平均池化汇总全局上下文，并使用一个 1×1 卷积对其进行投影：

$$u = \text{Conv}_{1 \times 1}(\text{GAP}(F_{in})), \quad (3.22)$$

为了以极小的计算开销建模互补的依赖关系， u 随后被送入两个轻量级的非对称卷积分支进行处理：

$$a = \text{Conv}_{k \times 1}(u), \quad (3.23)$$

$$b = \text{Conv}_{1 \times k}(u), \quad (3.24)$$

表 3.1 训练参数设置

数据集	Cityscapes	CamVid
Batch Size	6	8
Main Loss	CrossEntropy	OHEM CrossEntropy
Auxiliary Loss		Focal Loss
Optimization method	SGD	Adam
Weight decay	1×10^{-4}	2×10^{-4}
Initial learning rate	4.5×10^{-2}	1×10^{-3}
Learning rate policy		Poly

随后，通过可学习的权重 W_1 和 W_2 对这两个特征进行自适应融合：

$$s = W_1 \odot a + W_2 \odot b, \quad (3.25)$$

通过 1×1 卷积生成门控图，经 Sigmoid 激活将其约束至 (0,1) 范围后，对输入特征进行通道维度的调制，最终由 3×3 卷积输出分割预测结果：

$$G = \sigma(\text{Conv}_{1 \times 1}(s)), \quad (3.26)$$

$$F_{out} = \text{Conv}_{3 \times 3}(F \odot G). \quad (3.27)$$

由于门控信号 G 的生成基于全局池化表示，AGFS 模块得以依据全局上下文感知，对通道特征进行实例自适应的重标定；同时，非对称卷积分支高效地捕获互补的上下文模式，为门控生成提供丰富的特征依据。可学习组合权重 (W_1, W_2) 进一步增强了模块的自适应能力，使其能够在训练过程中动态平衡两个分支的贡献，从而更灵活地优化分割性能。

3.3 实验设计与结果分析

3.3.1 数据集与实验参数设置

本章提出的 MHMNet 模型在 Cityscapes 与 CamVid 两个数据集上进行训练与测试，所有实验基于 PyTorch 框架，并在单张 NVIDIA RTX 2080Ti GPU 上完成。数据集专用配置与训练超参数如表 3.1 所示。对于 CamVid 数据集，图像尺寸调整为 360×480 ，共涉及 11 个语义类别，批量大小设为 8，初始学习率为 1×10^{-3} 。对于 Cityscapes 数据集，输入分辨率设置为 512×1024 ，包含 19 个语义类别，批量大小设为 6，初始学习率为 4.5×10^{-2} 。两个数据集均训练 1000 轮，并采用多项式学习率衰减策略：

$$\text{lr} = \text{lr}_{\text{initial}} \times \left(1 - \frac{\text{iteration}}{\text{max_iteration}} \right)^{0.9}. \quad (3.28)$$

学习率在前 500 次迭代中线性预热，之后按上式衰减。数据增强方面，统一应用随机水平翻转与[0.5, 2.0]范围内的随机缩放。Cityscapes 的主损失函数为标准交叉熵损失，而 CamVid 则采用基于在线难例挖掘（Online Hard Example Mining, OHEM）的交叉熵损失以强化困难样本的学习。此外，两个数据集均引入 Focal Loss 作为辅助监督项。整体损失函数定义为：

$$\text{loss} = \text{loss}_{\text{main}} + \lambda \cdot \text{loss}_{\text{aux}}. \quad (3.29)$$

其中辅助损失权重 $\lambda = 0.1$ ，以确保辅助监督不会主导主目标。优化器方面，Cityscapes 使用带动量 0.9、权重衰减 1×10^{-4} 的 SGD 优化器，CamVid 则使用权重衰减 2×10^{-4} 的 Adam 优化器。所有关键超参数在实验与消融研究中均保持固定，每轮迭代通过反向传播更新模型参数，并依据上述学习率调度策略调整学习率。

3.3.2 消融实验

本部分通过一系列消融实验，系统分析 MHMNet 各模块的贡献。所有模型变体均在 CamVid 训练集上采用相同训练方案进行训练，并在对应测试集上进行评估，通过分割指标对比以验证各模块的有效性。

（1）多分支特征聚合模块的影响

为验证多分支特征聚合模块（MFAB）在多尺度混合特征编码上的有效性，在 CamVid 数据集上进行了消融实验，结果如表 3.2 所示。MFAB 的设计目标是通过多路径交互实现高效的局部特征提取与跨尺度融合，从而提升复杂城市场景中不同感受野空间信息的利用效率。本实验将完整 MFAB 与多个仅保留单一组件的单路径变体进行对比，包括仅通道注意力（CA only）、仅空间注意力（SA only）以及仅卷积分支（CNN only）。其中，完整 MFAB 配置（CA+SA+CNN）以红色剑标（†）标示，代表本文提出的设计方案。

实验结果表明，所有单路径设计的分割精度均不及完整 MFAB。具体而言，仅采用通道注意力的配置（CA only）仅达到 67.90% mIoU，单一空间注意力的配置（SA only）为 67.85% mIoU，说明仅依赖单一注意力机制难以充分捕获多样化的空间结构信息。仅保留卷积分支的变体（CNN only）通过强化局部卷积建模，将性能提升至 68.20% mIoU，但仍未超越完整配置。相比之下，集成 CA+SA+CNN 的完整 MFAB（以†标记）在保持轻量化特性（774K 参数量、3.81G FLOPs 计算量）与实时推理速度（292 FPS）的同时，取得了 69.50% mIoU 的最佳性能。上述结果验证了多路径交互的互补特性：基于注意力的机制增强特征选择性，卷积分

表 3.2 多分支特征聚合模块的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
CA only	698	3.50	315	67.90
SA only	702	3.51	318	67.85
CNN only	730	3.68	303	68.20
CA+SA+CNN [†]	774	3.81	292	69.50

表 3.3 混合视觉状态空间模块的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
CNN	715	3.15	298	68.96
Swin Block	1044	5.07	230	69.12
VSS	883	4.45	282	69.23
HVSS [†]	774	3.81	292	69.50

表 3.4 自适应门控特征分割头的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
-	766	3.75	300	68.93
CNN	770	3.77	290	69.15
AGFS [†]	774	3.81	292	69.50

支则丰富多尺度局部表征，二者的融合为城市场景分割任务提供了更具判别力的特征。

（2）混合视觉状态空间模块的影响

表 3.3 展示了在 CamVid 数据集上,将所提出的 HVSS 模块替换为不同方案后的消融实验结果。表中第一列列出了在不改变网络其余部分的前提下,用于替换原位置 HVSS 的各模块。其中, CNN 代表用于建模局部空间模式的传统卷积模块; Swin Block 指代基于 Swin Transformer^[59]改进的轻量级窗口自注意力模块; VSS 则为用于全局序列建模的标准状态空间模块。

实验结果显示,使用纯卷积模块替换 HVSS 后,模型取得 68.96% mIoU,仅依赖局部建模难以捕获城市场景中的长程语义信息。引入基于注意力的全局交互模块(Swin Block)虽将性能提升至 69.12% mIoU,但模型复杂度显著增加,吞吐率也大幅下降至 230 FPS。采用标准状态空间设计(VSS)替换 HVSS 后,精度进一步提升至 69.23% mIoU,但其参数量与计算量仍高于 HVSS,且精度尚未达到最优。相比之下,本文提出的 HVSS 模块在仅 774K 参数量、3.81G FLOPs 计算量及 292 FPS 吞吐率的情况下,取得了 69.50% mIoU 的最佳性能,实现了效率与精度的良好平衡。上述结果充分表明, HVSS 能够有效融合状态空间建模与局部特征处理,实现全局上下文语义与局部细节的协同建模,从而在轻量化约束下展现出优异的分割性能。

（3）自适应门控特征分割头的影响

如表 3.4 所示, 本节通过消融实验评估了所提出的 AGFS 模块。表中“-”表示采用原始分割头并且未引入任何特征选择模块的基线模型, CNN 表示在基线模型上加入卷积优化作为分割头。

实验结果显示, 基线模型取得了 68.93% mIoU, 参数量为 766K, 计算量 3.75G FLOPs, 推理速度达 300 FPS。在此基础上引入 CNN 优化块后, mIoU 小幅提升 0.22%, 但计算量有所增加, 吞吐率下降至 290 FPS。相比之下, AGFS 在参数量仅 774K、计算量 3.81G FLOPs 的轻微开销下, 取得了 69.50% mIoU 的最高精度, 同时保持 292 FPS 的实时推理速度。上述结果表明, 通道级门控机制能够有效重校准解码特征, 通过抑制低信息响应、增强判别性通道, 在轻量化约束下实现了分割精度与运行效率的双重提升。

3.3.3 与其它方法的比较

本节在 Cityscapes 和 CamVid 数据集上, 将所提方法与当前具有代表性的语义分割方法进行了对比。结果表明, MHMNet 在分割精度与计算效率之间取得了良好的平衡。

(1) Cityscapes 数据集结果对比

表 3.5 展示了在 Cityscapes 测试集上与代表性语义分割方法的定量对比结果, 相应的可视化结果如图 3.4 所示。可以看出, 本文提出的 MHMNet 在 512×1024 分辨率下, 无需依赖任何骨干网络, 仅以 0.77M 参数量和 7.12G FLOPs 的计算代价, 取得了 71.5% mIoU 的分割精度。在相近的轻量化预算下, MHMNet 超越了多个紧凑型 CNN 基线方法, 包括 LEDNet^[63] (0.94M 参数量、12.6G FLOPs、70.6% mIoU)、LRDNet^[67] (0.66M、16.0G、70.1%) 以及 SGCPNet^[71] (0.61M、4.5G、70.9%), 这表明所提出的设计在保持参数高效的同时提升了分割质量。与 MSCFNet^[72] (1.15M、17.1G、71.9%) 相比, 本模型以显著更低的计算成本取得了与之相当的精度。

在运行效率方面, MHMNet 在 RTX 2080Ti GPU 上达到 173 FPS 的推理速度, 展现出强劲的实时处理能力。在与同样基于 RTX 2080Ti 报告速度的方法对比中, MHMNet 明显快于 NDNet^[65] (40 FPS)、SCMNet^[66] (92 FPS)、AGFNet^[69] (60 FPS) 和 MSCFNet^[72] (50 FPS), 同时保持了良好的精度。此外, 与 DFANet^[62] (7.8M、3.4G、71.3%、100 FPS) 相比, MHMNet 以更少的参数量和更快的速度取得了更高的精度, 进一步证明了其轻量化设计的有效性。这些对比进一步表明, MHMNet 的设计始终遵循明确的轻量化计算约束, 而非单纯追求高精度。上述结果反映出模型在参数量、计算开销与吞吐率之间取得了良好平衡, 说明所提出的局部-全局融合机制能够在严格控制部署预算的前提下, 实现具有竞争力的分割质量。与许多以牺

表 3.5 Cityscapes 数据集预测结果的对比

Methods	Backbone	Resolution	Param.(M)	FLOPs(G)	Speed(FPS)	mIoU(%)
ERFNet ^[60]	No	512×1024	2.10	-	42	68.0
ESPNet-v2 ^[61]	No	512×1024	3.49	2.7	80	66.2
DFANet ^[62]	Xception	1024×1024	7.80	3.4	100	71.3
STDC1-50 ^[21]	-	512×1024	8.40	-	87	71.9
LEDNet ^[63]	No	512×1024	0.94	12.6	78	70.6
CGNet ^[64]	No	360×640	0.50	6.0	17.6	64.8
NDNet ^[65]	No	1027×2048	0.50	14.0	40	65.3
SCMNet ^[66]	No	512×1024	1.20	18.2	92	68.3
LRDNet ^[67]	No	512×1024	0.66	16.0	77	70.1
CFPNet ^[68]	No	1024×2048	0.55	-	30	70.1
AGFNet ^[69]	No	512×1024	1.12	14.4	60	70.1
PDBNet ^[70]	No	512×1024	1.82	15.0	50	69.5
SGCPNet ^[71]	MobileNet	1024×2048	0.61	4.5	80	70.9
MSCFNet ^[72]	No	512×1024	1.15	17.1	50	71.9
MHMNet(本章方法)	No	512×1024	0.77	7.12	173	71.5

表 3.6 CamVid 数据集预测结果的对比

Methods	Backbone	Resolution	GPU	Param.(M)	Speed(FPS)	mIoU(%)
DABNet ^[73]	No	360×480	1080Ti	0.76	72	66.40
FDDWNet ^[74]	No	360×480	2080Ti	0.80	79	66.90
NDNet ^[65]	-	360×480	2080Ti	0.50	50	57.20
PDBNet ^[70]	No	360×480	2080Ti	1.82	90	67.70
MSCFNet ^[72]	No	360×480	Titan XP	1.15	110	69.30
AGFNet ^[69]	No	360×480	2080Ti	1.12	100	69.40
FBSNet ^[75]	No	360×480	2080Ti	0.62	120	68.90
FAHDNet ^[76]	No	360×480	2080Ti	0.82	335	67.20
HDGNet ^[77]	No	360×480	1080Ti	0.68	100	65.70
BiSeNet-V1 ^[78]	Xception	720×960	Titan XP	5.80	116	65.50
ICNet ^[79]	PSPNet-50	720×960	Titan X	26.50	28	67.10
DFANet ^[62]	Xception	720×960	Titan X	7.80	120	64.70
LBN-AA ^[80]	No	720×960	1080Ti	6.20	39	68.00
MLFNet ^[81]	ResNet-34	720×960	Titan XP	13.03	57	69.00
MHMNet(本章方法)	No	360×480	2080Ti	0.77	292	69.50

牲速度换取更大参数量或更高计算量的实时基线方法不同, MHMNet 始终保持在百万参数量以内, 同时仍具备强大的实时处理能力, 特别适用于资源受限且对延迟敏感的应用场景。

(2) CamVid 数据集结果对比

表 3.6 将 MHMNet 与多种现有分割模型在 CamVid 数据集上的性能进行对比, 图 3.5 提供了相应的定性可视化结果。在 360×480 输入分辨率的轻量化设定下, MHMNet 无需任何骨干网络, 仅以 0.77M 参数量即取得了 69.50% mIoU 的分割精度。这一结果与同分辨率下评估




图 3.4 Cityscapes 验证集上预测结果对比图




图 3.5 CamVid 测试集上预测结果对比图

的其他紧凑型设计(如 MSCFNet^[72]的 69.30%、AGFNet^[69]的 69.40%以及 FBSNet^[75]的 68.90%)相比具有竞争力,表明所提出的架构在严格的参数量约束下仍能保持强劲的分割性能。

在推理效率方面, MHMNet 在 RTX 2080Ti 上达到 292 FPS 的推理速度,展现出优异的实时处理能力。在相同的 GPU 设定下, MHMNet 显著快于 FDDWNet^[74](79 FPS)和 PDBNet^[70](90 FPS),同时取得了更高的 mIoU 精度。尽管 FAHDNet^[76]报告了更高的吞吐率(335 FPS),但其精度明显偏低(67.2%)。此外,本实验还纳入了在更高分辨率(720×960)下评估的方法作为参考,如 BiSeNet-V1^[78]和 ICNet^[79],这些方法通常依赖于更重的骨干网络。相比之下, MHMNet 虽在较低分辨率下运行且模型规模小得多,其精度仍具备竞争力。

3.4 本章小结

本节提出了 MHMNet, 一种专为严格计算约束下的实时语义分割任务设计的轻量化架构。

该框架在编码器中引入多分支特征聚合模块 (MFAB)，通过多路径交互实现高效的多尺度特征提取与跨尺度融合。在解码器部分，我们设计了混合视觉状态空间模块 (HVSS)，将状态空间建模与局部特征处理相结合，以线性计算复杂度协同捕获全局上下文语义与细粒度细节。此外，还提出了自适应门控特征分割头 (AGFS)，通过通道级门控机制选择性地重标定解码特征，增强判别性响应并提升预测稳定性。在公开数据集上的大量实验表明，MHMNet 取得了良好的精度-效率平衡，凸显了其在自动驾驶等实际应用场景中的潜力。

第四章 基于协同注意力机制的轻量级语义分割网络

4.1 引言

语义分割是计算机视觉中的一项基础任务，旨在将图像中的每个像素分配到特定的语义类别。在自动驾驶系统中，语义分割能够提供对复杂城市环境的细粒度理解，从而支持精准决策和安全导航，因此是不可或缺的基础。随着深度学习的快速发展，基于卷积神经网络和注意力机制的方法取得了显著进展。

在基于 CNN 的方法中，PP-LiteSeg^[82]引入了一种高效的编码器-解码器架构，通过轻量级设计原则平衡了计算效率和分割精度。该模型融合了灵活的特征融合和上下文聚合策略，实现了增强的多尺度表示和精细的边界恢复，从而能够从无人机影像中提取屋顶区域。FasterSeg^[83]利用神经网络架构搜索自动设计轻量级编码器和解码器，在保留高分辨率特征的同时显著降低了计算成本，使其适用于实时应用。SegTransConv^[84]提出了一种 Transformer 和卷积神经网络混合的编码器-解码器结构。其四级分层编码器能够更好地利用输入的全局上下文信息并扩展感受野。此外，还利用知识蒸馏策略来提升模型性能。另外，诸如 PDBNet^[70]等轻量级架构采用了参数高效的卷积模块和有效的特征融合策略，在资源受限的情况下进一步提高了分割精度，使其适用于计算资源有限的设备。

近年来，注意力机制的进步显著提升了语义分割的性能。RAM^[85]改进了注意力响应，以减轻对抗性块状攻击的影响，凸显了注意力在确保分割模型性能和安全性方面的重要作用。SeaFormer^[86]引入了一种轴向注意力机制，降低了计算复杂度，从而能够在资源受限的场景下实现快速推理。TSG^[87]引入了一种尺度感知门控机制，能够自适应地选择和重新加权多尺度特征，从而实现更有效的上下文融合。此外，MobileSAM^[88]利用动态原型来引导注意力，从而增强了模型对前景区域的关注，并提高了细粒度细节建模能力。

尽管取得了这些进展，但仍存在一些挑战。在自动驾驶等实际场景中，现有方法往往难以准确勾勒物体边界，也难以区分动态城市场景中视觉相似的类别。虽然许多方法提高了分割精度，但它们通常会带来高昂的计算开销，难以在车载平台上同时满足实时推理和资源效率的双重要求。特别是，多尺度融合和全局上下文建模往往会显著增加计算量，阻碍轻量级部署。因此，如何在保持较高精度的同时降低模型复杂度和计算成本，仍然是语义分割的关键研究方向，尤其对于满足自动驾驶的实际需求而言。

为了解决这些问题，本章提出了基于协同注意力机制的轻量级高效语义分割网络

(Collaborative Attention Network, CoANet), 专为实时城市场景理解而设计。与那些通过大量解码器扩展或计算密集型上下文模块来追求更强表征的架构不同, CoANet 基于紧凑的编码器-解码器框架和轻量级残差块构建, 这为网络的高效性提供了根本基础。在这个轻量级骨干网络之上, 我们引入了三个基于注意力机制的定向模块, 以弥补紧凑模型通常存在的表征不足。这些模块并非作为繁重的附加组件, 而是被设计成低开销的优化模块, 在网络的不同阶段选择性地增强特征质量。通过这种方式, CoANet 既保持了轻量级骨干网络的高效优势, 又提升了上下文推理、边界恢复和语义可分性。在 Cityscapes 和 CamVid 等基准数据集上的广泛评估表明, CoANet 在准确率与效率之间取得了良好的平衡, 并展现出在自动驾驶等实时应用领域的巨大潜力。该模型与其他方法的性能结果对比如图 4.1 所示。本章的主要贡献如下:

(1) 提出了通道聚合多尺度注意力 (Multiscale Attention with Channel Aggregation, MACA) 模块, 它是一种用于浅层特征提取的轻量级增强单元。MACA 通过联合建模空间和通道依赖性, 并结合局部和多尺度深度可分离卷积, 在有限的额外计算开销下, 增强了上下文表示和显著区域感知。

(2) 引入了三级上下文融合 (Tri-level Contextual Fusion, TCF) 模块, 用于高效的跳跃连接融合。TCF 协同利用通道级、空间级和像素级注意力线索, 在不依赖繁重融合操作的情况下, 提升了跨尺度特征对齐、边界保持和语义一致性。

(3) 提出了选择性嵌入分割头 (Selective Embedding Segmentation Head, SESH), 它采用选择性注意力机制嵌入具有区分性的类特定特征。SESH 通过增强类间区分度并缓解语义歧义, 在保持轻量级架构的同时, 提供了用于精确分割的鲁棒特征表示。




图 4.1 不同方法在 Cityscapes 数据集上的分割性能对比




图 4.2 CoANet 整体网络结构

4.2 基于协同注意力机制的轻量级语义分割网络

4.2.1 整体网络结构

如图 4.2 所示，CoANet 采用了与 UNet^[28] 相似的编码器-解码器结构。对于给定的输入图像 $I \in \mathbb{R}^{3 \times H \times W}$ ，模型首先利用编码器进行分层特征提取。CoANet 的轻量化特性主要源于这一紧凑的骨干网络设计，其中采用轻量级残差块（Lite Residual Block, LiteRB）作为基本构建单元，并以受控的分阶段方式增加通道宽度，从而保持较低的参数量和计算成本。

编码器由四个依次堆叠的编码块组成，每个编码块包含两个轻量级残差块。第一个编码块对输入图像 I 进行处理，生成特征图 $F_1 \in \mathbb{R}^{8 \times H \times W}$ 。为了在有限计算预算下增强浅层特征的代表质量，在早期编码阶段之后引入了 MACA 模块，此时特征图仍保持较高的空间分辨率，但通道宽度相对较小。通过这种方式，可以以较小的额外开销增强空间与通道交互及多尺度上下文响应。输出结果随后传入下采样模块，该模块将通道数加倍并将空间分辨率减半，生成 $F_1' \in \mathbb{R}^{16 \times \frac{H}{2} \times \frac{W}{2}}$ 。将 F_1' 通过第二个编码块后，得到相同尺寸的特征图 F_2 ，再经过一次下采样，生成 $F_2' \in \mathbb{R}^{32 \times \frac{H}{4} \times \frac{W}{4}}$ 。

在后续的编码阶段，通道维度逐渐增加，空间分辨率则持续降低，生成中间特征 $F_3 \in \mathbb{R}^{32 \times \frac{H}{4} \times \frac{W}{4}}$ 和 $F_4 \in \mathbb{R}^{64 \times \frac{H}{8} \times \frac{W}{8}}$ 。最后，编码器通过最后一个下采样模块输出深层语义特征 $F_4' \in \mathbb{R}^{128 \times \frac{H}{16} \times \frac{W}{16}}$ 。随后，将 F_4' 输入网络底部的瓶颈块中，该模块在残差连接结构内嵌入了空间感知与方向性通道注意力，通过大核条状卷积在紧凑的计算预算下重构空间信息、增强类间语义判别性并抑制背景噪声。

解码器采用对称设计，通过多个转置卷积逐步恢复空间分辨率。在同一阶段的编码器




图 4.2 通道聚合多尺度注意力模块(MACA)

与解码器特征之间建立跳跃连接。我们并未直接拼接这些特征，而是在每个跳跃路径中引入 TCF 模块，以自适应地融合浅层空间细节与高层语义信息。TCF 通过联合利用通道、空间及像素维度的线索，在不引入繁重融合操作的前提下，改善跨尺度特征对齐与边界恢复效果。

在最终预测阶段，融合后的特征图进一步经 SESH 模块进行细化。该模块通过将紧凑的全局语义信息嵌入分割头，有选择地增强类别判别响应，并缓解视觉相似类别之间的语义模糊性。通过上述整体设计，CoANet 在保持轻量级骨干网络高效性优势的同时，逐步弥补了紧凑型分割网络在上下文建模、特征融合及语义判别方面常见的局限性。

4.2.2 通道聚合多尺度注意力模块

在计算机视觉任务中，空间注意力强调特征响应在不同位置上的分布，而通道注意力则捕获特征通道间的语义依赖关系。尽管两者均已被证明有效，但现有方法通常将二者独立处理，限制了对其互补特性的利用。为解决这一问题，我们提出了通道聚合多尺度注意力(MACA)模块，将空间注意力与通道注意力整合到一个统一的设计中。通过联合建模空间分布与通道依赖关系，MACA 能够捕获更丰富的上下文信息，并生成更具表达力的特征表示。此外，在空间维度中融入了局部与多尺度全局深度卷积，以增强对不同范围的上下文建模能力，使网络更能适应复杂的图像结构。

如图 4.3 所示，MACA 首先捕获空间维度上的长短程依赖关系。对于输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ ，沿高度和宽度维度进行平均池化，得到一维上下文信息：

$$X_h = \frac{1}{W} \sum_{i=1}^W X_{b,c,h,i}, \quad (4.1)$$

$$X_w = \frac{1}{H} \sum_{j=1}^H X_{b,c,j,w}, \quad (4.2)$$

其中 $X_h \in \mathbb{R}^{C \times H \times 1}$ 表示垂直方向的上下文特征， $X_w \in \mathbb{R}^{C \times 1 \times W}$ 表示水平方向的上下文特征。

随后将 X_h 和 X_w 分别划分为四个通道组，其中一组用于编码局部依赖关系，其余三组分别使用卷积核大小为 5、7 和 9 的一维深度可分离卷积进行处理，分别建模短程、中程和长程依赖关系：

$$\tilde{X}_h = [\mathcal{D}_{k_1}(l_h), \mathcal{D}_{k_2}(g_h^s), \mathcal{D}_{k_3}(g_h^m), \mathcal{D}_{k_4}(g_h^l)], \quad (4.3)$$

$$\tilde{X}_w = [\mathcal{D}_{k_1}(l_w), \mathcal{D}_{k_2}(g_w^s), \mathcal{D}_{k_3}(g_w^m), \mathcal{D}_{k_4}(g_w^l)], \quad (4.4)$$

其中 $\mathcal{D}_{k_i}(\cdot)$ 表示核大小为 k_i 的一维深度可分离卷积操作， l_h 、 l_w 为局部特征， g_h^s 、 g_h^m 、 g_h^l 为垂直方向的全局特征， g_w^s 、 g_w^m 、 g_w^l 为水平方向的全局特征。所得特征经过通道拼接和组归一化（Group Normalization, GN）后，通过门控机制生成垂直和水平方向的空间注意力图，再利用两个方向的注意力图对输入图像进行加权，最终得到空间增强后的特征。其计算过程如下所示：

$$A_h = \sigma(\text{GN}(\tilde{X}_h)), \quad (4.5)$$

$$A_w = \sigma(\text{GN}(\tilde{X}_w)), \quad (4.6)$$

$$X_s = X \odot A_h \odot A_w, \quad (4.7)$$

在此基础上，MACA 进一步沿通道维度建模非局部依赖关系。首先，将空间细化后的特征进行下采样得到 $\tilde{X} \in \mathbb{R}^{C \times H' \times W'}$ ，以降低计算成本。随后，通过 1×1 深度卷积生成查询 Q 、键 K 和值 V 特征。接着计算通道注意力图，最后将通道注意力作用于空间细化后的特征，得到最终输出。该输出可通过上采样恢复至原始分辨率，用于与骨干网络特征进行融合。上述步骤可归纳为：

$$X_c = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V, \quad (4.8)$$

$$A_c = \sigma\left(\frac{1}{H'W'} \sum_{i=1}^{H'} \sum_{j=1}^{W'} X_c[b, c, i, j]\right), \quad (4.9)$$

$$X_{out} = X_s \odot A_c, \quad (4.10)$$

其中 $X_{out} \in \mathbb{R}^{C \times H' \times W'}$ 为输出特征图。通过这一统一的设计，MACA 有效地将空间注意力与

通道注意力融合在一起，使二者相互补充，从而生成更具判别性和鲁棒性的特征表示。

4.2.3 三级上下文融合模块

在语义分割任务中，精确的特征融合对于提升预测精度与恢复边界细节起着至关重要的作用。当前主流方法多采用特征拼接、加权求和或单一注意力机制进行跨尺度或多分支特征融合。尽管这些方法在一定程度上实现了信息整合，但仍面临以下挑战：融合策略缺乏多维度的上下文感知能力，难以同时兼顾全局语义一致性与局部空间精度。在存在语义冲突或特征噪声的区域，由于缺少细粒度的动态调节机制，容易导致目标边界模糊或类别间混淆，从而限制融合特征的表达能力。

为解决上述问题，本章提出了三级上下文融合（TCF）模块，该模块协同整合了通道、空间与像素级注意力机制。TCF 并非将这些机制独立使用，而是将其组织为一种层次化精炼流程，使全局语义感知、显著区域定位与细粒度细节调节相互增强。具体而言，通道注意力突出判别性语义响应，空间注意力强调显著区域的结构布局，而像素注意力则自适应地精炼局部相关性。这一协同策略不仅提升了语义分割精度，还增强了边界细节保持能力与类别间判别性，从而实现更具表达力与可靠性的特征融合。

如图 4.4 (a) 所示，TCF 通过自适应注意力权重 $W \in \mathbb{R}^{B \times C \times H \times W}$ 动态调节低层特征图 F_l 与高层特征图 F_h 的融合过程，构建了一个像素级引导的融合框架。具体而言，将来自编码器的高分辨率特征 F_h 与上采样后的低分辨率特征 F_l 相加，输入三重注意力层级精炼（Tri-Attention Hierarchical Refinement, THR）模块以计算权重 W ，随后通过加权求和进行特征重组。该设计使网络能够根据语义内容自适应地调整特征贡献：在边界区域增强低层特征，在语义显著区域则突出高层特征。为防止梯度消失并保持信息流通，引入了双重跳跃连接，直接将 F_h 和 F_l 添加至加权特征之上。最后，通过 1×1 卷积进行投影，消除通道冗余并保持维度一致。该过程可表示为：

$$X_m = F_h + F_l, \quad (4.11)$$

$$F = F_h \odot W + F_l \odot (1 - W), \quad (4.12)$$

$$F_{out} = \text{Conv}_{1 \times 1}(F + F_h + F_l). \quad (4.13)$$

THR 模块是 TCF 的核心，负责以由粗到精的方式为输入特征 $X \in \mathbb{R}^{C \times H \times W}$ 生成自适应注意力权重 W 。如图 4.4 (b) 所示，首先，输入 X 经过并行的全局平均池化与全局最大池化生




图 4.4 (a) 三级上下文融合模块(TCF) (b) 三重注意力层级精炼模块(THR)
(c) 选择性嵌入分割头(SESSEH)

成空间显著性图，二者求和后通过 7×7 卷积进行压缩，得到粗粒度空间权重 $W_s \in \mathbb{R}^{1 \times H \times W}$ ；同时，通道注意力分支通过全局平均池化与两个 1×1 卷积自适应校准各通道的重要性，生成通道注意力权重 $W_c \in \mathbb{R}^{C \times 1 \times 1}$ ，随后对 W_s 和 W_c 进行广播操作并求和，形成初始聚合权重图 $W_a \in \mathbb{R}^{C \times H \times W}$ 。此过程可描述为：

$$W_s = \text{Conv}_{7 \times 7}(\text{GAP}(X_m) + \text{GMP}(X_m)), \quad (4.14)$$

$$W_c = \text{Conv}_{1 \times 1}^2(\text{GAP}(X_m)), \quad (4.15)$$

$$W_a = W_s \oplus W_c, \quad (4.16)$$

其中 $\text{Conv}_{1 \times 1}^2(\cdot)$ 表示两个连续的 1×1 卷积操作。紧接着，将 W_a 与 X 沿通道维度拼接，得到增强权重图 $W_{en} \in \mathbb{R}^{2C \times H \times W}$ ，该操作在注入注意力先验的同时保留了原始细节。为促进像素级的跨语义交互，对 W_{en} 进行通道重排，随后通过两个并行的多尺度核深度可分离卷积，结合残差连接对细粒度像素信息进行校准，并由 Sigmoid 门控单元输出归一化权重 W 。上述过程可表示为：

$$W_{en} = \text{Concat}(X_m, W_a), \quad (4.17)$$

$$W_1 = \text{CS}(\text{DSConv}_{3 \times 3}(W_{en})), \quad (4.18)$$

$$W_2 = \text{CS}(\text{DSConv}_{5 \times 5}(W_{en})), \quad (4.19)$$

$$W = \sigma(W_{en} + W_1 + W_2), \quad (4.20)$$

式中, $CS(\cdot)$ 为通道混洗操作, $DSCConv_{n \times n}(\cdot)$ 表示深度可分离卷积。通过这一层次化协同设计, TCF 将全局、区域与局部线索有机统一, 为语义分割任务提供了兼具稳定性与精细度的特征融合方案。

4.2.4 选择性嵌入分割头

在精细图像分割任务中, 语义混淆仍是一个核心挑战: 在复杂场景下, 不同目标类别的特征容易相互混淆, 这在目标重叠或纹理相似时尤为明显。同时, 语义类别间特征区分不足, 导致嵌入向量缺乏类别特异性判别能力, 进而影响图像中主要类别的分类准确性。针对这一问题, 本章提出了选择性嵌入分割头 (SESH) 模块。该模块通过构建类别特定的特征嵌入机制, 精准捕获每个类别独有的判别性特征, 进行细粒度加权, 并强化语义类别间的特征差异, 从而增强模型对显著实例的分类能力, 为精准分割提供更可靠的特征支持。

如图 4.4 (c) 所示, 对于输入特征图 $X_t \in \mathbb{R}^{B \times C \times H \times W}$, 首先将其沿空间维度展开为向量形式, 并引入额外维度以用于后续矩阵乘法。随后, 通过 1×1 卷积对输入特征进行线性映射, 生成注意力掩码 $M \in \mathbb{R}^{1 \times H \times W}$, 再将其沿空间维度展平并重排为二维张量 $A \in \mathbb{R}^{1 \times HW}$ 。上述过程可表示为:

$$X' = \text{Re}(X_t), \quad (4.21)$$

$$M = \text{Conv}_m(X_t), \quad (4.22)$$

$$A = \text{Re}(M), \quad (4.23)$$

其中 $X' \in \mathbb{R}^{1 \times C \times HW}$ 为增维后的图像特征, $\text{Re}(\cdot)$ 表示 Reshape 重排操作, $\text{Conv}_m(\cdot)$ 为掩码卷积。对注意力张量 A 的空间维度进行 Softmax 归一化, 再与空间展开的特征图矩阵相乘, 通过全局加权聚合得到类别感知的嵌入向量 $V_{\text{embedding}} \in \mathbb{R}^{C \times 1 \times 1}$ 。该向量整合了图像所有空间位置的通道特征, 能够自适应地为每个语义类别选择最具代表性的全局上下文信息。随后, 通过两个全连接层对该类别嵌入向量进行非线性变换, 映射至权重空间, 生成最终的动态特征增强权重 $S \in \mathbb{R}^{C \times 1 \times 1}$ 。

$$V_{\text{embedding}} = \sigma(A) \otimes X', \quad (4.24)$$

$$S = \sigma \left(\delta_2 \left(\text{ReLU} \left(\text{GN} \left(\delta_1 (V_{embedding}) \right) \right) \right) \right), \quad (4.25)$$

其中， $\otimes$ 表示矩阵乘法， δ_i 为全连接操作。最后，将原始输入 X_l 与权重 S 逐元素相乘，选择性增强图像中的显著实例，生成最终的语义预测结果 $Y \in \mathbb{R}^{K \times H \times W}$ 。

4.2.5 其他模块

CoANet 的核心组件与瓶颈层如图 4.5 所示，其中(a)为轻量级残差块（LiteRB），(b)为空间信息提取（Spatial Information Extraction, SIE）模块。编码器与解码器的基础单元均为轻量残差块，它采用两阶段级联的分解卷积结构。每个卷积块由一个 3×1 卷积和一个 1×3 卷积依次串联组成。通过采用这种空间分离操作替代残差块中传统的 3×3 卷积，参数量得以显著减少，从而提升了模型效率。为进一步扩大感受野并捕获多尺度上下文信息，该模块引入了可调的膨胀率参数。该参数通过在卷积核元素之间插入零值来拓宽特征感知范围，在不增加卷积核大小或计算成本的情况下，实现了更强的上下文感知能力。该过程可描述为：

$$F_1 = \text{Conv}_{1 \times 3}^{(d)} \left(\text{ReLU} \left(\text{Conv}_{3 \times 1}^{(d)} (X_l) \right) \right), \quad (4.26)$$

$$F_2 = \text{Conv}_{1 \times 3}^{(d)} \left(\text{ReLU} \left(\text{Conv}_{3 \times 1}^{(d)} (F_1) \right) \right), \quad (4.27)$$

$$X_{out} = \sigma(F_2 + \text{Conv}_{1 \times 1}(X_l)), \quad (4.28)$$

其中 $X_l \in \mathbb{R}^{C \times H \times W}$ 为输入特征图， $\text{Conv}_{k \times i}$ 表示 $k \times i$ 卷积，上标 (d) 表示膨胀率。

在模型的瓶颈层中，空间信息提取（SIE）模块被嵌入到两个高效残差块之间。通过将 3×3 深度卷积与大核带状卷积相结合，模型能够有效捕获局部细节特征和长距离空间依赖关系，从而缓解重复下采样导致的空间信息丢失。借助空间注意力机制，低分辨率图像中的语义信息得到动态调整，在自适应地突出关键区域的同时抑制无关背景噪声，进而提升了特征的判别性。

输入特征图 $X_b \in \mathbb{R}^{C \times H \times W}$ 首先通过带状卷积空间增强（Strip Convolution Spatial Enhancement, SCSE）模块进行处理。该模块采用水平与垂直平均池化初步提取全局语义信息，随后将二者求和以生成注意力图 $X' \in \mathbb{R}^{C \times H \times W}$ 。接着，通过两个级联的大核带状卷积对注意力图进行解耦与细化，以增强图像中关键实例的显著性。在此之后，通过 3×3 卷积提取输入特征的局部特征，并将其与细化后的注意力图逐元素相乘，从而得到增强特征 $X_{en} \in \mathbb{R}^{C \times H \times W}$ ：

$$X' = \sigma \left(\text{Conv}_{1 \times k} \left(\text{Conv}_{k \times 1} \left(P_h(X_b) + P_w(X_b) \right) \right) \right), \quad (4.29)$$




图 4.5 (a) 轻量级残差块(LiteRB) (b) 空间信息提取模块(SIE)

$$X_{en} = X' \odot \text{Conv}_{3 \times 3}(X_b), \quad (4.30)$$

其中 P_h 和 P_w 分别表示水平平均池化与垂直平均池化。增强后的特征图 X_{en} 经过层归一化后，被输入到具有指定通道扩张率的多层感知机中。随后，其输出通过残差连接与输入特征图 X_b 相结合，以生成最终输出：

$$X_{out} = X_b + \text{MLP}(\text{BN}(X_{en})). \quad (4.31)$$

4.3 实验设计与结果分析

4.3.1 数据集与实验参数设置

CoANet 所有实验均基于 PyTorch 框架实现，CamVid 与 Cityscapes 两个数据集的训练、测试流程，分别在 NVIDIA RTX 2080Ti GPU 与 NVIDIA RTX 3090 GPU 上独立完成。本章实验参数设置与第三章相同，详细取值如表 3.1 所示。

4.3.2 消融实验

本节主要验证提出的协同注意力轻量级语义分割网络 CoANet 的有效性。消融实验主要包括模型整体架构的合理性验证，各个模块的有效性验证。 $\dagger$ 符号用于标识本章采用的方法。

(1) 模型结构的影响

为探究轻量级残差块与模型整体深度对语义分割性能的影响，本章开展了两组消融实验。

表 4.1 轻量级残差块的影响

Model	Parameter (K)	FLOPs (G)		mIoU (%)	
		Cit.	Cam.	Cit.	Cam.
LiteRB $\times$ 1	434	4.95	1.66	66.06	62.81
LiteRB $\times$ 2 $\uparrow$	673	6.20	3.04	71.73	69.67
LiteRB $\times$ 3	1082	12.89	4.31	70.15	68.33
LiteRB $\times$ 4	1411	16.71	5.59	69.02	67.14

表 4.2 模型深度的影响

Model	Depth	Parameter (K)	FLOPs (G)		mIoU (%)	
			Cit.	Cam.	Cit.	Cam.
CoA-Small	3	380	4.16	1.88	60.18	59.44
CoA-Middle	4	557	5.43	2.61	65.95	65.63
CoANet $\uparrow$	5	673	6.20	3.04	71.73	69.67

不同基础模块中 LiteRB 堆叠数量的消融实验结果如表 4.1 所示, 结果表明: 单 LiteRB 配置下模型参数量与计算量最低, 在 Cityscapes、CamVid 数据集上分别取得 66.06%、62.81% 的 mIoU; 堆叠 2 个 LiteRB 时, 模型性能大幅提升至 71.73%、69.67% mIoU, 仅伴随计算开销的小幅上升; 进一步增加至 3 至 4 个 LiteRB 时, 计算量显著增加, 而性能不升反降。因此 CoANet 最终采用每模块 2 个 LiteRB 的平衡配置。网络深度消融实验结果如表 4.2 所示, 完整架构的 CoANet 在两个数据集上分别实现了 71.73%、69.67% mIoU, 相较浅层模型分别获得 11.55%、8.23% 的显著精度增益。结果证明, 网络深度的提升可强化模型对层级特征的提取能力, 有效优化复杂场景的分割表现。

(2) 通道聚合多尺度注意力模块的影响

表 4.3 展示了将 MACA 模块渐进式嵌入 UNet 主干网络不同分辨率层级的消融实验结果。表格第一列采用四维向量 $[n_1, n_2, n_3, n_4]$ 进行标注, 其中每个元素 n_i 表示 UNet 第 i 个分辨率层级中嵌入的 MACA 模块数量。此处, 分辨率层级对应编码器与解码器中共享相同空间分辨率的配对阶段。

无 MACA 模块的基线模型在 CamVid 测试集上取得了 69.06% 的 mIoU, 对应参数量为 654K, 推理速度达 350 FPS; 向更深层级渐进嵌入 MACA 模块可在保持高效推理的同时持续提升分割精度, 其中前两个分辨率层级嵌入 MACA 的配置实现了精度与效率的最优平衡, mIoU 达 69.67%, 仅 FLOPs 小幅增至 3.04G、速度微降至 320 FPS, 该配置为 CoANet 最终模型架构; 更深层级继续添加模块仅会增加计算开销、引入冗余, 无额外精度增益。实验结果验证了 MACA 协同注意力机制的有效性, 其通过空间、通道特征融合增强了模型的上下文感知与细节表征能力, 仅需在高分辨率阶段选择性嵌入即可充分发挥其性能优势。

表 4.3 通道聚合多尺度注意力模块的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
[0,0,0,0]	654	2.81	350	69.06
[1,0,0,0]	662	2.92	340	69.18
[1,1,0,0] [†]	673	3.04	320	69.67
[1,1,1,0]	685	3.26	310	69.56
[1,1,1,0]	701	3.47	285	69.47

表 4.4 三级上下文融合模块的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
Add	665	2.98	304	67.09
Weight Add	668	3.00	300	67.84
Concat	690	3.36	290	67.52
TCF [†]	673	3.04	320	69.67

表 4.5 协同注意力机制的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
PR only	657	2.91	328	66.23
SA only	660	2.91	323	66.79
CA only	667	2.96	323	67.10
SA + PR	662	2.95	325	68.46
CA + PR	669	3.00	318	68.77
CA + SA	671	3.00	319	69.00
CA + CA + PR [†]	673	3.04	320	69.67

（3）三级上下文融合模块的影响

为验证 TCF 模块的有效性，本章将其与逐元素相加（Add）、加权相加（Weighted Add）、通道拼接（Concat）三种主流融合策略对比，结果如表 4.4 所示。其中 Add 运算计算开销最低、速度最快但精度最差，Weighted Add 可通过可学习权重实现小幅精度提升，Concat 虽提升了模型复杂度，但精度增益有限，无法有效利用多级上下文信息。TCF 模块取得了 69.67% 的最优 mIoU，较 Add 基线提升 2.58%，同时保持了 3.04G FLOPs 的高效计算与 320 FPS 的最快推理速度。该优势源于 TCF 的协同注意力机制，其融合三级注意力可同步捕获全局语义与局部细节，解决了传统策略的精度短板。

（4）协同注意力机制的影响

为验证本章所提出的协同注意力机制的有效性，本章在 CamVid 数据集上对 THR 模块开展消融实验，通过渐进式启用 THR 模块内的不同注意力组件验证各部分的性能贡献，实验结果如表 4.5 所示。其中，CA、SA、PR 分别代表通道注意力、空间注意力与像素细化模块。单独启用任一注意力机制均无法取得理想性能，只包含像素注意力 PR 的基线模型 mIoU 为

表 4.6 Cityscapes 数据集预测结果的对比

Methods	Backbone	Resolution	Param.(M)	FLOPs(G)	Speed(FPS)	mIoU(%)
ERFNet ^[60]	No	512×1024	2.10	-	42	68.0
ESPNet-v2 ^[61]	No	512×1024	3.49	2.7	80	66.2
DFANet ^[62]	Xception	1024×1024	7.80	3.4	100	71.3
BiSeNetV2 ^[54]	Xception	512×1024	3.40	21.2	82	72.6
MLFNet ^[81]	ResNet-34	512×1024	13.03	15.5	72	72.1
SegTransConv ^[84]	STDC	512×1024	7.00	10.2	57	72.0
PCNet ^[89]	Scratch	1024×2048	1.63	11.8	72	72.7
BANet ^[90]	No	512×1024	0.72	6.69	83.2	70.1
SFRSeg ^[91]	No	512×1024	1.60	19.6	98	70.6
FBSNet ^[75]	No	512×1024	1.62	9.7	90	70.9
LETNet ^[92]	No	512×1024	0.95	13.6	150	72.8
FAHDNet ^[76]	No	512×1024	0.82	9.98	135	70.6
DAABNet ^[93]	ResNet-18	512×1024	0.94	-	107	70.8
LMIINet ^[94]	No	512×1024	0.72	11.7	100	72.0
HDGNet ^[77]	No	512×1024	0.68	13.2	48	70.5
MHMNet(第三章方法)	No	512×1024	0.77	7.12	173	71.5
CoANet(本章方法)	No	512×1024	0.67	6.2	190	71.7

表 4.7 CamVid 数据集预测结果的对比

Methods	Backbone	Resolution	GPU	Param.(M)	Speed(FPS)	mIoU(%)
DABNet ^[73]	No	360×480	1080Ti	0.76	72	66.40
FDDWNet ^[74]	No	360×480	2080Ti	0.80	79	66.90
PDBNet ^[70]	No	360×480	2080Ti	1.82	90	67.70
MSCFNet ^[72]	No	360×480	Titan XP	1.15	110	69.30
FBSNet ^[75]	No	360×480	2080Ti	0.62	120	68.90
FAHDNet ^[76]	No	360×480	2080Ti	0.82	335	67.20
HDGNet ^[77]	No	360×480	1080Ti	0.68	100	65.70
MHMNet(第三章方法)	No	360×480	2080Ti	0.77	292	69.50
CoANet(本章方法)	No	360×480	2080Ti	0.67	320	69.67
BiSeNet-V1 ^[78]	Xception	720×960	Titan XP	5.80	116	65.50
ICNet ^[79]	PSPNet-50	720×960	Titan X	26.50	28	67.10
DFANet ^[62]	Xception	720×960	Titan X	7.80	120	64.70
EFRNet-16 ^[95]	EAA	720×960	1080Ti	1.44	154	68.20
LBN-AA ^[80]	No	720×960	1080Ti	6.20	39	68.00
SGCPNet ^[71]	No	720×960	1080Ti	0.61	278	69.00
MLFNet ^[81]	ResNet-34	720×960	Titan XP	13.03	57	69.00
SegTransConv ^[84]	STDC	720×960	3090	7.00	60	68.50
CoANet(本章方法)	No	720×960	2080Ti	0.67	280	70.09

66.23%，效果最优的 CA 仅实现 67.10% mIoU；两两组合的组件可实现显著性能提升，验证了各机制的互补性，其中 CA+SA、CA+PR 组合的 mIoU 分别达 69.00%、68.77%；同时集成 CA、SA、PR 三类注意力组件的方案，取得了最优分割性能，mIoU 达 69.67%，向较于基线

表 4.8 基于 RTX 3090、512×1024 分辨率，不同方法在 Cityscapes 测试集运行速度对比

Model	Parameter (K)	FLOPs (G)	Time (ms)	Speed (FPS)	mIoU (%)
CGNet ^[64]	0.50	9.0	29.41	34	66.0
NDNet ^[65]	0.50	10.0	11.63	86	64.2
FBSNet ^[75]	0.62	9.7	9.43	106	70.9
LRDNet ^[67]	0.66	16.0	10.99	91	70.1
LETNet ^[92]	0.95	13.6	6.67	150	72.8
AGFNet ^[69]	1.12	14.4	10.87	92	70.1
MSCFNet ^[72]	1.15	17.1	10.64	94	71.9
PDBNet ^[70]	1.82	15.0	16.13	62	69.5
SegTransConv ^[84]	7.00	10.2	16.67	60	72.0
CoANet(本章方法)	0.67	6.2	5.26	190	71.7

提升 3.44%。实验结果表明三类注意力机制可相互增益，其协同交互实现了鲁棒特征融合，仅需小幅增加参数量与计算开销，即可显著提升模型分割精度。

4.3.3 与其它方法的比较

为全面验证本章方法的优越性，本节在 Cityscapes 与 CamVid 两个公开数据集上开展了系统的对比实验，选取了当前领域内若干具有代表性的语义分割模型作为基准。定量评估结果显示，CoANet 拥有更为出色的综合性能。

(1) Cityscapes 数据集结果对比

在 Cityscapes 数据集上对 CoANet 与主流语义分割方法进行定量对比，结果如表 4.6 所示，对应的可视化效果如图 3.6 所示。由表格可见，CoANet 在分割精度与推理效率之间实现了优异的均衡。该模型仅含 0.67M 参数量与 6.2G FLOPs，在 Cityscapes 测试集上达到 71.7% mIoU，显著优于 BANet^[90]、FAHDNet^[76]等多款轻量级模型。尤为突出的是，CoANet 在 RTX 3090 GPU 上推理速度高达 190 FPS，分别为 SFRSeg^[91]的 1.94 倍、FBSNet^[75]的 2.11 倍，极高的运行效率使其非常适用于资源受限平台的实时推理场景。与 BiSeNetV2^[54]这一类中等规模模型相比，CoANet 在精度接近的前提下，参数量与计算量分别降低 5.1 倍与 3.4 倍。此外，本文方法无需依赖预训练主干网络即可实现优异性能，进一步体现了网络结构设计的有效性。实验结果充分表明，CoANet 能够很好地兼顾高性能与低计算开销的应用需求。

(2) CamVid 数据集结果对比

表 4.7 展示了 CoANet 与当前主流语义分割方法在 CamVid 测试集上的全面对比，可视化结果如图 4.7 所示。现有语义分割模型大致可分为两类：一类以 ICNet^[79]、MLFNet^[81]为代表，依靠大模型容量追求高精度，但计算复杂度高、推理速度较慢；另一类以 DABNet^[73]、FBSNet^[75]




图 4.6 Cityscapes 验证集上预测结果对比图




图 4.7 CamVid 测试集上预测结果对比图

为代表，侧重轻量化设计以适配实时场景，推理速度较快但分割精度普遍偏低。相比之下，CoANet 含 0.67M 参数量与极低计算开销，在 360×480 分辨率下以 320 FPS 的速度达到 69.67% mIoU，在 720×960 分辨率下以 280 FPS 取得 70.09% mIoU。与参数量超其两倍的 EFRNet-16^[95] 等轻量级方法相比，CoANet 精度更优且推理速度显著更快。实验结果充分验证了本章所提方案在极低计算开销下实现实时分割的有效性。

(3) 推理速度对比

为评估所提 CoANet 的推理效率，在 Cityscapes 测试集上与多款典型轻量级分割网络进行速度对比，所有方法均在单张 NVIDIA RTX 3090 GPU 上、以 512×1024 输入分辨率统一测试，以保证公平性。结果如表 4.8 所示，CoANet 仅以 6.2G FLOPs 的计算量实现了 190 FPS 的优异推理速度，显著优于 LRDNet^[67]、MSCFNet^[72]等现有方法，同时保持 71.7% mIoU 的竞争力精度；部分方法如 SegTransConv^[84]虽精度略高至 72.0%，但速度仅 60 FPS，且参数量与计算量均远高于 CoANet。实验表明，CoANet 在有效降低计算与内存开销的同时，可满足高分辨率城市场景的实时处理需求，适用于自动驾驶、视频场景理解等实际应用。

4.4 本章小结

本章提出了一种面向实时语义分割的新型轻量化架构 CoANet。该网络引入多尺度注意力与通道聚合（MACA）模块，以高效捕获分层局部特征；同时设计三级上下文融合（TCF）模块，实现对多维上下文信息的精准实时融合。为进一步提升模型的语义判别能力，本章构建了选择性嵌入分割头（SESH）用于提升输出特征的语义区分度。在多个标准数据集上的大量实验表明，CoANet 能够在保持极低计算开销的同时，获得具有竞争力的分割性能，可高效支撑实时场景下的高精度推理需求。

第五章 用于高效语义分割的频率感知上下文网络

5.1 引言

近年来，在深度学习的驱动下，语义分割技术取得了显著进展，然而，分割精度与推理速度之间的内在矛盾依然是制约其应用于自动驾驶等实时场景的关键瓶颈。为在两者之间寻求平衡，研究者主要沿两条路径展开探索：其一是提升上下文建模能力，借助多种算子与机制增强特征的判别性；其二是设计轻量化网络结构，通过高效架构压缩计算开销。然而，这两条路径各自存在难以克服的局限：高精度方法通常计算复杂度过高，难以满足实时处理需求；而轻量化方法受限于模型表达能力，往往难以充分解析复杂场景中的语义信息。

进一步分析现有实时语义分割方法可以发现，其性能瓶颈逐渐从单纯的模型容量不足，转向特征建模维度受限与结构设计冗余并存的问题。当前主流方法大多依赖空间域进行特征表达，通过卷积或注意力机制捕获局部纹理或长距离依赖关系，但对频域信息的建模仍较为缺失。频域特征在描述图像的全局结构分布、周期性变化以及边界响应方面具有独特优势，能够在复杂光照、动态模糊及高频噪声干扰等场景下提供更加稳定的判别信息。仅依赖空间域进行特征学习，容易导致模型对结构一致性与细节变化的刻画能力不足，从而限制其在复杂驾驶环境中的泛化性能。

与此同时，为弥补特征表达能力的不足，部分方法引入多分支结构以分别建模空间细节与语义上下文信息。这类设计虽然在一定程度上提升了特征多样性，但也不可避免地带来了额外的计算路径与频繁的特征交互操作，显著增加了模型的计算开销与内存访问成本。随着分支数量与融合模块的叠加，网络结构复杂度持续上升，不仅削弱了推理效率，也使得模型在资源受限设备上的部署变得更加困难。因此，在保证表达能力的同时减少结构冗余、提升信息建模效率，成为当前实时语义分割网络设计中的关键挑战。

基于上述分析，本章提出一种轻量化实时语义分割网络——频率感知上下文引导网络（Frequency Aware Contextual Network, FACNet）。该方法从特征建模与结构设计两个层面出发，在保持单分支高效推理框架的前提下，引入频域信息参与特征表达过程，通过构建空间-频率协同建模机制，有效提升模型对全局结构与细节信息的综合感知能力，从而在计算开销可控的条件下实现分割性能的进一步提升。本章的主要工作如下：

（1）提出了空间精炼下采样单元（Spatial Refinement Downsampling Unit, SRDU），该模块针对传统降采样过程中表征退化与信息利用不足的问题，构建“先特征编码、再降维压缩”

的结构范式,使下采样特征在压缩空间分辨率的同时仍具备较强的判别能力与结构表达能力,从而为后续语义建模提供高质量输入。

(2) 为突破纯空间域建模的局限性,设计了频率感知上下文模块(Frequency Aware Contextual Module, FACM),将特征映射至频域并引入可学习的复数调制权重,对低频结构信息与高频边界细节进行解耦与自适应强化,在轻量化计算约束下显著提升了特征表达的鲁棒性与全局场景结构一致性,增强了模型对光照突变、运动模糊等干扰的适应能力。

(3) 提出了跨尺度特征融合模块(Cross-Scale Feature Fusion, CSFF),针对不同层级特征在表征空间上的语义偏移问题,实现了浅层细节信息与深层语义信息的精准对齐与融合,有效缓解了传统融合方式带来的语义冲突与结构错位问题,在保证计算效率的同时显著提升了模型的边界刻画能力与小目标识别精度。

5.2 用于高效语义分割的频率感知上下文网络

5.2.1 整体网络结构

FACNet 整体采用多尺度渐进式特征提取与单阶段跨尺度融合的架构设计,通过分层递进的特征提取范式与轻量化的模块设计,在有限的算力和内存约束下,同时保障了场景感知的实时响应与目标分割精度。网络的完整前向传播流程如图 5.1 所示,对于给定的输入图像 $I \in \mathbb{R}^{3 \times H \times W}$,依次经过初始特征提取、第一级多尺度上下文提取、第二级全局语义提取三个特征处理阶段,生成不同空间尺度的高级特征图;随后通过跨尺度特征融合模块完成多尺度特征的自适应融合;最终经过通道调整与上采样操作,输出与输入图像同分辨率的逐像素语义分割结果。

初始特征提取阶段由三个连续的 3×3 标准卷积层串联构成,其中首个卷积层采用步长为 2 的设计实现空间维度的首次压缩,后续两个卷积层保持特征空间尺寸不变,逐步将输入图像的通道维度映射至 32,输出基础特征图 $F_0 \in \mathbb{R}^{32 \times H \times W}$ 。该阶段在极低计算开销下完成原始图像的边缘、纹理等底层视觉特征提取,为后续的上下文建模提供高质量的特征输入。

第一级多尺度上下文提取阶段首先通过空间精炼下采样单元(SRDU)将基础特征图的空间分辨率压缩至原有的 $1/4$,输出下采样特征 $F_{d1} \in \mathbb{R}^{32 \times H \times W}$ 。SRDU 单元通过先多尺度特征编码再空间降采样的流程设计,有效缓解了传统步长卷积下采样过程中高频空间细节的不可逆丢失问题。在此基础上,堆叠 3 个频率感知上下文模块(FACM),利用空间-频域协同建模




图 5.1 FACNet 整体网络结构


机制同步捕获局部空间细节与长距离上下文依赖关系，生成具有强判别性的多尺度上下文特征。最后通过通道拼接操作完成下采样特征与上下文特征的聚合，得到第一级高级特征图 $F_1 \in \mathbb{R}^{64 \times H \times W}$ 。

第二级全局语义提取阶段延续第一级的模块化设计范式，首先通过 SRDU 单元将第一级高级特征图的空间分辨率进一步压缩至原有的 1/8，输出深层下采样特征 $F_{d2} \in \mathbb{R}^{64 \times H \times W}$ 。随后堆叠 7 个 FACM 模块提取更深层次的全局语义信息，重点建模道路场景中大范围的场景布局与目标间的空间关系。同样通过通道拼接操作完成特征聚合，得到第二级高级特征图 $F_2 \in \mathbb{R}^{128 \times H \times W}$ 。这种两级渐进式的特征提取结构能够在不同空间尺度上逐步挖掘丰富的上下文信息，同时保持整体网络的轻量化特性。

跨尺度特征融合（CSFF）与预测阶段是网络的核心输出部分。该模块同时接收来自初始特征提取阶段的浅层空间特征 F_0 、第一级多尺度上下文提取阶段的中级特征 F_1 以及第二级全局语义提取阶段的深层语义特征 F_2 ，通过自适应权重分配机制实现不同尺度特征的有效对齐与融合，解决了浅层细节信息与深层语义信息之间的语义鸿沟问题。融合后的特征图首先经过 1×1 卷积层调整通道维度至预测类别数，再执行 4 倍双线性上采样操作，将特征图的空间分辨率恢复至与输入图像一致，最终输出逐像素的语义分割预测结果 $P \in \mathbb{R}^{C \times H \times W}$ 。

5.2.2 空间精炼下采样单元

现有轻量级分割模型依赖传统步长卷积实现特征降维，其跳跃式采样机制会直接丢弃空间像素，导致局部几何信息不可逆丢失、小目标特征被淹没以及空间语义错位等问题。为此，本章提出一种轻量化的空间精炼下采样单元（SRDU），以替代常规的下采样操作，在完成特征图空间维度压缩的同时，最大程度保留驾驶场景的空间细节与上下文语义信息。如图 5.2 (a) 所示，对于输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ ，SRDU 首先通过 1×1 标准卷积对输入特征进行通道维度的



线性变换与全局信息交互,在不改变特征空间尺寸与通道数的前提下,得到初始精炼特征 F 。

在此基础上, SRDU 构建并行双分支结构对适配特征进行差异化编码,以同时实现高效的局部细节提取与自适应的全局语义增强:局部分支采用分解卷积结构,将标准 3×3 卷积分解为 1×3 卷积与 3×1 卷积的串行组合,在保持 3×3 卷积感受野的同时,将参数量与计算量降低约 33%,并且能够更精准地捕获水平与垂直方向的空间细节特征,输出局部分支特征 F_l ;全局门控分支则采用 3×3 深度可分离卷积提取全局上下文特征,随后通过 Sigmoid 激活函数生成空间注意力权重图,并与初始适配特征 F 进行逐元素相乘,实现对不同空间位置特征的自适应权重校准,抑制无效背景信息的干扰,强化前景目标的语义响应,输出全局门控特征 F_g 。

随后,对局部分支与全局门控分支的输出特征进行逐元素相加融合,得到多尺度融合特征 F_{fus} ,在保留双分支特征优势的同时避免通道维度的急剧膨胀,相较于通道拼接的融合方式进一步降低了计算复杂度。以上计算过程可表示为:

$$F = \text{Conv}_{1 \times 1}(X), \quad (5.1)$$

$$F_l = \text{Conv}_{3 \times 1}(\text{Conv}_{1 \times 3}(F)), \quad (5.2)$$

$$F_g = \sigma(\text{DSConv}_{3 \times 3}(F)) \odot F, \quad (5.3)$$

$$F_{fus} = F_l + F_g. \quad (5.4)$$

为实现特征图的空间维度降采样, 本文采用步长为 2 的 3×3 标准卷积对融合特征 F_{fus} 进行下采样操作, 得到 $F_{down} \in \mathbb{R}^{C \times \frac{H}{2} \times \frac{W}{2}}$ 。相较于先下采样再提取特征的传统范式, 先完成多尺度特征编码再执行下采样的设计, 可有效缓解下采样过程中高频细节信息的不可逆丢失问题。为进一步增强下采样特征的判别性, 缓解降采样带来的语义信息衰减, SRDU 依次引入通道注意力模块与 3×3 部分卷积 (Partial Convolution, PConv) 对下采样特征进行二次精炼, 通过通道注意力强化关键语义通道的响应权重, 通过部分卷积优化空间特征的表达效率, 最终输出精炼后的下采样特征 $D \in \mathbb{R}^{C \times \frac{H}{2} \times \frac{W}{2}}$, 其最终计算过程可表示为:

$$F_{down} = Conv_{3 \times 3}^{S=2}(F_{fus}), \quad (5.5)$$

$$D = PConv_{3 \times 3}(CA(F_{down})). \quad (5.6)$$

SRDU 整体采用轻量化的卷积算子构建核心结构, 通过分解卷积与深度可分离卷积的组合设计, 在保持极低参数量与计算开销的同时, 引入自适应空间门控机制与多阶段特征精炼策略, 有效解决了传统下采样模块的信息丢失问题, 为后续的上下文特征提取提供了高质量的低分辨率特征输入, 完全适配实时语义分割网络的轻量化设计需求。

5.2.3 频率感知上下文模块

在自动驾驶语义分割任务中, 仅依赖空间域的上下文建模方法难以满足复杂路况的感知需求。卷积的局部特性使其无法有效建模全局场景的结构一致性, 而光照变化、车辆运动带来的模糊更会严重降低特征质量, 现有方法往往无法充分利用频域信息。针对上述问题, 本章提出频率感知上下文模块 (FACM), 通过空间域多感受野特征提取与频域不变性增强的串行融合架构, 在保持轻量化计算开销的同时, 提升模型对复杂驾驶环境的适应性与特征判别性, 其完整网络结构如图 5.2 (b) 所示。

对于前序 SRDU 输出的下采样特征图 $D \in \mathbb{R}^{C \times H \times W}$, FACM 首先通过 1×1 标准卷积对输入特征进行通道维度降维, 在压缩后续计算量的同时完成初始的通道间信息交互, 得到通道数为 $C/2$ 的基础特征 $F_0 \in \mathbb{R}^{C \times H \times W}$ 。为了在有限的计算开销下获取多尺度空间上下文信息, FACM 采用两条基于深度卷积的互补特征提取路径: 一条路径使用标准 3×3 深度卷积保留精细的局部边缘与纹理细节, 另一条路径使用扩张率为 d 的 3×3 深度空洞卷积扩大感受野, 捕获中远距离的场景结构信息。两条路径的输出经逐元素相加融合后, 得到同时包含局部细节与全局




图 5.3 (a) 跨尺度特征融合(CSFF) (b) 跨层级对齐子模块(CHAM)

上下文的空间特征 F_1 。随后将此特征图与基础特征 F_0 沿通道维度进行拼接得到高维融合特征

$F_2 \in \mathbb{R}^{\frac{3C}{2} \times H \times W}$ 。此计算过程如下所示：

$$F_0 = \text{Conv}_{1 \times 1}(D), \quad (5.7)$$

$$F_1 = D\text{Conv}_{3 \times 3}(F_0) + D\text{Conv}(d)_{3 \times 3}(F_0), \quad (5.8)$$

$$F_2 = \text{Concat}(F_0 + F_1), \quad (5.9)$$

其中， $D\text{Conv}(d)_{3 \times 3}(\cdot)$ 表示扩张率为 d 的 3×3 深度空洞卷积。在此基础上，采用通道注意力与 3×3 部分卷积串行结构完成特征精炼，将通道维度映射回 C ；随后将精炼后的空间特征输入分组频率引导增强模块（Group Frequency-Guided Enhancement Module, GFGE），通过通道分组的频带自适应调制强化全局结构与边界细节，利用频域特征提升模型对复杂环境的鲁棒性；最后通过全局残差连接将频域增强特征与原始输入特征逐元素相加，实现空间域与频域特征的互补融合，同时缓解网络加深带来的梯度消失问题。上述过程的数学表达如下：

$$F_3 = P\text{Conv}_{3 \times 3}(CA(F_2)), \quad (5.10)$$

$$F_f = \text{GE}(F_3), \quad (5.11)$$

$$F_{out} = F_f + D, \quad (5.12)$$

如图 5.2 (c) 所示, GFGE 模块首先对输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ 沿通道维度进行均等分组, 得到两个通道规模均为 $C/2$ 的特征子集 $X_L \in \mathbb{R}^{\frac{C}{2} \times H \times W}$ 与 $X_H \in \mathbb{R}^{\frac{C}{2} \times H \times W}$, 其中 X_L 负责全局低频结构的建模, X_H 负责高频边界细节的增强, 以此实现不同频率特性的通道级解耦。针对两个分组特征, 分别执行二维快速傅里叶变换将其从空间域映射至复数频域, 得到对应的频域特征图 $F_L \in \mathbb{R}^{\frac{C}{2} \times H \times W}$ 与 $F_H \in \mathbb{R}^{\frac{C}{2} \times H \times W}$, 其数学表达为:

$$F_L = FFT2D(X_L), \quad (5.13)$$

$$F_H = FFT2D(X_H), \quad (5.14)$$

$$FFT2D(F)_{(u,v)} = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} F_{(x,y)} \cdot e^{-j2\pi\left(\frac{ux}{H} + \frac{vy}{W}\right)}, \quad (5.15)$$

式中 (x,y) 为空间域像素坐标, (u,v) 为频域坐标, j 为虚数单位。随后, 为两个频域分支分别引入独立的可学习复数调制权重矩阵 $W_L \in \mathbb{R}^{\frac{C}{2} \times H \times W}$ 与 $W_H \in \mathbb{R}^{\frac{C}{2} \times H \times W}$, 对低频与高频频域特征执行逐元素的自适应加权调制, 强化对应频率分量的有效特征并抑制成像噪声与伪影, 调制过程的数学表达为:

$$F'_L = F_L \odot W_L, \quad (5.16)$$

$$F'_H = F_H \odot W_H, \quad (5.17)$$

W_L 与 W_H 可随网络训练过程端到端优化, 自适应学习不同通道分组对应的最优频率响应特性。完成频域调制后, 对两个分支的特征分别执行二维逆快速傅里叶变换, 将其从复数频域映射回实数空间域, 通过取实部操作剔除数值误差带来的虚数分量, 得到空间域增强特征 $X'_L \in \mathbb{R}^{\frac{C}{2} \times H \times W}$ 与 $X'_H \in \mathbb{R}^{\frac{C}{2} \times H \times W}$, 此过程可表示为:

$$X'_L = Real(IFFT2D(F'_L)), \quad (5.18)$$

$$X'_H = Real(IFFT2D(F'_H)), \quad (5.19)$$

$$IFFT2D(F)_{(x,y)} = \frac{1}{H \cdot W} \sum_{u=0}^{H-1} \sum_{v=0}^{W-1} F_{(u,v)} \cdot e^{j2\pi\left(\frac{ux}{H} + \frac{vy}{W}\right)}, \quad (5.20)$$

随后, 将两个分支的空间域特征沿通道维度进行拼接, 得到融合后的频域增强特征 $X_{freq} \in \mathbb{R}^{C \times H \times W}$, 并通过一组深度卷积实现局部空间上下文的补充与通道维度的融合, 同时引入批归一化与 GELU 非线性激活函数提升模块的非线性建模能力:

$$X_{conv} = GELU\left(BN\left(DConv(X_{freq})\right)\right), \quad (5.21)$$

最后，为实现原始特征与增强特征的自适应融合，避免梯度消失并保留输入特征的有效语义信息，GFGE 引入通道注意力门控机制对主分支特征与原始输入特征进行加权融合，得到模块的最终输出 $Y \in \mathbb{R}^{C \times H \times W}$ ：

$$Y = X_{conv} + X \odot CA(X_{conv}). \quad (5.22)$$

5.2.4 跨尺度特征融合模块

不同尺度特征存在固有的层级表征错位问题：浅层特征编码像素级的空间纹理与边缘信息，深层特征编码语义级的类别与全局布局信息，二者处于完全不同的表征空间。直接采用逐元素相加或通道拼接的融合方式会导致特征语义混淆、边界定位偏差，而现有融合方法多聚焦于权重分配优化，却忽略了层级间特征空间的对齐与校准这一核心问题。为此，本文提出跨尺度特征融合模块（CSFF），通过引入跨层级对齐子模块（Cross Hierarchical Alignment Module, CHAM）实现浅层空间表征与深层语义表征的空间对齐，在轻量化计算开销下完成多尺度特征的精准融合。

如图 5.3 所示，CSFF 模块同时接收浅层空间特征 $F_0 \in \mathbb{R}^{32 \times 2H \times 2W}$ 、中层特征 $F_1 \in \mathbb{R}^{32 \times H \times W}$ 与深层语义特征 $F_2 \in \mathbb{R}^{128 \times \frac{H}{2} \times \frac{W}{2}}$ 。首先对不同尺度特征进行空间与通道维度的统一适配：将 1/2 尺度浅层特征通过步长为 2 的 3×3 深度卷积下采样至 1/4 尺度，再经 1×1 卷积后与 1/4 尺度中层特征逐元素相加，得到融合了基础空间细节的初始空间特征 F_H ；同时将 1/8 尺度深层语义特征通过 1×1 卷积调整通道维度，再经双线性上采样恢复至 1/4 尺度，得到全局语义特征 F_L 。在此基础上，将 F_H 与 F_L 输入 CHAM 模块进行跨层级表征对齐与融合。

CHAM 子模块采用双分支对称的多粒度交叉编码架构，输入特征首先经共享的 1×1 卷积完成通道维度统一，随后分别进入两个结构完全相同的编码分支。每个分支先通过层归一化稳定特征分布，再并行采用 3×3 与 5×5 深度可分离卷积提取不同感受野的局部特征，经 ReLU 激活后进行交叉拼接以实现多尺度特征互补；接着再次采用反向配对的 3×3 与 5×5 深度可分离卷积进行特征变换，拼接后通过 1×1 卷积压缩通道维度。两个分支输出的特征经逐元素相加完成跨层级的特征交互与语义对齐，最后通过 3×3 深度卷积进行特征平滑与语义增强，输出 1/4 尺度的对齐融合特征。上述过程的数学表达如下：

$$F'_L = LN(Conv_{1\times 1}(F_L)), \quad (5.23)$$

$$F'_H = LN(Conv_{1\times 1}(F_H)), \quad (5.24)$$

$$\bar{F}_L = Conv_{1\times 1}(\mathcal{M}(F'_L)), \quad (5.25)$$

$$\bar{F}_H = Conv_{1\times 1}(\mathcal{M}(F'_H)), \quad (5.26)$$

$$F_{out} = DConv_{3\times 3}(\bar{F}_L + \bar{F}_H). \quad (5.27)$$

其中， $\mathcal{M}(\cdot)$ 算子表示两级深度可分离卷积与交叉拼接过程。CSFF 模块通过跨层级表征对齐，有效解决了多尺度特征融合中的语义混淆问题，显著提升了模型对道路边界、交通标识等小目标的分割精度，同时保持了网络的实时推理能力，完全适配自动驾驶场景的轻量化部署需求。

5.3 实验设计与结果分析

5.3.1 数据集与实验参数设置

本章提出的 FACNet 模型基于 PyTorch 深度学习框架实现，所有训练与测试过程均在单张 NVIDIA RTX 2080Ti GPU 上完成。实验在 Cityscapes 与 CamVid 自动驾驶语义分割基准数据集上完成训练调优与泛化验证。网络架构各项超参数、优化器配置、学习率衰减策略等完整实验设置细节统一汇总于表 3.1。

5.3.2 消融实验

为明确 FACNet 各组件对最终分割性能的影响程度，本章开展了全面的消融实验研究。实验严格遵循单一变量原则，所有变体模型均遵循相同的训练流程在 CamVid 数据集上训练与测试，通过对比不同模块组合下的分割精度，逐一验证各模块的有效性与必要性。 $\dagger$ 符号用于标识本章提出的方法。

(1) 空间精炼下采样单元的影响

本实验旨在单独验证本章提出的空间精炼下采样单元 (SRDU) 在特征降维过程中的信息保留能力，量化其相较于传统下采样策略在精度与效率平衡上的优势。表 5.1 对比了三种下采样策略的综合性能，其中 Max Pooling 代表无参数的 2×2 最大池化，Strided Conv 作为实验基线代表步长为 2 的 3×3 标准卷积，SRDU 代表本章提出的空间精炼下采样单元。

表 5.1 空间精炼下采样单元的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
Max Pooling	697	3.70	212	67.12
Strided Conv	786	4.05	205	67.85
SRDU [†]	839	4.35	198	69.75

表 5.2 频率感知上下文模块的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
ECA Block	808	4.11	210	68.67
CA Block	815	4.16	200	69.01
GC Block	821	4.23	202	69.18
FACM [†]	839	4.35	198	69.75

表 5.3 跨尺度特征融合模块的影响

Model	Parameter (K)	FLOPs (G)	Speed (FPS)	mIoU (%)
Add	819	4.24	203	68.90
Concat	827	4.29	200	69.26
CHAM [†]	839	4.35	198	69.75

实验结果表明， 2×2 最大池化凭借无参数特性实现了最低的计算开销与最快的推理速度，但其分割精度在三种方法中表现最差，这是由于最大池化仅通过局部最大值聚合完成维度压缩，无法学习特征的空间变换规律，会导致道路边界、交通标识等关键高频细节与语义信息的不可逆丢失。 3×3 步长卷积通过引入可学习参数在降维的同时实现了基础特征编码，分割精度较最大池化提升 0.73% mIoU，但其通过步长跳跃实现降采样的固有机制仍会丢失大量精细空间位置信息，单一卷积核的特征表达能力也较为有限。相比之下，本文提出的 SRDU 仅较基线增加 53K 参数量与 0.30G FLOPs，推理速度仅下降 7 FPS，却实现了 1.90% 的 mIoU 提升，较最大池化的提升幅度更是达到 2.63%，性能增益显著高于计算开销的增长。这一结果充分验证了 SRDU 先编码后下采样范式的合理性，其通过双分支差异化编码、自适应空间门控与多阶段特征精炼的组合设计，在降维过程中最大程度保留了关键特征信息，有效缓解了传统下采样策略的信息丢失问题。

(2) 频率感知上下文模块的影响

为单独评估本章提出的 FACM 模块的全局上下文建模效果，本实验将其与其它轻量级上下文增强模块进行对比，综合分析各方法在分割精度与推理效率两方面的表现。实验结果如表 5.2 所示，其中 ECA Block 代表来自 ECA-Net^[96]的高效通道注意力模块，CA Block 代表来自 Coordinate Attention^[30]的坐标注意力模块，GC Block 代表来自 GCNet^[97]的全局上下文模块。

结果表明，在四种对比方法中，ECA Block 具有最低的参数量与计算量，推理速度最快，

表 5.4 Cityscapes 数据集预测结果的对比

Methods	Backbone	Resolution	Param.(M)	FLOPs(G)	Speed(FPS)	mIoU(%)
ERFNet ^[60]	No	512×1024	2.10	-	42	68.0
BiSeNetV2 ^[54]	Xception	512×1024	3.40	21.2	82	72.6
STDC1-50 ^[21]	-	512×1024	8.40	-	87	71.9
MLFNet ^[81]	ResNet-34	512×1024	13.03	15.5	72	72.1
SegTransConv ^[84]	STDC	512×1024	7.00	10.2	57	72.0
LEDNet ^[63]	No	512×1024	0.94	12.6	78	70.6
CGNet ^[64]	No	360×640	0.50	6.0	17.6	64.8
NDNet ^[65]	No	1027×2048	0.50	14.0	40	65.3
SCMNet ^[66]	No	512×1024	1.20	18.2	92	68.3
LRDNet ^[67]	No	512×1024	0.66	16.0	77	70.1
CFPNet ^[68]	No	1024×2048	0.55	-	30	70.1
AGFNet ^[69]	No	512×1024	1.12	14.4	60	70.1
PDBNet ^[70]	No	512×1024	1.82	15.0	50	69.5
SGCPNet ^[71]	MobileNet	1024×2048	0.61	4.5	80	70.9
MSCFNet ^[72]	No	512×1024	1.15	17.1	50	71.9
FBSNet ^[75]	No	512×1024	1.62	9.7	90	70.9
LETNet ^[92]	No	512×1024	0.95	13.6	150	72.8
FAHDNet ^[76]	No	512×1024	0.82	9.98	135	70.6
DAABNet ^[93]	ResNet-18	512×1024	0.94	-	107	70.8
MHMNet(第三章方法)	No	512×1024	0.77	7.12	173	71.5
CoANet(第四章方法)	No	512×1024	0.67	6.2	190	71.7
FACNet(本章方法)	No	512×1024	0.84	8.87	106	72.1

表 5.5 CamVid 数据集预测结果的对比

Methods	Backbone	Resolution	GPU	Param.(M)	Speed(FPS)	mIoU(%)
DABNet ^[73]	No	360×480	1080Ti	0.76	72	66.40
FDDWNet ^[74]	No	360×480	2080Ti	0.80	79	66.90
MSCFNet ^[72]	No	360×480	Titan XP	1.15	110	69.30
AGFNet ^[69]	No	360×480	2080Ti	1.12	100	69.40
FBSNet ^[75]	No	360×480	2080Ti	0.62	120	68.90
FAHDNet ^[76]	No	360×480	2080Ti	0.82	335	67.20
HDGNet ^[77]	No	360×480	1080Ti	0.68	100	65.70
BiSeNet-V1 ^[78]	Xception	720×960	Titan XP	5.80	116	65.50
ICNet ^[79]	PSPNet-50	720×960	Titan X	26.50	28	67.10
DFANet ^[62]	Xception	720×960	Titan X	7.80	120	64.70
EFRNet-16 ^[95]	EAA	720×960	1080Ti	1.44	154	68.20
LBN-AA ^[80]	No	720×960	1080Ti	6.20	39	68.00
SGCPNet ^[71]	No	720×960	1080Ti	0.61	278	69.00
MLFNet ^[81]	ResNet-34	720×960	Titan XP	13.03	57	69.00
SegTransConv ^[84]	STDC	720×960	3090	7.00	60	68.50
MHMNet(第三章方法)	No	360×480	2080Ti	0.77	292	69.50
CoANet(第四章方法)	No	360×480	2080Ti	0.67	320	69.67
FACNet(本章方法)	No	360×480	2080Ti	0.84	198	69.75

但分割精度也最低。CA Block 通过引入空间坐标信息增强了特征的位置感知能力, 在参数量增加 7K、计算量增加 0.05G FLOPs、推理速度下降 10 FPS 的情况下, mIoU 较 ECA Block 提升 0.34%。GC Block 通过全局上下文聚合实现了更全面的特征建模, 在参数量较 CA Block 增加 6K、计算量增加 0.07G FLOPs、推理速度提升 2 FPS 的情况下, mIoU 进一步提升 0.17%。相比之下, 本文提出的 FACM 仅较次优的 GC Block 增加 18K 参数量与 0.12G FLOPs, 却实现了 0.57% mIoU 提升, 性能增益显著高于计算开销的增长。

FACM 通过频率域分解与多频带上下文建模的创新设计, 有效捕捉了不同频率分量的语义特征, 在极小的计算代价下实现了分割精度的大幅提升, 为实时语义分割任务提供了一种高效的全局上下文建模方案。

(3) 跨尺度特征融合模块的影响

表 5.3 展示了针对跨尺度特征融合模块 CSFF 中跨层级对齐子模块 CHAM 的消融实验结果。表格第一列分别对应逐元素相加融合、通道拼接融合以及本章提出的 CHAM 模块。

逐元素相加作为最简单的特征融合方式, 不引入任何可学习参数与额外计算开销, 参数量为 819K、FLOPs 为 4.24G、推理速度达 203FPS, 但完全忽略了高低层特征的空间错位与语义差异, mIoU 仅为 68.90%; 通道拼接通过保留高低层特征的全部通道信息提升了融合效果, 参数量增至 827K、FLOPs 增至 4.29G、速度降至 200 FPS, mIoU 较逐元素相加提升 0.36%, 但仍未解决跨尺度特征的空间对齐问题; CHAM 模块仅较通道拼接增加 12K 参数量与 0.06G FLOPs, 推理速度微降至 198FPS, 却实现了 0.49% 的 mIoU 提升, 性能增益显著高于计算开销的增长。实验结果验证了 CHAM 多分支多尺度特征提取与自适应语义校准机制的有效性, 其有效解决了传统跨尺度融合中存在的空间错位与语义不匹配问题, 在极小的计算代价下实现了分割精度的大幅提升。

5.3.3 与其他方法的比较

本章在 Cityscapes 和 CamVid 两个自动驾驶道路场景基准数据集上, 将 FACNet 与当前主流语义分割模型进行了定量对比实验。实验涵盖了不同设计范式的代表性方法, 从精度与效率两个维度综合评估模型性能。结果表明, FACNet 在保持轻量化特性的同时, 取得了具有竞争力的分割精度, 展现出良好的跨场景泛化能力与实际应用价值。

(1) Cityscapes 数据集结果对比

表 5.4 展示了本章提出的 FACNet 与主流实时语义分割模型在 Cityscapes 测试集上的综合性能对比, 不同方法的定性分割对比如图 5.4 所示。




图 5.4 Cityscapes 验证集上预测结果对比图

在参数量与计算量方面, FACNet 仅包含 0.84M 参数与 8.87G FLOPs, 远低于 ERFNet^[60]、BiSeNetV2^[54]等经典实时分割架构, 也显著优于同精度水平的 STDC1-50^[21]、MSCFNet^[72]与 MLFNet^[81]; 在推理速度方面, FACNet 达到 106 FPS, 仅略低于 DAABNet^[93], 大幅领先于 BiSeNetV2^[54]、SegTransConv^[84]等模型; 在分割精度方面, FACNet 取得 72.1% mIoU, 与采用 ResNet-34 骨干网络的 MLFNet^[81]持平, 优于 ERFNet^[60]、LEDNet^[63]、FAHDNet^[76]等众多轻量级方案。

实验结果验证了频率感知上下文模块与空间精炼下采样单元的协同有效性, 二者通过轻量化的特征建模与精准的跨尺度特征融合, 使 FACNet 在保持极低计算开销的同时实现了精度与速度的优异平衡。相较于现有实时语义分割模型, FACNet 在资源受限的边缘设备上具有更强的部署适配性, 能够满足自动驾驶、智能监控等场景对实时性与准确性的双重要求。

(2) CamVid 数据集结果对比

表 5.5 展示了 FACNet 与主流实时语义分割模型在 CamVid 测试集上的综合性能对比, 典型场景的可视化分割结果见图 5.5。所有模型均标注了对应的输入分辨率与测试 GPU 型号, 以保证不同方法间的横向可比性。

在 360×480 输入分辨率下, FACNet 取得 69.75% mIoU, 在所有同分辨率模型中位居首位,




图 5.5 CamVid 测试集上预测结果对比图

较次优的 AGFNet^[69]提升 0.35%，较 MSCFNet^[72]提升 0.45%。在硬件开销方面，FACNet 仅包含 0.84M 参数，推理速度达到 198 FPS，在同精度水平的模型中具有显著的速度优势。虽然 FAHDNet^[76]的推理速度更高，但其分割精度较 FACNet 低 2.55%，无法满足实际应用的准确性要求。与输入分辨率为 720×960 的模型相比，FACNet 在更低的计算开销下仍能实现更高的分割精度，例如 SGCPNet^[71]在 720×960 分辨率下的推理速度为 278 FPS，但 mIoU 仅为 69.00%，低于 FACNet 的 360×480 分辨率结果。

实验结果进一步验证了频率感知上下文建模与跨层级特征对齐机制的跨数据集泛化能力。不同于主流方法依赖多分支结构提升特征表达的设计思路，FACNet 始终保持单分支高效推理框架，避免了额外计算路径与频繁特征交互带来的内存访问开销，结合对特征频率分布与跨尺度语义差异的针对性设计，在有限的计算预算内最大化了模型的分割性能。

5.4 本章小结

本章提出了频率感知上下文网络 FACNet，旨在解决现有实时分割方法中普遍存在的下采样信息丢失、全局上下文建模低效以及跨尺度特征融合错位三大核心问题。

FACNet 采用纯单分支高效推理框架,从根本上避免了多分支结构带来的额外计算路径与内存访问开销。在此基础上,本章设计了三个核心创新模块:首先提出空间精炼下采样单元(SRDU),在降低特征分辨率的同时保留关键空间细节信息,缓解了传统下采样操作导致的边缘模糊问题;其次设计频率感知上下文模块(FACM),通过空间-频率协同建模机制解耦不同频率分量的语义特征,显著提升了模型对全局结构与局部纹理的综合感知能力;最后构建跨尺度特征融合模块(CSFF),其内部的跨层级对齐子模块(CHAM)通过多分支多尺度特征提取与自适应语义校准,有效解决了高低层特征融合时的空间错位与语义不匹配问题。在 Cityscapes 和 CamVid 两个主流语义分割数据集上的综合对比实验结果表明, FACNet 在参数量与计算量均处于极低水平的情况下,取得了优于众多主流实时分割模型的分割性能。

第六章 总结与展望

6.1 总结

图像语义分割作为计算机视觉核心基础任务，是机器实现像素级语义理解的关键技术，在自动驾驶、智能监控等领域具有不可替代的应用价值。随着边缘计算与嵌入式智能设备的普及，语义分割的部署场景逐渐从云端向资源受限的车载终端、移动设备迁移，但现有高精度模型普遍参数量大、计算复杂、推理延迟高，难以满足边缘设备的实时性要求；而轻量化模型又受限于特征表达能力，存在精度不足、全局语义一致性差、复杂场景鲁棒性弱等缺陷。如何在严格的资源约束下兼顾分割精度与泛化能力，已成为该领域亟待解决的核心科学问题。本文围绕轻量级实时语义分割的精度与效率协同优化问题展开研究，深入剖析现有方法在局部多尺度特征提取、全局长距离依赖建模与跨尺度特征融合等环节的技术瓶颈，从多尺度混合状态空间建模、多维度协同注意力机制与空间-频域协同表征三个方向探索，提出三种轻量级语义分割网络架构，在 Cityscapes 与 CamVid 两个权威城市场景数据集上完成全面实验验证。本文主要研究工作与成果总结如下：

(1) 提出了基于多尺度混合 Mamba 的轻量级语义分割网络 MHMNet。为解决卷积神经网络局部感受野受限、Transformer 自注意力机制二次计算复杂度高、纯状态空间模型空间结构建模能力不足的三重技术瓶颈，该网络将 CNN 的局部空间归纳偏置与 Mamba 的线性复杂度全局建模能力有机融合。在编码器阶段设计多分支特征聚合模块 (MFAB)，通过通道注意力、空间注意力与多核深度可分离卷积的并行协同，实现高效的多尺度局部特征提取与跨维度信息交互；在解码器阶段构建混合视觉状态空间模块 (HVSS)，通过局部卷积增强与二维多向选择性扫描的结合，协同捕获全局上下文语义与细粒度空间细节；同时提出自适应门控特征分割头 (AGFS)，通过通道级门控机制选择性重标定解码特征，抑制噪声干扰并强化判别性响应。实验验证表明，该模型在保持线性计算复杂度的前提下，以 0.77M 参数量和 7.12G FLOPs 的计算开销，在 Cityscapes 数据集上实现 71.5% mIoU 的分割精度，单卡推理速度达 173 FPS；在 CamVid 数据集上分割精度为 69.50% mIoU，推理速度提升至 292 FPS，成功实现了全局建模能力与实时推理效率的协同优化。

(2) 提出了基于协同注意力机制的轻量级语义分割网络 CoANet。针对紧凑模型特征表征能力薄弱、传统跨尺度融合易引发语义冲突与空间错位、视觉相似类别边界模糊的行业痛点，该网络以轻量级残差块 (LiteRB) 为基础构建高效骨干网络，并通过三个低开销的注意

力增强模块定向提升模型性能。设计通道聚合多尺度注意力模块 (MACA)，将空间注意力与通道注意力统一于同一框架，并融入多尺度一维深度卷积，在高分辨率阶段以极小计算代价增强上下文表示；提出三级上下文融合模块 (TCF)，通过通道、空间与像素级注意力的层次化协同，实现浅层空间细节与高层语义信息的精准融合；构建选择性嵌入分割头 (SESH)，通过类别特定的特征嵌入机制强化类间区分度，缓解语义歧义。性能测试显示，该模型在本文提出的三个架构中实现了参数量与推理速度的极致压缩，仅用 0.67M 参数量和 6.2G FLOPs 计算量，就在 Cityscapes 数据集上达到 71.7% mIoU 的分割精度，单卡推理速度高达 190 FPS；在 CamVid 数据集上分割精度达 69.67% mIoU，推理速度突破 320 FPS，在同参数量级下全面超越现有主流轻量级分割方法。

(3) 提出了用于高效语义分割的频率感知上下文网络 FACNet。针对现有方法在传统下采样过程中高频信息不可逆丢失、纯空间域建模对光照突变与运动模糊鲁棒性不足、跨尺度特征融合存在语义鸿沟的固有缺陷，该网络采用纯单分支高效推理框架，从特征建模与结构设计两个层面突破性能瓶颈。提出空间精炼下采样单元 (SRDU)，通过 "先特征编码、再降维压缩" 的结构范式，结合双分支差异化编码与多阶段特征精炼策略，最大程度保留下采样过程中的关键空间信息；设计频率感知上下文模块 (FACM)，将特征映射至频域并引入可学习的复数调制权重，实现低频全局结构与高频边界细节的解耦与自适应增强，显著提升模型对复杂干扰场景的鲁棒性；构建跨尺度特征融合模块 (CSFF)，通过跨层级对齐子模块 (CHAM) 实现浅层空间表征与深层语义表征的精准对齐，有效缓解语义冲突与空间错位问题。综合评估结果证实，该模型在三个架构中取得了最优的分割精度，以 0.84M 参数量和 8.87G FLOPs 的计算代价，在 Cityscapes 数据集上斩获 72.1% mIoU 的最高精度，单卡推理速度为 106 FPS；在 CamVid 数据集上分割精度达 69.75% mIoU，推理速度为 198 FPS。

6.2 展望

本文主要针对轻量级实时语义分割中精度与效率难以协同优化的核心问题，提出了一系列针对性的架构设计策略，依次构建了基于多尺度混合 Mamba 的轻量级语义分割网、基于协同注意力机制的轻量级语义分割网络，以及用于高效语义分割的频率感知上下文网络。三种架构分别从状态空间建模、多维度协同注意力与空间-频域协同表征三个维度突破了现有方法的性能边界，为资源受限平台的实时语义分割提供了多样化的技术解决方案。尽管本研究在轻量级语义分割领域取得了阶段性进展，但仍存在若干可拓展与深化的方向：

(1) 模型架构的精细化优化与能力增强。针对 MHMNet 中混合视觉状态空间模块的硬

件适配性不足问题,可探索面向 NPU/TPU 的结构化剪枝与算子融合策略,进一步提升 Mamba 模块的端侧推理效率;针对 CoANet 中注意力权重静态分配的局限,可引入动态注意力机制,根据输入场景的复杂度自适应调整通道与空间注意力的计算强度;针对 FACNet 中频率分解粒度较粗的问题,可构建多尺度频域分解框架,实现不同频率分量的精细化建模与独立增强。此外,可在三个模型中统一引入边缘感知损失与小目标感知损失,通过多任务监督强化模型对边界细节与小尺度目标的表征能力,缓解复杂场景下的边缘模糊与小目标漏检问题。

(2) 学习范式的拓展与泛化能力提升。本工作采用全监督学习范式,模型性能高度依赖标注数据的质量与覆盖范围。后续可探索半监督与自监督学习框架,利用海量无标注街景视频数据,通过时序一致性约束与对比学习挖掘跨帧不变特征,降低模型对人工标注的依赖;同时研究跨域语义分割技术,引入域对抗训练与风格迁移机制,提升模型在不同光照、天气、地理环境下的鲁棒性,解决城市场景到乡村道路、工业园区等新场景的迁移适配问题。

(3) 垂直应用场景的定制化适配。本文模型主要面向自动驾驶城市场景设计,未来可针对工业质检、医疗影像、遥感对地观测等垂直领域进行定制化改造。例如,在工业质检场景中,可强化模型对微小缺陷的检测能力;在医疗影像场景中,可优化模型对器官边界与病变区域的分割精度;在遥感影像场景中,可扩展模型对大尺度地物目标的全局建模能力,通过领域自适应与小样本学习技术,快速适配不同行业的特定需求。

参考文献

- [1] Liu Z, Mao H, Wu C Y, et al. A ConvNet for the 2020s[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022: 11966-11976.
- [2] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2014: 580-587.
- [3] Kaymak Ç, Uçar A. A brief survey and an application of semantic image segmentation for autonomous driving[J]. Handbook of Deep Learning Applications, 2019: 161-200.
- [4] Minaee S, Boykov Y, Porikli F, et al. Image segmentation using deep learning: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(7): 3523-3545.
- [5] 殷晓航,王永才,李德英.基于 U-Net 结构改进的医学影像分割技术综述[J].软件学报,2021,32(02):519-550.DOI:10.13328/j.cnki.jos.006104.
- [6] 段续庭,周宇康,田大新,等.深度学习在自动驾驶领域应用综述[J].无人系统技术,2021,4(06):1-27.DOI:10.19942/j.issn.2096-5915.2021.6.051.
- [7] Ghassemian H. A review of remote sensing image fusion methods[J]. Information Fusion, 2016, 32(Part A): 75-89.
- [8] Liu D, Yu J. Otsu method and K-means[C]. Proceedings of the International Conference on Hybrid Intelligent Systems (HIS), 2009, 1: 344-349.
- [9] 谷玉海,朱腾腾,饶文军,等.基于 EMD 二值化图像和 CNN 的滚动轴承故障诊断[J].振动.测试与诊断,2021,41(01):105-113+203.DOI:10.16450/j.cnki.issn.1004-6801.2021.01.015.
- [10] 施庭雨,黄丽婷,林靖宇,等.融合图像边缘的区域生长点云分割算法[J].小型微型计算机系统,2023,44(04):805-811.DOI:10.20009/j.cnki.21-1106/tp.2021-0624.
- [11] 袁渊,李娜.一种基于边缘增强的高效图论图像分割算法[J].数据,2023,(02):176-178.
- [12] 谢七月,孙武彪,申忠利,等.基于灰度聚类的光伏红外热斑图像分割方法[J].太阳能学报,2023,44(09):117-124.DOI:10.19912/j.0254-0096.tynxb.2022-1809.
- [13] Li Y, Zhao H, Qi X, et al. Fully convolutional networks for panoptic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2021: 214-223.
- [14] Cao H, Wang Y, Chen J, et al. Swin-unet: Unet-like pure transformer for medical image segmentation[C]. Proceedings of the European Conference on Computer Vision, 2022: 205-218.
- [15] Chen L C, Papandreou G, Kokkinos I, et al. DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(4): 834-848.
- [16] Liu C, Chen L C, Schroff F, et al. Auto-DeepLab: Hierarchical neural architecture search for semantic image segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 82-92.
- [17] Liu Y, Bai X, Wang J, et al. Image semantic segmentation approach based on DeepLabV3 plus network with an attention mechanism[J]. Engineering Applications of Artificial Intelligence, 2024, 127: 107260.
- [18] Yan L, Liu D, Xiang Q, et al. PSP net-based automatic segmentation network model for prostate magnetic resonance imaging[J]. Computer Methods and Programs in Biomedicine,

- 2021, 207: 106211.
- [19] Yu C, Xiao B, Gao C, et al. Lite-HRNet: A lightweight high-resolution network[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 10440-10450.
- [20] Tan M, Yuan X, Liang B, et al. DRFnet: Dynamic receptive field network for object detection and image recognition[J]. Frontiers in Neurorobotics, 2023, 16: 1100697.
- [21] Fan M, Lai S, Huang J, et al. Rethinking BiSeNet for real-time semantic segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 9716-9725.
- [22] Xu J, Xiong Z, Bhattacharyya S P. PIDNet: A real-time semantic segmentation network inspired by PID controllers[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 19529-19539.
- [23] Sutton C, McCallum A. An introduction to conditional random fields[J]. Foundations and Trends in Machine Learning, 2012, 4(4): 267-373.
- [24] Chen Z, Zhou H, Lai J, et al. Contour-aware loss: Boundary-aware learning for alien object segmentation[J]. IEEE Transactions on Image Processing, 2020, 30: 431-443.
- [25] Han K, Wang Y, Chen H, et al. A survey on vision transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(1): 87-110.
- [26] hang H, Zhu Y, Wang D, et al. A survey on visual Mamba[J]. Applied Sciences, 2024, 14(13): 5683.
- [27] hang Y, Yan J. Crossformer: Transformer utilizing cross-dimension dependency or multivariate time series forecasting[C]. The Eleventh International Conference on Learning Representations, 2023.
- [28] Zhang W, Huang Z, Luo G, et al. TopFormer: Token pyramid transformer for mobile semantic segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 12083-12093.
- [29] Wang Q, Zhang J, Yang K, et al. MatchFormer: Interleaving attention in transformers for feature matching[C]. Proceedings of the Asian Conference on Computer Vision, 2022: 2746-2762.
- [30] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 13713-13722.
- [31] Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 3146-3154.
- [32] Yan H, Zhang C, Wu M. Lawin transformer: Improving semantic segmentation transformer with multi-scale representations via large window attention[EB/OL]. arXiv:2201.01615, [2026-04-22].
- [33] 周冬梅, 贾琴琴. 融合Mamba的多尺度遥感图像实例分割网络[J]. 光学精密工程, 2025, 33(24): 3940-3955.
- [34] Gu A, Goel K, Ré C. Efficiently modeling long sequences with structured state spaces[EB/OL]. arXiv:2111.00396, 2021.
- [35] Zhu L, Liao B, Zhang Q, et al. Vision Mamba: Efficient visual representation learning with bidirectional state space model[EB/OL]. arXiv:2401.09417, [2026-04-22].
- [36] Liu Y, Tian Y, Zhao Y, et al. VMamba: Visual state space model[C]. Advances in Neural Information Processing Systems 37, 2024: 103031-103063.
- [37] Ruan J, Li J, Xiang S. VM-UNet: Vision Mamba UNet for medical image segmentation[J].

- ACM Transactions on Multimedia Computing, Communications and Applications, 2024.
- [38] Zhang M, Yu Y, Jin S, et al. VM-UNet-V2: Rethinking vision Mamba UNet for medical image segmentation[C]. International Symposium on Bioinformatics Research and Applications, Singapore: Springer Nature Singapore, 2024: 335-346.
- [39] Ma X, Zhang X, Pun M O. RS3Mamba: Visual state space model for remote sensing image semantic segmentation[J]. IEEE Geoscience and Remote Sensing Letters, 2024, 21: 1-5.
- [40] Li B, Yang X, Fan Y. MAFMamba: A multi-scale adaptive fusion network for semantic segmentation of high-resolution remote sensing images[J]. Sensors, 2026, 26(2): 531.
- [41] Rahman M M, Marculescu R. EffiDec3D: An optimized decoder for high-performance and efficient 3D medical image segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2025: 10435-10444.
- [42] Lee Y, Park J, Lee C O. Balanced group convolution: An improved group convolution based on approximability estimates[J]. Pattern Analysis and Applications, 2025, 28(4).
- [43] Park C, Park M, Moon H, et al. DEPrune: Depth-wise separable convolution pruning for maximizing GPU parallelism[C]. Advances in Neural Information Processing Systems 37, Vancouver, 2024: 106906-106923.
- [44] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [45] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 5987-5995.
- [46] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 1310-1320.
- [47] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems 30, 2017: 5998-6008.
- [48] Zeng H, Song X, Jiang S. Goal-oriented dynamic weight optimization for multi-object navigation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2026.
- [49] Everingham M, Eslami S M A, Van Gool L, et al. The Pascal visual object classes challenge: A retrospective[J]. International Journal of Computer Vision, 2015, 111: 98-136.
- [50] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context[C]. Computer Vision – ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V, Springer International Publishing, 2014: 740-755.
- [51] Zhou B, Zhao H, Puig X, et al. Scene parsing through ADE20K dataset[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 633-641.
- [52] Brostow G J, Shotton J, Fauqueur J, et al. Segmentation and recognition using structure from motion point clouds[C]. Proceedings of the European Conference on Computer Vision, 2008: 44-57.
- [53] Cordts M, Omran M, Ramos S, et al. The Cityscapes dataset for semantic urban scene understanding[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 3213-3223.
- [54] Yu C, Gao C, Wang J, et al. BiSeNet V2: Bilateral network with guided aggregation for real-time semantic segmentation[J]. International Journal of Computer Vision, 2021, 129: 3051-3068.
- [55] Zhang Z, Chen G, Wang X, et al. DDRNet: Fast point cloud registration network for large-scale scenes[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 175: 184-198.

- [56] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers[C]. Advances in Neural Information Processing Systems 34, 2021: 12077-12090.
- [57] Guo M H, Lu C Z, Hou Q, et al. SegNeXt: Rethinking convolutional attention design for semantic segmentation[C]. Advances in Neural Information Processing Systems 35, 2022: 1140-1156.
- [58] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[EB/OL]. arXiv:2312.00752, 2023.
- [59] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 10012-10022.
- [60] Romera E, Alvarez J M, Bergasa L M, et al. ERFNet: Efficient residual factorized ConvNet for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 19(1): 263-272.
- [61] Mehta S, Rastegari M, Shapiro L, et al. ESPNetv2: A light-weight, power efficient, and general purpose convolutional neural network[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 9190-9200.
- [62] Li H, Xiong P, Fan H, et al. DFANet: Deep feature aggregation for real-time semantic segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 9522-9531.
- [63] Wang Y, Zhou Q, Liu J, et al. LEDNet: A lightweight encoder-decoder network for real-time semantic segmentation[C]. Proceedings of the IEEE International Conference on Image Processing (ICIP), IEEE, 2019: 1860-1864.
- [64] Wu T, Tang S, Zhang R, et al. CGNet: A light-weight context guided network for semantic segmentation[J]. IEEE Transactions on Image Processing, 2020, 30: 1169-1179.
- [65] Yang Z, Yu H, Fu Q, et al. NDNNet: Narrow while deep network for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(9): 5508-5519.
- [66] Singha T, Bergemann M, Pham D S, et al. SCMNet: Shared context mining network for real-time semantic segmentation[C]. Proceedings of the Digital Image Computing: Techniques and Applications (DICTA), IEEE, 2021: 1-8.
- [67] Zhuang M, Zhong X, Gu D, et al. LRDNet: A lightweight and efficient network with refined dual attention decoder for real-time semantic segmentation[J]. Neurocomputing, 2021, 459: 349-360.
- [68] Lou A, Loew M. CFPNet: Channel-wise feature pyramid for real-time semantic segmentation[C]. Proceedings of the IEEE International Conference on Image Processing (ICIP), 2021: 1894-1898.
- [69] Zhao Z, Liu Z, Peng C. AGFNet: Attention guided fusion network for camouflaged object detection[C]. Proceedings of the CAAI International Conference on Artificial Intelligence, Springer, 2022: 478-489.
- [70] Dai Y, Wang J, Li J, et al. PDBNet: Parallel dual branch network for real-time semantic segmentation[J]. International Journal of Control, Automation and Systems, 2022, 20(8): 2702-2711.
- [71] Hao S, Zhou Y, Guo Y, et al. Real-time semantic segmentation via spatial-detail guided context propagation[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 36(3): 4042-4053.

- [72] Gao G, Xu G, Yu Y, et al. MSCFNet: A lightweight network with multi-scale context fusion for real-time semantic segmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(12): 25489-25499.
- [73] Li G, Yun I, Kim J, et al. DABNet: Depth-wise asymmetric bottleneck for real-time semantic segmentation[EB/OL]. arXiv:1907.11357, [2026-04-22].
- [74] Liu J, Zhou Q, Qiang Y, et al. FDDWNet: A lightweight convolutional neural network for real-time semantic segmentation[C]. Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), IEEE, 2020: 2373-2377.
- [75] Gao G, Xu G, Li J, et al. FBSNet: A fast bilateral symmetrical network for real-time semantic segmentation[J]. IEEE Transactions on Multimedia, 2023, 25: 3273-3283.
- [76] Hu X, Feng J. A fast attention-guided hierarchical decoding network for real-time semantic segmentation[J]. Sensors, 2024, 24(1): 95.
- [77] Zhang Y, Zhang X, Miao D, et al. Real-time semantic segmentation of road scenes via hybrid dilated grouping network[J]. International Journal of Network Dynamics and Intelligence, 2025, 4(1): 100006.
- [78] Yu C, Wang J, Peng C, et al. BiSeNet: Bilateral segmentation network for real-time semantic segmentation[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 325-341.
- [79] Zhao H, Qi X, Shen X, et al. ICNet for real-time semantic segmentation on high-resolution images[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2018: 405-420.
- [80] Dong G, Yan Y, Shen C, et al. Real-time high-performance semantic image segmentation of urban street scenes[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(6): 3258-3274.
- [81] Fan J, Wang F, Chu H, et al. MLFNet: Multi-level fusion network for real-time semantic segmentation of autonomous driving[J]. IEEE Transactions on Intelligent Vehicles, 2023, 8(1): 756-767.
- [82] Peng J, Liu Y, Tang S, et al. PP-LiteSeg: A superior real-time semantic segmentation model[EB/OL]. arXiv:2204.02681, 2022.
- [83] Chen W, Gong X, Liu X, et al. FasterSeg: Searching for faster real-time semantic segmentation[EB/OL]. arXiv:1912.10917, [2026-04-22].
- [84] Fan J, Gao B, Ge Q, et al. SegTransConv: Transformer and CNN hybrid method for real-time semantic segmentation of autonomous vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(2): 1586-1601.
- [85] Yuan Z, Zhang J, Wang Y, et al. Towards robust semantic segmentation against patch-based attack via attention refinement[J]. International Journal of Computer Vision, 2024, 132(11): 5270-5292.
- [86] Wan Q, Huang Z, Lu J, et al. SeaFormer: Squeeze-enhanced axial transformer for mobile semantic segmentation[C]. Proceedings of the International Conference on Learning Representations, 2023.
- [87] Shi H, Hayat M, Cai J. Transformer scale gate for semantic segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 3051-3060.
- [88] Zhang C, Han D, Qiao Y, et al. Faster segment anything: Towards lightweight SAM for mobile applications[EB/OL]. arXiv:2306.14289, [2026-04-22].
- [89] Lv Q, Sun X, Chen C, et al. Parallel complement network for real-time semantic segmentation of road scenes[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(5):

4432-4444.

- [90] Mazhar S, Atif N, Bhuyan M K, et al. Block attention network: A lightweight deep network for real-time semantic segmentation of road scenes in resource-constrained devices[J]. Engineering Applications of Artificial Intelligence, 2023, 126: 107086.
- [91] Singha T, Pham D S, Krishna A. A real-time semantic segmentation model using iteratively shared features in multiple sub-encoders[J]. Pattern Recognition, 2023, 140: 109557.
- [92] Ta N, Chen H, Liu X, et al. LET-Net: Locally enhanced transformer network for medical image segmentation[J]. Multimedia Systems, 2023, 29(6): 3847-3861.
- [93] Tang Q, Chen Y, Zhao M, et al. DAABNet: Depth-wise asymmetric attention bottleneck for real-time semantic segmentation[J]. International Journal of Multimedia Information Retrieval, 2024, 13(1): 12.
- [94] Qiu Y, Xu G, Gao G, et al. Efficient semantic segmentation via lightweight multiple-information interaction network[EB/OL]. arXiv:2410.02224, [2026-04-22].
- [95] Li X, Yang F, Luo A, et al. EFRNet: Efficient feature reconstructing network for real-time scene parsing[J]. IEEE Transactions on Multimedia, 2022, 24: 2852-2865.
- [96] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 11534-11542.
- [97] Cao Y, Xu J, Lin S, Wei F, Hu H. GCNet: Non-local networks meet squeeze-excitation networks and beyond[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops, Seoul, 2019: 1971-1980.

附录 A 攻读硕士学位期间撰写的论文

- [1] **Wang H**, Xie J, Gao G, et al. Multi-scale Hybrid Mamba Network for Lightweight Semantic Segmentation[J]. Cognitive Robotics, 2026.(DOI: 10.1016/j.cogr.2026.03.003, 已录用)
- [2] **Wang H**, Xu G, Gao G, et al. A Lightweight Semantic Segmentation Network via Collaborative Attention Mechanism[J]. Neural Networks, under review.

附录 B 攻读硕士学位期间参加的科研项目

- [1] 国家自然科学基金，基于空间一致性的低质量人脸图像识别研究(61972212)；
- [2] 教育部重点实验室开放课题，复杂交通场景下的图像复原与识别研究(AI202404)；
- [3] 江苏省重点实验室开放课题，基于空间一致性的跨域图像重建与识别(KJS2274)。

致谢

研究生生涯即将画上句号，我由衷地感谢我的导师高广谓老师。整个求学期间，他严谨的治学精神与悉心的学术指导让我受益匪浅。高老师不仅在科研上给予我启迪与支持，更对我未来的人生方向提出了许多宝贵建议。我还要感谢谢九成老师，他对我的指导使我拓宽学术视野，收获良多。同时，我也感谢我的同学与朋友们，正是你们的理解与陪伴，让我度过了这段充实而温暖的时光。无论面对学业上的瓶颈，还是生活中的波折，你们的鼓励都给了我莫大的力量。最后，我深深感激我的家人，是他们的默默支持伴随着我一路走到今天。

站在当下，放眼未来，也希望自己能够不断成长，越来越好。